

birdclef-2026

BirdCLEF 2026 7位解法

Rank	7
Team	空飛ぶ宝石
Author	Joseph Zhou
Topic ID	704292
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704292>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文 (Kaggle Discussion) : <https://www.kaggle.com/competitions/birdclef-2026/discussion/704292>

多くの参加者が0.955を超えるスコアを出していることは承知しているので、私の解法にはおそらく特別なところはありません。その多くは単なる運かもしれません。ここでは、このコンペで得た考察や分析を、いくつかのモデリングの詳細とともに共有するだけにとどめます。

データ前処理

私の時間の大半は、データ作業に費やされました。これは量と質の問題です。

「量」の問題

今年の公式データには、情報源間で学名が一致しないためにサンプル数が非常に少ない種が3つあります。それらは以下の通りです。

- **Spot-tailed Nightjar** (Anturus maculicaudus ↔ Hydropsalis maculicaudus)
- **Ocellated Crane** (Rufirallus schomburgkii ↔ Micropygia schomburgkii)
- **Yellow-headed Caracara** (Daptrius chimachima ↔ Milvago chimachima)

各ペアの最初の名前が公式の分類学およびiNaturalistで使われているもので、2番目の名前がxeno-cantoで使われているものです。実際、xeno-cantoには公式データに対応するサンプルがかなり多く存在します。

「質」の問題

BirdCLEFデータの長年の問題は、学習データとスコアリングに使われるテストセットとの間の粒度のミスマッチです。テストセットは鳥類の専門家によって5秒ごとに細かくラベル付けされていることが分かっています。一方、公開データはほとんどがアマチュアによる録音で、あらゆる長さのクリップ（5分を超えるものもある）が含まれています。より大きな問題は、そのような長いクリップに1つのラベルしか付いていないことです。

このコンペでは、約4k+のサンプルがマルチクラスラベルを持っており、つまり `secondary_labels` を持っています。中には5つを超える secondary label を持つサンプルさえあります。もし5秒/10秒のクリップを先頭や末尾からランダムに切り出したらどうなるか想像してみてください。その小さなウィンドウの中で、それらの種すべてが本当に鳴いていると保証できるでしょうか。それは非常に難しいと思いますし、これは多くの偽陽性 (false positive) をもたらします。4k+のサンプルは全体の約10%であり、決して少なくない数です。そこで私は、これらの4k+のサンプルを自分で再ラベル付けすることにしました。

私のアプローチは、スペクトログラムを見て、できるだけ多くの共起する種を含む10秒のクリップを選び出すというものでした。スペクトログラムを見るのにAudacityを使い、種を認識するのを助けてもらうために懂鳥app (aboutbirds) を使いました。確認できない secondary label が多すぎる場合（たとえば3つを超える場合）は、偽陽性を切り捨て、確認できたものだけを残しました。時には1つの音声が複数のサンプルに分割されることもありました。XC128801を例にとって説明しましょう。

- ランダムクロップのラベルはこうなります。
`grepot1` (primary_label) + `['litnig1', 'whtdov', 'compau', 'chacha1']` (secondary_labels)

- 私の選択はこうです。

17-27秒のクリップ → [grepot1, 'whtdov', 'compau', 'chacha1']

65-75秒のクリップ → [grepot1, 'litnig1', 'whtdov', 'compau', 'undtin1']

このようにして、chacha1 や litnig1 のような希少クラスに対してよりクリーンなラベルを得ました。この過程で、いくつかのラベル付けの誤りにも気づきました。XC2747は weeping frog（泣きガエル）を roahaw とラベル付けしています。XC353371は roahaw を Crested Oropendola と間違えています。XC375114は明らかに whbwar2 であって flawar1 ではありません、などです。また、多くの録音で redjun（Red Junglefowl）のラベル付けが漏れていることにも気づきました。おそらく録音者はニワトリを録音する価値がないと考えたのでしょう。47144（Domestic Dog、飼い犬）でも同じことが起きています。一部のクリップには犬の吠え声があるのにラベルが付いていません。これらはおそらくモデリングにあまり影響しませんが、共有するのは面白いでしょう。

こうしたデータ作業はすべて退屈に見えるし、モデリングにそれほど役立たないかもしれませんが、さまざまな鳥の鳴き声について学ぶのは正直かなり楽しかったです。

モデリング

モデリングの面は昨年とあまり変わらず、依然としてtimm backbone + SED head + 10秒クリップです。今年の新しい点はPerch蒸留（distillation）のアプローチで、これは私を大いに助けてくれました。私のすべてのモデルは蒸留を使っていますが、backboneはdetachしていません。backboneは勾配フローの一部です。蒸留には2つの教師（teacher）を使いました。**Perch v2** と **AudioProtoPNet-5-BirdSet-XCL** です。BirdSetは9k+の種で事前学習されており、私の実験では特定のbackboneでより良い結果をもたらしました。また、オープンソースのProtoSSM + MLPモデルの自分版も学習させました。最終的な解法は、4つのSEDモデル + 1つのオープンソース系モデルのrank ensembleです。

モデルとハイパーパラメータの選択

私の最終的なbackboneは、tf_efficientnetv2_s with Perch v2、mambaout_tiny with BirdSet、eca_nfnet_l0 with BirdSet です。これらは単体で約0.946~0.949のスコアです。mambaout_tiny は非常に良い学習lossカーブを持ち、唯一の欠点は推論が遅いことです。より小さい mambaout_kobe を試したところ、こちらは速かったのですが、スコアが約0.003下がりました。これら3つのモデルだけを使う予定だったので、私にとって90分は十分すぎるほどであり、少し大きめのモデルを採用しました。

もう1つはmelパラメータの選択でした。melパラメータをチューニングする前は、（擬似ラベルなしで）0.92を突破するのがやっとでした。以下のパラメータに落ち着いた後は、単一モデルで（擬似ラベルなしで）0.94に到達できました。

- n_fft = 1024 or 2048, n_mels = 128, hop_length = 320, fmin = 50, fmax = 16000
- モデルへの最終的な入力形状（128, 512）です（320000 / 320 = 1000 を512にダウンサンプル）。

エポックは約30、learning rateは1e-3です。最初の数エポックは蒸留をオフにしておき、6~8エポック目からPerchまたはBirdSetの蒸留をオンにします。入力に10秒を使うため、毎バッチで各10秒から5秒をランダムに切り出して蒸留の教師に与える必要があります。kaggleでの推論にはmodel soupを使い、たとえば [24, 28, 32] エポックのチェックポイントを組み合わせます。

擬似ラベルの利用

擬似ラベルを生成した後、それらをメインのhard-sampleデータに単純にconcatしました。しかしこれはラベル分布を乱し、学習セットを大きくしすぎてしまいます。私の対策は、各エポックで擬似ラベル部分をランダムにweight-sampleすることです（昨年の1位の `ss_weight` のようなものです）。これによりランダム性を保ち、モデルが多様なサンプルを見られるようにしつつ、学習サイズを管理可能に保って時間を節約します。最終的に、各エポックで約10kの擬似サンプルがhard-sampleのメインデータに混ぜ込まれます。擬似ラベル付けは1ラウンドだけ行いました。

学習の詳細

EDAを通じて、ほとんどのsoundscapeクリップに**夜行性（nocturnal）**の種が含まれていることに気づきました。モデルがこうした夜間の共起パターンをよりよく学習できるように、夜行性のサンプルが他の夜行性のサンプルと高い確率（0.8）で混ざるようにmixupを設定しました。

非常に希少なクラスについては、約20〜30までアップサンプリングしました。

オープンソースモデル

正直に言うと、このモデルは確かに私の助けになりましたが、オープンソース版には深刻な過学習のリスクがあります。私はその `ProtoSSM + MLP` の構造だけを残し、site-hour-prior、residualモデル、そしてあの膨大な後処理の山は捨てました。ProtoSSM + MLPの学習データは、66個のラベル付きsoundscape + 自分の擬似ラベルでした。

Perchの種マッピングについてもう1つ。私たちのデータでは 1595929 は学名 **Lysapsus limellum** に対応しますが、Perchの対応名は **Pseudis limellum** です。このステップを処理すれば、1595929 の予測はより良くなるはずです。自分のオープンソース系モデルを追加することで、約+0.005の改善が得られました。

共有する価値があるのはこれくらいです。金メダルを獲得できてとても嬉しいです。

インドネシア・バリで撮影したJava Kingfisher（ジャワショウビン）を共有します。来年のBirdCLEFがさらに素晴らしい鳥たちに出会わせてくれることを願っています！