

birdclef-2026

12位解法 - MixMax Consistency Regularization (MixMax一貫性正則化)

Rank	12
Team	Bobbing Redstart
Author	Antoine Masq
Topic ID	704404
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704404>
Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文（Kaggle Discussion）：<https://www.kaggle.com/competitions/birdclef-2026/discussion/704404>

まず初めに、BirdCLEFコンペを実験と学びのための素晴らしい機会にしてくださった主催者の方々に感謝します。今年の多くの解法は何らかの形でPerchを使っていましたが、私が最初にPerchで行った実験はあまり有望ではなかったため、別の道を探ることにしました。Perchの埋め込みを蒸留はしませんでした、[彼らの論文](#)が私のmixup正則化のアイデアの発端になりました（ある意味これも知識蒸留の一種ですね、笑）。また、今年ゴールドメダル圏内に入れるとは思っていなかったのも、最終的にリーダーボードの上位からシェイクアウトされなかったことにはさらに驚きました。

データ

前処理

空の録音


以前[ディスカッション投稿](#)で述べたように、1秒間のグリッチノイズだけの破損した録音がありました。train.csv ファイルに記載されているURLからそれらをダウンロードしてみたところ、クリーンで正常な録音であることがわかりました。この方法で復元できたファイルは合計369個ありました。

重複

また、録音に対してtorchのhash_tensor関数を適用したところ、一部のファイルが重複していることに気づきました。データリークを避けるため、ハッシュの重複をすべて削除しました。合計で86個のユニークな録音が最大3回まで出現していました。

手動クリーニング

私の可視化ツール（[こちら](#)にあります）を使って、一部のマイノリティクラスには、実際の鳴き声がかかなりまばらな長い録音があることに気づきました。特にBos Taurusではほとんどの録音が同じラベルなしの背景種を持っていました。これはラベルなしの背景種とターゲット種との間で混同が生じる可能性があります。例えば：



このような混同を避けるため、ターゲット種が鳴いていない時間窓を手動でアノテーションし、録音から除去しました。

無音のサウンドスケープ

私たちは正例の学習データしか持っていないため、モデルが正のラベルを予測する方向にバイアスがかかることを少し懸念していました。正のラベルが存在しない学習データを用意するために、初期のモデルをサウンドスケープに対して反復的に実行し、最大値が一定の閾値を下回るものにフラグを立て、それらが実際に無音であることを手動で確認し、それらを負例として新しいモデルの学習に使用しました。このプロセスを2回繰り返しました。

追加データ

フォーラムのディスカッションで@patrobと@kdmitrieが指摘したように、一部の種はiNatとは異なる非アクティブな分類群を持っていたため、Xeno-Cantoにいくつかの例がありました。具体的には、Hydropsalis maculicaudusには同義分類群のAntiurus maculicaudusがあり、それについてはXeno-Cantoにデータがあると彼らは指摘していました。そこで私はマイノリティクラスの他の可能な同義語を調べ、Rufirallus schomburgkii (Micropygia schomburgkii) の同義語を見つけました。これらの種については、合計で71個と92個の録音がXeno-Cantoから利用可能でした。

事前学習データ (Xeno-Canto)

モデルは、私がXeno-Cantoのデータで事前学習したバックボーンも使用していました。事前学習中に使用したファイルのメタデータは[こちら](#)にあります。また、次のBirdCLEFで誰でも使えるように、後で音声データも含めて事前学習済みの重みを共有できるように努めます。

損失関数

損失関数は、クラスごとに異なるgammaを使用したカスタムのAsymmetric Loss (ASL、非対称損失) で、私はこれをCASL (Class-wise ASL、クラスごとのASL) と呼んでいます。その背後にある直感は、ノイズの多いラベルを持つ可能性が高いクラスをソフトにダウンウェイトすることです。例えば、ラベルなしの昆虫のノイズを含む録音や、鳴き声が短い種の多くは、ランダムに5秒窓をサンプリングする際に鳴き声が途切れてしまう可能性があります。

	Aves	Amphibia	Insecta	Mammalia	Reptilia
γ^+	0.5	0	0	0.5	0
γ^-	0.5	0.5	2	0.1	0.5

もう一つの細かい点として、昆虫のソノタイプのラベルはサウンドスケープに特有のものであったため、focal録音についてはそれらの損失の重みを減らしました。

モデル


モデル自体は、2層の分類ヘッドを持つシンプルなEfficientNetv2バックボーン (b0、b3、s) です。

学習

モデルは、AdamWオプティマイザとcosine-annealingスケジューリングで学習され、学習率は $5e-4$ から $1e-6$ まで減衰し、バッチサイズは32サンプルでした。


ベースライン

ベースラインの学習パイプラインは主にMixmatch論文に着想を得ており、冒頭で述べたように、Perch論文がmixupの一貫性を正則化として使用するアイデアの発端となりました。この論文では、線形補間ではなくラベルの最大値を取るmixupを使用していました。その考え方は、種が録音に存在するなら、補間における重みに関係なく混合物にも存在すべきだ、というものです。私はこれをさらに一歩進めて、ノイズの多いラベルを扱うための一貫性正則化として使用しました。その背後にある直感は、モデルが個々の録音で種を検出するなら、混合物でもそれを検出すべきだ、というものです。さらに、録音にノイズの多いラベルがある場合、個々の録音と混合物の両方で欠けている種を予測してもモデルはペナルティを受けません。これは正則化として、**そして**自己教師あり信号として機能します。また、図中の「model*」にはスペクトログラム変換とオーグメンテーションモジュールが含まれています。これはつまり、モデルが個々の録音とその混合物の間、そして異なるオーグメンテーション間の両方で一貫性を保つ必要があることを意味します。正則化のために混合物におけるラベルの最大値を取るので、これにMixMax consistency regularization (MixMax一貫性正則化) という洒落た名前を付けましょう ☺



半教師あり学習

疑似ラベリング (pseudo-labeling) の部分については、ラベルなしのサウンドスケープからより多様なサンプルが得られるため、オンライン疑似ラベリングを使用してベースラインパイプラインを単純に拡張しました。教師モデルは各foldでベースラインパイプラインで学習されたモデルで、それらの予測はシャープ化され、その後平均されました。



ベースライン結果

得られた結果から見ると、CASLと私のMixMax正則化はそれぞれ単独ではそれほど強力ではなかったようですが、良い相乗効果があったようです。願わくは、Working Noteでこの点をさらに深く掘り下げる時間が取れればと思います。

また、事前学習の効果は無視できないもので、privateとpublicの両方のLBで約0.01の向上をもたらしました。

Loss	XC Pre-training	$\mathcal{L}_C$	Local Soundscape AUC	Public LB	Private LB
BCE			0.889	0.917	0.917
BCE		☒	0.896	0.917	0.927
BCE	☒		0.900	0.926	0.931
BCE	☒	☒	0.894	0.924	0.932
CASL			0.882	0.913	0.922
CASL		☒	0.901	0.928	0.927
CASL	☒		0.898	0.925	0.931
CASL	☒	☒	0.918	0.938	0.940

後処理

後処理パイプラインには以下が含まれます：

- アンサンブル前のロジットのシャープ化 (T=0.8)
- 2.5秒のスライディングウィンドウTTA。各窓の予測はその窓自身と隣接する窓の予測の最大値とする
- Amphibians（両生類）とInsects（昆虫）に対する平滑化量み込み
- ファイルレベルの平滑化（ファイル全体における最大確率）
- 同じモデルで計算した大まかな事前分布（site、hours、monthsについての単純平均）

Post-processing step	Public LB	Private LB	$\Delta \text{Private LB}$
Ensemble raw predictions	0.9476	0.9413	0
+ logits sharpening	0.9477	0.9418	0.0005
+ sliding window	0.9555	0.9517	0.0099
+ smoothing	0.9588	0.9560	0.0043
+ priors	0.9595	0.9558	-0.0002

最終アンサンブル

Backbone	Augmentation regime	Mixup α	Fold	Public LB	Private LB
tf_efficientnetv2_b0	extreme	1	NA	0.947	0.950
tf_efficientnetv2_b3	light	2	NA	0.947	0.950
tf_efficientnetv2_s	strong	0.5	NA	0.941	0.951
tf_efficientnetv2_b0	strong	0.2	NA	0.939	0.941
tf_efficientnetv2_s	strong	0.5	4	0.944	0.951
tf_efficientnetv2_b3	light	0.5	0	0.942	0.942
tf_efficientnetv2_b0	strong	0.5	3	0.949	0.936
tf_efficientnetv2_s	light	2	1	0.944	0.951
Ensemble				0.960	0.956

私からは以上です！繰り返しになりますが、これは試し、失敗し、そして最も重要なこととして学ぶための素晴らしい機会でした！ソースコードとコンパイル済みのモデルは以下で見つかります。もし何か質問があれば、喜んでお答えします ☺