

birdclef-2026

# 13位解法

|          |                      |
|----------|----------------------|
| Rank     | 13                   |
| Team     | riesentots           |
| Author   | noobanot             |
| Topic ID | 704276               |
| Version  | Japanese Translation |

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704276>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文 (Kaggle Discussion) : <https://www.kaggle.com/competitions/birdclef-2026/discussion/704276>

このコンペティションのホストの皆さん、そしてコンペティションを通じて貴重な知見を共有してくださった参加者の皆さんに感謝します。私たちの解法の多くのコンポーネントは、公開解法や過去年の解法の一部を利用しており、それらなしには実現できませんでした。

## 概要

私たちの解法は、OpenVINOで変換した6つのモデル（CNN 3つとSEDモデル 3つ）で構成され、公開されている Perch / ProtoSSMパイプラインの0.949で公開スコアを記録する [raunak](#) 版と0.5対0.5の比率でアンサンブルしています。public LBでは、私たちの6モデルアンサンブルが0.943を記録し、perch/protossmを加えることでpublicで0.957まで引き上げられました。しかしprivateでは、私たちのCNN/SEDアンサンブルの方が良く、0.953を記録しました。perchを加えるとこれが0.955に上がります（ただし、私たち対perchを0.6対0.4の比率にすると0.957になります ）。

## データセット

2026 BirdCLEFの学習用音声と（擬似ラベル付けした）サウンドスケープ。

## 学習

### サンプリング

私たちのモデルは、音声のランダムな5秒セグメントで学習します。RMSサンプリングや先頭からのサンプリングはうまくいきませんでした。より長いセグメントはそこまで性能が良くありませんが、多様性のために10sモデルをアンサンブルに残しました。

### モデル

私たちの3つのCNNはすべて、[tawara氏](#)の [hgnet](#) 学習ノートブックを使い、最小限の変更で学習しています。私たちの3つのSEDは、[tucker arrant氏](#)の [sed](#) ノートブックを使って学習していますが、ヘッ드의差し替え、perch蒸留の無効化（擬似ラベルを含めると私たちにはうまくいきませんでした）、そして拡張の変更といった、より中程度の変更を加えています。

### 損失

CNNとSEDの両方で、focal BCE lossを使用しています。CE loss、ASL loss、AUC lossを試しましたが、すべて性能が悪かったです。

## データ拡張

CNNについては、メルスペクトログラムに対してmixupのみを使用しました。特にeffnetv2sについては、2023年2位解法の拡張を加えることでスコアが向上しました。SEDについては、メルスペクトログラムへのmixupに加えて、2023年2位解法の拡張を使用しました。すなわち、One of(white noise, pink noise, gaussian noise) を  $p = 0.3$  で、gainを  $p = 0.5$  で適用しました。

## メルスペクトログラムのパラメータ

各CNN / SEDファミリー内のすべてのモデルは、それぞれ同じメルスペックのパラメータを使用しました。

CNN用:  $n\_fft=2048$ ,  $hop\_length=313$ ,  $win\_length=626$ ,  $n\_mels=256$ ,  $fmin=20$ ,  $fmax=16000$ ,  $power=2.0$

SED用:  $n\_fft=2048$ ,  $hop\_length=512$ ,  $win\_length=2048$ ,  $n\_mels=128$ ,  $fmin=20$ ,  $fmax=16000$ ,  $power=2.0$

## バックボーン

私たちの3つのCNNバックボーンは以下の通りです - hgnetv2b0を1つ、effnetb3nsを1つ、effnetv2sを1つ (volodymyrによる2025年の事前学習済みチェックポイント)

私たちの3つのSEDバックボーンは以下の通りです - effnetv2sを2つ (うち1つは10sウィンドウを使用)、eca-nfnetを1つ、すべてvolodymyrによる2025年の事前学習済みチェックポイントを使用。

擬似ラベルを含めると、これらのモデルのスコアは0.934~0.938の範囲です。2025年の事前学習済みチェックポイントは、LBで大きなブースト (約0.007) をもたらしました。擬似ラベルなしの場合、モデルのスコアはおおよそ0.88~0.90ですが、擬似ラベルなしで各モデルを個別にサブミットはしていません。

## 擬似ラベリング (Pseudolabeling)

私は実際には擬似ラベリングの初回イテレーションを行いませんでした。代わりに、Ali Memetogluが[こちら](#)で生成した公開されている擬似ラベルを使用しました。これらの擬似ラベルは非常に強力で、それだけで私が使用していたtawara氏の単一モデルベースのhgnetを0.881から0.934へと押し上げました。私はすべてのモデルの学習に同じ擬似ラベルを使用し、学習のために全擬似ラベルを学習用音声に連結しました。

擬似ラベルを特定の比率でサンプリングすることはうまくいきませんでした。

6モデルアンサンブルを使って生成した擬似ラベルで学習する2回目のイテレーションはうまくいきませんでした。擬似ラベルにperchのロジットを組み合わせてそれを学習に使うこともうまくいきませんでした。

## その他の詳細

- 30 epochs
- $5e-4$  LR
- One cycle scheduler

## 推論とTTA

私たちはサウンドスケープの5sウィンドウをモデルに入力します。10sモデルについては、Nikitaの2025年戦略を使用します。すなわち、60秒ファイル全体を5sステップで10sウィンドウをスライドさせ、各ウィンドウが5s行を中心とするように両端を2.5sずつパディングします。また、5sモデルではTTAとして2.5秒のシフトも適用します。

## アンサンブルと後処理

---

私たちは6モデルすべてを等しい重みで、単純な加重平均を用いてアンサンブルしました。後処理は一切使用していません。公開Perchパイプラインがすでに多くの後処理を行っており、それを私たちのCNN/SEDに重ねると性能が悪化したためです。

## うまくいかなかったこと

---

- background noise（背景ノイズ）
- 自前でのXeno Cantoでの事前学習
- perch蒸留
- raw signalモデル

上記で既に述べたいくつかの他の戦略も含まれます。