

3位解法

Rank	3
Team	BTYND
Author	TmT
Topic ID	611856
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/rsna-intracranial-aneurysm-detection/discussion/611856>

Retrieved with Kaggle CLI on 2026-07-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

このcompetitionをhostしてくださったRSNAとKaggleに感謝します。実世界のmedical dataに取り組む素晴らしい機会でした。またteammateの@yosukeyama、@nmstopen、@heroalchem、@dainagaoにも感謝します。collaborationが結果へ直接貢献しました。

Overview

主解法は2 stageからなる。


1. 3D vessel region detection
2. 3D ROI classification

Stage 1: Vessel region detection

target vesselがfield of viewの限られた部分しか占めないため、downstream analysisの前にvessel region全体をdetectした。vessel segmentationも試したが、caseをまたいで十分なrobustnessが得られなかった。

aneurysm locationのaxial plane上のXY coordinateはcase間で比較的一貫していたため、sagittal planeとcoronal planeの中央sliceをdetection input imageとして使った。segmentation maskをsagittal方向とcoronal方向へMIPし、各viewのmask coordinateの最小値・最大値から2D axis-aligned bounding boxを作った。detectionにはYOLOv8nとYOLOv8mを使い、validation setで0.95超のmAP@0.5を得た。detection後、sagittal viewとcoronal viewの結果を組み合わせる3D ROIを再構成し、各detectionを中心に固定size 90×90×90 mm（または120×120×120 mm）の3D bounding boxをcropしてanalysis patchを作った。

Detection結果の例。緑 = prediction、赤 = ground truth。




Stage 2: 3D ROI classification

Training

Stage 1の3D vessel ROIを使い、`timm-3d` libraryで実装した3D ResNet-18 backboneを学習した。modelは[BYU 4位解法](#)から着想を得た。

volume全体ではなく**各feature map**へ14-class classification headを付け、weighted BCE loss (multi-label setting) で最適化した。defaultの3D configuration (input $128 \times 128 \times 128$) ではnetworkが $4 \times 4 \times 4$ feature mapを出力したが、良い結果は得られなかった。spatial resolutionを上げると改善したため、一部convolution layerのstrideを2から1へ変えて大きなfeature mapを得た。

input volumeは $128 \times 128 \times 128$ から $224 \times 224 \times 224$ まで、feature-map sizeは $8 \times 8 \times 8$ から $48 \times 48 \times 48$ まで調べた。特にfeature mapを $8 \times 8 \times 8$ から $25 \times 25 \times 25$ へ、image sizeを $128 \times 128 \times 128$ から $196 \times 196 \times 196$ へ拡大すると、single-fold modelのLB scoreが0.77から0.81へ改善した。



Inference & aggregation

inferenceではfeature-map predictionをcase単位のpredictionへaggregateした。具体的にはclassごとにspatial position全体のAneurysm Present scoreをsortし、top-N scoreの平均（Top-N mean）をfinal class predictionとした。Nはmodel configurationによって異なる。

Model ensemble

異なるcrop size、image resolution、一部convolution layerのstrideを小さくしたvariantからなる11 modelをensembleした。すべて3D ResNet-18 backboneを使用した。このensembleのPublic/Private LBIは0.86/0.84だった。

Missing DICOM tags & fallbacks

test dataでは多くのDICOM tagが欠損していたため、X、Y、Z axisのvoxel spacingを推定するmodelを構築した。XY spacingを保つため、各sliceをpadして512×512 pixelsへcenter cropし、Z-axis方向の中央10 sliceをsampleした。Z-axis情報を捉えるため、各sliceを隣接sliceとstackして2.5D RGB inputを作った。このinputからEfficientNet V2 S regression modelがimage appearanceに基づいてvoxel spacingを予測し、10 sliceのoutput平均をfinal valueとした。internal validationのMAEはXが0.015 mm、Yが0.020 mm、Zが0.071 mmで、Private LBIは0.84から0.85へ改善した。

私たちにはうまくいかなかったもの

- Vessel segmentation
- auxiliary loss用のModality headとPlane head

- MIL、LSTM、decoder headなどの複雑なmodel
- [Inference code](#)
- [Training code](#)

補足Q&A

LSL000UD（質問）：3D CNNによるdirect classificationでは、vesselやaneurysmのsegmentation labelをauxiliary supervisionとして使っていないようです。どうoverfittingを避けましたか。pretrained modelを使いましたか。

Tom（質問）：different crop sizeのensembleは賢いですね。teamはいつ32-channel public approachを諦めましたか。

YYama（Tomへの回答）：32-channel public notebookはteam projectではなく私個人のbaseline codeで、最初から単純なstarting baselineでした。full volumeを32 sliceへ圧縮すると性能に必要な情報が失われすぎました。32-channel（および62-channel）inputのMILや3D modelも試しましたが、標準的な2D modelと同程度でした。当時より強いpublic notebookはMIP representationを使っていたので、communityへより貢献できることを期待し3D-volume baselineを共有しました。teamではreliableなROI detectionが鍵だと早期に合意し、TmTがこのpipelineを設計・完成させました。私自身は3D EfficientNet-V2（PublicではなくPrivate scoreを改善したためfinal submissionには選ばなかった）や複数のMIL variantも試しましたが、安定したscore改善はありませんでした。

TmT（LSL000UDへの回答）：vessel maskは使いませんでしたがaneurysm coordinateを使いました。trainingではvolume-levelではなくfeature map上のvoxel-wise BCE lossを使いました。pretrained weightは使っておらず、overfittingも見られませんでした。voxel-level supervisionのおかげかもしれません。

Tom（追加質問）：3D EfficientNet-V2のCV性能はどの程度でしたか。teamで最高のsingle model CVだったのでしょうか。

YYama（回答）：best modelではありませんでした。5 foldのうち1 foldでCVは0.79弱でした。TmTのbest modelは0.8を超えました。single EfficientNet-V2をLBへsubmitしてはいませんが、TmT modelとのensembleでPrivate scoreが少し改善しました（architecture diversityによるものと思われます）。ただしPublicは改善しませんでした。

shiba-inu（質問）：共有された32-channel EfficientNetを参考に学習しましたが、scheduler、class weight、loss functionを変えてもtraining lossが安定せず振動しました。32-channel modelで同じ現象はありましたか。final pipelineのlossは安定していましたか。

TmT（回答）：whole volumeで学習したときはlossが不安定なままで、scoreも0.7を超えませんでした。aneurysmは3D内で強く局在するため、whole volume trainingでは大半のvoxelがnoiseになります。その結果、modelは偶然の非因果的patternを学び、lossが不安定になります。localization（tight ROIとlocation hint）を加えると真のaneurysm featureへ集中し、trainingが安定しました。私たちのpipelineではROI croppingと高resolution feature mapによって一貫してstableなlossになりました。

YYama（回答）：私の32-channel modelではlossはtraining中に着実に低下しました。[training log](#)を参照できます。不安定さや振動は経験していません。ただしmedical imaging taskではpreprocessing pipelineやhyperparameterへmodelが非常に敏感で、normalization、clipping、augmentationの小さな違いでもtraining stabilityが大きく変わります。TmTが述べたとおりwhole volumeの圧縮では大幅に情報が失われ、性能に上限が生じます。manual EDAでは大きなaneurysmはよく保持されましたが、非常に小さなaneurysmやz-axisが長いvolume（CTAなど）は見えにくくなり、それが性能上限へ寄与したと思います。