

9位解法：各種augmentationと多数のモデリング技巧

Rank	9
Team	No Overfitting, Just Skills
Author	Mohamed Eltayeb
Topic ID	549624
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/um-game-playing-strength-of-mcts-variants/discussion/549624>
Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

素晴らしい体験を提供したホストとKaggleに感謝します。チームメイト [@cody11null](#)、[@leehann](#)、[@gauravbrills](#) と参加でき、特に楽しいコンペでした。3年を経て金メダルを獲得し、Masterになりました！

概要

解法は、調整した AdvantageP1、CatBoost、異なるデータ・特徴量で学習した2つのLightGBM Dartのensembleです。Privateでは2番目に良い提出を選べました。これはPublic 2位相当で、CVでも上位でした。

8-fold GroupKFoldを使いました。5または10 foldより8 foldの方がCVが安定し、相関も高くなりました。

データ拡張

Flip

Agent1=a, Agent2=b を Agent1=b, Agent2=a へ反転し、AdvantageP1 を 1-AdvantageP1、utility_agent1 を負にします。最も有用な拡張です。学習とTTAの双方で効きました。元データ専用モデルと拡張データ専用モデルを別々に作ってensembleすると、同じモデルへ混ぜる場合 (LB約+0.001) より大きく改善 (CV約+0.01、LB約+0.003) しました。

ただし実験を重ねると学習での利用はモデルを不安定にしたため、最終的に学習は元データだけにしました。Privateではこれが正解でした。推論時にはflip TTAだけを使いました。

Self-play

a 対 b から a 対 a と b 対 b を作り、AdvantageP1=0.5、utility_agent1=0 としました。CVでは大幅改善、LBでは無効でした。

Transitivity

a 対 b と b 対 c から a 対 c を作ります。wins/draws/lossesと AdvantageP1 の設定が難しく、中間agentに対する成績差をskill differenceとして、符号に応じwinsまたはlossesとadvantageへclip付きで加えました。

```
new_row[] = row1[]
new_row[] = row2[]
new_row[] = (row1[] + row2[])
diff = row1[] - row2[]
diff < : new_row[] += (diff)
diff > : new_row[] += (diff)

new_row[] = row1[]
new_row[] = row2[]
diff_adv = row1[] - row2[]
clip_val = - (new_row[] + new_row[])
diff_adv < : new_row[] += np.clip((diff_adv),,clip_val)
diff_adv > : new_row[] += np.clip((diff_adv),,clip_val)
```

約20万行を生成し、target分布も元trainに近くなりましたが、CVに有意な差はなくLBでは試みませんでした。改善余地はあると思います。

元データ+拡張データで学習し元データだけで検証するとCVは0.405から0.395へ改善し、リークはありません。しかしLBは0.416から0.421へ悪化しました。CVへ簡単にoverfitできると判断し、CVとLBの両方を改善する案だけを採用しました。

モデリング

私とCody_Nullは上記アイデアを基にCatBoostとDartを作りました。特徴量設計・選択は効果がなく不使用。leehannとGaurav Rawatは、相関・分散・permutation importanceで上位300特徴量を選んだDartを作り、こちらでは効果がありました。

第1のCatBoost+DartはCV 0.412 / LB 0.419、第2 DartはCV 0.416 / LB 0.421、結合するとCV 0.406 / LB 0.416でした。TabNet、XGBoost、clustering、embeddingは無効でした。

AdvantageP1 をtargetから引く

`utility_agent1 - AdvantageP1` を予測して推論時に戻すと、CV約0.02、LBは0.000台改善しました。

最終ensembleへ AdvantageP1 を直接使う

AdvantageP1 は勝率ですがtargetはwins-lossesなので、`AdvantageP1 - (1-AdvantageP1)` に変換しました。model特徴量では効かず、最終予測へ混ぜるとCV 0.404 / LB 0.415へ改善しました。

wins/lossesを別予測

utilityを直接予測せずwins/nとlosses/nを予測して差を取りました。CVは約0.01改善、LBは0.421へ悪化。`AdvantageP1` とwinsの意味・分布が一致しすぎ、依存が強まった可能性があります。

MultiRMSE

CatBoostの `objective="MultiRMSE"` で `y = concat([y, -y])` を学習し、予測2列の差を取る方法はCV約0.002改善、LB 0.416と少し悪化。第2提出に選びPrivate 0.424でした。

その他

- agent別model: CV約0.002改善、LB 0.416で同じ、Private 0.425。
- full fit: LB +0.001でPrivateにも移行。
- targetの一意値を減らしclassifierの期待値を取る方法：無効。
- pseudo labeling: testの100行batchごとにensemble予測でDartを継続学習：無効。
- ensembleの `a*pred+b` とclip境界を最適化：CV/LB双方を改善し最終解法で使用。

[最終推論Notebook](#)

補足Q&A

Andreas Bisiadis: TTAとは何の略ですか？

Noussair Mighri: Test-Time Augmentationだと思います。推論時に入力を拡張し、拡張入力からの予測を結合します。ただし今回はどう使うのか理解できません。

Cody_Null (チームメイト) : はい、Test-Time Augmentationです。第2モデル群と同じくagentをflipして拡張します。

Andreas Bisiadis: testを拡張してLBが改善するのはなぜですか。要求されたものより大きなデータを予測する理由が分かりません。batchごとの10分制限は問題になりませんでしたか？

Mohamed Eltayeb: 元sample agent1=a, agent2=b, AdvantageP1=v の出力を utility_agent1、反転 sample agent1=b, agent2=a, AdvantageP1=1-v の出力を utility_agent2=-utility_agent1 とします。最終予測は $0.5 * \text{Output1} + 0.5 * (-\text{Output2})$ です。学習はせず、拡張sampleも予測し、その出力を-1倍して utility_agent1 の向きへ戻し、元sampleの予測と平均するだけです。同じ予測を2つの視点からモデルに行わせ、多様性を増やします。