

5位 解法

Rank	5
Team	Dieter
Author	Dieter
Topic ID	679360
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/vesuvius-challenge-surface-detection/discussion/679360>

Retrieved with Kaggle CLI on 2026-07-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

TLDR

custom SEResNeXt152 encoder + Attention UNet decoder中心のUNet ensemble。binary maskでなくSigned Distance Field (SDF) を回帰し、新しいSDF L1 + SDF mass loss (BCE + DiceのSDF版) を使用。checkpointと最大8 TTAのSDFを平均し0.3でbinarize、persistent-homologyによる反復tunnel fillingでrefineした。train cropは 160^3 だが、sliding-window artifactを避けfull 320^3 で推論した。

Cross-validation

4-fold CVでSurface Dice、GPU版VOI、10x downsampleのCPU topologyを追跡した。local CVもPublicもPrivateとの相関が悪く、最終選択は失敗した。

Training

320^3 volumeからrandom 160^3 ROI。SDF targetはon-the-fly。Adam lr= $1e-3$ 、cosine annealing、bfloat16、large modelはgradient checkpointing、batch 16。各軸flip p=0.5、axis 1-2平面 90° rotation p=0.5。CutMix beta=1.0は初期modelだけで、最終SEResNeXt152には効かなかった。

Loss: SDF L1 + mass

```
fg_edt = distance_transform_edt(foreground_mask)
bg_edt = distance_transform_edt(~foreground_mask)
sdf = bg_edt - fg_edt
sdf = clamp(sdf, -100, 5)
```

lossはequal weightの2項。

Weighted SDF L1 (0.5): $W(sdf)=1+w_0*\exp(-((sdf+core_radius)^2)/(2*\sigma^2))$ 、 $w_0=8, \sigma=4, core_radius=5$ 。sdf=-5で9.0、深いinteriorも9.0、遠いbackgroundは約1。surface近傍へgradientを集中。

SDF Dice (0.5): thresholdせずprediction/targetのReLU(-sdf) をcontinuous massとしてsoft Diceを計算し、大域volume overlapを与える。

このlossはsheet separation、continuity、boundary sharpness、precise skeletonを改善した。

Architecture

- **SEResNeXt152 + Attention UNet:** pure PyTorch 3D encoder [3, 8, 36, 3], groups=32, width=8, SE reduction=16, DropPath=0.3、decoder [256, 128, 64, 32, 16]。48x8d variantも使用。
- **ResNet152 + skip maxpool:** early maxpoolを1つ飛ばし高解像度を保つ。deep supervisionはtrainのみ。

- **ResNet152 + external data:** additional scrollと、external/bad labelを示すbinary input channelを使用しdiversityを付加。

SwinUNETR、UNETR++, MedNeXt、SegFormer3D、ConvNeXt V2、U-Mamba、SEResNeXt200は主力を超えず。topology lossも試し、遅いPD-matching版は短期fine-tune modelだけensembleへ入れた。

Ensemble / inference

raw SDF logitをcheckpoint・TTA間で単純平均。large modelは時間内にidentity + triple flipの2 TTA、小modelは8 flips。bfloat16 trainからfloat16 inferenceへのNaN対策でweightを `[-65504, 65504]` へclampしactivationのNaN/Infをhookで置換。full 320³推論を2 GPUへsample shardし、modelを順に処理してdiskへoffloadした。

Post-processing

1. SDF<0.3をforeground。
2. 6-connectivityで50,000 voxels未満を除去。ただし3 volume boundary以上に接するcomponentは保持。
3. **13-iteration H1 tunnel filling:** foreground SDFを `threshold-1.0` へ置換しcubical filtrationを構成。volumeを2×2×2 tileへ分け、Betti matching由来のC++ `barcode3d_fast_v3` でH1 birth/deathを取得。`birth<threshold<death` だけ残し、background EDTからradiusを `clip(width+1, 3.5, 7.0)`。ball fillingがcomponentをmergeする座標は除外し、death座標へsphereを充填。最終iterationでmorphological hole filling。component数が減ればrevert。

SDF regressionはbinary classificationより良く、Gaussian weightingと反復tunnel fillingが重要だった。0→13 iterationsでlocal topologyが約0.08改善し、11~13回以降は遞減した。

補足Q&A

Innat: mediacai/Kerasからpure PyTorchで60%高速化した比較は？

Dieter: controlled benchmarkではない。KerasのPyTorch backendでmemory leakがあり `torch.jit.trace` した。mediacaiのrepository設計は優れているが、このbackendが遅かった。reimplementationを添付した。

Giorgio Angelotti: SDF由来probabilityのBCE版やhigh-capacityの必要性は？

Dieter: binarization 0.3はmodel予測より少し大きいvolumeを系統的に作るがCV grid-searchで3 metricsのtradeoffを調整でき、mergeはthresholdで制御できる。Voronoi lineのSDF weightは効果なし。`sigmoid(-sdf/T)` も試したが悪くT tuningも難しい。capacity増加は明確に効いた。

Cody_Null: full-volume inferenceとraw-logit averagingの影響は？

Dieter: 160³ window、overlap 0.5は320³当たり27 patchesで3倍のvoxelを処理する。full volumeなら8 TTAでも1.5x安くborder artifactもない。modelはprobabilityでなくSDFを出すためraw SDFをensembleする。

Bartley: trainとinferenceのpatch size不一致をどう扱った？

Dieter: これほど大きく変えたのは初めて。SWIのborder artifactとvoxelごとの予測回数不均一がTopoを傷つけ、patch mismatch由来の不整合より悪かった。patchごとのmean/std normalizationもsize間では不整合だが、それでもfull inferenceが勝った。