eedi-mining-misconceptions-in-mathematics

1位 Solution概要

Rank	1
Team	MTH 101
Author	Raja Biswas
Topic ID	551402
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/551402
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

このコンペには本当に楽しく取り組めましたし、多くのことを学びました。素晴らしいideaを共有し、活発な議論をしてくださったKaggle communityに大いに感謝します。

私のsolution pipelineは次のとおりです。

- retrieverのensemble: `intfloat/e5-mistral-7b-instruct`、`BAAI/bge-en-icl`、`Qwen/Qwen2.5-14B`
- 3つのRe-ranker: `Qwen/Qwen2.5-14B`、`Qwen/Qwen2.5-32B`、`Qwen/Qwen2.5-72B`

すべてのmodelは、コンペのデータ（約1.8k例）+ 合成データ（約10k例）を使ってfine-tuningしました。

Retrievers

retrieverのensembleを使い、動的なthresholdによって各QuestionId_Answerの組み合わせに対して`top 32-64 misconception candidates`を特定しました。具体的には、retrieveした上位32件のcandidateを残し、さらにtop candidateとのsimilarity scoreの差が0.06以内のcandidateを最大32件まで追加しました。

retrieverは`MAP@25`ではなく`recall@32`のscoreに基づいて選びました。私のmodelでは、この2つのmetricはしばしば逆相関していました。hard miningは`recall@32`の改善に役立たなかったため、学習時には省きました。重要な点の1つは、1つのbatch内に同じmisconceptionのdemonstrationが複数含まれないようにすることでした。

Rerankers

まず`Qwen/Qwen2.5-14B`のrankerでretrieveされたcandidateを処理し、`top 8`まで絞り込みました。推論には`enable_prefix_caching=True`を指定した`vllm`を使い、これにより効率が大幅に向上しました。

次に、`Qwen/Qwen2.5-32B`のrankerでcandidateをさらに上位5件に絞り込み、それを`Qwen/Qwen2.5-72B`のmodelに渡して最終的なrankingを行いました。

- Pointwise ranking: `Qwen/Qwen2.5-14B`と`Qwen/Qwen2.5-32B`にはpointwise rankingを使いました。これらのmodelは、contextの中で一度に1つのmisconception candidateを処理します。
- Listwise ranking: `Qwen/Qwen2.5-72B`はlistwiseで、contextの中で上位5件のcandidateを一度に見ます。

性能と汎化のためには、次の4点が重要でした。

- **Chain of Thought (CoT)**: まず`Claude 3.5 Sonnet`にpromptを与え、誤答を選ぶ背後にある思考や理由（rationale）を生成させました。次に、このデータでQwen2.5のmodelをfine-tuningしました。推論時には、fine-tuning済みのmodelでCoTを生成し、それをrerankerに与えてrankingを助けました。本質的には、claudeのmodelからreasoningを蒸留する役割を果たしています。
- **Few shot例**: LLMのin-context-learning能力を保ち、活用したいと考えました。そのため、学習時には分類対象のmisconceptionのdemonstrationをいくつか任意で含めました。以下はその例です。

```
<|im_start|>system
You are an expert  detecting grade-school level math misconceptions. Verify  the incorrect answer
```

```
stems  the provided misconception.<|im_end|>
<|im_start|>user
Misconception: Thinks there are   a centimetre

Demos  the misconception:
Question: A    metre long rope has    centimetres chopped  the end.
What  the length  the rope  remains?
Give your answer  millimetres
Answer:
Misconception Answer:

--
Subject: Length Units
Topic: Convert between m  cm
Question: To convert  metres  centimetres, you should:
Correct Answer: Multiply
Incorrect Answer: Divide
Does the misconception (Thinks there are   a centimetre) lead  the incorrect answer? (Yes/No)<|
im_end|>
<|im_start|>assistant
```

推論時には、training setから1〜2件のdemoを使いました。これは14bのrankerに最も効果がありました。

- **Negative Ratio**: 学習時にrankerへ大量のnegativeを見せることが、性能向上に役立ちました。各positiveにつき、24件のnegativeをsamplingしました。
- **Distillation/Pseudo Labelling**: まず2つのpointwiseの72b model（`Qwen/Qwen2.5-Math-72B`と`Qwen/Qwen2.5-72B`）をコンペのデータでfine-tuningし、それらをensembleして合成データの例にpseudo labelを付けました。コンペのデータ + pseudo labelを付けたデータを使って、14bと32bのmodelをfine-tuningしました。

合成データ

- **グループ化した合成データ生成**: まず、関連するmisconceptionのclusterを作成しました。例えば次のようなものです。

```
>> Assumes a   linear
>> Thinks terms  linear  are  direct proportion
>> Does  know how  find the next term  a
>> Describes position  term   term  term
>> Does  recognise that a linear  must increase  decrease  same amount
>> Uses  the first two terms  a     a term--term
>> Does  know the definition  term  term--term
>>  uses two terms  a     a term--term
>>  asked  a specific term  a  just gives the next term
>> Does    changes  a   visual patterns
```

その後、Claude 3.5 Sonnetにさらに多くの例を生成させました。合成データの生成時には、training setから関連するMCQを5〜8件含めました。promptはcommentに載せています。

--

Links

- Inference notebook

近いうちに詳細な記事を書き、code + datasetを公開する予定です。

補足Q&A

Zhongkai Shangguan — 質問

おめでとうございます。reranking無し（retrievalのみ）でのscoreを伺ってもよいですか。

InnerVoice — 質問

Rajaさん、素晴らしいapproachですね。32Bと72Bのmodelをfine-tuningされていますが、同じことをするのに最低限必要なGPU RAMはどれくらいでしょうか。 もう1つ質問です。listwise rerankingに関する論文や記事をいくつか紹介していただけますか。

Raja Biswas — 回答

ほぼすべてのmodelを2xH100で学習しました。72b modelのfine-tuningには(Q)LoRAを、32b modelにはLoRAを使いました。私の学習設定では、どちらも約80GBのVRAMが必要でした。

listwise rankingは過去のKaggleのsolution投稿で知りました。これについて良い論文があるかどうかは分かりません…

Raja Biswas — 回答

私のretrieverのみの最良submissionは、public LB 0.524、private LB 0.475でした。retrieverでMAP@25を追求しようとはせず、主にrecallに注力しました。

narsil (jobs-in-data.com) — 質問

共有ありがとうございます。私もほとんどのコンペでとても似たやり方で取り組んでいます。最初の直感こそ、たいてい最も検証する価値があります。

興味本位ですが、chain of thoughtsにSonnetを使ったのはなぜですか。私はいつもhttps://huggingface.co/spaces/lmarena-ai/chatbot-arena-leaderboardでSOTAを確認していますが、そこではSonnetはトップではありません。

Dipam Chakraborty — 補足

7Bのmodelで一度full model tuningを試したところ、興味深いことにLoRAより悪い結果になりました。とはいえ、hparam tuningで改善できるかもしれません。私はmax learning rateを下げただけでした。

SiWeiLin — 質問

おめでとうございます。misconceptionをどのようにグループ化したのか伺ってもよいですか。embeddingのclusteringによるものでしょうか。

Raja Biswas — 回答

@narsil 特別な理由はなく、単に他のLLMよりclaudeに慣れているからです。o1-miniも少し調べてみましたが、vibe testに基づくと、sonnetは同等かそれ以上だと感じました。

ktr — 質問

1位おめでとうございます。 promptが非常に丁寧に作り込まれていることに驚きました。 solutionのpromptをどのような過程で作成したのか知りたいです。ゼロから作成したのでしょうか。

Raja Biswas — 回答

metaprompt notebookを使って作り始めました。

Raja Biswas — 回答

共有ありがとうございます、@dipamc77。以前、function calling能力のためにLLMをfine-tuningしたことがあり、そのときはfull tuningがLoRAより大幅に良いことを確認しました。一般に、reasoningやcodingのような、より複雑なtaskではfull-tuningに分があるはずだと感じています。ここではHPについてもっと実験する必要があるかもしれません。

Bilzard — 質問

単独での1位入賞おめでとうございます。

2つ質問があります。

1. あなたのsolutionによると、推論時間が十分に小さい場合には、list-wise rerankerよりもpoint-wise rerankerを選んでいるように見えます。list-wise modelに比べたpoint-wise modelの利点は何でしょうか。
2. 合成データ生成でmisconceptionをclusteringする際には、どのような戦略を使いましたか。

Raja Biswas — 回答

1. LLMベースのlistwise approachには通常position biasがあり、candidateを並べ替えると予測がそれなりに変わります。ranking対象のcandidateを増やすと、このbiasはさらに強くなるだろうと考えました。これに対処する1つの方法は、candidateの順序を変えて複数回推論を行い、scoreを平均することです（test time augmentation (TTA)のように）。
2. re-rankerのOOFにおけるmisconceptionの共起統計を使いました。こちらがgist notebookです。

Raja Biswas — 回答

re-rankerのOOFにおけるmisconceptionの共起統計を使いました。こちらがgist notebookです。