eedi-mining-misconceptions-in-mathematics

4位 Solution | Takoi

Rank	4
Team	takoi & charmq & kami
Author	Takoi
Topic ID	551559
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/551559
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このような素晴らしいコンペを開催してくださったhostの皆様に感謝申し上げます。また、協力してくれたチームメイトのcharmqとkamiにも感謝します。

Summary

- **コンペへのアプローチ**
  - test setのmisconceptionの大半はtrain setに存在しないと予想されたため、こうした未知のmisconceptionに対する精度向上に注力しました。
- **Solutionの概要**
  - **データ生成**
    - `Qwen2.5-72B-Instruct-AWQ` を用いてデータを生成しました。
    - 特にtraining datasetに存在しないmisconceptionを対象として生成しました。
  - **Misconceptionの生成**
    - `Qwen2.5-32B-instruct-AWQ` を用いて、Question、Answerなどからmisconceptionを生成しました。
  - **Retriever**
    - 学習
      - 2つのmodelを作成し、LoRAでfine-tuningしました。
        - Qwen2.5-14B-instruct
        - Qwen2.5-32B-instruct
      - 学習時には、QuestionTextやAnswerTextなどの提供データに加えて、前段のmisconception生成フェーズで生成したmisconceptionもtextに追加しました。
    - 推論とRetrieval:
      - Qwen2.5-14B-instructとQwen2.5-32B-instructの出力を連結してretrievalを行いました。出力は複数のfoldについて生成しました。
      - 各Question-Answerペアについて、以下の数のmisconceptionを取得しました。
        - 全misconceptionの中から最も類似した25件
        - train setに存在しないmisconceptionの中に限定して最も類似した15件
        - 重複は除去しました。
  - **Reranker**
    - **学習**
      - negative sampleの数を調整したり、生成データをtraining datasetに追加したりしながら、複数のQwen2.5-32B-instruct modelをLoRAでfine-tuningしました。
    - **推論**
      - 学習済みmodelのLoRA部分をensembleして、3つのmodelを作成しました。
      - 最後に、これら3つのmodelの出力をensembleしました。

- **後処理**
  - train setに存在したmisconceptionについては、予測スコアを下げるように調整しました。
    - Prediction Score * 0.40
- データ生成および推論（Retreival、Rerankなど）では、`vLLM`を使って処理を高速化しました。

Solution

Validation戦略

- Group KFold (group = `QuestionId`)
- 5 folds
- fold全体のスコアだけでなく、training dataに含まれないmisconceptionに限定して抽出したvalidation dataでのスコアも評価しました。

データ生成

- `Qwen2.5-72B-Instruct-AWQ`を用いて、training datasetに登場しない各misconceptionに対応する新しい問題、選択肢、誤答を生成しました。
- 約8000問を作成し、そのうち2500問をランダムにサンプリングしてreranker modelの学習に使いました。
- 各misconceptionについて、training datasetからランダムにサンプリングした100問を、データ生成の入力例としてpromptに追加しました。

データ生成用のpromptは以下のとおりで、最大token数は約20000です。

```
```

以下は生成された問題の例です。72B modelは高い問題生成能力を持っているようです。

```
:  the circumference  a circle given the radius
:
 :  the radius  a circle is \(  \) cm, what is the circumference  the circle?
 A : \(  \) cm
 B : \(  \) cm
 C : \(  \) cm
 D : \(  \) cm
: B
 : A
:  circumference is radius x pi
```

```
:  algebraic fractions by identifying and cancelling common factors
:
 :  the following algebraic :
\[
\frac{6x^2y}{9xy^}
\]
 A : \( \frac{2x}{3y} \)
 B : \( \frac{6x}{9y} \)
 C : \( \frac{2xy}{3y^} \)
 D : \( \frac{6x^}{9y^} \)
: A
```

```
 : B
:  identify a common factor when simplifying algebraic fractions
```

これらの例は数学的に妥当であり、妥当な問題を生成するには、promptに多数の例（100件）を含めることが重要でした。

Misconceptionの生成

- `Qwen2.5-32B-instruct`を用いてmisconceptionを生成しました。使用したpromptは以下のとおりです。

```
```

Retriever

- retrieval modelは、MAP@25だけでなくtop-25 recallも確認して評価しました。
- Final Submissionに使用したretrieval model
  - 以下のmodelのensemble
    - `Qwen2.5-14B-instruct`
      - Misconception Generationステップで生成したmisconceptionもtextに追加しました。
      - Loss : MultipleNegativesRankingLoss
      - LoRAでfine-tuning:
        - `LoRA_rank` : 32
        - `LoRA_alpha` : 64
      - 各question-answerペアについて、1件のpositive sampleと47件のnegative sampleからなる1 batchで学習しました。
        - negativeの数を増やすことが決定的に重要でした。
        - 学習に使うnegativeは、training data内でpositive sampleとして紐づいているものに限定しました。
        - negativeはランダムに選択しました。
      - map 25 : 0.511
      - recall 25 : 0.923
    - `Qwen2.5-32B-instruct-GPTQ-Int4`
      - 14Bとほぼ同じです。
      - 各question-answerペアについて、1件のpositive sampleと255件のnegative sampleからなる1 batchで学習しました。
      - 10 epochs（各foldにA100で10時間かかりました）。
      - 推論時間が長い（50min/fold）ため、final submissionには2 foldのみを使用しました。
      - map 25 : 0.554
      - recall 25 : 0.926
      - 生成データでのmap 25: ~0.7
      - 生成データでのrecall 25: ~0.99

• **Submission時の推論**
  ◦ embedding計算の高速化に`vllm`を利用しました。そのままでは使えなかったため、用途に合わせて実装に一部修正を加えました。これにより、精度を維持したまま効率的な推論が可能になりました。
  ◦ 上記modelのembeddingを連結して最終的な表現を生成しました。
  ◦ 取得件数
    ▪ 全misconceptionから25件
    ▪ training dataに存在しないmisconceptionから15件:
      ▪ test setのmisconceptionの大半はtraining dataに存在しないと予想されたため、こちらを優先しました。
    ▪ 上記の間の重複は除去しました。
• Rerank候補のためのRetrieval
  ◦ reranking用の候補として、以下のmodel ensembleを使用しました。
    ▪ Salesforce/SFR-Embedding-2_R
    ▪ BAAI/bge-large-en-v1.5
    ▪ Alibaba-NLP/gte-large-en-v1.5
  ◦ recall top 25はsubmissionに使用したものより低いため、submissionには使用しませんでした。
  ◦ これらの候補で学習したrerank modelの方が、より良いpublic scoreを達成しました。

Reranker

• 3つの最終modelを用いて推論を行いました。
• **Model 1 & Model 2**
  ◦ `Qwen2.5-32B-Instruct-GPTQ-Int4`
    ▪ 4 foldで学習しました。
    ▪ LoRAでfine-tuningしました。
    ▪ 学習時はpositive 1 : negative 9の比率を使用しました。
    ▪ negativeをpositiveに存在するものに限定しました。
      ▪ これによりCVが改善しました。
  ◦ **Fold 1の結果:**
    ▪ MAP@25: 0.653
    ▪ training dataに存在しないmisconceptionのみで評価した場合: MAP@25: 0.601
  ◦ **Model 1:**
    ▪ fold 1とfold 2のLoRA部分をensembleしました。
  ◦ **Model 2:**
    ▪ fold 3とfold 4のLoRA部分をensembleしました。
• **Model 3**
  ◦ `Qwen2.5-32B-Instruct-GPTQ-Int4`
    ▪ コンペのデータに加えて、生成した2500サンプルを学習に使用しました。
    ▪ 2 foldで学習し、それらのLoRA部分をensembleしました。
    ▪ 学習時はpositive 1 : negative 19の比率を使用しました。

        - 2epochs（各foldに4 x A100で10時間かかりました）。
    - **Fold 1の結果:**
        - MAP@25: 0.664
        - training dataに存在しないmisconceptionのみで評価した場合: MAP@25: 0.605

72B modelで生成したデータで学習したreranker model（Model 3）をensembleすることで、private scoreが0.01向上しました。

PostProcess

- train setに存在したmisconceptionについては、予測スコアを下げるように調整しました。
    - Prediction Score * 0.40
        - 他の係数も試しましたが、0.40で最も高いpublic scoreが得られました。

code

takoi part : https://github.com/TakoiHirokazu/kaggle-Eedi-4th-solution

charmq part : https://github.com/charmq00/kaggle_eedi_public

Inference : https://www.kaggle.com/code/charmq/eedi-pp040-ret15-exp345-341-348-multi-32b-ret-c015

補足Q&A

Camaro — 質問

4位入賞おめでとうございます。詳細なまとめをありがとうございます！

いくつか質問があります。

1. 約8,000問を作成したものの、reranker modelの学習にはそのうち2,500問だけをランダムにサンプリングしたとのことでした。なぜ2,500問だけを選んだのでしょうか。8,000問すべてを使うより、小さなsubsetを使う方が効果的だったのでしょうか。
2. Misconception Generationのプロセスについて、このタスクのためにQwen2.5-32B-instructをfine-tuningしていない、という理解で正しいでしょうか。
3. 学習設定について:
    - 各batchは、各question-answerペアについて1件のpositive sampleと47件のnegative sampleで構成されていたとのことでした。ここでのbatch sizeを明確にしていただけますか。この文脈では、実質的にbatch sizeが1 sampleということでしょうか。
4. そのままでは使えなかったため、embedding計算を高速化するためにvllmを修正したとのことでした。この修正版の実装（できればコードベース全体）を公開する予定はありますか。
5. negativeをpositiveに存在するものに限定することでCVが改善したとも書かれていました。この方法はLBの改善にもつながりましたか。

Takoi — 回答

ありがとうございます！ご質問への回答は以下のとおりです。

1. 8,000問すべてを使うと学習に時間がかかりすぎるため、学習時間を短縮するために2,500問だけを選びました。
2. そのとおりです。Qwen2.5-32B-instructのfine-tuningは行っていません。fine-tuningなしの初期テストでCVとpublic scoreの両方が改善したため、fine-tuningなしで進めることにしました。
3. 本文では、batch内の1つのquestion-answerに着目し、その場合のnegative数を説明していました。説明がわかりにくかったら申し訳ありません。

   batch sizeは6です。具体的には、data loaderで6つのquestion-answerとそれぞれに対応するpositive misconceptionを用意します。さらに42件のmisconceptionを追加します。1つのquestion-answerから見ると、同じbatch内の他のpositive misconceptionのうち5件がnegativeとして扱われるため、negativeは合計47件になります。
4. 現時点では、修正版の実装やコードベース全体をコンペのhost以外と共有する予定はありません。
5. retrievalについては、上記の制限を適用しないsubmissionは行っていないため、影響は不明です。判断はCVの結果のみに基づいています。rerankingについては、CVとpublic scoreの両方が改善し、private scoreも改善しました。単一のrerank modelで比較すると、publicとprivateの両方のスコアが約0.025改善しました。

CsOH — 質問

おめでとうございます！ solutionを詳しく共有してくださりありがとうございます。あなたのsolutionから多くを学びました。

1つ質問ですが、fold 1とfold 2のLoRA部分はどのようにensembleしたのでしょうか。単純にパラメータを平均したのですか。

Takoi — 回答

ありがとうございます。

はい、そのとおりです。単純にパラメータを平均しました。