eedi-mining-misconceptions-in-mathematics

Private 7位（Public 2位）Solution Summary | kaerururu

Rank	7
Team	terekaerumasahmet
Author	kaerururu
Topic ID	551388
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/551388
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このコンペを開催してくださったkaggle teamとhost、そしてチームメイト（@tereka @irrohas @aerdem4）に感謝します。

ついに5枚目の金メダルを獲得しました。Competitions Grand Masterになれて本当に嬉しいです。

Overview

3つのpipeline（Retriever + Reranker）のVoting Ensemble

rerankerの推論はすべてvllmで行いました。

Pipeline1 by Masaya

これは簡潔なまとめです。

詳細はMasayaがこちらのlinkで書いてくれる予定です。

Retriever

- pretrainedのqwen35Bでtestの解答を生成
- model :SFR-Embedding-2_R、Hard Negative Sampling(N=100)。training dataでunseenの場合は除外
- dataset: 未知のMisconceptionをGPT4o-miniで補完
- candidate 60

Reranker

- Qwen2.5 32B AWQ+LoRA（40個の選択肢）
  - options → 0~9 + A~Z + a~z（40 charactors）
- dataset: originalのみ
- candidate 40
- 2回実行してマージ（[:40] と [20:]）
- logprobsを用いて25件を残す

Pipeline2 by Tereka+Kaeru

Retriever

- model1 :SFR-Embedding-2_R、Hard Negative Sampling(100）
  - dataset: original + gemma 27B/Qwen2.5 32Bによる合成データ
  - lb 0.378
- model2 : sayoulalaによるpublic model
- model1とmodel2の加重平均
- candidate 70、masayaの予測でフィルタリング

- single foldのみ

Reranker

- Qwen2.5 32B AWQ+LoRA（binaryの選択肢）
  - options → yes, not
- dataset: original + gemma2 27B/Qwen2.5 32Bによる未知のmisconceptionの合成データ
- single foldのみ

Pipeline3 by Ahmet

Retriever

- 最終pipelineでは省略

Reranker

- 候補は前段のpipelineからそれぞれ上位9件
- Qwen2.5 32B（9個の選択肢）

Ensembling

- 各pipelineのVoting ensemble
- 以下のようにrankを付与し、join、rankを合計、sum_rankで並べ替え

```
sub0
  .with_columns(pl.col()..split())
  .with_columns(pl.lit([/i  i  ((, , ))]).alias())
  .explode(pl.col([, ]))
```

```
submission
  .sort(by=[, , , ], descending=[, , , ])
  .group_by([], maintain_order=)
  .agg(pl.col())
```

Postprocessing

- 欠けているmisconceptionのrankをブースト

高速化のTips

Retreiver

- cuda:0とcuda:1で並列実行
- Misconception Vectorを事前計算

- collate_fnによるDynamic padding

Reranker

- vllmで推論（AWQ 4bit量子化）
- vllmのパラメータenabling_prefix_cacheをTrueに設定
- pipelineの前段の予測で候補をフィルタリング

うまくいかなかったこと

Retrieval

- vectorの連結
- 多数のvectorの平均

Reranker

- Full-dataで学習したmodel
- QwQ model

ありがとうございました!!