eedi-mining-misconceptions-in-mathematics

Private 11位（Public 9位）Solution Summary

Rank	11
Team	H&Y&L
Author	huangxiaojian
Topic ID	551424
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/551424
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、Kaggleの主催者とチームメイトに感謝します。 私たちの解法を簡単に共有します。

概要

私たちのpipelineは主にflagembedding https://github.com/FlagOpen/FlagEmbedding に従っています。retrievalとrerankerの2 stageに分けられます。

@sayoulala : https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/543519 共有ありがとうございます。私たちのpipeline設計の多くはここから来ています。

Retrieval

training dataに加えて、discussion https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/533764 と https://www.kaggle.com/competitions/eedi-mining-misconceptions-in-mathematics/discussion/541222 の外部データも使用しました。共有ありがとうございます。便宜上、これらをext1とext2と呼びます。

学習プロセスを3 stageに分けています。まずext1でmodelを学習し、次にext2でmodelを学習し、最後にtraining dataで学習します。

ext1にはnoiseがあるのかもしれませんが、ext1+training dataでmodelを学習すると、2-stageの学習よりも性能が悪くなることを観察しました。またext2はconstruct nameとsubject nameを欠いているため、引き続きmulti-stageの学習戦略を使っています。

Reranker

上記の3つのstageそれぞれから、学習済みのretrieval modelを3つ得ます。そしてこの3つのmodelを使って、ext1、ext2、training dataそれぞれのhard negative dataを作成します。さらにrerankerの学習プロセスも3 stageに分け、各stageで対応するhn dataを使って学習します。

いくつかの詳細

retrievalの3rd stageを学習する際には、negative cross deviceを使って各positiveに対するnegativeの数を増やしています。これを使うと、public scoreは0.567->0.574になりました。

retrievalとrerankerにはQwen2.5-32Bを使っています。制限のため、推論ではtop 18のみをrerankしています。

Model	Public LB
retrieval	0.582
retrieval+reranker	0.623

コード

主な学習コードは https://github.com/MilchstraB/Eedi で公開しています。

補足Q&A

no fit just luck — 質問

シンプルながら効果的な手法を見られて嬉しいです。特に、2つのopen source datasetを使うだけでこれほど良いLBとPBを達成できるとは。MalAlgoQAにはmisconceptionが含まれていませんが、どのように使ったのでしょうか。このコンペでは合成データが重要であり、特に追加データがすべてのmisconceptionをカバーしているべきだということが見て取れます。しかし、共有いただいた手法からはこの点が見つけにくいです。これほど素晴らしいPBを得た主なポイントかもしれないので、使用した合成データについてもう少し共有していただけますか。

huangxiaojian — 回答

MalAlgoQAについては、incorrect answerのrationaleをそのままmisconceptionとして扱っています。私の実験では、外部データによってretrieval stageで約0.02〜0.03のscore改善が得られました。高品質なデータが最も重要だと思います。というのも、主な改善はtraining setで学習する際のparameter調整、たとえばnegativeの数やbatch sizeによってもたらされたからです。

no fit just luck — 補足

この2つのdatasetでLB 0.582のretrieval modelを得られたのは素晴らしいです。私たちも挙げていただいた1つ目のdatasetを使ってみましたが、うまくいきませんでした。そしておそらくMalAlgoQAが顕著な理由なのでしょう。もっとも、それはmodelに異なるmisconceptionを予測するよう導くものであり、通常はmodelの性能改善には役立たないのですが。

huangxiaojian — 回答

まずext1を使ってretrievalを学習します。学習に使ったmodelはQwen-2.5-7B-mathです。次に、学習済みmodelを使ってext1をrelabelします。これはext1とコンペで提供されたmisconceptionとの類似度を計算するものです。

no fit just luck — 質問

もう少し明確に質問させてください。ext1 datasetでQwen-2.5-7B-mathを学習し、そのmodelでext1をrelabelすることで、ext1の元のmisconceptionを修正したということでしょうか？ これまで考えたことのない手法で、多くを学びました。

huangxiaojian — 回答

はい、3-stageの学習戦略に従ってQwen-2.5-7B-mathを学習し、その後ext1をrelabelしています。