

3位解法：2段階flip augmentation stacking（コード付き）

Rank	3
Team	senkin13
Author	senkin13
Topic ID	549588
Version	Japanese Translation


Source: <https://www.kaggle.com/competitions/um-game-playing-strength-of-mcts-variants/discussion/549588>
Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

この興味深いコンペを開催してくれたUMの主催者とKaggleチームに感謝します。リークがなく、CVとLBの相関が安定し、改善の可能性が数多くあるコンペで、無限にある可能性の中から精度の限界を探ることを本当に楽しみました。

概要

重要なのはデータ拡張と、安定したCV-LBパイプライン（LBの方が重要）を作ることだと思います。Private Leaderboardでほとんどshake-upがなかったことは、PublicとPrivateのデータが同じ分布だったことを示しています。



データ拡張

agent1-agent2の組をagent2-agent1へ反転し、AdvantageP1 を $1 - \text{AdvantageP1}$ に、utility_agent1 を $-\text{utility_agent1}$ に変更し、その他はそのままにしました。

Cross Validation

GameRulesetName によるStratifiedGroupKFoldを使い、utility_agent1 の少数クラスを隣接クラスへ変更しました。

特徴量エンジニアリング

素晴らしい公開Notebook [MCTS Starter](#) の特徴量をいくつか追加しました。さらに `EnglishRules` のTF-IDF-SVD特徴量も追加しました。この特徴量では適切な `max_features` を見つける必要があり、LBスコアを見ながら何度も試しました。

特徴量選択

target shiftが起きたときに大きく変動する特徴量を落とすため、null importanceによる特徴量選択を好んで使いました。

ハイパーパラメータ調整

OptunaでLightGBMとCatBoostの最良ハイパーパラメータを探索しました。

モデル

2段階モデリングを用いました。第1段階はflip augmentationデータで学習し、元の学習データとテストデータを予測します。そのOOF予測を第2段階の特徴量として使いました。

アンサンブル

最終提出は、LightGBMとCatBoostを3 seed平均したアンサンブルのブレンドです。

後処理

最終予測の平均値は元ラベルの平均値より低く、Public LBでも同様でした。そのため係数 `1.12` を掛けることでLBを0.002改善できました。

効果がなかったもの

`LudRules` のTF-IDF、BERT embeddings、より多くのagent1-agent2-game groupを用いたpseudo label、neural network。

Notebook

[um-final-sub-1](#)

補足Q&A

yunsuxiaozi: コンペ経験から見て、`oof_pred` をデータの特徴量として追加した方がよいですか？

senkin13: はい。単にaugmentationを学習データへ加えるより良いです。

Athar Sayed: 予測に掛ける係数 `1.12` はどのように見つけましたか？

senkin13: Leaderboard probingです。異なる係数を試し、LBスコアが最良になるものを選びました。

Cafelatte1: 第1段階のモデルはすべての特徴量を予測するのですか。それともSVDで次元削減しますか？

senkin13: 第1段階は第2段階と同じtarget (`utility_agent1`) を予測します。

mavillan: stackingを機能させるため、nested cross-validationなどの工夫を使いましたか？

senkin13: 第1段階でも `GameRulesetName` によるStratifiedGroupKFoldを使っただけです。