czii-cryo-et-object-identification

11位解法: batch normalization と 2D の後段フィルタ

Rank	11
Team	MNISTery
Author	Jeroen Cottaar
Topic ID	561837
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/czii-cryo-et-object-identification/discussion/561837
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

コード（学習 + 推論、すぐに提出可能）: https://www.kaggle.com/code/jeroencottaar/czii-11th-place-solution

コンペ主催者に感謝します。3D セグメンテーションへのすばらしい入門になりました。そしてもちろん、私自身からチームメイトの @davidlist に感謝します！

はじめに

このコンペの目的は、クライオ電子線トモグラフィーのデータ（基本的には電子密度の 3D マップ）の中にあるさまざまなタンパク質を特定することで、3D の粒子認識の問題でした。重要な要素の一つは、コンペの指標が precision より recall に大きく偏っていたことです。粒子を見逃すこと（偽陰性）は、多く予測しすぎること（偽陽性）よりはるかにコストが高くなっていました。

多くの解法と同様に、私たちの中核は UNet のセグメンテーションモデルです。他の解法ではあまり見られない、いくつかの要素を加えました。

- Batch normalization。学習を安定させ、ウィンドウの位置によらず推論を一貫させる
- 2D の分類ニューラルネットワークに基づく後段フィルタ。beta-galactosidase と thyroglobulin の偽陽性を取り除く
- 近接した複数の ribosome を予測する。紛らわしい領域で、より多くの ribosome を当てられる

本当に足りなかったのは、public のテストデータセットでモデルをきちんと最適化することでした。多くの提出をしたにもかかわらず、それらは実際には probing には使っていませんでした。UNet のアーキテクチャやハイパーパラメータについてはかなり実験しましたが、交差検証の中だけで行っており、学習セットが小さいため、そこから有用な結論を引き出すのはほとんど不可能でした。

この記事では、解法の概要をごく簡単に説明し、その後、これら3つの要素に順に焦点を当てます。

解法の概要

私たちの解法の中核は UNet です。

- 32 個のモデルをアンサンブル。ResNet のアーキテクチャを混ぜている。CV や LB による選択はせず、異なる seed で 32 回学習するだけ。
- モデルは、softmax の前のヒートマップの平均をとってアンサンブルする。
- 正規化はすべて BatchNorm（詳細は後述）。
- 学習は常に 2200 エポックで、early stopping はなし。最後に向けて学習率を下げる
- データ拡張: Z 軸周りの 90 度回転、Y 軸での反転。その他は役に立たなかった。
- Loss: cross-entropy と Tversky loss（alpha=0.5、beta=8）の重み付きの組み合わせ。
- test time augmentation はなし。

UNet のセグメンテーションマップから粒子の位置を得るには、次のようにします。

- 閾値をかけて連結成分を特定する。
- 各クラスタの重心を予測とする。クラスタがとても大きい場合は、複数の予測を出す（詳細は後述）。

- 連結クラスタのサイズに基づいて、含める粒子を選ぶ。beta-galactosidase と thyroglobulin については、2D ニューラルネットワーク分類器に基づく追加のフィルタを適用する（詳細は後述）。

Batch normalization

UNet のすべての正規化層で batch normalization を使っています。これは、各インスタンスを正規化するのではなく、学習中に求めた移動平均に基づく正規化係数を使う（そして推論中は固定する）ということです。これにより、スコアと学習の安定性が大幅に改善します。なぜでしょうか。

下の赤または青のウィンドウで推論しているとして、batch normalization 以外のものを使った場合に、位置 X で何が起きるかを考えてみてください。



赤いウィンドウを使っている場合、正規化はウィンドウ内のすべてのデータに基づくので、右下のアーティファクトが X での予測に大きな影響を与えます。青いウィンドウを使うと、X での予測は突然まったく違うものになりま

す。ニューラルネットワークにおいてある種の長距離の影響が有益なこともありますが、この影響がまったくの見せかけであることは明らかでしょう。また、これは推論ウィンドウの切り替わりで不連続が生じることも意味します（端のピクセルを捨てた場合でも）。

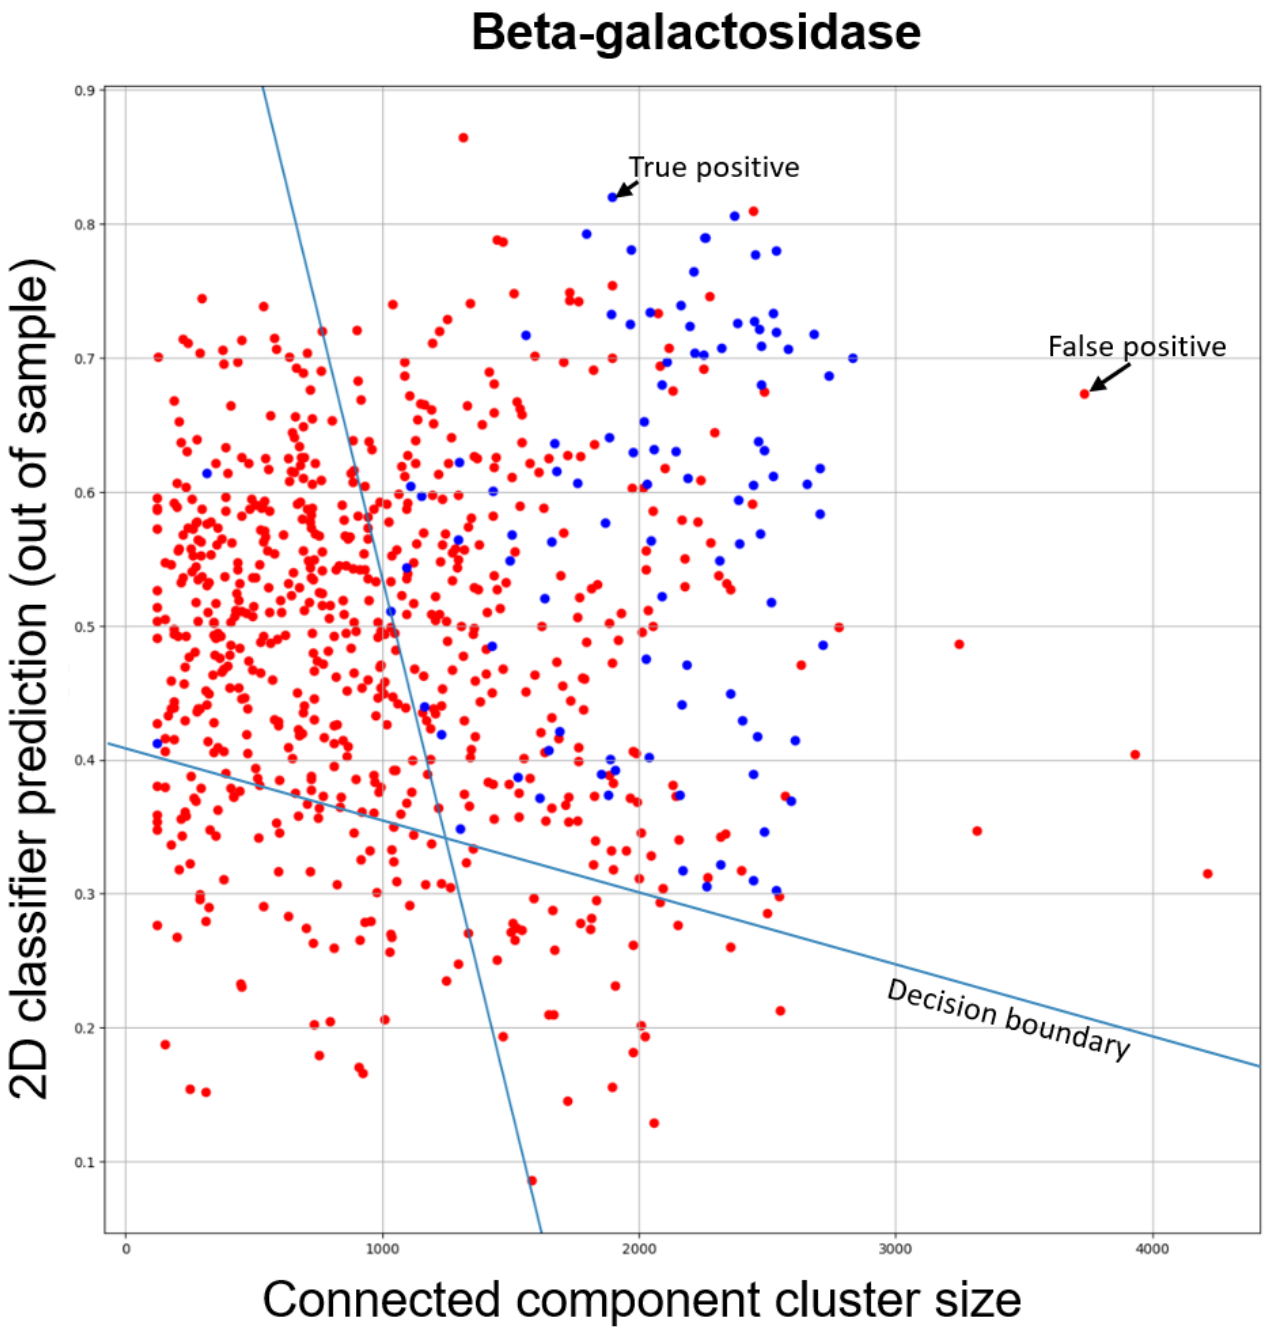
MONAI では特に、コンストラクタに "batch='NORM'" を加えるだけで instance normalization から batch normalization に簡単に変更できます。ただし、学習を安定させるためには momentum もいじる必要があるかもしれません（詳細は私たちのコードを参照してください）。

2D 分類器

コンペの論文に記載されているとおり、主催者は 2D 画像に基づく分類を取り入れていました。これに触発されて、私たちも同じことを試しました。

UNet モデルの真陽性と偽陽性（Z 軸方向に足し合わせたもの）で 2D ニューラルネットワークを学習します。最も単純なアーキテクチャが最も良く機能しました。単に3つの全結合層（dropout 付き）です。beta-galactosidase では、最初に畳み込み層を1つ追加しています（活性化関数なし）。一般的なデータ拡張を適用し、真陽性と偽陽性のバランスを取るための工夫もしています（詳細はコードを参照してください）。

下の beta-galactosidase の例で分かるように、これにより（クラスタのサイズだけを特徴量に使う場合と比べて）かなりの偽陽性を取り除けます。ただし、決定境界は leaderboard で調整する必要があり、残念ながら私たちはそれを十分に行いませんでした。



ribosome の改善

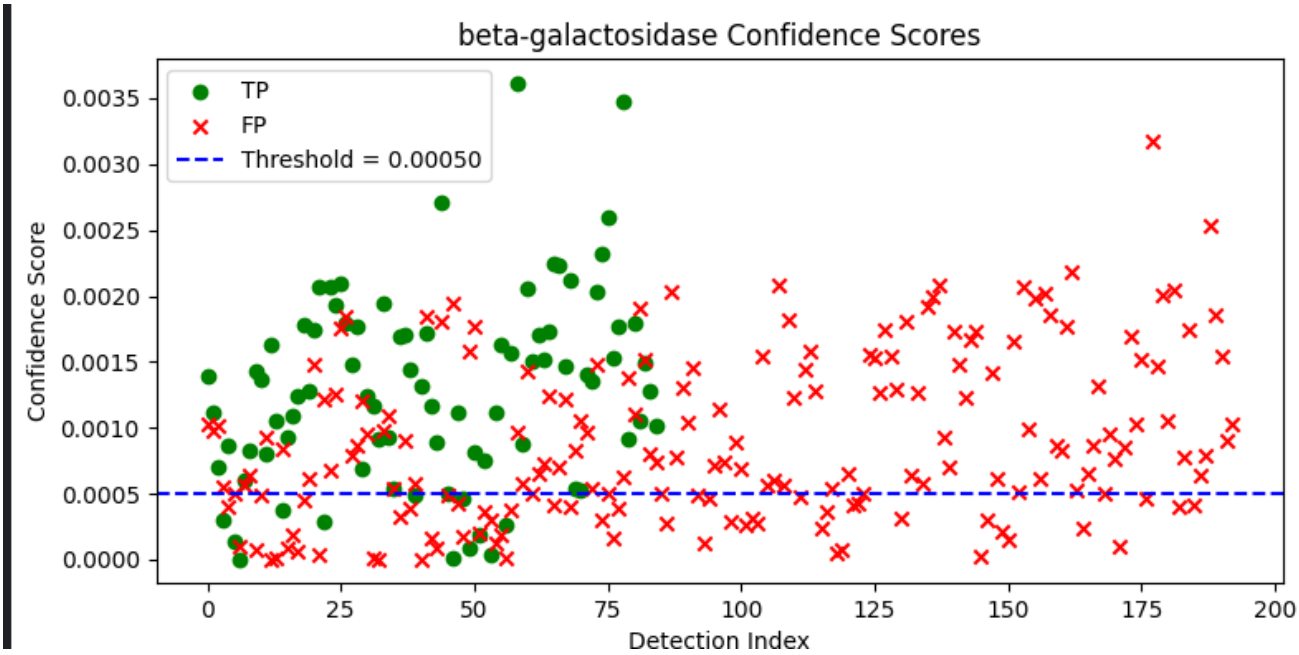
これはどちらかというと「Kaggle 的なこと」（本番の機械学習の解法には普通は入れないもの）かもしれません…

私たちは、ribosome のクラスタや、他のものに囲まれた単一の ribosome に苦戦していることに気づきました。これはクラスタが溶け合ってしまう傾向があるからです。私たちは、大きく細長いクラスタに対して、K-means を使ってクラスタを分割し、複数の ribosome を予測することでこれを解決しました

補足Q&A

IAmParadox — 質問

すばらしい仕事です @jeroencottaar。解法をとても楽しく読みました。beta-galactosidase と thyroglobulin 向けの 2D NN 分類器で、スコアがどれくらい上がったか共有していただけますか。私も似たようなことを試していて、予測した blob の中心ピクセル、たとえば beta-galacotosidase の 2x2x2 の立方体のようなものの平均確率を確認し、それに対する確信度スコアを見つけようとしていました。



分類器がうまく機能するには精度が 94% を超える必要があると考え、難しい粒子ではそれはかなり難しいと思ったので、分類の選択肢は除外していました。

Jeroen Cottaar — 回答

興味を持っていただきありがとうございます！2D 分類器の影響を正確に見積もるのは難しいです。オフにすると他の閾値を再最適化する必要があるからです。ただ、コンペを通じて見てきたことからすると、0.01 から 0.02 の改善になっていると思います。

なお、2D 分類器のスコアだけで粒子を選んでいるわけではありません。既存の選択の仕組み（UNet によるクラスタのサイズ）と組み合わせています。