wsdm-cup-multilingual-chatbot-arena

1位 Solution

Rank	1
Team	whitefebruary
Author	Max
Topic ID	569902
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena/discussion/569902
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、運営チーム、チームメイトのMichael、そしてこのチャレンジを楽しいものにしてくれた他の参加者の皆さんに感謝します。またどこかでお会いしましょう ･ᴗ･

概要

私たちのsolutionは、@sayoulala のdistillation手法と @tascj0 の推論手法（前回コンペの1位と2位のsolution）を組み合わせたもので、base modelにはQwen2.5-14B-Instructを使っています。

推論コードと学習コードは公開しています。

セットアップ

2つの出力クラスを持つ標準の `ForSequenceClassification` modelを使い、二値分類を行います。入力ではpromptと2つのresponseを連結し、整形後のサンプルが最大長を超える場合は、それぞれを長さに比例して中央から切り詰めます。学習では、1回のgradient stepに両方のresponse順序を含めます。

Stage 1. 事前学習

student（Qwen2.5-14B-Instruct）とteacher（Qwen2.5-72B-Instruct）の両方を、次のdatasetで事前学習します。

- mlabonne/orpo-dpo-mix-40k（40k）
- opencsg/UltraFeedback-chinese（50k）

どちらのmodelもDeepSpeed ZeRO3でfull parameter finetuningを行います。すべての実験のlearning rate scheduleは、50 stepのwarm-upの後、peak lr（4e-6）の10%まで線形に減衰させます。gradient clippingの閾値は、両modelとも64.0に引き上げています（前回の2位と3位のsolutionで指摘されていた通りです）。

Stage 2. Teacherの学習

事前学習済みのQwen2.5-72b-Instructから、次のdatasetの5 foldで5つのteacherをさらに学習します。

- lmarena-ai/arena-human-preference-55k（57k）
- このチャレンジのdataset（48k）

tie、multi-turnのresponseを除外し、promptとresponseの重複を除くと、結合datasetは80kサンプルになりました。さらにteacherの学習では、各responseの前にmodel名を付け加える形に入力形式を変えています。

Stage 3. Distillation

5つのteacher modelを使って、上記datasetにout-of-foldでsoft labelを付け、人間のannotationとの不一致が最も大きいサンプルを手作業で見直して、誤ってラベル付けされたペアを修正しました。加えて、次のデータにもsoft labelを付けました。

- 上記lmarena datasetのうち、tieとmulti-turn会話の最初のturnを含めたもの（106k）
- lmsys/chatbot_arena_conversations（33k）

- lmarena-ai/PPE-Human-Preference-V1（16k）（評価用datasetであり、相関が近いことから当初はこれがLBではないかと疑いましたが、他の人も使うだろうと恐れて学習mixに含めました）
- lmarena-ai/Llama-3-70b-battles（1k）
- lmarena-ai/gpt-4o-mini_battles（1k）
- @nbroad のdataset（v1、v2、v3）（25k）
- lmsys/lmsys-chat-1m のpromptをseedにした私たちの合成データ（50k）

最後のdatasetは、（Arena-hardと同様に）promptにcomplexity scoreを付けて簡単なpromptを除き、score ≥ 3のpromptを採用して作りました。その際、このチャレンジのdatasetに合わせて、言語分布（50%が非英語）とpromptのdomain分布（MT-Benchの8カテゴリを使用）を保っています。responseは、vLLMを使って次のmodelから一様にサンプリングしたcompletionです。

- meta-llama/Llama-3.1-405B-Instruct-FP8
- meta-llama/Llama-3.3-70B-Instruct
- Qwen/Qwen2.5-72B-Instruct
- Nexusflow/Athene-V2-Chat

distillationは、重み付けした3つのlossで行いました（元のラベルがあればそれに対するCE、なければhard labelに対するCE、soft labelに対するKLとCosine loss）。最終modelは2つのmodelの線形mergeです。1つは全データで学習したmodel、もう1つは最後の2つのdatasetを除いて学習したmodelです。

推論

推論では、前回の2位 solutionのコードをQwen2.5向けに改変し、sequence concatenation（unpadding）を使います。推論は2回行います。1回目はmerge済みmodelで全サンプルを推論し、2回目は予測が最も不確かな33%のサンプルだけに対して、元のmodel（全データで学習したもの）でresponse順序を入れ替えて推論します。

うまくいかなかった実験

- teacherの学習と推論にCoTを加えるため、別のcritique modelを学習しました。人間の投票との一貫性でフィルタしたGPT-4oのcritique 2万件のdatasetを作りましたが、critiqueを使って作ったsoft labelでの学習は、使わない場合より一貫して悪い結果でした。
- 2回目の推論パスに、vLLMとAWQでQwen2.5-72Bを使うことも試しました。しかし推論コストが高いため、TTAを適用できたのはサンプルの5%だけで、LBでは大幅に悪く見えました。
- activationの類似度に基づくlayer pruningも実験しました。これができれば、はるかに大きなmodelで推論できます。しかし私たちの実験では、gemma-2-27bやQwen2.5-14Bをlayer pruningしても、gemma-2-9bをそのまま使うのと同等か、それより悪い結果でした。
- 2つのresponse順序に対して、linear headの前の出力embeddingが近くなるよう強制し、modelの入力順序へのbiasを取り除くことも試しました。これにより2回目のパスを不要にするか、そこに使う計算資源を減らせる可能性がありました。