wsdm-cup-multilingual-chatbot-arena

WSDM Cup - Multilingual Chatbot Arena 5位 Solution

Rank	5
Team	Just doing
Author	Albert Wang
Topic ID	567724
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena/discussion/567724
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

入賞された皆さん、おめでとうございます！

このような楽しいコンペを開催してくださった主催者の皆様、そしてChatbot Arenaに惜しみない支援を提供したUC Berkeley SkyLab、a16z、Sequoia、Fireworks AI、Together AI、RunPod、Anyscale、Replicate、Fal AI、Hyperbolic、Kaggle、MBZUAI、HuggingFaceに感謝します。 このコンペには価値があり、私の興味をかき立てました。組織はmodelを使って、ユーザーが好む回答を提供できるからです。ユーザーの時間は貴重です。ユーザーの好みを予測し、関心のある情報を提供する方法は、情報伝達の効率を上げることで、ユーザーにより多くの価値をもたらします。

コンテキスト

- ビジネスのコンテキスト: https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena
- データのコンテキスト: https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena/data

アプローチの概要

最終提出ではQwen2.5-14Bを使いました。このmodelは、ユーザーの質問に対する2つのLLMの回答（AとB）を評価し、どちらが「より良い」かを判定します。まずvllm libraryの有無を確認し、なければinstallします。system promptが、judge LLM（Qwen2.5_14b）に、網羅性や明確さといった基準で回答を評価するよう指示します。コードは入力を前処理し、modelのtoken制限に収まるよう長いテキストを切り詰めます。vllmを使ってtoken 'A' と 'B' のlog probabilityを生成し、好みを表します。後処理のステップで判断を精緻化します。log probabilityが近い場合は、回答に含まれる数字の数を数えてtie-breakerにします。最後に、コードは「winner」（model_aまたはmodel_b）をCSVファイルに出力します。

進捗のロードマップ

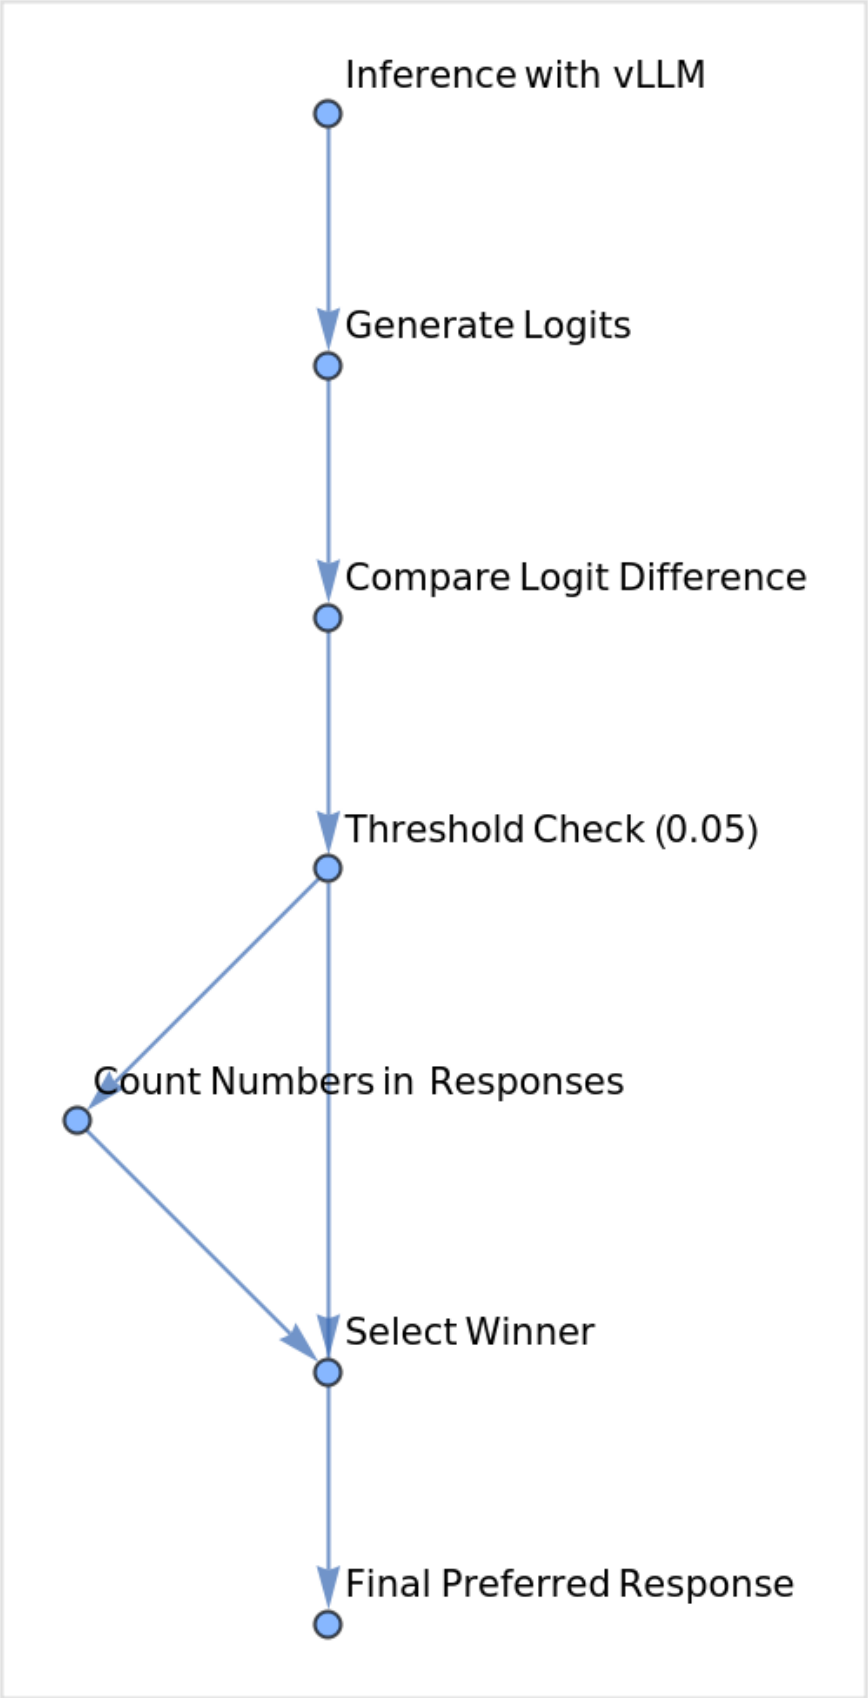
- 0.661 Gemma-2 9b 4-bit QLoRAから開始。大規模言語modelを最小限のGPUメモリでfine-tuningできる効率の良さから、4-bit QLoRAで動かすGemma-2 9Bを堅実なbaselineとして始めました。
- 0.665 後処理を適用。LLMの生成結果が近すぎて信頼できない場合に勝者を選びます。初期のLLMの生成結果は、scoreが近すぎる場合に信頼できませんでした。これに対処するため、2つの回答のlog probabilityの差が一定の閾値未満の場合に、heuristicなルールで勝者を決める後処理ステップを導入しました。
- 0.685 LGBMとのensemble。精度をさらに上げるため、token長、意味的類似度、回答の一貫性といった手作りの特徴量を使うLightGBM modelとLLMの予測をensembleしました。
- 0.690 vLLM _ Qwen2.5-14B。base LLM modelを、より多言語能力と指示追従の精度が高い強力なQwen2.5-14Bに切り替えました。
- 0.693 max_lenを超えたらtokenを切り詰め、ユーザーがより注目する先頭と末尾を優先します。長い回答はmodelのmax_length制限を超えることがよくありました。これに対処するため、回答の先頭と末尾を優先してtokenを切り詰めました。これらの部分には通常、最も価値のある情報が含まれているからです。
- 0.697 回答の位置を入れ替え。回答の構造が最適でない場合がありました。入力の整形で回答の位置を入れ替えることで、modelが文脈をより良く評価できるようにし、ranking精度が向上しました。

- 0.703 wsdm_lmsysデータを追加。追加のWSDM_LMSYS学習データを統合し、多様なchatbotのやり取りとユーザーの好みでdatasetを豊かにしました。
- 0.706 soft_label_swap（二値ではなく確率のラベルを生成）。回答の選択を二値のタスクとして扱うのではなく、確率に基づくラベルを生成し、modelがより細やかな判断をできるようにしました。
- 0.706 ➡️ 0.712 public ➡️ privateのテストセット

コード

https://github.com/datahubber/Natural-Language-Processing/blob/main/ChatbotArena/vllm-qwen2-5-14b-2ef57b.ipynb

後処理



vllmは予測結果をlogitで出力します。差が0.05より小さい場合、確率に換算すると勝率の差は2.5%になります。数字が多いほど回答は正確であり、ユーザーに好まれやすい可能性があります。数を数える関数は、LLMが判断に迷うときに働きます。たとえば、vllmがresponse aの勝率を80%、bを20%と予測した場合、aという予測はおそらく

正しいでしょう。しかし、vllmがresponse aを51%、bを49%と予測した場合、vllmには強い確信がありません。この場合、正解率0.58の単一のルールが、solution全体の正解率を改善します。 このアイデアは、Stephen Wolframの『What Is ChatGPT Doing … and Why Does It Work』から得ました。彼は、数字は言葉よりも正確だと考えています。そこでこの方法をmodelに実装したところ、効果がありました。

試してみたいこと

1. ユーザーが書いたpromptに応じて、ユーザーを論理的/感情的 ∈ [0, 1]（論理的な比率 + 感情的な比率 = 1）とラベル付けします。そして、LLMの予測が曖昧なときに、ユーザーと内容の一致を見るため、response a/bにも論理的/感情的な比率 ∈ [0, 1]（論理的な比率 + 感情的な比率 = 1）をラベル付けします。

補足Q&A

Jianbo Wang — 質問

金メダルおめでとうございます！ 私もheuristicなルールを適用しましたが、単純に回答の長さに基づくものでした。あなたのsolutionの方が合理的に思えます。 間違っていたらすみませんが、「soft_label_swap」はlabel smoothing（例: [0, 1] -> [0.1, 0.9]）に似た方法でしょうか。

Chew Kok Wah — 質問

最終的な14B modelも4bit QLoraで学習したのですか。

Albert Wang（著者） — 回答（Chew Kok Wahへ）

いいえ、違います。

Albert Wang（著者） — 回答（Jianbo Wangへ）

はい、部分的には正しいです。smoothing（例: [0, 1] -> [0.1, 0.9]）を含み、さらにrobustnessを高めるために位置の入れ替えも行っています。