wsdm-cup-multilingual-chatbot-arena

5位 詳細Solution

Rank	5
Team	Just doing
Author	Chenyu Lin
Topic ID	567856
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena/discussion/567856
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

入賞された皆さん、おめでとうございます！チームメイトの @mianwang1024 @zhengnie233 に感謝します。他の2人のチームメイトには、座って成果を享受するとはどういうことかを教えてくれたこと、そして人間の本性に潜む貪欲さを明らかにしてくれたことに感謝したいと思います。このような興味深いコンペを開催してくださった主催者の皆様に感謝します。革新的なアイデアと活発な議論を提供してくれたKaggleコミュニティにも感謝しています。多くのことを学びました。ここでは、それを補足する詳細なsolutionを紹介します。 code: 5th code infer : notebook

タスク

大規模言語model（LLM）を使ったchatbot同士で、ユーザーがどちらの回答を好むかを予測します。 単純なアイデアは、大きなmodelで二値分類をすることです。大きなmodelは小さなmodelより表現能力が高く、このタスクに向いています。ただし、いくつかの課題がありました。

- 大きなmodelは、テキスト内での回答A/Bの位置に非常に敏感で、位置バイアスを示します。単純なアイデアは、大きなmodelで二値分類をすることです。大きなmodelは小さなmodelより表現能力が高く、このタスクに向いています。
- ユーザーの好みは回答の合理性に限らず、回答の正確さ、スタイルの度合い、言語、長さ、流暢さも含むため、大きなmodelは実データに基づいて追加の知識を学ぶ必要があります。
- このコンペでは、大量のデータを短時間で推論する必要があります。

考え方

- LoRAはQLoRAより良く、速い可能性があります。高いrankは、modelが好みに関するより多くの知識を重視するのに役立ちます。full trainingはLoRAより良いかもしれません。
- promptの中で回答A/Bの位置を入れ替えるdata augmentationは素直な選択でしょう。入れ替えの後にさらに多様な変更を加えると、もっと良いかもしれません。
- この状況では、soft labelの方がhard labelより学びやすく、logitの分布の方がラベルそのものより学びやすいかもしれません。
- 入力promptは、より多くの情報を残すよう特別に処理すべきです。
- vllmによる高速な推論とより良い推論能力のために、AutoModelForCasualLMの方がAutoModelForSequenceClassificationより良いかもしれません。
- 後処理によって、大きなmodelが2つの回答を見分けにくいという問題に対処できるかもしれません。

データ

複数のデータソースを集めました。 WSDM48k LMSYS_55K Add_33k open-model(8.5k+13k+5k)（@nbroad に感謝します） 重複データを除き、入れ替えによるdata augmentationを行いました。 最終的なデータは2*120k行です。

Model

Qwen2.5-14b-it、Gemma2b-it、deepseek-r1-distill-14bを試しました。Qwen2.5-14b-itと比べると、deepseek-r1-distill-14bはcvを約0.001改善しましたが、LBは約0.003下がりました（主な理由は、1 tokenしか生成しないため、deepseek-r1が推論能力を失うことだと思います）。Gemma2b-itはどちらでも低い結果でした。そこで最終的にQwen2.5-14b-itを選びました。

学習

1.Prompt

切り詰めによる情報の損失を抑えるため、質問と両方の回答の中央部分を切り詰めて省略記号に置き換えます。たとえば "Have a nice day" を "Have … day" に切り詰めるような方法です。



2.2段階の学習

data

Stage 1

Dataset WSDM48k LMSYS_55K Add_33kをhard label [0,1] で使用。 **学習**

- Qwen2.5-14b-it modelを、fp16精度のLoRAで学習しました。hard labelに基づいて回答AとBに対する出力確率分布を直接最適化し、他のtokenのlossは無視します。
- LoRAのパラメータはr=64、alpha=128に設定しました（rをもっと大きくした方がおそらく良いのですが、実装する時間がありませんでした）。learning rateはlora_aに1e-5、lora_bに5e-5を設定しました（このアプローチを参考にしました。@conjuring92 に感謝します）。batch sizeは16、max_lengthは4096、Epochs =1です。
- 学習は6台のA100で約12時間かかりました。

logitの予測

- すべてのデータを入れ替えてdata augmentationを行い、ペアごとにshuffleして最終的な学習データにしました。
- 学習済みmodelを使ってopen-model datasetのlogitを推論し、回答AとBの確率を得ました。

Stage 2

Dataset WSDM48k LMSYS_55K Add_33kを [0,1]->[0.05,0.95] のようなsoft labelで使用。 open-model(8.5k+13k+5k)をstage 1で推論したsoft labelで使用。 **学習**

- stage 1と同じで、loss関数を少し調整するだけです。
- 学習は6台のA100で約16時間かかりました。

推論

推論にはVLLMを使いました。modelを半精度でloadし、promptと出力を合わせた最大長を8192とし、T4 GPUのメモリが足りないためCPU offloadingを実装しました。推論時、modelは1 tokenだけを生成するよう設定し、そこから回答AとBのlogitを取り出しました。logitの値が大きい方の回答を最終的な回答として選びます。両方の回答のlogitが近すぎる場合は、後処理を適用して最終的な回答を決めました。

いくつかの発見

LBでのいくつかの実験です（一部の実験はCVでのみテストしたため、表には含まれていません）。

model	data	operation	LB
qwen2.5-14b-it	wsdm	zeroshot	0.6254
qwen2.5-14b-it	wsdm	mid_cut+0.7dpo+0.3bce	0.689
qwen2.5-14b-it	wsdm	left_cut+lora	0.6907
qwen2.5-14b-it	wsdm	mid_cut+random_fewshot	0.6910
qwen2.5-14b-it	wsdm	mid_cut	0.6938
qwen2.5-14b-it	wsdm+lmsys+add_33k	mid_cut	0.6964
qwen2.5-14b-it	wsdm	mid_cut+swap	0.6967
qwen2.5-14b-it	wsdm	mid_cut+cot_multi_task	0.6973
qwen2.5-14b-it	wsdm+lmsys+add_33k	mid_cut+swap	0.7038
qwen2.5-14b-it	wsdm+lmsys+add_33k	mid_cut+swap+postprocess	0.7039

model	data	operation	LB
qwen2.5-14b-it	wsdm+lmsys+add_33k+open_model	mid_cut+swap +softlabel	0.706812（最終LB=0.712）

- いくつかの実験から分かったことです。 **次の結果はCVでのみテストし、有意な改善は見られませんでした:**
- 1つの入力の中で、質問、回答A、回答Bのベクトル表現を平均値で取り出し、学習時にcross-entropyの学習に加えてcontrastive learningを導入しました。
- promptの文言が学習結果に与える影響は、それほど大きくありません。 **次の結果はCVとLBでテストしました:**
- 学習時にランダムなfew-shot learningを導入すると、CVはわずかに改善しましたが、leaderboard（LB）のscoreは下がりました。
- より大きなmodelでCoTを生成し、そのCoTに基づいて14B modelにmulti-task learningを適用しました。結果はより良く、0.003の改善の可能性がありました。実際の仕組みを十分に理解できなかったため、このアプローチは最終的に採用しませんでした。 **次の結果はLBでのみテストしました:**
- 学習のmax lengthを8192に増やしました。LBは下がりました。
- modelを2ラウンド学習しました。LBは下がりました。
- AとBに対するBCE lossに加えて、modelの好みの確率を最適化するDPO学習も追加しました。LBは下がりました。