wsdm-cup-multilingual-chatbot-arena

6位 Solution

Rank	6
Team	Oh Your Mercy Never Fails
Author	Zhecheng Li
Topic ID	567600
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena/discussion/567600
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、この意義深いコンペを開催してくださったKaggleとChatbot Arenaに心から感謝します。また、1年近く一緒にKaggleで戦ってきたチームメイトの @pingfan、@xuanmingzhang777、@xiaoqinglong1996、@tonyarobertson に深く感謝します。残念ながら、これまでのコンペでは予期せぬ事態に見舞われ、shake downしたり金メダルを逃したりしてきました。しかし今日、5人のKaggle competition expertがそろってcompetition masterになりました。チームメイトとこの成功を分かち合えることは、私たちの旅の中でも本当に信じられない瞬間の1つです！

TL;DR

1. **擬似ラベル（Pseudo Labeling）：**
   - LMSYSの3位チームが生成したデータを活用しました。
   - 1Mのdatasetからpromptをサンプリングし、APIを使ってresponseを生成しました。
   - オープンソースのDPOデータ（例: RLHFlow）を取り入れ、それらを混ぜて擬似ラベルを生成しました。
2. **Distillation:**
   - Llama3.3-70BとQwen2.5-72BのmodelをGemma2-9BとQwen2.5-14Bにdistillationしました。
   - 4-bit量子化を使い、最大sequence長2500 tokenで学習しました。
3. **多言語戦略:**
   - GemmaとQwenはすでに最も強力な多言語modelの1つであるため、多言語性能は主な焦点ではありませんでした。
   - 英語の精度が最適でないことが分かったため、上位5つの主要言語、特に英語を優先しました。

擬似ラベル

擬似ラベルは私たちのアプローチで決定的な役割を果たしました。擬似ラベル付きデータを効果的に活用することで、コンペのデータセットで直接学習しなくても、**0.693** を超えるLB scoreを達成しました。

Dataset

複数のデータソースを集め、短いresponseをフィルタして約560Kのサンプルを得ました。

1. **LMSYSの3位チーム** が生成したデータ（@conjuring92 に特別な感謝を）。
2. 1Mのdatasetからサンプリングしたpromptと、APIで生成した様々なmodelのresponse。
3. 約10個のオープンソースのDPO dataset（例: RLHFlow）。

これらのdatasetを処理して、高品質な擬似ラベルを生成しました。

擬似ラベルのアプローチ

ラベルの精度を確保し、data leakageを最小限にするため、judge modelについて2つのアプローチを試しました。

1. **Baseline Method:** コンペのデータでGemma2-9Bをfine-tuneする。
2. **Enhanced Method:** コンペのデータでLlama3.3-70BとQwen2.5-72Bをfine-tuneする。

enhanced methodはわずかな改善を示しましたが、推論時間が大幅に長くなりました。最終的に、擬似ラベル付きデータでGemma2-9Bを学習し直すと、KL Divergence LossとCross-Entropy Lossのどちらでも同等の結果が得られました。

Knowledge Distillation

- **Teacher Model:** Qwen2.5-72B、Llama3.3-70B
- **学習データ:** WSDM + LMSYS
- **Loss関数:** KL Divergence Loss、Cross-Entropy Loss、および2つのlossを等しく重み付けした平均

distillationのために大規模なpost-trainingを行いました。distillationはQwen2.5-14B modelには有意な効果がありませんでしたが、Gemma2-9Bでは測定可能な改善を示しました。

最終学習フェーズ

1. Qwen2.5-14BとGemma2-9Bの両方について、4-bit量子化modelで **直接LoRA学習** を行いました。
2. **最大sequence長: 2500** — 3072に伸ばしても目立った効果はなく、学習時間の制約からそれ以上の延長は見送りました。

推論戦略

- **主model:** Qwen2.5-14B
- **補助model:** Gemma2-9B
- **推論の仕組み:**
  - 主な分類にはQwen2.5-14Bのlogitを使いました。
  - Gemma2-9Bは、Qwen2.5-14Bが分類に苦労したケースを優先して選択的に使いました。
  - 推論時間を効率よく管理し、12時間の制限を使い切りました。

うまくいかなかったこと

1. **TTA（Test-Time Augmentation）** は、sequence classificationでは測定可能な効果を示しませんでした。
2. **LoRA Merge** は大きな性能低下を引き起こし、debugしても解決しませんでした。
3. **Multi-LoRA ensemble** のアプローチは性能を改善しませんでした。
4. **responseの長さに基づく動的なtoken割り当て** は、異常な長さの分布を招きました。
5. **Modelの選択:** Gemma2-9BとQwen2.5-14Bが他のmodelより優れていました。
6. **DPO datasetの元のラベル** はpost-trainingには効果がありませんでしたが、擬似ラベル付けには有用でした。
7. **Chain-of-Thought prompting** の戦略は意味のある改善をもたらしませんでした。
8. **推論時の動的な切り詰め** は当初 **+0.003のLB向上** をもたらしましたが、学習コードと切り詰め方法を更新した後は効果が薄れました。

私個人の「うまくいかなかったこと」リスト

1. `AutoModelForMultipleChoice` を使って、多肢選択タスク向けにmDeBERTa modelをfine-tuneしました。しかし予想通り、modelのパラメータ数の制約で性能は低いものでした。
2. 10Kサンプルでfine-tuneしたGPT-3.5を、擬似ラベル付けのjudge modelとして使おうとしました。しかし、OpenAIの学習過程の不透明さとパラメータ調整への敏感さにより、満足のいく結果は得られませんでした。
3. few-shot promptingで精度が向上するという研究とは逆に、このコンペの設定では当てはまりませんでした。2-shotから32-shotまでのGPT-3.5の構成を試しましたが、精度の有意な改善はありませんでした。人手の介入が多すぎたためかもしれません。

改善の余地

1. teacher modelの **cross-validationとleaderboardの性能が最適でない** — 大規模パラメータのmodelの学習は依然として大きな課題です。たとえば、Gemma2-27Bの学習では満足のいく結果を得られませんでした。
2. **LoRAのmergeと学習後の量子化の問題** が予期せぬ性能低下を引き起こし、依然として重大なボトルネックになっています。

結論

改めて、4人の素晴らしいチームメイト、@pingfan、@xuanmingzhang777、@xiaoqinglong1996、@tonyarobertson に感謝します。