jigsaw-agile-community-rules

5位 Solution - 多様なアンサンブル

Rank	5
Team	Flash ⚡
Author	Kishan Vavdara
Topic ID	613421
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/jigsaw-agile-community-rules/discussion/613421
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、主催者の皆さん、素晴らしい public notebook、そしてコミュニティと、途中でアイデアを共有してくれたすべての人に感謝します。

概要

最終的な解法は、意図的に多様にしたアンサンブルです。ルールごとのスペシャリスト（DeBERTa の NLI 学習、ロジスティック回帰 + k-NN を使った埋め込みモデル）、推論専用の大型モデル（公式データで学習し、類似度ベースのサンプリングで推論した Qwen-32B）、そしてすべてのルールにまたがるいくつかの test-time training（TTT）コンポーネント（public の DeBERTa 学習、public の FAISS + triplet パイプライン、Qwen-3 1.7B のフルファインチューニング、Llama-3.1 8B の LoRA）を組み合わせました。すべてのモデルで一貫した指示のみのプロンプトと Yes/No に制約したデコードを使い、ルールごとの順位正規化による重み付けでブレンドしました。

データ前処理

- subreddit を落とす - ノイズが多く不安定な信号として扱った。取り除くことで一貫性が向上した。
- 行の重複除去: 完全な重複を取り除き、学習サイズを 10k 件未満に減らした。学習が速くなり、lb での測定可能な低下はなかった。

性能評価

“public LB を信じる” 方法を使いました。

モデル

Model	Public LB	Private LB	Runtime*
LLaMA-3.1 8B Instruct (TTT)	0.92084	0.92618	~130 min
Qwen-3 8B (TTT)	0.91971	0.92314	~130 min
Triplet + FAISS (public, improved)	0.90082	0.91131	~70 min
6× Embedding models → LR + kNN (per-rule)	0.90067	0.90976	~90 min
DeBERTa (public training recipe)	0.90149	0.90767	~45 min
DeBERTa NLI (custom)	0.89853	0.90636	~90 min
Qwen-32B (Inference-only, similarity sampling)	0.89065	0.89671	~300 min

* 私たちの 2×T4 環境でのエンドツーエンドの実行時間。

学習と推論:

LLaMA-3.1 8B Instruct & Qwen-3 8B（LoRA、DDP）

- 設定: 2×T4 で DDP、fp16 + gradient checkpointing、学習と推論で seq len 512。
- LoRA: `r=256, lora_alpha=32, lora_dropout=0.0, bias="none", target_modules=["q_proj","k_proj","v_proj","o_proj","gate_proj","up_proj","down_proj"]`。
- 最適化/スケジュール: paged_adamw_8bit、LR≈2e-4、cosine、warmup≈10%。

プロンプト:

```
 Instructions: You are a expert Reddit Moderator, you are given a comment and a rule. Your task is to classify whether the comment violates the rule. Only respond Yes/No.
<Rule>{rule}</Rule>
<Comment>{body}</Comment>
Answer:
```

推論:

vLLM TP=2、max_model_len=512。{Yes, No} に制約し、max_tokens=1 で Yes の確率を取る。予算を超える場合は、 だけを切り詰める。

埋め込みモデル

使ったファミリー: E5（base、large）、Qwen3-Embedding（0.6B）、BGE（small、large）、GTE（large）。

ルールごとのパイプライン

- 重複除去とバイアス除去: 各ルール内でほぼ重複したもの（cosine > 0.95–0.97）をクラスタリングし、重みを下げて、分類器が繰り返しのパターンに過学習しないようにする。
- 2つの軽量なヘッドを学習する（6-fold CV）:
  - ロジスティック回帰: 31 個の C の値 でグリッド探索。
  - KNN: K=10–15 でグリッド探索、距離で重み付け。
  - 埋め込みモデルとルールごとに、最良の CV 設定を残す。
- ヘッドのブレンド（ルールごと）: 0.7・LR + 0.3・KNN。キャリブレーション（LR）と局所的な近傍の手がかり（KNN）を組み合わせるため。
- モデルアンサンブルの探索（ルールごと）: 6つの埋め込みモデルの重みについて、GPU で高速化した simplex/グリッド探索を行い、CV AUC を最大化する（制約付き、非負、合計1）。
- 安定化: ルールごとの最終スコア = 0.9・アンサンブル確率 + 0.1・順位平均（裾のバイアスやルール間のスケールのずれを防ぐ）。

- 出力: 行ごと・ルールごとのキャリブレーション済み確率。後で全体アンサンブルの中で他のモデルファミリーとブレンドする。

（この埋め込みスタックは私たちの最初の強いベースラインで、重複除去の閾値、CV の fold、埋め込みモデルについて大量に反復しました）

DeBERTa NLI（ルールを考慮した zero-shot → TTT）

ベース: MoritzLaurer/deberta-v3-large-zeroshot-v2.0

NLI の枠組み:

- Premise: コメント本文
- Hypothesis: “This comment violates the rule: {rule}.”（加えて8つの言い換え）
- ラベルの対応: Entailment → 違反、Contradiction/Neutral → 準拠

ルールごとの Test-Time Training（TTT）:

- テストの正規の positive/negative からルール専用の小さなセットを作る。
- 約 25k ペアにアップサンプルし、2 epoch 学習する。
- bias + 分類ヘッド + LayerNorm だけを更新する（バックボーンは凍結）。学習が速くなる。

バランス調整: positive/negative の倍率を動的に変えて約 50/50 にする（上限 32×）。

非対称な例の選択を使った Qwen 2.5 32B LLM

核となるアイデア: 各推論の前に、埋め込みを使って文脈的に関連する例を選び、それから LLM にプロンプトを与える。

- positive の例: コメントに最も似たものを選ぶ（明確な違反のプロトタイプ）。
- negative の例: 最も似ていないものを選ぶ（難しく多様な非違反）。

この非対称な組み合わせにより、決定境界が引き締まります。

パイプライン:

- 正規の例（ルールごとに pos 2 + neg 2）を Qwen3-0.6B の埋め込みで埋め込む。
- 各コメントについて: (rule+comment) をエンコード → cosine 類似度を計算 → pos は argmax、neg は argmin を、簡単な品質の閾値付きで選ぶ。
- 選んだ pos/neg の例でプロンプトを組み立てる。

Qwen-32B-Instruct（GPTQ）+ LoRA で推論する。出力を Yes/No に制約し、logits に softmax をかける。

結果: 通常の few-shot より +0.006。関連する positive + 難しい negative が分類を顕著に改善することを示している。

Triplet + FAISS

public の解法に学習セットを含める。

1 epoch 余分に学習する。

アンサンブル（積み上げ式、ルールごとの順位）

アンサンブルは段階的に行いました。新しい強いモデルができるたびに、ゼロから作り直すのではなく、現在のブレンドの上に積み上げました。各提出のスコアはルールごとに順位正規化し、モデル間（LLM 対 NLI 対 検索）のキャリブレーションのずれを取り除きました。その後、階層的なブレンドのスケジュールを適用しました。最も強い検索系（Embeddings LR+kNN）と最も強い NLI（DeBERTa-NLI）の 50/50 から始め、FAISS/Triplet、Qwen-32B（学習データのみ）、DeBERTa-public、Qwen-3-8B（TTT）、LLaMA-3.1-8B（TTT）を順に混ぜていきます。追加のたびに固定の混合比を使い、それまでのスタックはそれに応じて重みを下げました（幾何的な減衰）。これは自然に正則化として働き、単一のモデルが支配するのを防ぎます。最後に [1e-6, 1−1e-6] にクリップしました。この戦略は、パラダイム（検索、NLI、LLM-TTT）にまたがる多様性を活かし、キャリブレーションを安定に保ちました。

引用

https://www.kaggle.com/code/neibyr/lb-0-878-train-on-test-data-qwen2-5-0-5b

https://www.kaggle.com/code/nahidhossainredom/deberta-v3-base-3-epochs-lb-0-906

https://www.kaggle.com/code/datafan07/jigsaw-speed-run-10-min-triplet-and-faiss