jigsaw-agile-community-rules

6位 Solution: Deep Mutual Learning によるオンライン蒸留

Rank	6
Team	ducnh279
Author	ducnh279
Topic ID	613150
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/jigsaw-agile-community-rules/discussion/613150
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このような素晴らしい LLM コンペを開催してくださった主催者の皆さんに感謝します。そして、私の先生である @justmarkham にも大きな感謝を。あなたのオンラインのデータサイエンス教育は計り知れない価値があり、あなたなしではこれを成し遂げられませんでした。

要約

このコンペでは、**Deep Mutual Learning (DML)** を使って Qwen3 ファミリーの3つの LLM をテキスト分類用にファインチューニングし、頑健性と安定性を高めるために重み付きアンサンブルを適用しました。

入力データ

テストの positive と negative の例を、それぞれのルールと一緒に学習に使い、次のプロンプトテンプレートに整形しました。

```
prompt = f"""<|im_start|>user
You are given a Reddit comment and a specific subreddit rule. Your task is to decide if the comment
violates the rule. Respond only with "Yes" or "No".

Rule: {RULE_HERE}

Now, here is the comment to classify:
"{COMMENT_HERE}"

Answer "Yes" if it violates the rule, otherwise "No".<|im_end|>
<|im_start|>assistant
<think>

</think>

Answer:"""
```

モデル

- **実験用のモデル:** Qwen3-14B と Qwen2.5-14B-Instruct
- **最終提出用のモデル:** Qwen3-14B、Qwen3-8B、Qwen3Guard-Gen-4B

早期の競争力ある提出

テストの例で単一の Qwen3-14B を学習すると、すぐに次のスコアが得られます。

Model	Public Score	Private Score
Qwen3-14B	0.925	0.921

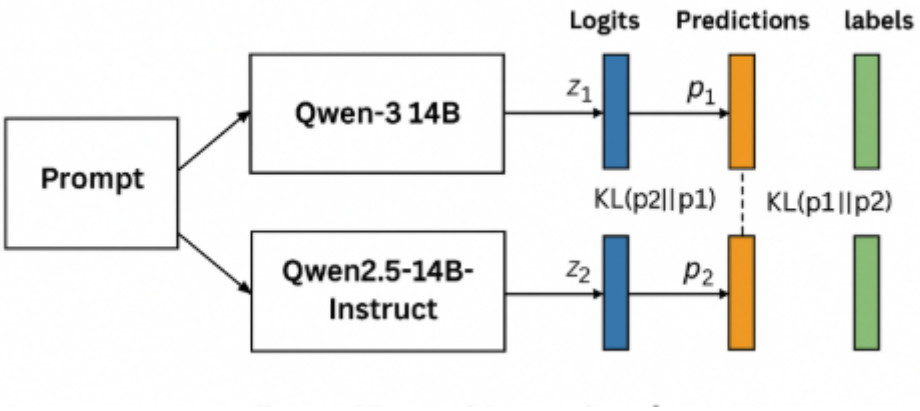
Deep Mutual Learning

論文: Deep Mutual Learning (arXiv:1706.00384)

T4 GPU が2枚しかないので、より大きな教師モデルを使って 14B モデルの性能を改善することはできません。オフラインの蒸留は試せますが、学習セットにある既知の6ルールのうち2つしかカバーできません。全体として最良のスコアを達成するには、知識蒸留がすべてのルールを取り込む必要があります。

古典的な logits ベースの知識蒸留は、このコンペでは課題があります。教師の softmax 出力が極めて鋭く、one-hot ラベルとほぼ同じだからです。温度スケーリングで柔らかくしようとしても効果がありません。

こうした制約の下では、より実用的なアプローチは **Deep Mutual Learning (DML)** です。これはオンライン蒸留の手法で、同程度またはより小さいサイズの複数のピア生徒モデルが、同時に互いから学びます。標準的な分類の cross-entropy に **Kullback-Leibler (KL) divergence loss** を加えるだけで、より大きな教師なしに効果的な知識の転移が可能になります。



DML の利点は、モデルがハードラベルではなく互いのソフトな予測から学べるようにすることで、より大きく強い教師の必要をなくす点です。この過程は教師信号を豊かにし、暗黙の正則化を加え、より滑らかな決定境界を促します。各ピアモデルは、もう一方が共有する知識から実質的に追加の能力を得て、より安定した最適化とより良い汎化につながります。このため DML は、LLM コンペや現代の産業環境で特に価値があります。そこではハードウェアの制約で大きな教師モデルの学習やデプロイができないことが多い一方、効果的な知識の転移と頑健な性能は依然として不可欠だからです。

Qwen3-14B と Qwen2.5-14B の性能に対する DML の効果

ピア生徒: Qwen3-14B、Qwen2.5-14B-Instruct

Training Type	Model	Public Score	Private Score
Independent	Qwen3-14B	0.925	0.921
Independent	Qwen2.5-14B-Instruct	0.923	0.919
DML	Qwen3-14B	**0.929**	**0.925**
DML	Qwen2.5-14B-Instruct	**0.929**	**0.924**

アンサンブル

Ensemble Type	Public Score	Private Score
DML models	**0.932**	**0.9271**
Independently trained models	0.929	0.925

DML は Qwen3-14B と Qwen2.5-14B の両方で一貫して性能を改善し、private スコアとアンサンブルの結果で顕著な向上を示しており、モデルの汎化を高める効果を示しています。

最終提出

DML は各モデルに追加の能力を与えますが、共同学習の過程でモデルの誤りに相関が生じることがあります。強いアンサンブルには多様性が重要なので、締め切りの2日前に、DML のために3モデルのコホートを作ることにしました。このアプローチはアンサンブルの多様性を高め、各「ピア」モデルの単発のミスをさらに緩和するのに役立ちます。

3ピアのアンサンブルの性能

ピア生徒: Qwen3-14B、Qwen3-8B、Qwen3Guard-Gen-4B

Public Score	Private Score
0.93237	0.92781



モデルの実行時間

- **学習:** 3つのモデルを1つの DML プロセスでまとめて学習し、約5時間かかった。
- **推論:** 学習後、各モデルを順に実行してアンサンブル用の予測を生成した。GPU の負荷を均等にするため、系列長の分布が両方でほぼ同じになるようテストデータを半分に分けた。それぞれの半分を長さでソートして効率的にバッチ処理し、2枚の GPU で並列に実行した。推論全体で約5時間かかった。

補足Q&A

Shivam A. — 質問

おめでとうございます！ 素晴らしい解法です。共有ありがとうございます。

LLM の最適な設定（LORA の設定、learning rate など）を見つけるためのアドバイスはありますか？

ducnh279 — 回答

実はこれを投稿に含めたかったのですが、解法の主な要素に焦点を絞ることにしたので省きました。質問ありがとうございます！

以下は、主に Qwen ファミリーのファインチューニングから得た、LoRA の設定についての個人的な経験です。私にとってうまくいったデフォルトにすぎません。

- Qwen ≤ 14B → lr=2e-4、rank=8、alpha=16
- Qwen > 14B → lr=5e-5（またはやや低め）、rank=8、alpha=16

分類や回帰のタスクでは、lm_head を埋め込みや隠れ層の次元に合う新しいヘッドに置き換えることがよくあります。元の lm_head を残すことは vLLM での推論に役立ちますが、ヘッドとバックボーンの間で learning rate を慎重に調整する必要があります。

私の場合は通常ヘッドを丸ごと置き換え、両方に同じ learning rate（lr=2e-4）を使います。異なる LR は必要ありません。このアプローチは、元の lm_head が（語彙の次トークン予測/デコードに使う）大量のパラメータを持つため、学習中のメモリ使用量を減らすのにも役立ちます。詳しくは、ヘッドの設計の選択について @conjuring92 と関連する議論をしました。https://www.kaggle.com/competitions/wsdm-cup-multilingual-chatbot-arena/discussion/567589#3154067

他のモデルファミリーの設定を共有する自信はありませんが、一般には、信頼できる検証セットを得て、ファインチューニングし、LoRA の rank (r)、alpha、learning rate を調整して検証スコアを最適化する最良の組み合わせを見つけることに尽きます。

私の経験では、MoRA や DoRA などのバリアントは、通常の素の LoRA より性能が悪いことが多いです。

Sebastian Raschka による素晴らしいブログもチェックするとよいかもしれません。実践的なファインチューニングのヒントが満載です。

Blog: Practical Tips for Fine-Tuning LLMs。

結局のところ、いろいろ試してスコアを確認することだと思います😄

Pavel Kazlou — 質問

とても興味深い解法に敬意を表します！ そして上位入賞おめでとうございます！

コードを見ると、モデルのサイズが違うにもかかわらず、KL loss はモデル間で対称になっています。このような設定で、KL loss に何らかの重みをかける（大きいモデルへのペナルティを軽くする）のは意味がありますか？

ducnh279 — 回答

素晴らしい質問です!!! 実際に重み付き DML を試しましたが、対称な DML（λ[?][?] = 1）より性能が悪かったので、論文の元のアプローチに従いました。1つの教訓は、事前学習済みのピアモデルはすべて、おおむね釣り合った能力を持つべきだということです（互いに少し良くても悪くてもよい）。この釣り合いが保たれていると、対称な DML の学習はより安定し、すべてのピアが一緒に改善します。

Raviksh Singh Dikola — 質問

qwen 14b のような llm モデルのヘッドを置き換えたとのことですね。

そのカスタマイズしたモデルは、vllm の推論フレームワークと互換性がありますか？

ducnh279 — 回答

質問ありがとうございます！ 私は vllm を使いませんでした。今の私の設定では、vllm と互換性がないかもしれません。でも Unsloth にはこの件についての工夫があります！ この notebook を見てみるとよいでしょう。vLLM での推論と互換性を保ったまま分類ヘッドを置き換える方法が示されています。@danielhanchen に大きな感謝を。

Colab: https://colab.research.google.com/github/timothelaborie/text_classification_scripts/blob/main/unsloth_classification.ipynb#scrollTo=FNLDlj923Fx9

BokingChen — 質問

共有ありがとうございます！ 非常に効率的で革新的な解法です！ 解法のコードを見たのですが、学習には positive と negative の例だけを使っていますか？ また、コード全体の学習と推論の合計時間はどれくらいですか？ 限られた時間の中で複数の LLM モデルを使えたなんて信じられません！

ducnh279 — 回答

> 学習には positive と negative の例だけを使っていますか

はい、学習にはすべての pos と neg の例を使っています！

> また、コード全体の学習と推論の合計時間はどれくらいですか？

3つのモデルすべてで、学習 + 推論に約9〜10時間かかりました。

> 限られた時間の中で複数の LLM モデルを使えたなんて信じられません！

学習には Distributed Data Parallel (DDP) を使い、推論は2枚の GPU で並列に実行して、どの GPU も遊ばないようにしました。55k 件のサンプルをシミュレートし、推論パイプラインをローカルで最適化しました。

Nikita Babych — 質問

ソロと初の金メダル、おめでとうございます！

DML を使うのは興味深いアプローチですが、ピア生徒が Qwen3-14B と Qwen2.5-14B の場合の Qwen3-14B（DML）が、別々に学習した Qwen3-14B と Qwen2.5-14B のアンサンブルと比べてどれくらい良いのか気になります。

私の実験によれば、同程度の結果になるはずです。もしそうなら、主に時間の節約の問題になります。どちらの場合も2つのモデルを学習しますが（DML は並列化されていないようです）、DML では Qwen3-14B の推論を1回実行するだけで済みますよね？

p.s. 相互学習と高い相関にもかかわらず、それらのアンサンブルは別々に学習した場合より高い 0.932 というスコアを出していますね。

Chew Kok Wah — 質問

使うベースモデルの量子化の種類（BnB、GPTQ、AWQ など）は、学習の結果に影響しますか？

あなたのコードはその場で BnB に量子化していますが、それは学習パイプラインが他の形式の事前量子化モデルを使えないから選んだのですか、それとも BnB が最良の結果を出すと分かったからですか？

ducnh279 — 回答

質問ありがとう @nikitababich！ まず、Noisy Student Training を使ったあなたの解法に触発されたことをお伝えしたいです。このコンペでも実際に試しましたが、残念ながらあまりうまくいきませんでした。それでも、2017〜2020年ごろの古き良き手法や論文の中には、今でも価値があり、本当の強みになるものがあると信じています。モデルを改善するためにさまざまな手法を探っていて、DML はその1つです。

> ピア生徒が Qwen3-14B と Qwen2.5-14B の場合の Qwen3-14B（DML）が、別々に学習した Qwen3-14B と Qwen2.5-14B のアンサンブルと比べてどれくらい良いのか。

別々に学習したモデルと DML で学習したモデルの比較結果は次のとおりです。

Model	Public Score	Private Score	Notes
Qwen3-14B (trained separately)	0.925	0.921	—
Qwen2.5-14B (trained separately)	N/A	N/A	単独では提出していない
Ensemble: Qwen3-14B + Qwen2.5-14B	0.929	0.925	別々に学習したモデルのアンサンブル
Ensemble: Qwen3-14B + Qwen2.5-14B	0.932	0.927	DML モデルのアンサンブル

-> つまり、DML を使うと、同じモデルを別々に学習してアンサンブルした場合と比べ、Public で約 +0.003、Private で約 +0.002 になります。

> どちらの場合も2つのモデルを学習します（DML は並列化されていないようです）

はい、DDP を DML で動かせなかったので、DML は並列化されていません。DML の学習中は、モデルのパラメータを GPU 間で分割しませんでした（device_map='balanced' や 'auto' は使っていない）。代わりに、各モデルのパラメータ全体が1枚の GPU に収まるようにしました。PyTorch の CUDA のセマンティクスがデバイスの配置を自動で効率的に扱うので、これはデータ転送と通信のオーバーヘッドを減らすのに役立ちます。

> DML では Qwen3-14B の推論を1回実行するだけで済みますよね？

はい、1回です！ 2つ/3つのモデルのコホートを学習しました！ 各 epoch に約1時間30分かかるので、学習は合計で約4時間30分です。推論では、コホート内の各ピアモデルを順に、2枚の GPU で並列に実行し、それらの出力をアンサンブルします。これに約5時間かかります。

ducnh279 — 回答

LoRA + bnb 量子化モデルでの学習と、LoRA + gptq 量子化モデルでの学習の間に、性能の大きな違いはありません。bnb を選んだのは、LLM のファインチューニングを始めたころから使っていて、それを使い続けているというだけの理由です。

Aic — 質問

ソロ金メダル獲得おめでとうございます！

解法を読んで多くを学びました。

あなたはこう書いていました:

強いアンサンブルには多様性が重要なので、締め切りの2日前に、DML のために3モデルのコホートを作ることにしました。

質問したいのですが、多様性を高めるために3つ目のモデルを導入したとき、モデル間でペアごとの相互学習をしたのですか、それとも DML 中に3つのモデルすべてが同時に互いから学び、その後でアンサンブルしたのですか？

また、この2つのアプローチの間に性能面で大きな違いはありますか？ 2つ目の方法（3つのモデルすべてが一緒に学ぶ）の方が、より良い結果を出す可能性がありますか？

ducnh279 — 回答

> 多様性を高めるために3つ目のモデルを導入したとき、モデル間でペアごとの相互学習をしたのですか、それとも DML 中に3つのモデルすべてが同時に互いから学び、その後でアンサンブルしたのですか？

DML 中に3つのモデルが同時に互いから学び、その後でアンサンブルしています。

2つより多いモデルでの DML に時間や興味があれば、DML の論文、特にセクション 2.3 Extension to Larger Student Cohorts を読むとよいでしょう。

> また、この2つのアプローチの間に性能面で大きな違いはありますか？ 2つ目の方法（3つのモデルすべてが一緒に学ぶ）の方が、より良い結果を出す可能性がありますか？

DML のコホート内のモデル数が多いほど、アンサンブルの性能は良くなります。

Ankith Savio — 質問

解法とヒントをありがとうございます @ducnh279。CV 戦略も共有していただけますか？ 以前の投稿を覚えていて、実験でどの設定が段階的な改善をもたらしたのか知れるとうれしいです。

ducnh279 — 回答

LB の方が信頼できることが分かったので、このコンペでは LB をより信じることにしました。とはいえ、CV 戦略も使いました。

- すべての positive、negative、元の学習サンプル（body）を結合した
- rule_comment の両方に基づいて重複を除去した

```
df['rule_comment] = df['rule'] + df['comment']
df = df.drop_duplicates(['rule_comment'])
```

- rule_label で層化 k-fold 分割を行った

```
df['rule_label'] = df['rule'] + df['label'].astype(str)
```

検証セット全体で推論した後、2つのルールそれぞれで別々にスコアを計算し、その平均を取りました。これはコンペで使われている平均 AUC の指標と同じやり方です。この CV の設定は、私の DML アプローチを効果的に検証し、LB にもよく転移しました。

ducnh279 — 回答

@nikitababich こんにちは Nikita、新しく編集されたコメントを今見ました。

> p.s. 相互学習と高い相関にもかかわらず、それらのアンサンブルは別々に学習した場合より高い 0.932 というスコアを出していますね。

おっしゃるとおり、DML はモデルの誤りの相関を高める傾向があります。しかし、だからといってアンサンブルが役に立たないわけではありません。DML が適切に行われれば、同じ DML コホート内のモデルのアンサンブルは、通常、独立に学習したモデルのアンサンブルを上回ります。

これは、Qwen2.5 と Qwen3-14B の間で DML を使った、私の古い開発用 notebook のコピーです。fork して提出すると、Public で約 0.932x、Private で 0.927x〜0.928 になるはずです。報告したスコアと比べておかしなスコアになったら教えてください。

Notebook: https://www.kaggle.com/code/ducnh279/dml-qwen3-14b-qwen2-5-14b