jigsaw-agile-community-rules

9位 Solution: すべてを組み合わせる

Rank	9
Team	llllleeeo + mango
Author	llllleeeo
Topic ID	613185
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/jigsaw-agile-community-rules/discussion/613185
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このような素晴らしい LLM コンペを開催してくださった主催者の皆さんに感謝します。次に、この解法は主に5つの優れた public notebook の上に構築されています。アイデアを共有してくださった著者の皆さんに深く感謝します。リンクは末尾に記載しています。

概要

解法は3つの主要なコンポーネントで構成されています: 生成モデル、分類モデル、そして Faiss ベースの検索です。

Part 1: 生成モデル

このコンポーネントは、@wasupandceacar が共有した生成型の test-time training のアプローチに基づいています。この public notebook に対して、次の改善を行いました。

- Llama 3.2 3B を Qwen3-4B-Instruct-2507 に置き換え、テストデータの 5% だけを使って、public LB スコアを 0.916 から 0.919 に改善
- Unsloth で test-time training を最適化し、提出時間を 7.5 時間（デュアル GPU）から 2.5 時間（シングル GPU）に短縮し、public LB スコアを 0.919 から 0.920 に改善
- テストセットの例で学習する際に純粋なノイズを持ち込んでいた subreddit の情報を取り除き、提出時間を 2.5 時間から 2.1 時間に短縮し、public LB スコアを 0.920 から 0.922 に改善

別の学習データの探索:

使うテストデータを調整しようとしたとき、生成モデルがデータ量に極めて敏感であることが分かりました。これはおそらく、繰り返しの例やノイズの多いデータのためです。public LB への過学習を避けるため、より安定したアプローチを探りました（private LB が公開された後、これは最適ではなかったと分かりました）。

元の学習データの構成では、すべての例が body テキストとして学習されることを保証できなかったので、重複除去したすべての例を使い、各例に positive/negative のサンプルをランダムに組み合わせて多様性を高めました。

これらの新しく学習したモデルを元のモデルとアンサンブルした結果:

Model	Runtime (hours)	LB	PB
Qwen3-4B-Instruct-2507	3.0	0.924	0.918
Llama 3.2 3B	2.5	0.923	0.916
Phi-3.5-Mini-Instruct	3.5	0.918	0.913

***これら3つのアンサンブルモデルをアンサンブルすると、実行時間9時間で LB 0.930（PB 0.924）を達成しました。**

Part 2: DeBERTa ベースの分類モデル

このコンポーネントは、Team U DONNO WHO と DLH が共有した DeBERTa の分類アプローチの上に構築しています。いくつかの最適化を実装しました。

モデルのアーキテクチャと学習:

- より速く収束させるため、分類ヘッドに2倍の learning rate を適用
- より良い表現のため、CLS トークンのプーリングの代わりに mean pooling を実装
- 層ごとに異なる learning rate（LLDR）を使用

モデルの性能:

Model	Runtime (hours)	LB	PB
DeBERTa-v3-base	0.5	0.909	0.902
E5-base	0.5	0.910	0.904
MPNet-base	0.5	0.906	0.900

***これら3つのモデルの最終アンサンブルは、実行時間1.5時間で LB 0.921（PB 0.913）を達成しました。**

Part 3: Triplet Loss と検索を使った BGE モデル

このコンポーネントは、Aurora Rabbit と Ertuğrul Demir が共有した、BGE モデルを triplet loss で学習するアプローチに基づいています。

私たちの改善:

推論の段階で、単一重心と UMAP クラスタリングの手法をアンサンブルした

***最終モデルは、実行時間1.5時間で LB 0.909（PB 0.904）を達成しました。**

最終提出

最終評価には、2つの異なるアンサンブル戦略を提出しました。

各 Part について、まずモデルを内部でアンサンブルし、続いて各 Part 内で順位正規化を行い、その後加重平均で組み合わせました。

最終的なアンサンブルの重みは、LB の性能に基づいて **0.7 × Part 1 + 0.25 × Part 2 + 0.05 × Part 3** としました。

提出 1:

- デュアル GPU（T4 x 2）を使って4つの生成モデルを並列に学習: Qwen3-4B-Instruct-2507、Llama 3.2 3B、Phi-3.5-Mini-Instruct、Qwen2.5-7B-Instruct
- 各モデルは異なるランダムシードを使用
- これらの生成モデルを Part 2 と Part 3 のモデルとアンサンブル
- 実行時間: 9時間
- Public LB: 0.933 | Private LB: 0.927

提出 2:

- 3つの生成モデルを使用: Qwen3-4B-Instruct-2507、Llama 3.2 3B、Phi-3.5-Mini-Instruct
- 各モデルを2つの異なる学習データ構成で学習し、セルフアンサンブル（合計6モデル）
- これらの生成モデルを Part 2 と Part 3 のモデルとアンサンブル
- 各モデルは異なるランダムシードを使用
- 実行時間: 11時間
- Public LB: 0.933 | Private LB: 0.926

うまくいかなかったこと

- 2段階の学習
- positive/negative の例の意味的なマッチング
- ルール専用のプロンプト
- Label smoothing
- logit ベースのアンサンブル
- 層の凍結
- CLS、mean pooling、max pooling の SENet による融合
- ルールベースのアンサンブルの重み付け

参考文献

https://www.kaggle.com/code/wasupandceacar/jigsaw-pseudo-training-llama-3-2-3b-instruct

https://www.kaggle.com/code/nghiahoangtrung/jigsaw-speed-run-10-min-triplet-and-faiss

https://www.kaggle.com/code/nahidhossainredom/deberta-v3-base-3-epochs-lb-0-906

https://www.kaggle.com/code/daylighth/acrc-deberta-small-2epochs-1hr

https://www.kaggle.com/code/datafan07/jigsaw-speed-run-10-min-triplet-and-faiss

補足Q&A

Ankith Savio — 質問

共有ありがとうございます。変更を加える前の分類モデルの結果はありますか？ あるいは、あなたの見立てでは、それらの性能はどれくらい改善しましたか？

mango — 回答

ありがとうございます！ 以前の分類モデルと比べて、改善は約 0.003 です。主にまず1つのモデル（DeBERTa）で検証し、効果があると分かった時点で、他のモデルにそのまま適用しました。