map-charting-student-math-misunderstandings

MAP2025 Private&Public 2位

Rank	2
Team	looking for remote job
Author	HZM
Topic ID	612145
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612145
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

ホストの皆さまに心より感謝します。このコンペに参加できてとても嬉しく思います。チームメイトのBaiphは非常に熱心に取り組んでくれ、最終結果への貢献は2人とも同じです。2人はそれぞれ異なる学習パイプラインを持っており、そのおかげでPublicとPrivateの両方のリーダーボードで2位になれました。

追伸: NLPまたはLLM分野のリモートの仕事を探しています。UTC +8のタイムゾーンが希望です。可能性があればメールでご連絡ください。

解法の概要

このコンペのタスクは、生徒の説明からmisunderstanding（誤解）を予測することです。分類問題としてはとても易しいのですが、このコンペの指標はMAP@3で、通常はランキング問題で使われるものです。そのため、ラベルが曖昧なことがあり、生徒の説明が複数のtargetに当てはまりうるのだと考えました。

以上の分析から、必要なのは、ラベルのリークを避けつつ、OOFに基づいてノイズを除去するか、生徒の説明にsoft labelを与えることです。

データについては、30以上のラベルはデータが限られていたので、多くの商用LLMを使って外部データを生成しました。

モデル選択については、LLMをbackboneとして使い、qwne3、qwen2.5、mistral、phi-4を試しました。

学習戦略については、2人とも分類問題をmulti-choiceの生成問題に変換しました。そうすることでのみ、vllmを使って推論を時間内に終えられるからです。

HZMのパート

ここでは、Privateで最良の単体モデルであるqwen3 -14bを紹介します。こちらの方がずっと理解しやすいと思います。 学習パイプラインは4つのステップに分けられます。

Step1: 外部データの生成（私とBaiphの両方が使用）

各問題について、珍しい候補を持つ生徒の出力を1つ生成します。 ラベルを使ったcontrastive learningを取り入れます。

```
For example:
 I want to generate student
```

gpt-4、gpt-5、claude-sonnet、gemini、seed、doubaoを使い、80Kのデータを生成しました。

Step2: 外部データにラベルを付けるLLMの学習

train.csv全体で4つのLLMモデルを学習し、外部データにラベルを付けました（これをstep4の学習でsoft labelとして使用）。モデルはphi_4_reasoning_14b、qwen3_32b、mistral_12b、qwen2_5_72bです。

```
The following  training prompt:
```

Step3: soft labelを生成するための5 foldでのLLM学習

4つのLLMモデルを5 foldで学習し、oof.csvを平均しました（これをstep4の学習でsoft labelとして使用）。

Step4: qwen3-14bのmulti-loss設計

SFTTrainerを改変し、生成loss（hard label）と分類loss（soft label）を組み合わせました。 target_token_id は、各選択肢が語彙内のtoken idに変換されることを意味します。

```
():
   ():

        target_token_id = .model.config.target_token_id
        target_token_id = torch.tensor(target_token_id, device=model.device)

        labels = inputs[]
        mask = torch.isin(labels, target_token_id)
        labels[~mask] = -
        inputs[] = labels
        _, outputs = ().compute_loss(model, inputs, return_outputs=,
num_items_in_batch=num_items_in_batch)
        logits = outputs.logits
        loss = outputs.loss

        shift_logits = logits[..., :-, :].contiguous()
        shift_labels = labels[..., :].contiguous()

        logits_target = []
         i  ((shift_labels)):
            lbl = shift_labels[i].cpu().numpy()
            target_idx = np.where(lbl != -)[][-]
            logits_target.append(shift_logits[i][target_idx][target_token_id])


        logits_target = torch.stack(logits_target, dim=)

        labels_target = inputs[].to(outputs.logits.device)
        soft_loss = F.cross_entropy(logits_target, labels_target)


        loss = loss +  soft_loss
         (loss, outputs)  return_outputs  loss
```

以上のステップの後、fold-0のCVは **0.955**、publicは **0.950**、privateは **0.946** を達成できました。

Baiphのパート

1、Misunderstandingsの拡張

65カテゴリを37カテゴリに変換し、DeepSeekを使って短いmisunderstandingを拡張・説明しました。

```
mis2reason = {
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :,
    :
  }
```

2、Prompt

```
<|im_start|>user
You are now tasked  analyzing math problems  classifying student responses. Given a math problem, the
students correct,  the studentt fall into  of the above categories

Please analyze the given   provide your classification.

What fraction of the shape   shaded? Give your answer  its simplest form. [Image: A triangle split
into  equal smaller triangles.  of them are shaded.]
```

```
(A) \( \frac{}{} \) (B) \( \frac{}{} \) (C) \( \frac{}{} \) (D) \( \frac{}{} \)

A. \( \frac{}{} \)

I think that /  the answer,  it
```

3、学習戦略

LR=2e-4，BS=4*2 Epoch=2

追加データと蒸留を組み合わせるとLBとPBを改善できますが、fusion（アンサンブル）後には効果がありません。

model	data	LB	PB	use final	infere time
Qwen25-14B-AWQ	total data	0.948	0.946	submission 1（best）	20min
Qwen3-14B-AWQ	fold1	0.948	0.943	submission 1（best）	20min
Qwen25-32B-AWQ	fold1	0.948	0.944	submission 1（best）	40min
Qwen25-32B-AWQ	total data	0.949	0.945	submission 1（best）	40min
QWQ-32B-AWQ	ext data 80k total data training distal	0.949	0.948	submission 2	40min
Qwen25-32B-AWQ	ext data 80k fold1 distal	0.949	0.947	submission 2	40min
Qwen3-14B-AWQ	ext data 80k fold1 distal	0.950	0.945	submission 2	20min

4、アンサンブル

- 37クラス分類モデル4つ
- 65クラス分類モデル4つ
- 等しい重みでの平均によるfusion

補足Q&A

Levin — 質問・補足

素晴らしいwrite-upです。データ生成パイプラインと全体のアーキテクチャが見事に作り込まれています。
「vLLMでの推論を時間内に終えるため、分類をmulti-choiceの生成に変換した」という点について、分類のまま扱える実用的な代替手段を見つけました。LoRAをmerge → baseとclassifier headを分割 → baseだけをGPTQ-4bitに量子化 → vLLMをembedモード（LAST pooling、正規化なし）で実行 → embeddingを外部のFP16線形headに入力してlogitを得る、という方法です。生成に切り替えることなく、高速で安定した推論ができました。

Bilzard — 質問

2位入賞おめでとうございます。

@leehann contrastiveな例の活用方法に興味があります。 次の説明にある `False_Misconception:Additive_same_math_problem`、`False_Misconception:Additive_different_math_problem` などは何を意味しますか？ これらは、次の条件でサンプリングされた生徒の説明のin-context例でしょうか？

1. misconception=`False_Misconception:Additive`, QuestionId={different}
2. misconception=`False_Misconception:Additive`, QuestionId={same}
3. misconception=`True_Misconception:Additive`, QuestionId={different}
4. misconception=`True_Misconception:Additive`, QuestionId={same}

また、プロンプトの例を共有していただけますか？

```
For example:
 I want to  student's explation which is True_Misconception:Additive(  as hard label in step4
training),
I will
False_Misconception:Additive_same_math_problem  False_Misconception:Additive_different_math_problem
+
True_Misconception:Additive_same_math_problem  True_Misconception:Additive_different_math_problem
put the contrastive examples  the ChatGPT  Claude  better data
```

HZM — 回答

素晴らしい取り組みですね。私も以前試しましたが、うまくいきませんでした。コードを共有していただけると嬉しいです。

HZM — 回答

おっしゃるとおりです。生成データがより信頼できるものになるよう、problem idを使って例をサンプリングしました。 次のプロンプトを確認してください。

```
instruct_template =
```

Bilzard — 補足

すみません、分かりました。上に示した4つのカテゴリそれぞれから例が含まれるよう、均等にサンプリングされているのだと思います。（各例にはQuestionTextが示されているので、LLMは各例がどの問題のものかを区別できます。）