map-charting-student-math-misunderstandings

3位（Public 1位）Solution: monsaraida & Masaya

Rank	3
Team	monsaraida & Masaya
Author	monsaraida
Topic ID	612059
Version	Japanese Translation

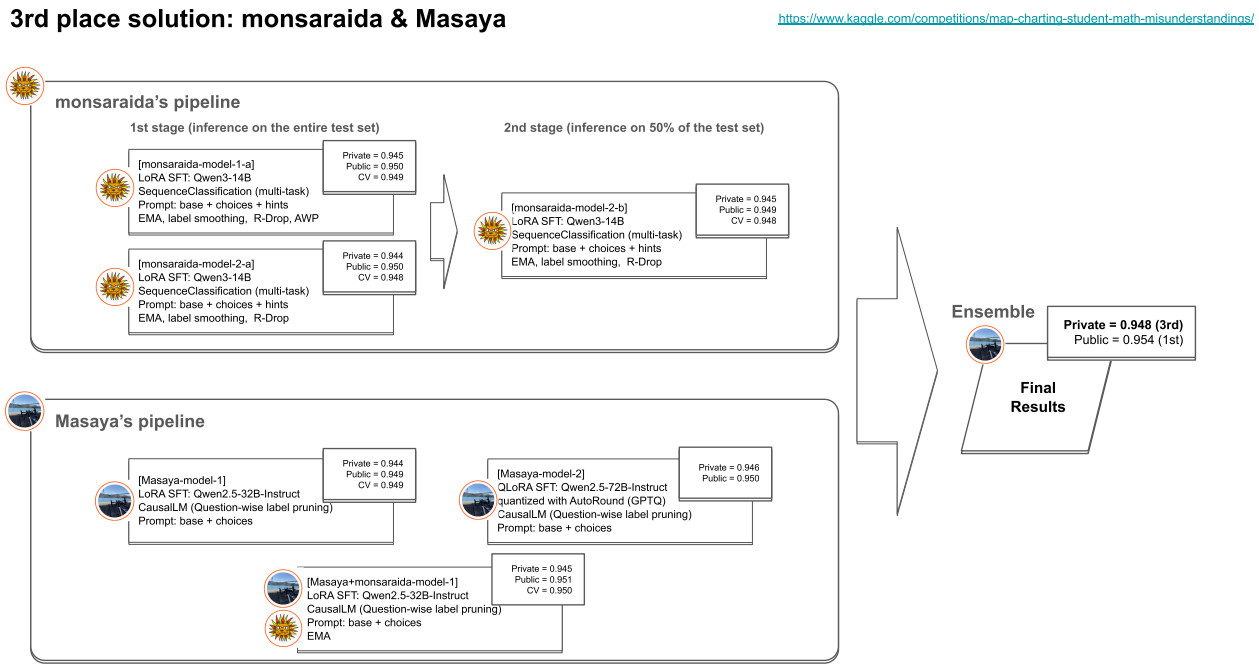
Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612059
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、議論、公開notebook、フィードバックを提供してくださった主催者とKaggleコミュニティに心より感謝します。私たちのチーム monsaraida & Masaya は、Private 3位（Public 1位）でした。皆さまの支えに感謝しています。

概要

私たちの解法の概要を示します。以降の節では、monsaraidaのパートとMasayaのパートを順に説明します。



monsaraidaのパート

Prompting

Choices

公開notebookで使われていた {Question / Answer / Correct? / Student Explanation} という構造の {Answer} を、{Choices / Selected} に変更しました。生徒が選んだAnswerだけでなく他の選択肢も示すことで、LLMが潜在的なmisunderstandingを見つけやすくすることが狙いです。この変更の効果は大きく、CV/Publicスコアが +0.001 以上改善しました。このアイデアはMasayaのモデルの精度も大きく改善したので、このコンペの重要なトリックの1つかもしれません。

Hints

このコンペでは、各問題のmisunderstandingの種類はあらかじめ決まっていました。そこでヒントとして、各問題のmisunderstandingの一覧を、出現確率の順にプロンプトへ追加しました。この変更でCVスコアが +0.0003 改善しました。

プロンプトの例

```
Question: What fraction  the shape   shaded? Give your answer  its simplest form.  A triangle split
into  equal smaller triangles.   them are shaded.
Choices: (A)    (B)    (C)    (D)
Selected:
Correct? Yes
Student Explanation:  goes into everything   goes into nine
Common mistakes  this question: Incomplete, WNB
```

学習

Base model

次の候補を試し、最も性能の良かった Qwen/Qwen3-14B をbase modelとして採用しました: google/gemma-2-9b-it, Qwen/Qwen2.5-14B-Instruct, Qwen/Qwen2.5-Math-7B-Instruct, deepseek-ai/deepseek-math-7b-instruct, Qwen/Qwen2.5-Coder-14B, deepseek-ai/DeepSeek-R1-Distill-Qwen-14B, mistralai/Mistral-Nemo-Instruct-2407, mistralai/Mixtral-8x7B-Instruct-v0.1, mistralai/Mathstral-7B-v0.1, AmanPriyanshu/gpt-oss-10.8b-specialized-instruction_following-pruned-moe-only-15-experts

multi-task learningを用いたLoRA SFT

LoRAでsupervised fine-tuningを行い、分類にはAutoModelForSequenceClassificationを使いました。分類では、メインタスク「Category: Misconception（65クラス）」と、次の補助タスクによるmulti-task learningを行いました。• True / False（2クラス）• Correct / Misconception / Neither（3クラス）• Misconception（36クラス）multi-task learningは精度のわずかな改善に寄与しました。

汎化性能の改善

このコンペのラベルはノイズが大きいため、汎化性能を改善する手段としてR-Drop（Regularized Dropout）を導入しました。R-Dropの効果は大きく、CVが +0.001 以上改善しました。R-Dropに加えてAWP（Adversarial Weight Perturbation）を入れると、さらにわずかにCVが改善しました。さらに、EMA（Exponential Moving Average）の導入でCVが安定し、精度も改善しました。

推論

多段階推論

9時間の推論時間制限内で複数のモデルをアンサンブルするため、多段階推論を実装しました。最初の段階では、テストセット全体で推論を行い、結果をアンサンブルします。次の段階では、結果を確信度の昇順に並べ、確信度が最も低い50%についてのみ推論をやり直しました。（より複雑な段階分けも試しましたが、最良のPrivateスコアにはなりませんでした。）

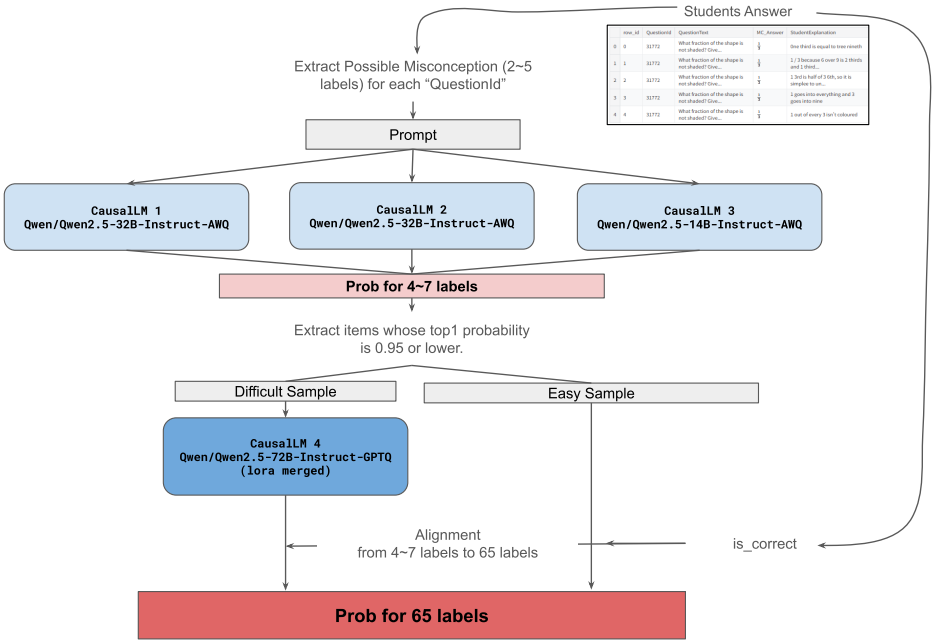
推論を速くするためのTips

一部の公開notebookでは `torch_dtype=torch.bfloat16` を使っていましたが、KaggleのT4実行環境ではbfloat16が使えず、変換のオーバーヘッドが生じます。bfloat16をfloat16に変えると、推論が2倍速くなりました。さらに、このコンペでは短いプロンプトが多いため、 `padding="max_length"` の代わりに `padding=False` にすると、さらに2倍高速化できました。合わせて4倍の高速化となり、アンサンブルにより多くのモデルを使えるようになって、精度の向上に寄与しました。

Masayaのパート

概要

私のパイプラインの概要は次のとおりです。



CausalLMを使う利点の1つは、ラベルが可変長であっても高い精度を達成できることです。 このコンペでは、各QuestionIdに現れるラベルがあらかじめ決まっていたため、37個や65個のラベル全体で推論する代わりに、QuestionIdごとにラベル集合を限定すれば精度が上がると仮説を立てました。 そのため、主にCausalLMを使って実験を行いました。

最良の単体モデルはQwen2.5-72B-Instruct-GPTQでしたが、テストセットの推論に約3時間かかりました。 そこで、まず14Bや32Bといった比較的小さなモデルで推論し、top1確率が低いサンプルだけを72Bモデルで推論し直すシステムを設計しました。 この方法で、72Bモデルの推論時間を約1時間に短縮しました。

注: このパイプラインは私たちのPublic LB最良の提出で使ったもので、Private LBのスコアは上述のパイプラインよりわずかに低くなりました。

前処理

このコンペでは、学習データとテストデータの両方でQuestionIdの数が限られていました（15個のみ）。さらに、各QuestionIdのMisconceptionも2〜5個に限られていました。そこで、CausalLMが予測するトークンを絞り込むため、各QuestionIdに現れるMisconception、Correct、Incorrectの選択肢だけを含むようにプロンプトを設計しました。こちらで議論されているように、`True_` / `False_` ラベルはルールベースのロジックで後から付けられるので、予測トークンの数をさらに減らすためにこれも除外しました。この方法で精度が大きく改善し、推論時間も短縮されました。（LB/CV +0.002~0.003、約3倍高速化） 上で述べたように、他の選択肢をプロンプトに追加することも精度の向上に役立ちました。（LB/CV +0.003~0.004）

プロンプトの例は次のとおりです。

```
You are Qwen, created  Alibaba Cloud. You are a helpful assistant.

You are a Mathematics teacher.
Your task   evaluate whether the student's explanation contains a misconception,    does,  identify
the specific type  misconception.

Question Text: Calculate
Choices: ()    ()    ()    ()

Student Answer:
Is Student Answer Correct: No

Student Explanation: Because you  half

You must choose the your answer  the following options:

A. Correct:NA
B. Neither:NA
C. Misconception:FlipChange
D. Misconception:Mult
E. Misconception:SwapDividend



Your Answer:
```

学習モデル

主にCausalLMとしてQwen2.5をチューニングしました。 最良の単体モデルはEMAで学習したQwen2.5-72B-Instructでしたが、public leaderboardでの性能が類似モデルより低かったため、最終提出には使わないことにしました。 finetuningにはLoRAを使い、設定は `r=16,lora_alpha=32,lora_dropout=0.05,target_modules=( "q_proj", "k_proj", "v_proj", "o_proj", "gate_proj", "up_proj", "down_proj")` です。 主な学習設定は次のとおりです。

- epoch=2
- learning_rate=1e-4
- per_device_batch_size=4
- gradient_accumulation_steps=4

Tips: 学習率を高くするとスコアが改善しましたが、高すぎると学習中に崩壊しました。

model	task	cv	lb*	pd	use final	inferrence time	Note (other info)
Qwen/Qwen2.5-14B-Instruct-AWQ	CausalLM	0.9469	0.943	0.942	✅	30 min	
Qwen/Qwen2.5-32B-Instruct-AWQ	CausalLM	0.9498	0.949	0.944	✅	60 min	
Qwen/Qwen2.5-72B-Instruct-GPTQ	CausalLM	-	0.950	0.946	✅	190 min	
		-				190 min	

model	task	cv	lb*	pd	use final	inferrence time	Note (other info)
Qwen/Qwen2.5-72B-Instruct-GPTQ	CausalLM		0.950	0.948			学習にEMAを使用（単体最良）
Qwen/Qwen2.5-32B-Instruct-AWQ	CausalLM	0.9474	0.945	0.941		60 min	プロンプトに選択肢なし
Qwen/Qwen2.5-72B-Instruct-GPTQ	CausalLM	-	0.946	0.940		190 min	プロンプトに選択肢なし

(*) CVはfold 0から計算しています（GPU不足のため）。LBは全データで学習して提出したモデルのものです。

推論

推論時のプロンプト設計は前述と同じです。 この段階では、各トークンの意味がQuestionIdによって異なるため、monsaraidaの確率と揃えるために出力を65ラベルに変換し直します。 `True_` / `False_` ラベルは `is_correct` の値から推定できます。 72BモデルについてはLoRAのまま推論できないため、LoRAのmergeと量子化（GPTQ）を行い、CPUにoffloadしながら実行しました。（参考はこちら）

うまくいかなかったこと

- Llama 3.3-70Bやgemma2を含む、Qwen2.5以外のモデル。
- pair-wiseの判定にCausal LMを使うこと。推論に時間がかかりすぎます。
- 各ラベルに対して選択肢のトークンを固定すること。例えば、

```
A.
B.
F.
D.
R.
```

- 他のコンペのデータでの事前学習。Eedi competitionで事前学習したモデルを使いましたが、うまくいきませんでした。
- こちらで議論されているラベルノイズを考慮すること。`QuestionId=31778` について、確信度の高いCorrect・Neitherのサンプルに対し、`True_` / `False_` を反転した版を上位2つの予測に含めました。しかし、CVはわずかに改善したものの、最終結果では精度がわずかに低下しました。

参考

- vllm
- auto-round
- Qwen
- Eedi competition
- Qwen2.5-72B & Llama 3.3-70B on 2xT4(questionable performance)
- Does Test Data Have Questions Different Than Train Data?

補足Q&A

Zhuohan Chi — 質問

おめでとうございます。とても参考になります。学習と推論にどのような計算環境を使ったのか知りたいです。A100ですか、それとも別のものですか？

monsaraida — 回答

コメントありがとうございます！ 学習には、A100（40GB）、RTX 6000 Ada（48GB）、RTX 4080（16GB）を含むいくつかのGPUを使いました。 推論には、Kaggle Notebooksで使える2台のT4（16GB）GPUを使いました。

Dimpi Mittal — 質問

おめでとうございます！多段階推論とプロンプトエンジニアリングの詳しい説明はとても参考になります。精度と推論時間のバランスの取り方が見事です。確信度の低いサンプルに72Bモデルを使う際、どのサンプルを再推論するかの閾値はどのように決めたのでしょうか？これが分かると、今後のLLMコンペで同様の戦略を使ううえでとても役立ちます。

Masaya — 回答

ありがとうございます！説明が役に立ったなら嬉しいです。

当然ながら、より精度の高い72Bモデルで推論するサンプルを増やせば、全体のスコアは改善します。しかし、推論時間とのトレードオフがあります。 このコンペでは、validationスコアと、全データで学習した後のleaderboard（LB）スコアとの相関が高かったです。 そのため、validationデータを使って、希望する推論時間に合わせて確信度の閾値を調整できました。（これは実際に推論を走らせて経験的に測ることもできます。）

72Bモデルの推論時間を約1h~1.5hに収めるため、閾値を0.95に設定しました。 より高い値（例: 0.98）も試しましたが、推論時間の大幅な増加に比べてleaderboardでの精度改善がわずかだったので、0.95のままにしました。