map-charting-student-math-misunderstandings

4位 Solution（単体モデル pb 0.948 lb 0.951）

Rank	4
Team	THLUO
Author	THLUO
Topic ID	612178
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612178
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このような素晴らしいコンペを開催してくださった主催者とKaggleに心より感謝いたします。私自身、このコンペを通じて非常に多くのことを学びました。以下では、私の解法と、スコア改善の過程全体を共有します。

1. データの前処理

- まず、StratifiedKFoldでデータを5 foldに分割しました。そして、スコアが高すぎるfoldや低すぎるfoldを使うのを避けるため、交差検証スコアが平均よりやや低いfoldをvalidationセットに選びました。
- こちらで議論されているように、学習データには誤ったcategoryラベルが12個あります。具体的には、QuestionId 31778の12行で、正解が6であるにもかかわらず、MC_Answerが9でCategoryがTrueになっています。そこで、このスレッドで説明されているのと同じ処理方法を、学習と推論の両方の段階で適用しました。

2. モデリング

- 学習セットとオンラインのテストセットは同じ15問を共有しているので、選んだ答えが正しいかどうかの判定には予測が必要ありません。したがって、タスクは説明の種類（CategoryのCorrect、Misconception、Neither）の予測だけに単純化でき、予測ラベルの数は65から37に減ります。
- 提供されたtrain.csvから、各問題には4〜6個の候補targetがあることが統計的に分かるので、target空間はさらに小さくなります。

```
train['candidate_targets'] = train['QuestionId'].map(train.groupby("QuestionId")
['target'].apply(set).apply(list))
train['neg_candidate_targets'] = train.apply(lambda x : [y for y in x["candidate_targets"] if
x["target"] != y], axis=1)
```

オンラインのテストセットでは、各問題に新しいmisconceptionラベルが現れるなど、異なる状況がありうるかもしれません。しかし、"Correct"と"Neither"のラベルが付いたサンプルが大多数を占めていることを確認しました。そのため、モデルには主に、現在手元にあるサンプルで観察されるパターンに集中させるつもりです。

- 私のrankerモデルは、「Eedi - Mining Misconceptions in Mathematics」の1位解法で議論されているように、context windowで一度に1つのラベルを見るpointwiseの手法で学習しました。各ステップで1つのrow_idのサンプルだけを処理するように学習を設定しました。各row_idには4〜6個の異なる候補ラベルがあり、それらをすべて1つのbatchに含める必要があるので、実際のbatch sizeは4〜6です。

3. Backbone

試したモデルは主にQwenシリーズです。各モデルの実験結果を、複数foldのデータからまとめると次のとおりです。

> Qwen3-32B >= Qwen3-Reranker-8B >= QWQ-32B >= Qwen3-14B >= Qwen2.5-Math-7B-Instruct > Qwen2.5-14B-Instruct > Qwen3-8B > Qwen2.5-7B-Instruct

Qwen3-Reranker-8BとQwen2.5-Math-7B-Instructが際立った性能を示したので、反復的な最適化にはQwen3-Reranker-8Bを使い、より大きなQwen2.5-Math-72B-Instructを知識蒸留の教師モデルとして使うことにしました。教師モデルの選択については、GPUリソースが限られていたため、他の大規模モデルはあまり試していません。

4. 効果のあった最適化の過程

1. Prompt_v1（ベースプロンプト）の例

```
<|im_start|>system
You are an expert in detecting grade-school level math misconceptions. The task performs 2 steps:
1.Assesses whether the explanation contains a misconception. (Correct, Misconception, or Neither)
2.Identifies the specific misconception present, if any.<|im_end|>
<|im_start|>user
Question: What fraction of the shape is not shaded? Give your answer in its simplest form. [Image: A
triangle split into 9 equal smaller triangles. 6 of them are shaded.]
Student's Answer: \( \frac{1}{3} \)
This answer is correct.
Student's Explanation: I think that 1/3 is the answer, as it's the simplest form of 3/9.

Now we judge the student's explanation is Correct, Does this diagnosis is correct? (Yes/No)<|im_end|>
<|im_start|>assistant
```

- Prompt_v1 + Qwen3-Reranker-8B を1 epoch学習すると、cvスコア0.9473、publicスコア0.944、privateスコア0.942でした。
- Prompt_v1 + Qwen3-Reranker-8B + distill を1 epoch学習すると、cvスコア0.9480、publicスコア0.946、privateスコア0.945でした。

2. Prompt_v2（ベースプロンプト + 各targetのfew-shot）の例

```
<|im_start|>system
You are an expert in detecting grade-school level math misconceptions. The task performs 2 steps:
1.Assesses whether the explanation contains a misconception. (Correct, Misconception, or Neither)
2.Identifies the specific misconception present, if any.<|im_end|>
<|im_start|>user
Question: What fraction of the shape is not shaded? Give your answer in its simplest form. [Image: A
triangle split into 9 equal smaller triangles. 6 of them are shaded.]
Student's Answer: \( \frac{1}{3} \)
This answer is correct.
Correct's Explanation Samples:
- Because there are 9 triangles and 3 arent shaded it is 3/9 and they are both multiples of 3 so it's
1/3
- The answer is 3/9 which can be simplified to 1/3
- I think this because there are 9 triangles and 3 are not shaded and 3/9 is 1/3.
- there are 9 triangles shaded and 3 are not shaded=3/9=1/3
- I think this because the answer is three over nine then they can be simplified to one over three.
- There are 9 triangles and 3 is not shaded. 3/9 is a possibility but the question says to put it in
its simplest form. 9 divided by 3 is 3 and 3 divided by 3 is one. You cannot simplify it anymore so
the answer is 1/3.
--
```

```
Neither's Explanation Samples:
- i counted the in-shaded parts then the shaded part then i made them a fraction.
- there are 9 triangles in total and 3 are not shaded. this means that 3 times 9 is 3 and 1 is 9.
- I think this because it is hard of the number
- 1/3. 3/9 shaded, and to find simplest from we divide the top and the bottom by 3.
- Because I counted them and seen the awnser
- I think this is because the fraction of the shape shaded is 3/9 but simplified it is 1/3.
--
Misconception:Incomplete's Explanation Samples:
- there are 9 boxes altogether and 3 of them are not shaded.
- there are 9 triangles andd 3 are not shaded
- Because there is nine triangular spaces and three are unshaded
- There are 9 squares but as you can see theree are 3 not shaded.
- I think this because there are nine triangles and thee are not shaded so it’s three over nine.
- i think this because 3 out of nine triangles are not shaded
--
Misconception:WNB's Explanation Samples:
- 6 is the total and 3 is blank
- because 3 arr white and 6 are blue.
- 6 triangles are shaded so 3 aren’t shaded
- 3 of the triangles are not shaded and 6 are shaded so therefore it is 3/6
- i counted the white ones and the blue ones.
- because 3 are shaded and 6 are not
--
Student's Explanation: I think that 1/3 is the answer, as it's the simplest form of 3/9.

Now we judge the student's explanation exhibited the misconception of WNB, Does this diagnosis is
correct? (Yes/No)<|im_end|>
<|im_start|>assistant
```

1). Prompt_v2 + Qwen3-Reranker-8B + distill を1 epoch学習すると、cvスコア0.9493、publicスコア0.948、privateスコア0.946でした。prompt_v2のfew-shot例の数については、学習時はtargetごとに1〜3例、オンライン推論時はtargetごとに6例をランダムにサンプリングしました。2). Prompt_v2 + Qwen3-Reranker-8B + distill + 全データ で1 epoch学習すると、publicスコア0.950、privateスコア0.947でした。3). Prompt_v2 + Qwen3-Reranker-8B + distill + 全データ で2 epoch学習すると、privateスコア0.951、publicスコア0.948でした（**最良の単体モデル**）。ここで興味深いエピソードがあります。全データで2 epoch学習したモデルが、オンライン推論で問題を起こしました。T4 GPUはvllmでbfloat16型をサポートしていないため、モデルをfloat16に変換したところオーバーフローが起き、大量のNaN値が出ました。この時点でコンペの締め切りが近づいており、調整の時間はほとんどありませんでした。代替策として、ローカルvalidation段階の2 epochモデルをbackboneとして使い、validationデータを加えてさらに2 epoch学習し、全データで2 epoch学習した効果を近似しました。4). Prompt_v1 + Qwen3-32B + distill を1 epoch学習すると、cvスコア0.9502でした。全データを使うと、publicスコア0.949、privateスコア0.946でした。5). Model 3（最良の単体モデル）とModel 4でアンサンブルを行いました。アンサンブルはpublicスコア0.952、privateスコア0.948を達成しました。これは最終的に選んだ提出の1つです。しかし、Model 4はcvスコアとpublicスコアが高かったにもかかわらず、private leaderboardでの性能が比較的低かったため、アンサンブルの最終結果は最良の単体モデルを上回りませんでした。

Submission and Description	Private Score	Public Score	Selected
th_eedi_v2_blend_model_v3 - Version 1 Succeeded · 7d ago	0.949	0.951	☐
th_eedi_v2_blend_model_v3 - Version 2 Succeeded · 7d ago	0.949	0.951	☐
th_eedi_v2_base_model_v4 - Version 9 Succeeded · 2d ago · 目前公榜最强单模型	0.948	0.951	☐
th_eedi_v2_blend_model_v2 - Version 4 Succeeded · 10d ago	0.948	0.951	☐
th_eedi_v2_blend_model_v9 - Version 2 Succeeded · 2d ago	0.948	0.951	☐
th_eedi_v2_blend_model_v2 - Version 8 Succeeded · 8d ago	0.948	0.950	☐
th_eedi_v2_blend_model_v9 - Version 1 Succeeded · 2d ago	0.948	0.952	☑
th_eedi_v2_blend_model_v2 - Version 2 Succeeded · 10d ago	0.948	0.951	☐
th_eedi_v2_blend_model_v2 - Version 5 Succeeded · 10d ago	0.948	0.951	☐
th_eedi_v2_blend_model_v2 - Version 3 Succeeded · 10d ago	0.948	0.951	☐
Fork of th_eedi_v2_blend_model_v3 - Version 1 Succeeded · 6d ago	0.948	0.951	☐

3. 結論

model	task	cv	lb	pb	use full	inferrence time
prompt_v1 + Qwen3-Reranker-8B + 1 epoch	CausalLM	0.9473	0.94419	0.94270		40 min
prompt_v1 + Qwen3-Reranker-8B + distill + 1 epoch	CausalLM	0.9480	0.94674	0.94502		40 min
prompt_v2 + Qwen3-Reranker-8B + distill + 1 epoch	CausalLM	0.9493	0.94875	0.94617		4 hours
prompt_v2 + Qwen3-Reranker-8B + distill + 1 epoch	CausalLM	0.9493	0.95014	0.94737	✅	4 hours
prompt_v2 + Qwen3-Reranker-8B + distill + 2 epoch	CausalLM	0.9499	0.95120	0.94873	✅	4 hours
prompt_v1 + Qwen3-32B-AWQ + distill + 1 epoch	CausalLM	0.9502	0.94955	0.94655	✅	2.5 hours
final seleced model (Best Qwen3-Reranker-8B + Qwen3-32B-AWQ)	CausalLM	0.9518	0.95211	0.94835	✅	6.5 hours

5. うまくいかなかったこと

- listwiseのranker
- chain of thought: 個人的にはChain-of-Thought（COT）に最も時間を費やしましたが、最終的に改善は得られませんでした。
- 最も関連する説明をプロンプトに加える: retrievalモデル（Qwen3-Emebedding-8B）をfine-tuningして、現在の生徒の説明に最も関連するN個の説明を探し、それをプロンプトに組み込みました。この方法はCVスコア0.9493というまずまずの値を達成しましたが、publicとprivateの両方のleaderboardでスコアが悪化しました。

```
<|im_start|>system
You are an expert in detecting grade-school level math misconceptions. The task performs 2 steps:
1.Assesses whether the explanation contains a misconception. (Correct, Misconception, or Neither)
2.Identifies the specific misconception present, if any.<|im_end|>
<|im_start|>user
Question: What fraction of the shape is not shaded? Give your answer in its simplest form. [Image: A
triangle split into 9 equal smaller triangles. 6 of them are shaded.]
Student's Answer: \( \frac{1}{3} \)
This answer is correct.
Top relevant explanations with their tags:
- Because there are 9 triangles and 3 of them were not shaded (Correct)
- because there is 9 triangles and 3 of them were not shaded (Correct)
- there aree 9 triangles in total and 3 of them are not shaded. this gives you 3 / 9. (Correct)
--
Student's Explanation: I think that 1/3 is the answer, as it's the simplest form of 3/9.

Now we judge the student's explanation is Correct, Does this diagnosis is correct? (Yes/No)<|im_end|>
<|im_start|>assistant
```

6. 試していないこと

data augmentationのために説明をさらに生成すること

7. 参考

kaggle_eedi offline-install-vllm-0.10.0 Qwen vllm

補足Q&A

common-people — 質問

おめでとうございます！お時間があれば、いくつか質問させてください。pointwise rerankerが1つのbatchですべての学習データ（候補）を見なければならないのはなぜですか？また、プロンプトのshotはどのように選んでいますか？

THLUO — 回答

1. pointwise rerankerでは、各batchに少なくとも1つのrow_idに対応するすべての候補targetのサンプルを含める必要があります。これは、私たちのタスクがrow_idをグループとするグループ内ランキングだからです。CrossEntropyLossを計算してグループ内ランキングを最適化するには、モデルがこのrow_id内のすべての候補targetのlogitを推定する必要があります。 さらに、pointwise rerankerでは1つのbatchに複数のrow_idを含めることもできますが、row_idごとに候補targetの数が異なるため、グループの長さが可変になります。これを扱うには追加の処理が必要です。コンペの初期段階では、1つのbatchに複数のrow_idを含め、各row_idのlossを平均して最終的なlossを計算していました。しかし、この方法では改善は得られませんでした。 私の仮説では、長さの異なるグループでCrossEntropyLossを計算すると、loss値のスケールに差が生じます。候補集合が短いrow_idのlossは一般に大きいため、学習中にモデルがそれらのlossに過学習し、候補集合が長いrow_idの寄与が薄まるのかもしれません。もう1つの考慮点として、batch sizeとlearning rateの間には微妙な関係があるため、batch sizeは大きければ良いとは限りません。
2. 各row_idについて、候補targetごとに1〜3個の生徒の説明をfew-shot例としてランダムにサンプリングします。疑似コードは次のとおりです。 `df_train.groupby(["question", "target"])["StudentExplanation"].apply(list).sample(1, 3)`