map-charting-student-math-misunderstandings

5位 Solution

Rank	5
Team	Naoism
Author	Naoism
Topic ID	612124
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612124
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

はじめに

まず、このコンペで非常に役立った素晴らしい公開notebookの作者の皆さまに心より感謝します。皆さまが共有してくださった知見がなければ、金メダルは獲得できませんでした。特に、次の5つのnotebookが大変役立ちました。本当にありがとうございました。

[1] Gemma2-9B-it - CV 0.945 [2] DeepSeekMath-7B LB:0.944 [3] [LB 0.942][Train] FullFT Qwen3-8B by SFTTrainer [4] [LB 0.942][Infer] FullFT Qwen3-8B by SFTTrainer [5] Some considerations. Fine tuning Gemma2-2b-it.

戦略の概要: 多様性の重視

このコンペでの私の主な戦略は、学習方法の**多様性**を確保することでした。

ベースラインのモデルは、すでにデータセット全体の約94%を正しく予測できていました。さらに、多くの人のスコアがベースライン付近に集中していたので、スコアをさらに上げるには、予測が難しい少数のデータに注力する必要があると考えました。具体的には、次の3種類のデータは量が少なくバリエーションに乏しいため、モデルが誤分類しやすいと仮説を立てました。

1. 生徒の答えは正しいが、説明が誤っているデータ（`True_Misconception:XXX`）
   - モデルはこれらを `Correct` または `Neither` と予測しがちです。
1. 生徒の答えは誤っているが、説明は正しいデータ（False_Correct:NA）
   - モデルは誤って何らかの `Misconception` ラベルを付けがちです。
1. 説明が曖昧なデータ
   - `Correct` / `Neither` や `Neither` / `Misconception` の区別が難しいものです。

このコンペでは `Question` が与えられているので、答えが正しいかどうかは事前に判定できます。つまり、予測のTrue/Falseの部分はほぼ100%の精度で答えられます。結果として、この問題は本質的に37クラス分類タスク（`Correct`、`Neither`、35種類の `Misconceptions`）になります。

これらのクラスのうち、`Correct` と `Neither` はどの問題のラベルにもなりうるので、モデルはこれらを予測候補に含めやすいと考えました。そのため、上記の2番目と3番目の仮説（`Correct` / `Neither` の区別）の改善に集中的に取り組む必要はないと結論しました。

代わりに、重要な課題は、曖昧な説明のデータについて、正しい `Misconception` をモデルの上位3候補の1つに含めることでした。

このような分類の難しいデータでは、単一のモデルや学習方法では、そのモデル特有の「癖」や「視点」に偏った予測になりがちです。この課題に対処するため、多様な手法を取り入れたモデルのアンサンブルが不可欠だと判断しました。この仮説が正しかったかは確信がありませんが、金メダルにつながってほっとしています。

アンサンブル戦略とCV/LBの相関

交差検証（CV）の戦略として、最初は `Misconception` ラベルに基づく `StratifiedKFold` を使っていました。しかし、一部の `StudentExplanation` が同一であり、評価が楽観的になりすぎる可能性があることに気づきました。そこで、空白とピリオドを除いた `StudentExplanation` に基づくグループを使い、`StratifiedGroupKFold` に切り替えました。

単体モデルのPublic LBスコアが0.947前後に達すると、CVスコアとLBスコアの相関がほぼ完全に消えることを観察しました。モデルのアンサンブルでも同様の現象が見られました。これは、先に挙げた予測の難しいデータがまれであり、テストセットには学習データにない表現が含まれている可能性が高いためだと推測しています。

この仮説に基づき、次の方針でモデルを選びました。

- 単体モデル: CVとLBの両方のスコアを組み合わせて選択。
- アンサンブル: CVスコアは無視し、Public LBスコアの改善だけに基づいて採否を判断。

0.949のような高いLBスコアを達成した単体モデルであっても、アンサンブルのLBスコアの改善に寄与しなければ使わないと判断しました。LBスコアへの過学習を防ぐため、アンサンブルの重みの調整は最小限にしました。 これはちょっとした賭けでしたが、最終的にはうまくいきました。

多様性を確保し、自分では思いつかなかったであろう手法を取り入れるため、2つの優れた公開notebookのモデルをそのままアンサンブルに含めました。これにより、他のモデルの学習に集中する時間もできました。アンサンブル自体は、各モデルの予測確率の単純な加重平均を使いました。notebookとモデルの重みを共有してくださった作者の皆さまに、改めて深く感謝します。

- [2] DeepSeekMath-7B LB:0.944
- [4] [LB 0.942][Infer] FullFT Qwen3-8B by SFTTrainer

分類クラス数

学習データには65種類のユニークなラベルがあります。しかし、答えのTrue/Falseの部分はほぼ完璧な精度で判定できるので、問題は37クラス分類タスクに帰着できます。

モデルの多様性を最大化するため、65クラスと37クラスの両方のモデルを作り、アンサンブルしました。

Data Augmentation

仮説で挙げた1種類目の難しいデータ、つまり「生徒の答えは正しいが、説明が誤っている（`True_Misconception:XXX`）」ケースに対処するため、data augmentationを行いました。これはアンサンブルしたモデルのうち1つにだけ適用しました。

精度の改善はわずかでしたが、アンサンブル全体の多様性には寄与したと考えています。

手順:

1. 各 `Question` について、「答えが誤っていて、特定のMisconceptionを含む（`False_Misconception:XXX`）」データを抽出する。
2. 抽出したデータの10%をランダムにサンプリングする。

3. サンプリングしたデータの生徒の答えの部分だけを正しいものに書き換え、ラベルを `True_Misconception:XXX` に変更する。

後処理

学習データを分析したところ、`QuestionId` ごとに起こりうる `Misconceptions` の種類が限られていることが分かりました。このドメイン知識を活用するため、次の後処理を適用しました。

1. 学習データから、各 `QuestionId` に対応する起こりうる `Misconceptions` の集合を作る。
2. 推論時、ある `QuestionId` について、学習データでその問題に現れなかった `Misconceptions` の予測確率を強制的に0にする。

Misconceptionマップを作るコード:

```
() -> [, ]:
    question_misconception_map = {}

    train[] = train.Category.apply(
         x: x.split(, )[-]    x  x
  )
    train[] = train.Category_del_prefix +  + train.Misconception

    unique_question_ids = train[].unique()
     question_id  unique_question_ids:
        question_data = train[train[] == question_id]
        possible_targets = (question_data[].unique())
        question_misconception_map[question_id] = possible_targets

     question_misconception_map
```

使用したモデルの一覧

#	Model	# Classes	Training Method	Data Aug.	CV (*1)	Public LB	Private LB	Weight	Note
1	Gemma2-9b-it	37	LoRA	-	0.946	0.946	0.943	0.25	-
2	Qwen2.5-14B-Instruct	37	QLoRA	☑	0.945	0.946	0.943	0.25	-
3	Gemma2-9b-it	65	QLoRA	-	-	0.947	0.942	0.25	-
4	Qwen2.5-14B-Instruct	37	QLoRA	-	0.938	-	-	0.1	-
5	Qwen3-8B	65	Full FT	-	-	0.942	0.938	0.1	Public Notebook [4]
6	Deepseek-math-7b-instruct	65	QLoRA	-	-	0.944	0.940	0.25	Public Notebook [2]

(*1) Model #1は `StratifiedKFold` で評価し、他のモデルはすべて `StratifiedGroupKFold` で評価しました。

使用したプロンプト

モデルごとに異なるプロンプトを使いました。（変数は省略しています。）

Model # 1

```
<start_of_turn>user
You are an expert math educator analyzing student responses  mathematical misconceptions.

Your goal  to analyze the studentQuestionTexts Answer:{row[]}
- Correct?:{correctness}
- StudentStudentExplanation
```

Model #2

```
<|im_start|>user
Question: {row[]}
Answer: {row[]}
{correctness}
Student Explanation: {row[]}<|im_end|>
<|im_start|>assistant
```

Model #3

```
<start_of_turn>user
You are an expert math educator analyzing student responses  mathematical misconceptions.

Question: {question}
Correct Answer: {answer}
Students response using EXACTLY ONE of these {(all_labels)} labels:

{labels_text}

Classification:<end_of_turn>
<start_of_turn>model
```

Model #4

```
<|im_start|>user
Question: {row[]}
Ground Truth: {ground_truth}
Student Explanation: {row[]}<|im_end|>
<|im_start|>assistant
```