map-charting-student-math-misunderstandings

✨ MAP 6位 Solution - Qwen-semble FTW! 🚀

Rank	6
Team	Manan Jhaveri
Author	Manan Jhaveri
Topic ID	612099
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612099
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

この楽しくも挑戦的なコンペを開催してくださった主催者とKaggleに感謝します。また、価値あるnotebookやdiscussionの投稿を共有してくださった参加者の皆さまにも感謝します。

解法のハイライト（TL;DR版）

- `Qwen3-Embedding-8B`、`Qwen3 14B`、`Qwen2.5 14B` を組み合わせて使いました。
- 珍しいラベルの合成データ、テキストのaugmentation、重複データへの疑似ラベル付けがスコアの改善に役立ちました。

詳細な解法

問題設定

- 数学の問題、生徒が出した答え、生徒が書いた説明が与えられます。
- 次の3つを予測する必要があります。
  - 答えが正しいかどうか
  - 説明が正しいか、misconceptionを含むか、どちらでもないか
  - misconceptionがある場合、その種類は何か

データと前処理

- 最初から、この問題は単なるmisconceptionの分類問題だと捉えました。そこで、categoryから `True_` と `False_` の接頭辞を取り除き、得られた37ラベルをfine-tuningに使いました。
- 次の入力形式を使いました。

```
correctness =   row[]
input_text = (




)
```

初期の実験で、プロンプトの最後の行を加えるとLLMのCVとLBのスコアが改善することに気づきました。そのため、以降の実験でもそのまま残すことにしました。

- 重複サンプルはすべて削除しました。重複 = 答えと説明が同じなのに、ラベルのmisconceptionが異なるもの。
- 最後のいくつかの実験では、これらの重複に疑似ラベルを付け、学習データに戻しました。

- 一部の実験では、categoryごとに約50個のaugmentedサンプルを追加しました。augmentationには、句読点の基本的な置換、単語と数字の相互変換、"plus" を "+" に置き換える、"equals to" を "equals" や "=" に置き換える、小さなタイプミスを加える、などが含まれます。
  - 学習データ内でfuzzy searchによって見つけた近似重複を分析し、それに合わせてaugmentedサンプルを作ろうとしました。
- 最後のいくつかの実験では、サンプル数が最も少ない10/37のcategoryに合成データを追加しました。ChatGPT 4oを使い、categoryごとに100〜120サンプルを生成しました。
- 最大シーケンス長160とdynamic paddingを使いました。これで学習と推論が速くなりました。
- ローカルでのテストには20%のtest splitを使い、提出用には全データでモデルを再学習しました。

モデル

- GTE、Ettinなどさまざまなモデルで実験を始め、後に最大8BパラメータのLLMに移行しました。私の場合は、`Qwen3-Embedding-8B` による `sequence classification` の手法が最も良い性能でした。
- プロンプトのテンプレートと前処理を固定した後、14Bパラメータのモデルにも移行しました。
- これらのLLMは4-bit Q-LoRAで学習しました。Rank = 128、alpha = 32-128（実験によって異なる）。
- 計算資源にはJarvis LabsのA5000/A100を使いました。

最終的にqwen-sembleで使ったモデルのまとめは次のとおりです。

Model	Data used	Public LB
Qwen3 Embedding 8B	Deduplicated data	0.946
Qwen3 14B	Deduplicated data	0.947
Qwen2.5 14B IT	Deduplicated data	0.947
Qwen3 Embedding 8B	Deduplicated data + Augmented data	0.945
Qwen3 Embedding 8B	Deduplicated data + Pseudo-labelled duplicates + Synthetic data	**0.949**（最良の単体モデル）
Qwen3 14B	Deduplicated data + Pseudo-labelled duplicates + Synthetic data	0.948
Qwen3 14B	Deduplicated data + Pseudo-labelled duplicates + Synthetic data（+ 上とは異なるseed）	0.943

アンサンブル

- @kishanvavdara さんの次のnotebookのアンサンブル方法を使いました: https://www.kaggle.com/code/kishanvavdara/ensemble-gemma-qwen-deepseek
- 上の表の最初の4モデルのアンサンブルで、public LBで0.95を突破できました。
  - このアンサンブルを使って、重複データに疑似ラベルを付けました。
  - augmentedデータで学習したモデルは、単体のスコアは他より低いものの、アンサンブルには大きく貢献しました。より良いモデルができるたびに何度か外してみましたが、スコアは毎回下がりました。
- 最初の6モデルのアンサンブルで、public LB 0.951（private LB 0.947）を得ました。

- 最後の2日間はアイデアが尽きており、アンサンブル方法でのモデルの重みの小さな調整は信頼できないと感じたのでやりたくありませんでした。そこで、以前0.948のモデルで使ったのと同じ設定で、seedとrandom stateだけを変えてQwen3 14Bをfine-tuningすることにしました。単体のスコアはかなり低かったものの、他の6モデルとアンサンブルすると、publicとprivateの両方のLBで最良のスコアになりました。

失敗した実験

- 複数の事前学習済みモデル。
- いくつかのプロンプトテンプレート。
- augmentedサンプルを増やしすぎること。分析から複数のパターンを選び出し、約10kのaugmentedサンプルを作りました。しかし、public LBスコアは約0.945のままで、これらのモデルはアンサンブルにもあまり貢献しませんでした。
- 異なるモデリングの手法:
  - 元の65ラベルをすべて使う。
  - 2段階の手法。第1段階のモデルは生徒の説明が正しいか、misconceptionを含むか、どちらでもないかだけを予測し、第2段階でmisconceptionの種類を予測します。
  - テキスト生成の手法。各category（その問題で起こりうるもの）の簡単な説明をプロンプトに入れ、生徒の説明の背後にある推論を最もよく表すものをモデルに予測させました。
  - Textual Entailmentの手法。あるサンプルが、misconception categoryの簡単な説明のいずれかを含意するかを予測しようとしました。
  - LoRA adapterの代わりに、分類headにMoE型のNNを使う。（ぜひうまくいってほしかったのですが、ハイパーパラメータを詰める時間が十分に取れませんでした。）
- focal-lossなどの異なる損失関数。