map-charting-student-math-misunderstandings

Private 7位（Public 10位）Solution

Rank	7
Team	S T I T Y
Author	yukichi0403
Topic ID	612134
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612134
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、主催者とKaggleに深く感謝いたします。このコンペは私たちのチームにとって素晴らしい学びの経験になりました。

チームメンバー: @yukitake93 @isakatsuyoshi @takai380 @sinchir0 @takaito

概要

- **Logitの直接学習:** Misconceptionラベルにトークンを割り当て、取り出したlogitに対してCrossEntropy lossで直接学習しました
- **vLLMとの統合:** 分類headも試して同程度のスコアでしたが、vLLMでの推論性能を最適にするためlogitベースの手法を選びました
- **アンサンブル戦略:** 異なるモデルとプロンプト戦略を持つ複数のパイプラインを組み合わせました

効いた工夫

1. 合成データの生成（主にISAKA）

モデルの精度を上げるため、GPT-4.1とGPT-5-miniを使って合成データを生成しました。

合成データの生成方法:

- 元の学習データセットから、特定の条件を満たすデータを抽出しました。条件は、「正解ラベル（True/False）」「Question ID」「Misconception」が同一のデータが5件以上あるグループです
- 各グループから3件をランダムにサンプリングし、それを参照として新しい「生徒の説明」を生成しました
- 3件の異なるデータを使うことで、より多様で高品質な合成データができました（単一の例への過学習を避けるため）

生成したバージョン:

- `ver2-46`: GPT-4.1で生成
- `ver47-56`: GPT-5-miniで生成
- データセットはこちらで公開しています

評価結果: Chris Deotteさんのnotebook "Gemma2-9B-it - CV 0.945" をベースラインとして使いました。

k=5 Results

Dataset	CV Score	LB Score
No synthetic dataset	0.940189	0.944
ver2-13	0.943963	0.946
ver14-25	0.943781	0.947
ver26-37	0.944208	0.949
ver26-37 (retrained)	0.943890	0.948
ver38-46	0.943645	0.947
ver47-56 (Created with GPT5-mini)	0.942850	0.946

k=6 Results

Dataset	CV Score	LB Score
No synthetic dataset	-	-
ver2-13	0.943990	0.947
ver14-25	0.944604	0.949
ver26-37	0.944294	0.947
ver38-46	0.943394	0.948
ver47-56 (Created with GPT5-mini)	0.944408	0.947

合成データによる改善:

- **CVスコア:** +0.003 〜 +0.004
- **LBスコア:** +0.002 〜 +0.005

重要な注意: これらの改善は、特にGemma2-9B-it + OOF予測で観察されたものです。他のモデルでは結果がまちまちで、合成データを効果的に活用するにはモデルごとの調整が重要であることを示唆しています。

2. Misconception候補の絞り込み

- 各問題であらかじめ決まっている誤答の候補を活用しました
- 関連するmisconception候補だけをプロンプトに追加 → プロンプト長を大幅に短縮

3. ノイズの軽減とラベル品質の向上

- **Label Smoothing:** ノイズのあるラベルに対処するため、一部のモデルで損失関数にα=0.1を加えました
- **知識蒸留:** コンペのデータでQwen2.5-32Bを学習し、その出力をsoft labelとして使いました（合成データに生成時のラベルを直接使う代わりに）

4. 正解の事前特定

- このdiscussionで共有されているように、学習データとテストデータは同じ15問を共有しています

- Misconceptionの予測だけに集中し、True/Falseラベルは後処理で付けました

5. プロンプトに他の選択肢を入れる

- 追加のcontextとして、同じ問題の他の選択肢（生徒が選んだ答えを除く）を加えました

うまくいかなかったこと

アンサンブルの重みの動的調整（主にtakaito）

- 問題ごとにアンサンブルのモデルの重みを動的に調整しようとしました
- 計算上の制約からfold0のCVに限定しました
- データ不足が性能の低さの原因だと思われます
- 複数foldのCVなら結果が改善したかもしれません

小さなモデルの追加（主にtakaito）

- 軽量なモデル（予測に数分）を用意しました
- アンサンブルに加えても改善はありませんでした

パイプラインの詳細

Pipeline 1（yukichi）

データ戦略:

- コンペのデータ + ISAKAの合成データ（v2-13を使用）
- 2種類のプロンプト:
  - **Type 1:** 関連するmisconception候補 + Claude Sonnetで逆算した説明（実際の生徒の回答パターンに基づいて、各misconceptionの詳細な説明を生成）
  - **Type 2:** misconceptionの完全な一覧

モデル構成:

Model	Prompts	Public Best	Private
Gemma-2-9B-IT	2	0.950	0.946
Qwen2.5-32B (AWQ)	2	0.950	0.947

アンサンブル結果: Public LB 0.952、Private 0.948🎯

蒸留戦略:

Data Type	Strategy
Competition	元のラベル（50%） + Qwen2.5-32BのOOF（50%）
External	Qwen2.5-32Bのlogitのみ

正則化:

- **Gemma2-9B:** Label smoothing（α=0.1） + Temperature 1.5
- **Qwen-32B:** smoothingなし + Temperature 1.0

Pipeline 2（takai）

データ戦略:

- コンペのデータ + ISAKAさんの合成データ
- Claude Sonnetで事前に生成したmisconception候補

モデル:

- deepseek-ai/DeepSeek-R1-Distill-Qwen-32B（Public Best: 0.950、Private: 0.945）
- 基本的に、foldごとに学習したモデルでデータセットを推論し、その出力をsoft labelとして使います。
- 外部データ（OOFのtop-1予測がラベルと一致する項目のみを使用）とコンペのデータで、CE_loss + KL_div_lossで学習（Public: 0.95、Private: 0.945）。
- コンペのデータで、CE_loss + KL_div_lossで学習（Public Best: 0.948、Private: 0.943）。

Pipeline 3（sinchir0）

基本的には、私の公開notebookのコードを使って学習しました。

改善につながった主な要因

- 追加したspecial tokenではなく、既存のトークンを正解として使う。（CV+0.005、LB+0.005）
- eval_lossが最小のcheckpointではなく、それより少し後のcheckpointを使う。（CV+0.008、LB+0.007）

データ戦略:

- コンペのデータのみ
- 起こりうるmisconceptionの選択肢のみ
- GPT-5で生成した、候補misconceptionの説明

モデル:

- Qwen/Qwen3-8B（Public Best: 0.948、Private: 0.945）
- 全データでの学習 + Full Fine-Tuning
- lr: 2e-5（1e-4では収束に問題が生じた）
- 3epoch

主な学び

- 合成データの効果はモデルに強く依存する
- プロンプトエンジニアリングと候補の絞り込みは効率のために重要
- 蒸留とlabel smoothingの組み合わせは、ノイズのあるデータに効果的に対処できる
- 正解を事前に特定することで、誤りの原因を1つ取り除ける

私たちの解法を読んでいただき、ありがとうございました！

補足Q&A

Bilzard — 質問

金メダルおめでとうございます。

@isakatsuyoshi

生成データは、特に新しいデータ（つまりLB）に大きな効果があったようですね。合計でいくつの例を生成しましたか？ また、生成プロンプトの例を共有していただけますか？

ISAKA Tsuyoshi — 回答

ありがとうございます！ 合計200,000件を生成し、最終的な解法ではバージョン2-13の約50,000件を使っています。

プロンプトは後で共有します。

追記: 設計上の選択として、生成のたびに参照データを3件ランダムにサンプリングしました。 これにより、出力に多様性を持たせることができました。

```
prompt =

 j, (_, row)  (sampled.iterrows(), ):
    prompt +=

prompt +=
```

Bilzard — 質問

> 合計200,000件を生成し、最終的な解法ではバージョン2-13の約50,000件を使っています。

かなりの量ですね。50Kの例を選ぶのに、どのようなフィルタリング方針を使いましたか？

ISAKA Tsuyoshi — 回答

はい。学習データとLBデータの両方をi.i.d.とみなし、誤解のパターンは有限だと仮定したので、起こりうるすべての種類を網羅するために大量のデータを生成しました。

プロンプトは1つしか使っていないので、すべてのサンプルは同じ確率分布から得られたものです。特別なフィルタリングは行っていません。結果のばらつきは、データの品質そのものよりも、主に生成した生徒の説明とラベルの不一致に起因すると考えています。 この問題は、チームメイトが提案したsoft labelの手法で軽減されたと考えています。