map-charting-student-math-misunderstandings

8位 Solution

Rank	8
Team	Takashi Someya
Author	Takashi Someya
Topic ID	612101
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612101
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

このような興味深いチャレンジを運営してくださったKaggleチームと主催者の皆さまに深く感謝します。ソロで金メダルを獲得でき、本当に嬉しいです。

概要

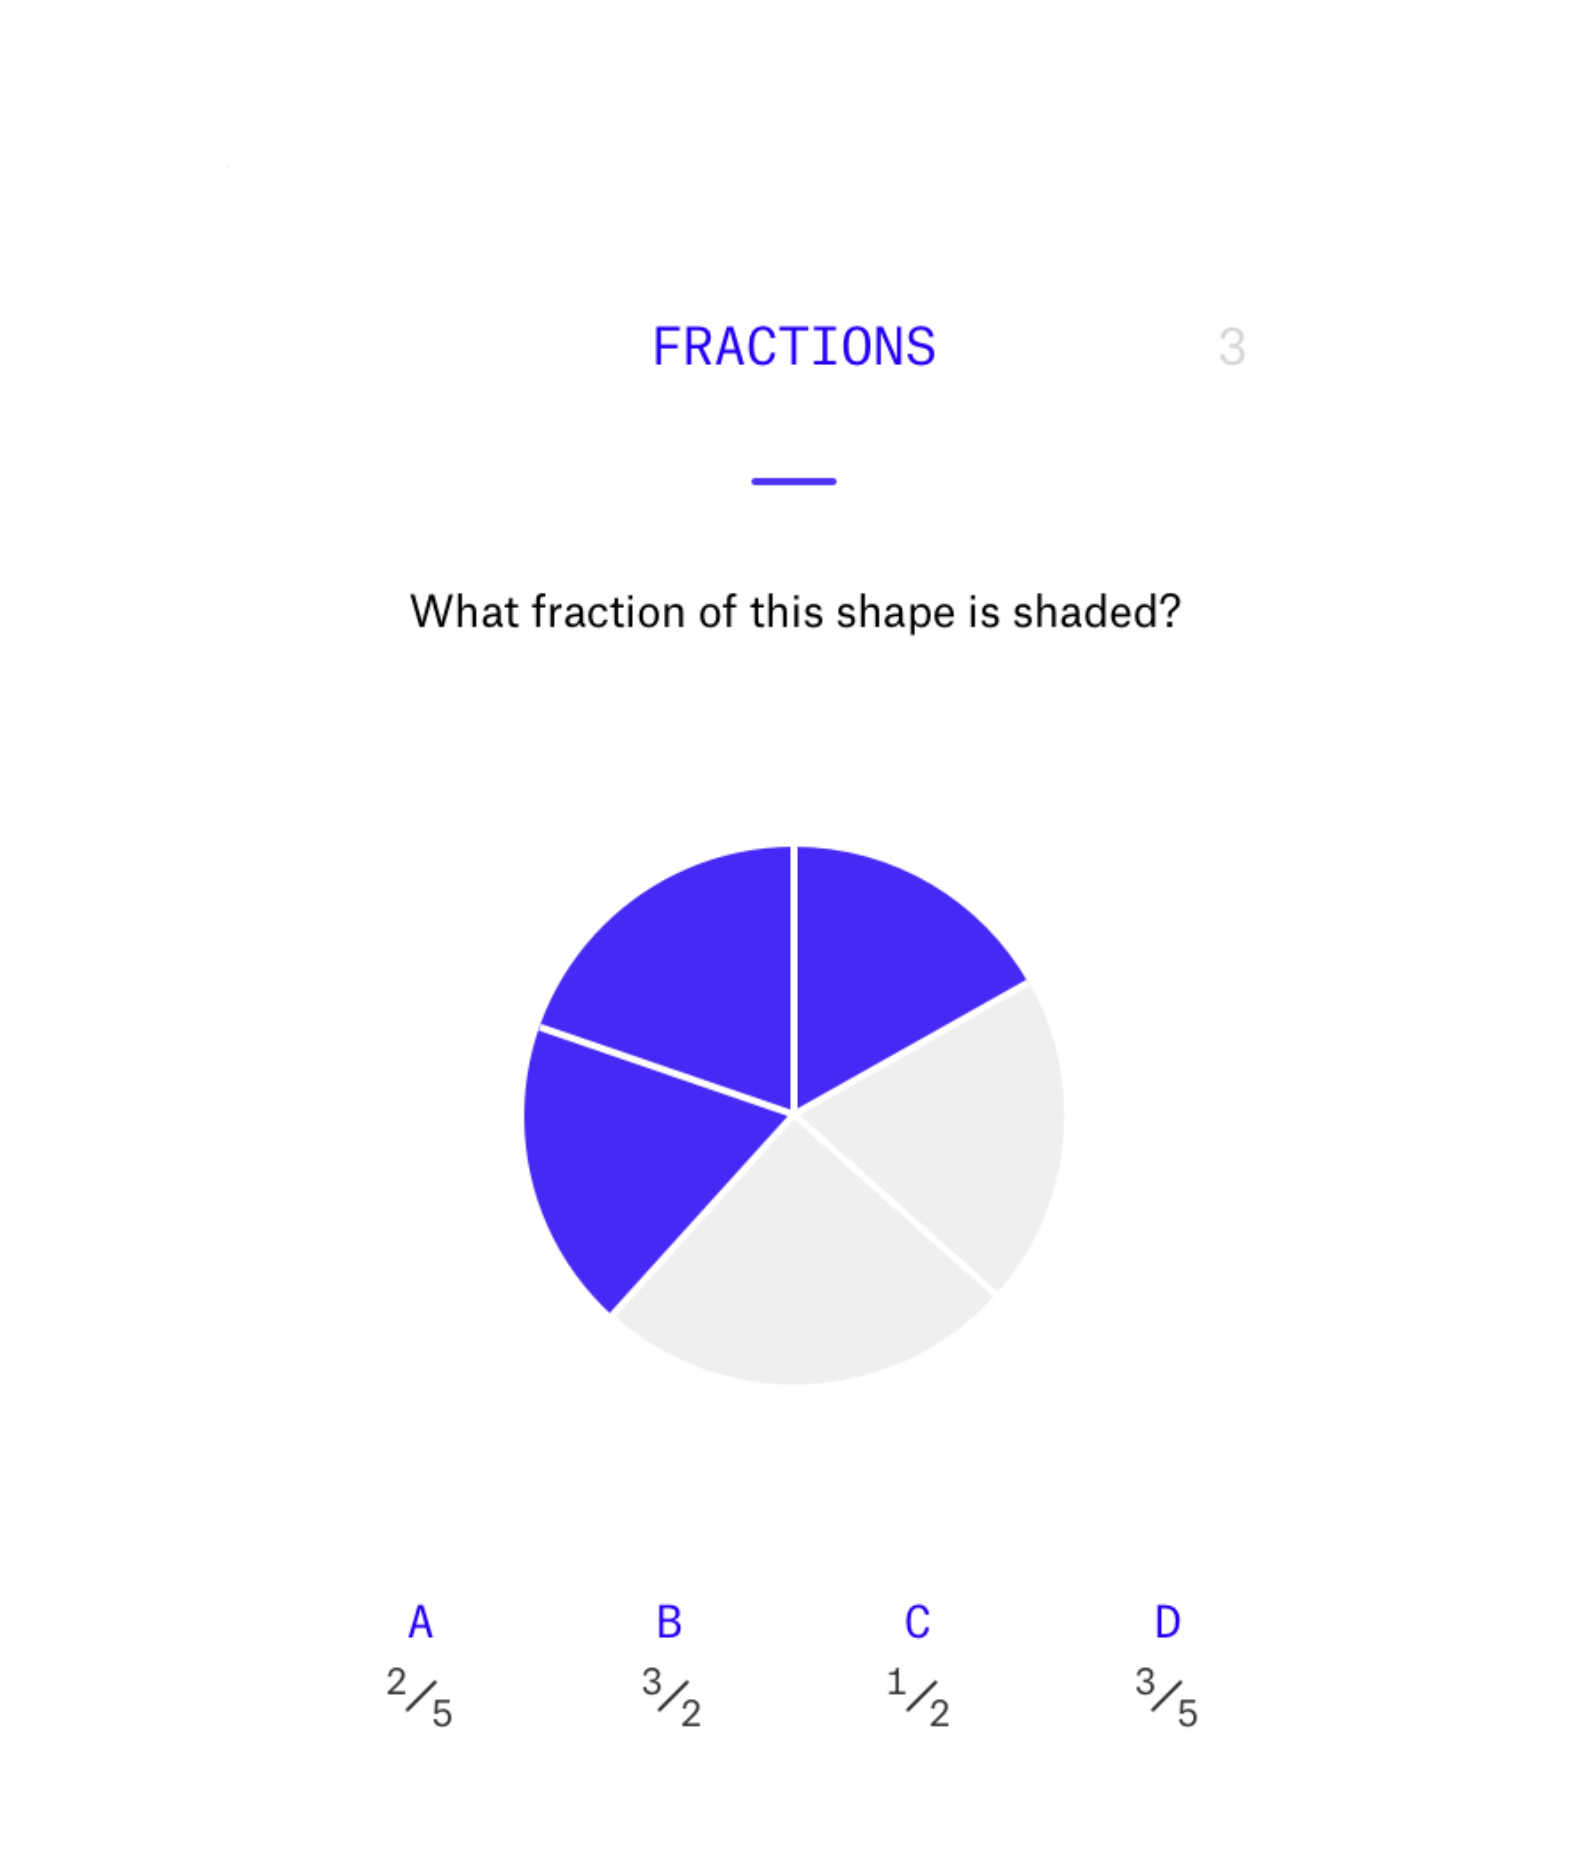
- vLLMによる推論の高速化 + 多数のモデルのアンサンブル
- 問題の選択肢をプロンプトに追加
- 最適な学習率とbatch sizeの探索
- サンプル数が少ない、または予測が難しいラベルの合成データを作成

モデル

- タスクの種類: vLLMで高速化しやすいため、Causal LMを選びました。
- アーキテクチャ: 私の実験では、試したアーキテクチャの中でQwen2.5とQwen3が最も良い性能でした。
- 最終的に使ったモデル:
  - **Qwen/Qwen2.5-7B**
  - **Qwen/Qwen2.5-14B-Instruct-AWQ**
  - **Qwen/Qwen3-8B**
  - **Qwen/Qwen3-14B-AWQ**
- 学習: すべてのモデルをLoRAで学習しました。

プロンプト

このdiscussionから、生徒はa〜dの選択肢から1つを選んで答えていることが分かりました。



そこで、`StudentExplanation` から `MC_Answer` と選択肢a〜dの対応を復元し、`QuestionText` を次のように変更しました。

```
Which number is the greatest? (a) 6 (b) 6.2 (c) 6.079 (d) 6.0001
```

これにより、モデルが生徒の `MC_Answer` と他の選択肢を比較して、対応する `Misconception` を特定できるようになり、予測に役立ったと考えています。

最終的なプロンプトは次のとおりです。

```
You are a specialist in identifying the types of misunderstandings that arise from students' answers
to math problems.
Based on the information provided below, please determine what kind of misunderstanding the student
has.

Question: What fraction of the shape is not shaded? Give your answer in its simplest form. [Image: A
triangle split into 9 equal smaller triangles. 6 of them are shaded.] (a) 1/3 (b) 3/6 (c) 3/8 (d) 3/9
Answer: 1/3
Correct: Yes
Student Explanation: 0ne third is equal to tree nineth
Type of Misunderstanding:
```

後の合成データ作成やEDAでの読みやすさのため、`QuestionText` と `MC_Answer` からLaTeX表記を取り除きました（**注**: スコアへの影響はありませんでした）。

このnotebookに着想を得て、targetラベルを次の記号に対応させ、1トークンを生成するようにしました。

```
special_character_list = [
  ,,,,,,,,,,,,
  ,,,,,,,,,,,,
  ,,,,,„,,,,,,,
  ,,,,,,,,,,,„
  ,,,,,,„,,,,,
]

special_token = [tokenizer(i, add_special_tokens=).input_ids[]  i  special_character_list]
```

これらの記号は、それぞれQwen tokenizerの1トークンに対応します。

学習

- **Epochs:** 3
- **Optimizer:** AdamW (weight_decay = 0.01)
- **Scheduler:** cosine (warmup_ratio = 0.03)
- **Batch size:** 12
- **Learning rate:** 0.0002
- **LoRAの設定**
  - **r:** 16
  - **alpha:** 16
  - **dropout:** 0.05
  - **target_modules:**
    - `q_proj`

- `k_proj`
- `v_proj`
- `o_proj`
- `gate_proj`
- `up_proj`
- `down_proj`

ハイパーパラメータの試行中に、batch sizeと学習率の小さな変更でCVスコアが大きく揺れることに気づきました。そのため、この2つを慎重に調整し、最良の組み合わせを探しました。 LoRAの `r` や `alpha` を変えても、スコアに意味のある改善はありませんでした。 私の実験では、full-parameter fine-tuningよりもLoRAの方が良いCVを達成しました（full-parameter学習のチューニングが不十分だった可能性があります）。

データ

コンペのラベルには不均衡と予測の難しさの違いがあったため、生成AI（`gpt-5` と `o3`）を使って合成データを作ろうとしました。 まずコンペのデータでモデルを学習し、MAP@3でout-of-fold（OOF）予測を計算しました。次に、（`QuestionId`、`Category`、`Misconception`）の組ごとに、MAP@3の平均とサンプル数を集計しました。MAP@3の平均が低い組やサンプル数が少ない組について、コンペのデータをfew-shot例として合成データを生成しました。生成プロンプトには `Category` と `Misconception` の説明を含め、最大50個の新しいサンプルを作るよう指示しました。few-shot例は、一様ランダムに、またはOOFスコアの低い項目からランダムにサンプリングしました。生成を何度も繰り返し、合計で約30,000件の合成サンプルを得ました。

合成データの構成を変えてモデルを学習し、アンサンブルに使いました。合成データの寄与は控えめで、leaderboard上ではおそらく0.001以下でした。（leaderboardの表示精度が上がれば、より詳しく調べるつもりです。）

最終提出

- **アンサンブル:** 10の実験設定（各設定を5 foldで学習 → 10 × 5 = 合計50モデル）
- **最終提出:** LB最良のアンサンブルとCV最良のアンサンブルの両方を選びました。Private LBではLB最良の方が良い結果でした。
- **重み付け:** LBとCVの結果に基づいて重みを付けました

LB最良の結果

Public LB: 0.951、**Private LB:** 0.948

Model	Synthetic Data	Public LB (Rank)	Private LB	Weight
Qwen/Qwen2.5-7B	✅	0.949 (#7)	0.944	0.5
Qwen/Qwen2.5-7B	✅	0.949 (#8)	0.945	0.5

Model	Synthetic Data	Public LB (Rank)	Private LB	Weight
Qwen/Qwen2.5-7B	✅	0.949 (#1)	0.946	1.5
Qwen/Qwen2.5-14B-Instruct-AWQ	✅	0.949 (#6)	0.946	1.5
Qwen/Qwen3-8B		0.949 (#5)	0.945	1.0
Qwen/Qwen3-8B	✅	0.949 (#4)	0.945	1.0
Qwen/Qwen3-8B	✅	0.949 (#9)	0.944	0.5
Qwen/Qwen3-8B	✅	0.949 (#10)	0.946	0.5
Qwen/Qwen3-14B-AWQ		0.949 (#3)	0.945	1.5
Qwen/Qwen3-14B-AWQ	✅	0.949 (#2)	0.945	1.5

*Rankは、SubmissionsページをPublic LBで並べ替えたときの、その提出の順位を示します。

補足Q&A

@kaggleqrdl — 質問

ソロ金メダルおめでとうございます！素晴らしい結果と見事なwriteupです！

CVスコアがとても気になります。public LBと一致していたのでしょうか？

WOOSUNG YOON — 質問

素晴らしいsolutionの共有ありがとうございます！ このコンペでは、多くの人が次のtarget modulesをfine-tuningしていることを知りました。

- target_modules: q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj

一方で、どのモジュールをfine-tuningするかの選び方には膨大な可能性があると感じます。 これについて標準的な指針や方法論があるのか気になります。

ShadowCoder — 質問

共有ありがとうございます。これらのモデルの学習に何台のGPUを使ったのか知りたいです。

Bilzard — 質問

@takashisomeya ソロ金メダルおめでとうございます。

> 生成プロンプトには Category と Misconception の説明を含め、最大50個の新しいサンプルを作るよう指示しました。

合成データについて、私も `claude-haiku` で合成データを生成しようとしましたが、生成された出力が互いに似すぎていました。データの多様性について何か工夫はしましたか？（また、生成プロンプトの例を共有していただけますか？）

Takashi Someya — 回答

自分独自のsplit（StratifiedGroupKFold）を使ったので、CVスコアは他の方のものと直接比較できないかもしれません。最良のCV（5-foldの平均）は0.945で、Public LBとよく相関していました。

Takashi Someya — 回答

標準的な指針があるかどうかは分かりません。 LoRAのtarget_modulesを増やせば、大きな欠点なしにモデルの表現力が上がると考えたので、すべてのtarget modulesで学習し、組み合わせは探索しませんでした。

Takashi Someya — 回答

主に単一のRTX 6000 Adaで学習しました。

Takashi Someya — 回答

合成データのプロンプトと出力の例を公開しました。

https://www.kaggle.com/datasets/takashisomeya/map-synthetic-data-o3-example

合成データの品質を上げるためにClaude Codeと一緒に作業しましたが、solutionに書いたとおり、合成データの寄与は控えめで、他のメダリストほどにはうまくいきませんでした。コンペの終わりまでデータのフィルタリングについてもさまざまな方法を試しましたが、特に効果的な方法は見つかりませんでした。