map-charting-student-math-misunderstandings

9位 Solution

Rank	9
Team	kanto-kaggler
Author	Rick
Topic ID	612105
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612105
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

主催者とKaggleスタッフの皆さまに深く感謝するとともに、入賞者の皆さまおめでとうございます。 このコンペからは多くのことを学びました。そして、初めての金メダルを獲得できて嬉しいです！

概要

- **手法**
  - 32BのCausal LMを使い、推論にはvLLMを使用: 5-fold × 2モデル = 合計10。
- **スコア**
  - Public LB: **0.950**、Private LB: **0.948**
- **モデル**
  - `Qwen/Qwen2.5-32B-Instruct`
  - `deepseek-ai/DeepSeek-R1-Distill-Qwen-32B`
- **推論時間**
  - 460分

データセット

- コンペの学習データ
  - QuestionId、Category、Misconceptionに基づくStratifiedKFoldで5 foldに分割。

学習

- **参考にした実装:** https://www.kaggle.com/code/sinchir0/lb-0-942-train-fullft-qwen3-8b-by-sfttrainer
- 65個のラベルをspecial tokenに変換しました。
- fine-tuningには **SFTTrainer + AutoModelForCausalLM** と **QLoRA** を使いました。
- **ハイパーパラメータ**
  - **Qwen/Qwen2.5-32B-Instruct**
    - `epoch=2, lr=1e-4, per_device_batch_size=8, gradient_accumulation_steps=2`
    - `r=32, α=64, lora_dropout=0.01, target_modules=["q_proj","k_proj","v_proj","o_proj","gate_proj","up_proj","down_proj"], modules_to_save=["lm_head"], trainable_token_indices={"embed_tokens": target_label_ids}`
  - **DeepSeek-R1-Distill-Qwen-32B**
    - `epoch=2, lr=8e-5, per_device_batch_size=8, gradient_accumulation_steps=2`

        - `r=64, α=128, lora_dropout=0.01, target_modules=["q_proj","k_proj","v_proj","o_proj","gate_proj","up_proj","down_proj"], modules_to_save=["lm_head"], trainable_token_indices={"embed_tokens": target_label_ids}`
- **環境**
    - Google Colab (A100 80GB)
- **学習時間**
    - 1 foldあたり220分

前処理

- 既知のアノテーションの誤りを修正し、重複したMisconceptionラベルを統一しました。
- 統一したラベルは、後処理で対応するQuestionIDに基づいて振り分け直しました。

```
() -> pd.DataFrame:
   false_to_true_ids = [, , , , , ]
   df[] = np.where(
       df[].isin(false_to_true_ids),
       df[]..replace(, ),
       df[]
 )

   true_to_false_ids = [, , , , , , , , , , , ]
   df[] = np.where(
       df[].isin(true_to_false_ids),
       df[]..replace(, ),
       df[]
 )
    df

() -> pd.DataFrame:
   df[] = df[].replace({: })
    df
```

プロンプトの最適化（精度向上のため）

- プロンプトを単純化すると、CVスコアがわずかに改善しました。
- 学習時間と推論時間の短縮にも役立ちました。

```
prompt_format =
```

推論

- 推論には **vLLM + AWQ** を使いました。

- 追加したspecial tokenのlogitを取り出し、すべてのモデルでスコアを平均しました（単純な加算平均）。

結果（MAP@3）

Model / Setting	Valid	Public LB	Private LB
Qwen2.5-32B-Instruct (fold0)	0.950182	0.946	0.944
Qwen2.5-32B-Instruct (5-fold)		0.950	0.946
DeepSeek-R1-Distill-Qwen-32B (fold0)	0.947956	0.948	0.945
DeepSeek-R1-Distill-Qwen-32B (5-fold)		0.950	0.946
5-fold × 2 ensemble		0.950	**0.948**

結果が改善しなかった試み

- **Reranker（pairwise / pointwise）** top1/top2の並べ替えのために実装しましたが、ベースの結果を上回りませんでした。
- **70B / 72Bモデル** CVは32Bより良かったものの、推論時間（約150分）が最終パイプラインには長すぎました。
- **Qwen2.5以外のモデル** Llama 3.3-70B、gpt-oss-20b、Mistral、Hermes、Gemma 3、Qwen 3などを試しました。 私たちの状況では、いずれもQwen 2.5のモデルを上回りませんでした。
- **Soft labels** 同じデータセットで学習した別のQwen-32Bモデルが出したlogitを使って、Qwen-32Bを再学習しました。 public leaderboardでは改善が見られませんでしたが、private leaderboardのスコアはわずかに上がりました（+0.001）。
- **LoRAのMerge** 5つのfoldで学習したLoRA adapterをmergeすると、単一のモデルを使う場合より性能が下がりました。
- **[Category: Misconception]だけで学習し、True/Falseのサンプルを除外する** True/Falseのサンプルを除外してMisconceptionのcategoryだけで学習しても、通常のcategory分類モデルを上回りませんでした。

参考

https://huggingface.co/Qwen/Qwen2.5-32B-Instruct https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-32B

https://www.kaggle.com/code/sinchir0/lb-0-942-train-fullft-qwen3-8b-by-sfttrainer https://huggingface.co/docs/peft/main/en/developer_guides/lora#efficiently-train-tokens-alongside-lora