map-charting-student-math-misunderstandings

MAPコンペ 13位 金メダル Solution

Rank	13
Team	iws
Author	iws
Topic ID	612069
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/map-charting-student-math-misunderstandings/discussion/612069
Retrieved with Kaggle CLI on 2026-10-21.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

コンペの主催者、データ提供者、そして価値ある議論に貢献してくださったすべての参加者に感謝します。

戦略

2つの手法 × 複数のモデル × アンサンブル

- 分類の手法: 14Bモデル × 2
- Listwiseの手法: 72Bモデル × 2 + 32Bモデル × 2
- 合計6モデルのハイブリッドアンサンブル
- 6モデルすべてを異なるseedで学習

36,696サンプルをすべて使用（validation splitなし）

モデルごとのスコア

Model	Task	Weight	Private Score	Public Score
Qwen3-14B-Base	Classification	0.9	0.943	0.949
Qwen3-14B-Base	Classification	0.9	0.944	0.948
Qwen3-32B	Listwise	1.0	0.943	0.949
Qwen3-32B	Listwise	1.0	0.943	0.948
Qwen2.5-72B-Instruct	Listwise	1.0	0.945	0.947
Qwen2.5-72B-Instruct	Listwise	1.0	0.945	0.949
Ensemble	-	-	0.947	0.952

手法

重要な設計判断

このコンペは固定された15問を使い、各サンプルにはCategory（Correct/Neither/Misconception）とMisconceptionのタグが付いています。私たちは3つの重要な観察をしました。

- Targetの削減: 各問題には、（True/Falseを除いた全37クラスのうち）4〜6個の候補targetしかありません。どちらの手法もこの制約を活用しています。
- True/Falseの分離: True/Falseラベルは、生徒の答えが正しいか誤っているかを示します。このコンペは固定の問題を使うので、予測しなくても学習データから正解を判定できます。True/Falseを予測targetから外し、最終予測に接頭辞として付けます。
- 入力の強化: 各問題の4つの選択肢を学習データから抽出し、すべての入力プロンプトに加えました。

分類モデル

- モデル: Qwen3-14B-Base
- タスク: SequenceClassificationで37クラスすべてを学習
- 学習: QLoRA 4bit、2 epoch
- 推論: 4bit量子化 + LoRA adapter、各問題の4〜6個のtargetのスコアを取り出す

Listwiseモデル

- モデル: Qwen2.5-72B-Instruct（×2）、Qwen3-32B（×2）
- タスク: CausalLMを使い、各問題の4〜6個のtargetを選択肢として提示し、選択肢の番号を生成させる
- 学習: QLoRA 4bit、1 epoch、選択肢の順序をランダムにシャッフル
- 後処理: LoRAのmerge →（72B: vLLMのtensor並列化のため、intermediate_sizeを29568→29696にパディング）→ gptqmodelを使ったGPTQ 4bit量子化
- 推論: vLLMを使って各選択肢のlogprobsを取得

アンサンブルの方法

各モデルのスコアを統一したスケールに変換します。

- 分類モデル: 確率をL1正規化
- Listwiseモデル: logprobsをSoftmax変換

加重平均でTop 3を選びます。最終予測にTrue/Falseの接頭辞を付けます。

リソース

- 学習: 14B（RTX 5090、2h）、32B（RTX 5090、10h）、72B（H200、4h）
- 推論: Kaggle T4×2、8時間

考察

データの特性:

- ラベルは主観的でアノテーションに一貫性がありません。misconceptionのタグは抽象的で複数の異なる概念を含んでおり、ラベルの誤りや境界的なケースが多くあります

これらの特性から生じた結果:

- 複数モデルのアンサンブルが効果的に機能した
- 合成データの生成やCoTの手法はうまくいかなかった（合成データはモデルの特性評価に使ったが、LBスコアとの相関は弱かった）

モデル選択について:

- モデル選択は難しいものでした。Public Scoreは楽観的すぎる結果を示し、ほぼどの組み合わせでも似たスコアになりました
- 実験から得たいくつかの知見が判断の指針になりました:
  - 精度は8B→14B→32Bと向上しましたが、32Bを超えると頭打ちになり、72Bではそれ以上の向上はありませんでした
  - ランダムなseedによって、スコアが約±0.002変動しました
  - 合成データでの評価では、listwiseの手法が分類モデルを一貫して上回りました
  - そこで、seedの変動を考慮して各構成で2モデルずつ使い、合成データでの性能に基づいてlistwiseモデルの重みを高くしました
- この手法は決定的に重要でした。Public Scoreの順位だけに頼っていたら、おそらくメダルを逃していたでしょう
- コンペ後の分析で、さらに知見が得られました。Qwen3-32BはQwen2.5-72Bより劣っていましたが、別の実験ではQwen2.5-32BがQwen2.5-72Bと同等で、Qwen3はこのタスクにあまり適していなかったことが分かりました。さらに、Private ScoreはPublic Scoreよりseedによる変動が小さく、（複数のseedではなく）異なるアーキテクチャによるより多様なアンサンブルの方が有益だった可能性が示唆されました