

1位解法

Rank	1
Team	tomoon33
Author	tomoon33
Topic ID	611846
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/rsna-intracranial-aneurysm-detection/discussion/611846>

Retrieved with Kaggle CLI on 2026-07-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

この意義深いchallengeをhostしてくださったRSNA、organizer、dataを提供したradiologistとinstitution、Kaggle teamに感謝します。このwrite-upでは私の1位解法をまとめます。中心となるのは、vessel segmentationでregion-of-interest (ROI) based classifierをguideし、location-aware predictionを出すrobustなcoarse-to-fine pipelineです。

Solution overview

High-level pipeline

1. **Preprocessing:** DICOM seriesをNIfTI volumeへ変換しstandardizeする。
2. **Vessel segmentation & ROI extraction:** coarse-to-fine nnU-Netを使う。高速なlow-resolution modelでcandidate regionを先に見つけ、詳細なhigh-resolution modelをこのROIだけへ集中させる。accuracyとspeedの両方が改善する。
3. **ROI classification:** 詳細なvessel maskをinputに使う3D classification modelで、13 anatomical locationとoverall aneurysm presenceのprobabilityを予測する。

Key design principles

- **Coarse-to-fine efficiency:** 高速なlow-resolution modelがvolume全体をscanしてcandidate regionを見つけ、high-resolution modelをROIへ集中させることでaccuracyとspeedを改善する。
- **Segmentation as a structural guide:** classification modelへ明示的なvessel maskを渡し、vessel structureの詳細なmapを与える。aneurysmが存在するvesselへmodelを集中させられる。

Data preparation

- orientation anomaly、corrupted DICOM、あり得ないslice spacingなどのdata-quality issueにより約60 seriesを除外した。
- multilabel-stratified 5-fold cross-validationを使った。

Pipeline

1. Preprocessing

- **Filter slices:** series内でmajorityの Rows × Cols および PixelSpacing configurationと一致するimageだけを保持し、interslice spacingがoutlierのsliceを除外した。
- **Convert DICOM to NIfTI:** `dcm2nii` で変換した。失敗時はfallbackとして `gdcmconv --raw` を先に実行し、再度変換した[1]。
- **Standardize orientation:** nnU-Netの `SimpleITKIOWithReorient` で全volumeを一貫したanatomical orientationへreorientした。

- **Normalize intensity:** nnU-Net標準のper-volume z-score normalizationを適用した。

2. nnU-Net segmentation + ROI extraction (coarse-to-fine)

3つのnnU-Net v2 model (nnUNetResEncUNetMPlans、3d_fullres configuration) を順に使い、coarse ROIを見つけてから内部の詳細なvessel segmentationを作る。

Model 1: Coarse vessel localization

- Spacing: (1.0, 1.0, 1.0) mm
- Classes: 3 vessel group (Posterior+Basilar / MCA / Other)
- Loss: Dice + Cross-Entropy
- Purpose: 高速なlow-resolution scanでhigh-resolution model用のsingle ROI candidateを効率的に見つける。後述のoptional orientation correctionにも使う。

Model 2: Fine segmentation (balanced)

- Spacing: (0.80, 0.45, 0.44) mm
- Loss: Dice + Cross-Entropy + SkeletonRecall (weight=1) [3]
- Purpose: precise vessel segmentationを生成する。SkeletonRecall lossは標準lossが見逃し得る細いvesselのconnectivityを改善する。

Model 3: Fine segmentation (recall-focused)

- Spacing: (0.80, 0.45, 0.44) mm
- Loss: Tversky + Cross-Entropy + SkeletonRecall (weight=3)
- Purpose: recallを優先してModel 2を補完し、見つけにくいvessel segmentへのsensitivityを高める。



Augmentation strategy

- anatomical asymmetryを保つためfine model (2, 3) のleft-right mirroringを無効化した。
- より強いintensity/geometric augmentationを使った[4]。
- thick slice scanへrobustにするlow-resolution simulation transformを加えた。

Two-stage inference

1. **Stage 1 (coarse scan)** : Model 1をsliding window (overlap=0.2) で実行してoutputをbinarizeし foreground maskを得る。DBSCAN clusteringで散在するfalse positiveを除去し、largest clusterのcentroidを中心に固定size ROI (140×140×140 mm) をcropする。
2. **Stage 2 (fine inference)** : coarse ROI内だけでModel 2, 3を高いoverlap (0.3) で実行する。Model 2のvessel segmentationからtight bounding boxを計算し、margin付きで再cropしてclassifier用final ROIを作る。

このstageの詳細なsegmentationをmaskとしてclassification modelへ渡す。




3. ROI classification (13 locations + Aneurysm Present)

ROIとvessel maskを準備した後、3D classification modelでfinal probabilityを予測する。


Model architecture


- **Input size:** 128 × 256 × 256 voxels のROI volume。
- **Backbone:** vessel segmentation taskでpretrainしたnnU-Net。standardな2.5D/3D timm backboneより accurateで、trainingも速かった。
- **Decoder simplification:** efficiencyのためdecoder末尾の計算量が大きいblockを除去した。performanceへの悪影響はなかった。
- **Auxiliary detection task:** annotated aneurysm位置に半径5 pixelsの小さなbinary sphereをdecoder feature から再構成するauxiliary taskを加え、aneurysm固有featureの学習を助けた。
- **Location-specific prediction head:**
 1. Vessel Region-Masked Pooling layerがvessel maskを使い、decoder feature mapから13 anatomical locationそれぞれのfeature vectorを抽出する。実際には両fine segmentation modelのmaskでpoolingし、結果をconcatenateする。
 2. 13 feature vectorをencoderのglobal feature vector (Global Average Pooling) とcombineする。
 3. combined featureをLocation-Aware Transformerへ入力し、vessel location間の関係をmodel化する。
 4. MLP headが13 locationのprobabilityを予測する。

- **Aneurysm Present head:** 全vessel maskのunionでvessel structure全体からfeatureをpoolし、encoder global featureとcombineして別のMLP headへ渡す。
- **Output design:** 14 labelをそれぞれ独立したbinary classification problemとして扱う。個別locationのpositiveが非常に少ないsevere class imbalanceに対応しやすい。



Vessel Region-Masked Pooling





Training details

Loss functions:

- 13 Locations: BCEWithLogitsLoss
- Aneurysm Present: BCEWithLogitsLoss
- Auxiliary sphere segmentation: Balanced BCE [5] + Focal-Tversky++ [6,7]。sparse targetに適し、Dice-like lossで起き得るover-confidenceを防ぐ。
- Loss weights: 13-location loss = 0.1、Aneurysm Present loss = 0.05、auxiliary sphere segmentation loss = 1.0。aneurysmの正確なlocation学習を優先し、sphere segmentationを最大weightとした。classification lossのweightを高くするとoverfitしたため、このbalanceが重要だった。

Data augmentation:

- Intensity: Gaussian noise/smoothing、intensity shift/scale、contrast adjustment、Gaussian sharpening、intensity inversion。

- Geometric: random flip (z/y/x axis) 、 small rotation ($\pm 10^\circ$) 、 scaling/shearing ($\pm 10\%$) 、 mild grid distortion、 simulated low-resolution transform。

Optimizer and schedule: AdamW、 learning rate $1e-4$ 、 gradient accumulationによるeffective batch size 8。warmup付きstandard cosine annealing。


EMA weights: inferenceにはmodel weightのExponential Moving Averageを使った。

Inference

- 5 cross-validation foldのうち4 foldのmodelを平均した。
- original volumeとleft-right flipped volumeのpredictionをTTAで平均した。

4. Other details

- **Fail-safe mechanism:** segmentation/ROI extractionでanomalyが起きた場合はpredictionを試みず、pre-determined probabilityへfallbackした。各classについてcross-validation OOF predictionのmeanを使った。
- **Optional orientation correction:** coarse segmentationの3 vessel groupのspatial arrangementを解析し、expected anatomical locationとのrelative position比較から正しいaxis permutationを推定する方法を実装した。training setで発見した全orientation issueを完全に修正したが、LB scoreへの測定可能な効果はなかった。test setに同種のorientation errorがなかった可能性が高い。



Processing time

training timeはsingle NVIDIA RTX 4090で計測。 $96 \times 192 \times 192$ inputは主に高速なexperiment/tuning用。

Model	Input size	Epochs	Training time
nnU-Net (Model 2)	$64 \times 192 \times 192$	1000	14 h
ROI classifier	$96 \times 192 \times 192$	30	6 h
ROI classifier	$128 \times 256 \times 256$	30	12 h

inference timeはKaggle notebookの2 T4 GPUで100 sample平均を計測。

Step	Time per series
Preprocessing	4.03 ± 3.78 s
Vessel segmentation	10.65 ± 4.10 s
ROI classification	3.33 ± 0.09 s

Ablation study

ROI classification modelのkey componentを検証した。簡略化したevaluationであり、epoch数やlearning rateなどをexperimentごとに再tuneしてはいない。fold 0、1、2でreduced input size $96 \times 192 \times 192$ を使った。

Model	Input size	AUC (Aneurysm Present)	AUC (13 Locations)	Score
Final model (full resolution)	$128 \times 256 \times 256$	0.915	0.916	0.916
Final model	$96 \times 192 \times 192$	0.907	0.898	0.902
Without Location-Aware Transformer	$96 \times 192 \times 192$	0.899	0.894	0.896
Using Dice instead of FocalTversky++	$96 \times 192 \times 192$	0.902	0.896	0.899
Setting all loss weights to 1.0	$96 \times 192 \times 192$	0.890	0.877	0.884
Without backbone pretraining	$96 \times 192 \times 192$	0.777	0.811	0.794
Without segmentation model 3	$96 \times 192 \times 192$	0.899	0.883	0.891
Without auxiliary segmentation loss	$96 \times 192 \times 192$	0.880	0.871	0.876

- vessel segmentation taskでのbackbone pretrainingが最重要で、scoreを大きく改善し、trainingもかなり速くした。多数のexperiment実行に役立った。
- Location-Aware TransformerとFocalTversky++は当初有効に見えたが、final scoreへの寄与は小さかった。他の改善やtuningのoverall effectが大きくなったためと思われる。

Design journey

1. 最初はvessel segmentationとaneurysm localizationのauxiliary headを持つsingle end-to-end 3D classifierを試した。aneurysm presenceはdetectできたが13 specific locationを正確に予測できなかった。

2. standard nnU-Netのvessel segmentationは容易に学習でき、全modalityへよくgeneralizeした。そこで segmentationをsubsequent classification taskのstrong guideとするtwo-stage vessel-first pipelineへ切り替えた。
3. image volumeとsingle binary vessel maskをconcatenateした2-channel inputの単純なmodelも試した。特定 labelのpredictionには対応mask（1 locationのmask、Aneurysm Presentならunion mask）を入力した。modelは単純だがpatient seriesごとに14 forward passが必要で、計算量が大きすぎた。
4. 最終的にsingle backbone pass + region-masked poolingを使い、accuracyとcomputational efficiencyの良い balanceを得た。

References

1. [DICOM conversion discussion](#)
2. Isensee, F., Jaeger, P. F., Kohl, S. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. Nature Methods, 18(2), 203-211.
3. Kirchhoff, Yannick, et al. "Skeleton recall loss for connectivity conserving and resource efficient segmentation of thin tubular structures." ECCV, 2024.
4. [MIC-DKFZ BYU 2nd-place solution](#)
5. [Balanced BCE reference solution](#)
6. Yeung, Michael, et al. "Calibrating the dice loss to handle neural network overconfidence for biomedical image segmentation." Journal of Digital Imaging 36.2 (2023): 739-752.
7. [Focal-Tversky++ reference solution](#)

Code release

- [Training code](#)
- [Submission notebook](#)

補足Q&A

Satwik（質問） : vessel segmentation nnU-NetのDice scoreはいくつでしたか。私は0.78近くでした。

Luca（質問） : segmentation ROI外にaneurysmはありましたか。その場合どう対処しましたか。また小さく missing labelも多いRight/Left PCAのDice scoreはどうでしたか。

Dennis（質問） : spacing (1.0, 1.0, 1.0) と (0.80, 0.45, 0.44) は実験で選んだのでしょうか。

LSL000UD（質問） : Location-Aware Transformerはどの程度結果へ寄与しましたか。loss weightはどう配分しましたか。

tomoon33（Satwikへの回答） : Model 2のvalidation Diceは約0.70でした。まだ改善余地はあります。ただし解法ではDice自体はそれほど重要ではなく、vessel segmentationをmaskingに使いました。そのためsmall regionと peripheral branchを中心にhigh recallを重視しました。

tomoon33 (LSL000UDへの回答) : Location-Aware Transformerは13 location labelのmacro AUCを約+0.02改善しました。lossはauxiliary segmentationへ比較的大きなweightを置き、aneurysm localizationの学習を優先しました。

tomoon33 (Dennisへの回答) : (0.80, 0.45, 0.44) はnnU-Net auto-configurationの提案値をそのまま使いました。(1.0, 1.0, 1.0) は時間とmemoryを節約するcoarse-scan path用のisotropicで粗いresamplingです。慎重なtuningはしていません。

tomoon33 (Lucaへの回答) : cleaned training setではvessel-based ROI外に10 aneurysm labelがあり、主に上方のoutlierでした。superior margin拡大も考えましたが、数が少なく、大きなROIはmemory/computeを増やすため変更せず、rare caseとして受け入れました。R/L PCA別のDiceは計算していません。PCAは小さいためSkeletonRecall lossでrecallを優先しました。segmentationはややover-inclusiveになりましたが、missは解消しました。

Dimpi Mittal (質問) : coarse-to-fine approachでinference speedをどう管理しましたか。latencyは増えましたか、それともscaleしてもefficientでしたか。

tomoon33 (回答) : 正確なtimeは共有できませんが、coarse-to-fineによりend-to-end latencyは増えませんでした。大きなCTA volumeでは通常、むしろ高速でmemoryもはるかに安定しました。