

5位解法（code付き）

Rank	5
Team	more CV challenge pls
Author	HoangHuyen
Topic ID	611849
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/rsna-intracranial-aneurysm-detection/discussion/611849>

Retrieved with Kaggle CLI on 2026-07-07.

2. Exp0: Aneurysm detection

私の経験では、classification label (train.csv) だけを使うより、classification labelとlocalization label (train_localizers.csv) を組み合わせた方が正確だった。そこでhostがtrain_localizers.csvで提供したlabelを基に、各aneurysm centroidの前後±10 sliceを探索し、Labellmgでaneurysmのbounding boxを手作業でannotateした。


aneurysm centroidはすでに提供されているため、この作業に専門的なmedical knowledgeは不要である。

2 classとした。

- aneurysm (modality: CTA、MRA、MRI T1post)
- aneurysm_mri_t2 (modality: MRI T2)

その後、YOLOv11x 1280を使って5 model (5 fold) を学習した。

metric	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
mAP50	0.705	0.647	0.766	0.702	0.691
mAP50-95	0.460	0.429	0.504	0.482	0.449



3. Exp1: Brain detection


training setの各 SeriesInstanceUID について全sliceを平均し、1枚のimageを生成する。

次にbrain bounding boxを手作業で次の2 classとしてannotateした。

- brain (axial viewのbrain)
- abnormal (ほかのviewのbrain)

series内の各sliceは、このmodelが予測したbounding boxに従ってcropする。これによりbackground noise (特にlung regionを含むsliceなど) が減り、model accuracyが約 **0.03-0.05**改善した。

yolov5n 640を使って1 modelを学習し、mAP50-95 = 0.948だった。



4. Image augmentation

```
train_transform = albu.Compose([
    albu.RandomResizedCrop(size=(self.image_size, self.image_size), scale=(0.5, 1.0), ratio=(0.75, 1.3333), p=1),
    albu.ShiftScaleRotate(rotate_limit=15, border_mode=0, p=0.5),
    albu.OneOf([
        albu.MotionBlur(blur_limit=5),
        albu.MedianBlur(blur_limit=5),
        albu.GaussianBlur(blur_limit=5),
        albu.GaussNoise(var_limit=(5.0, 30.0)),
    ], p=0.5),
    albu.CLAHE(clip_limit=4.0, p=0.5),
    albu.HueSaturationValue(p=0.5),
    albu.RandomBrightnessContrast(p=0.5),
    val_transform = albu.Compose([
        albu.Resize(self.image_size, self.image_size),
    ])
])
```

Horizontal flipは不合理に聞こえるかもしれないが、imageをhorizontal flipし、labelも次のように入れ替えた。

- Left Infraclinoid Internal Carotid Artery <-> Right Infraclinoid Internal Carotid Artery
- Left Supraclinoid Internal Carotid Artery <-> Right Supraclinoid Internal Carotid Artery
- Left Middle Cerebral Artery <-> Right Middle Cerebral Artery
- Left Anterior Cerebral Artery <-> Right Anterior Cerebral Artery
- Left Posterior Communicating Artery <-> Right Posterior Communicating Artery

これは有効で、model accuracyが約0.01改善した。

5. Exp2: 2 classification models

このcompetition datasetで、image size=384のmulti-label classification model (14 class) を2つ学習した。negative seriesでは全sliceを使い、positive seriesではsection 2で確認したaneurysm boxを含むsliceだけを使った。各sliceのlabelはtrain.csvにあるseries labelと同じである。

- vit large 384: OOF AUC = 0.8503
- eva large 384: OOF AUC = 0.8551

時間制約により予測に5 model (5 fold) は使えなかった。datasetのほぼ全体で学習し、evaluationには50 series だけを使ったsingle modelしか利用できず、best epochはPublic LBに基づいて選んだ。

6. Exp3: Multi-task classification + segmentation

RSNA datasetで1 model (mit b4 FPN) 、image size=384を学習した。Exp2と同じく、negative seriesでは全 slice、positive seriesではaneurysm boxを含むsliceだけを使った。各sliceのlabelは `train.csv` のseries labelと同じである。submissionにはclassification taskのpredictionだけを使った。segmentation taskのmaskはsection 2のaneurysm bounding boxから作った。

- mit-b4 FPN: OOF AUC = 0.8549

7. External dataset

competition datasetと次の2 external datasetを使った。

- [Lausanne_TOFMRA](#)
- [Royal_Brisbane_TOFMRA](#)

external dataのseries labelは2 model (Exp2のvit large + Exp3のmit b4) のpredictionから作り、localization labelはExp0のaneurysm detection modelのpredictionから作った。

8. Clean trainset

trainsetのnegative seriesのうち、2 model (Exp2のvit large + Exp3のmit b4) による Aneurysm Present prediction scoreが0.9を超えるものをpositiveへ変更し、Exp0のaneurysm detection modelでlocalization labelを作った。

9. Exp4: 2 classification models

cleaned RSNA dataset (section 8) と、pseudo labelingしたexternal dataset (Lausanne_TOFMRA + Royal_Brisbane_TOFMRA、section 7) で2つのclassification modelを学習した。

- vit large 384: OOF AUC = 0.8558
- eva large 384: OOF AUC = 0.8579

10. Exp5: Multi-task classification + segmentation

cleaned RSNA dataset (section 8) と、pseudo labelingしたexternal dataset (Lausanne_TOFMRA + Royal_Brisbane_TOFMRA、section 7) で1 model (mit b4 FPN) 、image size=384を学習した。

- mit-b4 FPN 384: OOF AUC = 0.8629

11. Final submission

final submissionは6 modelのensembleである。

```
Final1: 0.25 exp3_mit_b4 + 0.25 exp5_mit_b4 + 0.125 exp2_vit_large + 0.125 exp4_vit_large + 0.125 exp2_eva_large + 0.125 exp2_eva_large
```

```
Final2: 0.5 exp3_mit_b4 + 0.125 exp2_vit_large + 0.125 exp4_vit_large + 0.125 exp2_eva_large + 0.125 exp2_eva_large
```

- Final1: OOF AUC = 0.8823, Public LB = 0.89
- Final2: OOF AUC = 0.8767, Public LB = 0.89

補足Q&A

LSL000UD (質問) : modelを使ってdatasetをcleaningした際、合計何caseをcleaningしましたか。

HoangHuyen (回答) : negative caseを33件です。

Satwik (質問) : bounding boxを手作業でannotateした理由と、MRI T2のaneurysmを別classに分けた理由がありますか。classification modelは2.5D sliceだけで学習したのでしょうか。slice-wise classification modelのinferenceでは全sliceを推論してからaggregationするのですか。

HoangHuyen (回答) : 観察したcentroidに基づくと、MRI T2ではaneurysmが暗く見え、他modalityでは明るく見えます。はい、2.5Dです。GitHub repoで確認できます。全sliceを推論し、series predictionはz-axis (slice) 方向の最大値、つまり `num_slices x 14 -> 14 probs` です。

Hide on bush (質問) : final modelのensemble weightはどう計算しましたか。

HoangHuyen (回答) : いくつかのweight combinationを試し、OOF AUCとPublic LBが最も高くなるものを選びました。