

11位解法

Rank	11
Team	←→AB
Author	RihanPiggy
Topic ID	612186
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/rsna-intracranial-aneurysm-detection/discussion/612186>

Retrieved with Kaggle CLI on 2026-07-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

すべてのwinnerの皆さん、おめでとうございます。この興味深いcompetitionをhostしてくださったorganizerに感謝します。本当に難しいcompetitionでしたが、とても楽しめました。ここで私の解法を共有します。

TL;DR

解法は4 stageからなる。

1. TotalSegmentatorでbrain maskを生成し、CoW areaを含むROI regionをcropする3D U-Netを学習する。
2. 5-foldの2.5D CoW segmentation model (classification loss + segmentation loss) を学習してfeatureを抽出する。
3. 5-foldの2.5D aneurysm model (classification + keypoint loss) を学習してfeatureを抽出する。
4. CoW segmentation modelとaneurysm modelのfeatureをdepth方向にconcatenateし、RNNを学習する。

Preprocessing

TotalSegmentatorがこのlibraryを使っているため、[dicom2nifti](#)でDICOM fileをNIfTI fileへ変換した。

`train_localizers.csv`のcoordinateとframe indexを、NIfTI fileに揃った新しい値へ変換するcustom versionを実装した。

Stage 1: Brain mask

Brain mask generation

TotalSegmentatorを使って全scanのbrain maskを生成した。

奇妙なことに、一部のCT scanではTotalSegmentator CTよりTotalSegmentator MRIの方が良いbrain maskを生成した。そこで各scanについて2つのbrain maskを生成し、pixel数が多い方を選んだ。

1 million pixels未満のsmall maskも除外した。最終的に4386個のbrain maskを得た。

3D U-Net for brain segmentation

brainをsegmentする3D U-Netを学習した。training codeは[Qishen HaのRSNA2022解法](#)の再実装である。

まずTotalSegmentatorのtraining dataのsubsetであるZenodoの[CT scan](#)と[MRI scan](#)でmodelをpretrainし、その後4386 brain maskで学習した。5 foldで、input sizeは (128, 128, 128)。

学習済み3D U-Netで全scanのbrain maskを生成し、ROI regionをcropした。crop regionがCoW areaを含むよう、CoWSegと `train_localizers.csv` に基づいてcropping parameterを調整した。

Stage 2: CoW segmentation model

他のcompetitorとは異なり、良い3D CoW segmentation modelを学習できなかった。代わりにclassification head付き2.5D CoW segmentation modelを学習した。このmodelの目的はfinal RNNへ入力するpositional featureの抽出である。RSNA2022の経験ではpositional featureがCVを改善した。そのため2.5D modelのsegmentation lossが悪く（Dice=0.56）ても、抽出featureは有用だった。

training codeはUWMGIの[このnotebook](#)の再実装で、backboneは`tf_efficientnetv2_b0.in1k`（image size=224）。

Stage 1と同様に、CoW segmentation modelのOOF classification logitsを使い、CoW areaを含まないsliceをfilterした。

Stage 3: Aneurysm model

CoW segmentation modelと同様に、feature抽出用のclassification headとkeypoint headを持つ2.5D aneurysm modelを学習した。

学習を成功させた要点は次のとおり。

- 3 roundのnegative sampling。1 round目はCoW segmentation modelのclassification logitsを使い、vesselを含むsliceをsampleした。次の2 roundはaneurysm model自身のOOF classification logitsを使ってhard-negative sliceをsampleした。
- modelをvessel areaへ集中させるheuristic crop。全coordinateがcropped regionに入るようcoordinateに応じてcrop ratioを調整した。
- `alpha=0.75`のFocal loss。
- label noiseに対処するOOF logitsによるself-distillation。
- EMA。

使用したbackboneは次のとおり。

- `coatnet_rmlp_2_rw_384`: 5 fold、`img_size=384`
- `coatnet_rmlp_2_rw_384`: all-data training、`img_size=384`
- `tf_efficientnetv2_s.in21k_ft_in1k`: 別の5 fold、`img_size=384`

all-data trainingではhard-negative imageを少なくした別revisionのdatasetを使った。最初に5-fold modelを学習してbest CV epochを記録し、all-data trainingのtotal training stepを計算した。

Stage 4: RNN model

aneurysm modelごとに4種類のRNNを学習した。modelはすぐoverfitするため、EMAと強いMixUp（mixup ratio=0.5）でregularizeした。

5-fold CoAtNet

- Residual LSTM: aneurysm feature + CoW segmentation feature

- Residual GRU: aneurysm featureのみ
- BiLSTM: aneurysm featureのみ
- BERT: aneurysm featureのみ

5-fold EfficientNet

- Residual LSTM: aneurysm feature + CoW segmentation feature
- Residual GRU: aneurysm feature + CoW segmentation feature
- LSTM: aneurysm featureのみ
- BERT: aneurysm featureのみ

All-data CoAtNet

- Residual LSTM: aneurysm feature + CoW segmentation feature
- Residual GRU: aneurysm feature + CoW segmentation feature
- BiLSTM: aneurysm feature + CoW segmentation feature
- BERT: aneurysm feature + CoW segmentation feature

これらのRNN ensembleはAUC=0.8909へ到達した。OOF logitsによるself-distillationを使った別submissionはAUC=0.9035だった。

- submission 1: CV 0.8909、Public 0.87689、Private 0.82201
- submission 2: CV 0.9035、Public 0.86703、Private 0.81321

PublicとPrivateの大きなgapについては、今も非常に困惑している。

Maximizing GPU utilization

inference speedを最大化するため、MONAIを使ってGPU上でimageをpreprocessした。T4 x 2を使い、patient volumeを2つへ分割して2.5D modelのinferenceをparallelizeした。RNN modelは単純に2 groupへ分け、2 GPU上でparallelに実行した。これにより11個のaneurysm modelと45個のRNN modelのinferenceを12時間以内に完了できた。

最終日にはtimeout問題に苦しめられた。Kaggleが新evaluation frameworkを改善することを願っている。

補足Q&A

Tom (コメント) : 2.5D segmentationの活用が特に良い解法です。ただ、stageのどれかがoverfitを起こしているように見えます。generalizationを改善すれば1位になり得ると思います。

RihanPiggy (回答) : すべてのstageで同じK-foldを維持したため、training processにleakはないと考えています。Public LBはCVとかなりcorrelateしており、とても不可解です。test scanが異なるsiteから収集されていることを考えると、test dataのdomain shiftによりbrain segmentatorがうまく動かなかった可能性があります。もう一つの可能性はDICOM tagの問題です。orientationとscalingにtagを使っていたためです。