

csiro-biomass

合成データセット

Rank	2
Team	dino series
Author	Quan Vu
Topic ID	670664
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/csiro-biomass/discussion/670664>

Retrieved with Kaggle CLI on 2026-07-18.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

これは、Qwen-Image-Editを使って訓練データセットから生成した合成データセットです：

<https://www.kaggle.com/datasets/quan0095/csiro-synthetic-dataset>

画像回帰で合成データセットを使う際の主な難しさの一つは、ground truthの問題です。画像を変更すると、各targetのbiomass値もそれに応じて変化します。これに対処するため、私はpseudo-labelingを使いました。元の訓練データセットで学習したmodelを使って合成データセットのlabelを生成し、その後、元の訓練データセットと合成データセットを結合して最終modelを学習しました。

この合成データセットは、季節や天候の変化を再現し、砂利や石などのartifactを加えることで生成しました。

補足Q&A

外部のgrass/cloverデータセットがうまくいかなかった理由

Kh0a (質問・共有) : とても興味深いです。私は次のデータセットでpseudo-labelingを試しましたが、あまり成功しませんでした。

- <https://www.kaggle.com/datasets/usharengaraju/grassclover-dataset>
- <https://www.kaggle.com/datasets/amirmmahdavikia/irish-grass-clover/data>

Quan Vu (著者) : 私もこのデータセットで事前学習を試しましたが、結果は満足できるものではありませんでした。2つのデータセットには大きなdomain gapがあります。crop sizeやgrass typeが異なり、labeling protocolも違う可能性があります。

0 labelのbackground画像をどれだけ混ぜたか

Mohamed Eltayeb (質問・共有) : Banana Proを使い、画像内のgreenをすべてdeadへ変換しました。正しいtargetにするため、`green = clover = gdm = 0`、`dead = total = dead + green + clover` としましたが、うまくいきませんでした。

Quan Vu (著者) : 元の分布を歪めないよう、0 labelの割合を制限する必要があります。私が導入したlabel 0の画像は約10枚だけです（全357枚に対して約10枚）。

画像回帰へ合成データを適用することは、分類より難しいです。分類ではaugmentationを行ってもclassは変わりません（例えばcatはcatのままです）が、画像回帰では見た目を変更すると本質的にtarget値も変わります。私は当初、元のlabelを使って合成データを学習しましたが、LB performanceが低下しました。

Qwenをどこで、どのように使ったか

Komil Parmar (質問) : pseudo-labelingだったのですね。Nano Bananaを使うことも考えましたが、onlineで何枚も一つずつ作る必要があると思って断念しました。Qwenはlocal machineかColabへinstallしたのでしょうか。pipelineはありましたか。

Quan Vu (著者) : local環境で使いました。データセットには、データ生成に使ったscriptも添付しています。

Nano Bananaでも非常に高品質な画像を生成できましたが、local環境で大量の画像を生成する必要がある場合にはQwenの方が適しています。