

7位Solution — single/dual+TTT

Rank	7
Team	Genius Seed is all you need
Author	Boredom
Topic ID	670654
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/csiro-biomass/discussion/670654>

Retrieved with Kaggle CLI on 2026-07-18.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

素晴らしく魅力的なコンペを開催してくださったKaggleとsponsorに感謝します。非常に白熱した戦いでしたが、激しい競争の中で順位を守れたことを嬉しく思います。私にとってかけがえのない学習経験でした。ここから私たちのapproachを説明します。

私はコンペの途中でteamに参加し、teammateが作った優れたbaseline（LB 0.67）を土台にしました。baselineの詳細はteammateが後ほど説明します。

私のsolutionは2段階です。Stage 1で初期学習を行い、Stage 2でonline pseudo-labelingとTest-Time Training（TTT）を行います。

Stage 1

Model

Single-stream版: @shanzhong8によるDINOv3-Large+single-streamです。訓練・推論の両方で5 componentすべてを予測し、Softplus activation付きregression headを使います。学習中はparameterの最初の80%をfreezeしました。全体はshared feature extractor+task-specific headで、parameter efficiencyと関連regression task間のinductive bias共有を実現します。入力解像度は1024×2048で、超高解像度画像に対応します。TTAとTTTを使わないsingle model 5-foldでPublic 0.76、Private 0.65に到達しました。

Dual-stream版: DINOv3-Large+dual-streamです。学習時は5 componentすべてでsupervisionを行います。推論時は Dry_Green_g、Dry_Dead_g、Dry_Clover_g のみを予測し、GDM_g と Dry_Total_g は後から計算します（Softplus activationのheadを使用）。学習中はparameterの最初の80%をfreezeしました。

Loss

R^2 loss。

CV strategy

sampling date をgroup、stat をlabelとしてStratifiedGroupKFoldを使いました。元の3 dateでは5-foldに足りないため、WA dataを7つのvirtual dateへ細分化しました。全5 foldの分布が最も均衡するsplitを見つけるため、multi-threadで1,000万seedをbrute-force searchしました。

Augmentation (Albumentations)

Resize (single-stream: 1024×2048、dual-stream: 1024²)、HorizontalFlip、VerticalFlip、RandomBrightnessContrast、ColorJitter。

Training configuration

1. Optimizer: AdamW、lr=2e-4、wd=1e-2。
2. 各foldでbest-loss checkpoint上位3つとbest-score (CV) checkpoint上位3つを保持。この6 modelをSWA (Simple Weight Averaging) で結合し、一般化性能を高めた。

3. dual-stream modelでは、結合した画像をstreamへ分ける前にHFlipまたはVFlipを適用した。

Inference configuration

1. single-streamとdual-stream modelの結果を単純平均。
2. horizontal flip TTAだけを使用。

Stage 2 (TTT)

DINOv3以外のmodel heterogeneityがensembleに不足し、推論時間にもかなり余裕があったため、Test-Time Trainingを実装しました。

まずsingle-streamとdual-stream modelのensemble inferenceを、TTA有無の両方で行いました。効率化のため dual-GPU parallel inferenceを実装し、片方のGPUで5-fold single-stream、もう片方で5-fold dual-streamを処理しました。これで推論は大幅に高速化しました。

初期予測へ、Cloverを0.8倍し、0.2未満のcomponentを0にするなどのpost-processingを加えました。この結果を pseudo-labelとして使い、full training setとtest setを合わせ、LB/CVで最良のsingle-stream foldを学習しました。TTTは12 epochsで、最後の4 epochsへSWAを適用してoverfittingを防ぎ、一般化性能を高めました。その他のtraining configurationはStage 1と同じです。

single-streamとdual-streamを別GPUで並列にTTTすることも試しましたが、明確な改善はありませんでした。最終結果はStage 1とTTT予測を $0.2 * \text{Stage 1} + 0.8 * \text{Stage 2}$ でblendしました。

うまくいかなかったこと

1. SigLIP-2など、DINOv3以外のmodel architecture。
2. Mixup、CutMixと、そのさまざまな変形。
3. Auxiliary taskとauxiliary loss。
4. DINO embeddingとML modelの組み合わせ。
5. External dataset。そのほか、意味のあるgainを生まなかった多くのアイデア。

Inference code

[lb 0.77 | 0.65](#)

安定した改善をもたらすアイデアを見つけるのが、非常に難しいコンペでした。最後に皆さんへ感謝します。競い合えて光栄でした。

補足Q&A

TTTなしのsingle model score

BokingChen (質問) : 共有ありがとうございます。Test-Time Trainingを使わない場合、このsingle modelのscoreはいくつですか。

Boredom (著者) : 興味深いことに、single-stream 5-fold modelの一つはLBで0.65に到達しましたが、TTTありより僅かに低い結果でした。それ以外のTTTなしmodel (ensembleを含む) は、すべて一貫して0.64前後でした。

MixUpの確率とalpha

water joe (質問) : MixUp実験でのtrigger probabilityと λ はいくつでしたか。

Boredom (著者) : MixUpでCVとLBの両方が改善した、ということでしょうか。

water joe (補足) : 私は使いましたが、あなたは効果がなかったと書いています。scoreが小数2桁しか見えなかったので、本当に改善したか判断できません。実験ではtrigger probabilityが R^2 へ大きく影響し、 $p=0.5$ を超えるべきではないと分かりました。そのためparameterを質問しました。

Boredom (著者) : MixUp probabilityは0.5、alphaは0.3と0.4を試しましたが、うまくいきませんでした。私の場合だけかもしれませんが、他の方は成功した可能性があります。

Pseudo-labelとTTTの狙い

PursueML (質問) : hidden test dataを推論し、post-processing後にbest single-stream foldを12 epochs学習し、最後4 epochsでSWAを使った、という理解で合っていますか。また、pseudo-label生成ruleはLBへの複数回のprobeで決めたのでしょうか。この方法が本当に有効か疑問です。

Boredom (著者) : pseudo-labelingには、CV/LBを総合して最良だったsingle-streamとdual-stream modelの単純平均を使いました。Clover $\times 0.8$ などのpost-processingも使いましたが、正直なところ私も完全には納得しておらず、賭けのように感じます。

best foldをfull training setとpseudo-label付きtest setの両方で学習した狙いは、modelがoverfitする前にGround Truthとnoisy pseudo-labelの微妙な差を捉えさせることでした。ある意味ではadversarialなapproachに近いものです。