

13位Solution — Frozen DINOv3-7B+ Stacked Ridge

Rank	13
Team	Forrest_xlz
Author	Forrest_xlz
Topic ID	671818
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/csiro-biomass/discussion/671818>

Retrieved with Kaggle CLI on 2026-07-18.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

この難しいコンペを開催してくださったorganizerに感謝します。また、@zjayzzの[public notebook](#)にも感謝します。その仕事から素晴らしい視点と、このtaskを完了するための堅実なbaselineを得ました。Kaggleでこれほど良い結果を得たのは初めてです。このコンペから多くを学びました。以下で私の方法を紹介します。

概要

CSIRO Biomassのtraining setは非常に小さいため、overfittingを抑えtraining costをほぼ無視できるほど小さくするために、意図的に「frozen foundation model+軽量supervised head」というrecipeを採用しました。これはDINOv3のdownstream practiceともよく整合します。paperでは、DINOv3 backboneを完全freezeしても比較的小さなtask-specific adapter/decoderとの組み合わせで高い競争力を保つことが示されています。small-data regimeと効率的なmulti-task reuseに特に魅力的です。

pasture biomass predictionはglobal recognitionとdense understandingの中間にあります。局所領域（coverage、dryness、shadow、texture）が最終biomass targetへ不均等に寄与します。DINOv3はclassificationとdense prediction benchmarkの両方で一貫して強く、dense taskのlocal featureが大きく改善されたと報告されています。これは「local evidenceをglobal regressionへ集約する」ために求めるrepresentationそのものです。

具体的にはDINOv3をfeature extractorとしてfreezeし、multi-view representation+stacked Ridge regressorの単純かつ効果的なpipelineを構築しました。multi-scale（256/512/768）のleft-right viewで局所変動を捉え、multi-depth token tap（last layer+選択したintermediate block）でhigh-level semanticと、geometry/structure寄りのmid-level featureの両方を利用します。DINOv3のper-layer analysisではgeometry-heavy taskにintermediate layerが有効と示唆されており、mid-layer tapの動機になりました。

multi-resolution ensembleも有効でした。これはlocal featureを改善するhigh-resolution adaptationとmulti-resolution inferenceを重視したpaperの内容と整合します。

最後に、このfrozen+Ridge stacking設定では、backboneをLarge→Huge→7Bへscaleすると、ほとんど再tuningせずperformanceが改善しました。Ridge自体のtrainingはほぼ一瞬です。

コンペの理解

Leaderboard feedbackを使って理解を更新した方法

このコンペでは、自分がどの情報を持ち、それがどの程度信頼できるかを明示するよう努めました。

問題の理解は、competition descriptionとtraining data、自分のprior knowledge、Public LB scoreという3つのsourceから得ました。最初の2つは有用ですがnoiseも含まれます。直感、経験、関連paperのいずれから来たprior understandingにもbiasは避けられません。

そのため、最初の理解を真実とはせず、更新すべきprior beliefとして扱いました。Bayesianな意味で、Public LB scoreはpriorを修正するexternal signalとして機能しました。


この過程を、暗闇をtorchで進むことに例えて考えていました。直感は最初の方向を与えますが、地形の一部を照らすのはleaderboard feedbackだけです。自分のcodeでもpublic ideaの再現でも、各実験は問題の別の一部を示す小さなtorchです。局所的な観測を組み合わせ、taskのglobalな理解を徐々に作りました。

この考え方はmodel改善だけでなく、コンペ自体の構造を理解する助けになりました。small datasetがtraditional modelを有利にするか、forage quality recognitionがglobal informationとlocal patternのどちらに強く依存するか、どの仮説が実験結果で本当に支持されるかを考えました。

つまり、より良いscoreを探すだけでなく、score feedbackを使って問題理解を反復的に修正しました。

なぜtraditional modelをstackしたか


Small dataでの一般化性能



dataが少ない場合、traditional ML methodはdeep neural networkより一般化しやすいことがあります。このコンペのtraining setは357画像しかなく、比較的小規模でした。

序盤にdeep neural networkを使う多くの方法を試しましたが、CVとPublic LBに大きなgapがありました。その後、Ridge、XGBoost、LightGBMなどのtraditional modelをstackする方法へ切り替えると、CVとPublic scoreの関係が大幅に安定し、追加実験でleaderboard performanceを改善しやすくなりました。これが最終的にこの方向を選んだ理由です。

複雑なhyperparameter tuningなしで多くの実験ができる



強いperformanceには実験数が重要です。これはChris Deotteによる[writeup](#)から学びました。

少数のideaしか試さなければtop performanceへ到達するのは困難です。traditional modelはdeep neural networkより低levelのhyperparameter tuningが少なく、学習も高速です。そのためlearning rate、batch size、epoch数のようなdetail tuningに詰まらず、feature extraction、backbone selection、ensembleなどhigh-level designを反復する時間を増やせました。

強いbackboneでscaleしやすい

backboneをBase→Large→Huge→7Bへ強化すると、pipeline全体を最初から作り直さずに高scoreを得られることがよくありました。

より良いbackboneから良いfeatureを得れば、同じdownstream traditional modelですぐ試せるため、pipelineのscaleが容易でした。

Ridge vs. XGBoost vs. LightGBM

Model

Architecture

```
Input → Views
|
├─ Left-right split → {L, R}
└─ Scales  $S = \{256, 512, 768\}$ 

Frozen backbone
|
├─ DINOv3 ViT-7B (BF16 inference, final norm)
├─ token tap L0: last layer
└─ token taps L1,L2: mid blocks {35, 38}
→ Layers  $L = \{\text{last}, b35, b38\}$ 

View definition (9 views)
|
├─ Each view is a (scale, layer) pair:  $v = (s, \ell)$ , with  $s \in S$  and  $\ell \in L$ 
→ 3 scales  $\times$  3 taps = 9 views total
(e.g.,  $v1=(256,\text{last})$ ,  $v2=(256,b35)$ , ...,  $v9=(768,b38)$ )
```

```

Per-view embedding (computed independently for each v)
|
└ Patch tokens (drop CLS/prefix) → pool over patches: mean + max + min + signed-GeM(p=3)
→ embedding matrix E_v: [n_samples, d_v] where d_v = 4C
→ RobustScaler fitted/applied per view (per E_v)

Stacking (Ridge-only)
|
└ Level-1: one base model per view
  └ For each view v=1..9:
    MultiOutput Ridge_v(α=5): E_v → OOF predictions P_v
    where P_v is [n_train_samples, 5] (5 biomass targets)
  |
  └ Level-2: meta model per target
    └ For each target t ∈ {1..5}:
      X_meta(t) = concat of {P_v[:, t]} over v=1..9 → [n_train_samples, 9]
      Meta Ridge_t(α=1): X_meta(t) → ŷ_t

Dual label-space ensemble (outside meta)
|
└ Run the whole stack on raw y
└ Run the whole stack on log1p(y) → expm1 back
└ Blend: ŷ = 0.5·ŷ_raw + 0.5·ŷ_log

Outer ensemble + constraints
|
└ Repeat with n_folds ∈ {2, 3, 5} → average
└ Physics post-process: clip ≥ 0; GDM = Green + Clover; Total = GDM + Dead

Output: [Green, Dead, Clover, GDM, Total] per sample

```

これがmain model architectureです。詳細は下記notebookを参照してください。

重要な点

- **Multi-scale resolution** ensemble (256、512、768)
- **Intermediate-layer feature** tap (mid-block token 35、38)
- **Multi-pooling** aggregation (mean / max / min / signed-GeM)
- **Raw-space + log-space** ensemble (2回学習しraw spaceでblend)
- **High-resolution** feature extraction / inference
- 強く regularize された **Ridge regression** の inductive bias
- **Multi-fold** ensemble (異なる KFold 設定を繰り返して平均)

Ablation study

Ablation / variant	Public score	Private score
base	0.75696	0.64833
multi-scale (768のみ)	0.75332	0.64324
multi-scale (256, 512)	0.74585	0.63738

Ablation / variant	Public score	Private score
mid layerなし	0.74969	0.62957
mid layer (35のみ)	0.75466	0.64466
mid layer (38のみ)	0.75218	0.62950
ensemble fold (5のみ)	0.75493	0.64774
post processなし	0.75208	0.64986
raw-spaceのみ	0.74358	0.64147
average poolingのみ	0.72056	0.60662

うまくいかなかったこと

- **Stacked XGBoost** — 単純な設定を試しましたが改善しませんでした。

今後の課題

上のablation studyでは、最も影響の大きいcomponentはmid-layer featureとfeature pooling strategyです。どちらも抽出representationの品質へ直接影響するため、attention-based poolingなど、より強いfeature aggregation moduleを探ることが今後の方向になります。

Reference

- [DINOv3](#)
- [Stacked Generalization: An Introduction to Super Learning](#)
- [Stacked Generalization: when does it work?](#)
- [GeM pooling](#)

以下に、trainingとinferenceをend-to-endで実行するcodeと、このsolutionで使ったDINOv3-7B modelを示します。