

Recod.ai/LUC - Scientific Image Forgery Detection 2位解法 / SIFT マッチング（改訂版）

Rank	2
Team	shiba-inu
Author	shiba-inu
Topic ID	697809
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/recodai-luc-scientific-image-forgery-detection/discussion/697809>
Retrieved with Kaggle CLI on 2026-07-18.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、こんなにも素晴らしいコンペを開催してくださった主催者に感謝します。「科学研究の integrity（信頼性）を守る」という非常に意義深いテーマで、多くを学びました。

結果：Public 3位 → Private 2位（1564チーム中）

解法の概要

私の解法はディープラーニングベースのアプローチではなく、**古典的な特徴照合（SIFT + RANSAC）**を中心に、YOLOベースの前処理とカスタム後処理を組み合わせた3段階パイプラインで構築されています。

Stage 1: 有効領域の検出（YOLOv8によるパネル/テキスト検出）

↓

Stage 2: 特徴照合（SIFT + G2NN + RANSAC）

↓

Stage 3: 後処理（クラスタのマージ + 高精度マスク生成）

アルゴリズム全体の概要は下の画像に示すとおりです。

Stage 1: 有効領域の検出

後段の特徴照合ステージでは、グラフ領域が大量の偽陽性を生み、テキスト領域はキャプション部分での誤照合を引き起こします（例：「10 mm」の「mm」部分での照合）。これらは大幅な精度低下につながるため、除外が不可欠です。

この問題に対処するため、YOLOv8-m を使ってパネル検出モデルとテキスト検出モデルを学習しました。

パネル検出

グラフのような無関係な領域を除外するため、関連する領域（画像領域）のみを検出します。同時に、YOLOが検出を3クラスに分類します：**corn（トウモロコシ）画像**、**western blot タンパク質画像**、**その他の生物学的画像**。クラスを分ける理由は、最適なRANSACの inlier しきい値が画像タイプごとに異なるためです（後述）。

適切な学習データが存在しなかったため、**合成データを自動生成**することで対処しました。

- 時間の制約から、外部データ（BioFors データセット）から2,000枚のサブセットを使用
- コンペの authentic 画像から細胞/植物画像を分類・抽出
- 合成グラフ（散布図、折れ線グラフ、ヒートマップ、バイオリンプロット）を自動生成
- 上記をさまざまなレイアウトパターン（1×1、2×2、3×1 など）でランダムに配置して学習データを作成
- 異なるシードで学習した5つの YOLOv8-m モデルを Weighted Boxes Fusion (WBF) でアンサンブル

テキスト検出

既存のOCRソリューション（EasyOCR など）は精度が不十分でした。たとえば丸い細胞を文字「O」と誤認します。科学論文画像のテキストは歪みが最小限であるため、OCR専用のヘッドは不要と判断し、YOLOv8-m を**物体検出器**として学習しました。

- 低しきい値の EasyOCR 検出結果を手動修正してアノテーションを作成（約800枚）
- テキストのない画像にランダムにテキストを配置した合成データ（約2,000枚）を追加
- 背景色、文字色、フォント、回転、サイズに多様性を持たせて拡張
- 推論時、2つの画像サイズ（640、1280）でTTAを行い、両方の結果をマージ

Stage 2: 特徴照合

アグレッシブな SIFT キーポイント抽出

生物学的画像はテクスチャが非常に乏しく、デフォルト設定では十分なキーポイントを抽出できません。

- `contrast_threshold=0.001`（デフォルト 0.04 の約1/40）を使って大量のキーポイントを抽出
- 小さい画像（<1024px）は、特徴抽出の前に4倍にアップスケールし、その後座標を元のスケールに戻す

G2NN（Good-to-Next Neighbor）照合

L2距離の絶対値は画像間で大きく変動するため、固定しきい値は非現実的です。

G2NN（Good-to-Next Neighbor）を採用しました：照合距離をソートし、 $T_{n+1}/T_n > \alpha$ （ $\alpha=0.7$ ）となるブレイクポイントまでの一致のみを受け入れます。これにより、しきい値に依存しない照合を実現します。

高速化：KDTree

膨大な数のキーポイントのため、FLANN KDTree の近似最近傍探索を使って計算量を $O(N^2)$ から $O(N \log N)$ に削減しました。

RANSAC + 幾何フィルタリング

ここでは、Stage 1 で検出した有効領域内のキーポイントに基づいて照合特徴を検出します。検出には2つのサンプリング戦略を採用しました。

- **ローカルサンプリング**：画像全体から抽出したすべてのキーポイントに対して RANSAC を実行すると、膨大な計算時間がかかります。代わりに、抽出した全キーポイントからローカル領域内のキーポイントをサンプリングし、その部分集合に対して RANSAC を実行します。領域はキーポイント密度の高い順にサンプリングし、キーポイント数が一定のしきい値を下回るまで繰り返します。その後 H 行列を解析して、非現実的な変換（スケール4倍超、せん断変形など）を除外します。
- **グローバルサンプリング**：全一致に対して一度 RANSAC を実行し、その後 HDBSCAN クラスタリングを適用して誤照合を除去。

さらに、Stage 1 で検出した3クラスに基づいて、画像タイプごとに RANSAC の inlier しきい値を調整しました。

- **corn 画像**：細かい白黒の線パターンが頻繁に誤照合を生むため、inlier しきい値を高く設定して厳しくフィルタ
- **タンパク質画像 (western blot)**：特徴が非常に少なく照合が本質的に難しいため、inlier しきい値を低く設定して少ない一致でも検出可能に
- **その他の生物学的画像**：中間のしきい値を使用

Stage 3: 後処理

特徴照合の後、**丁寧なクラスタリングが不可欠**だと分かりました。これを欠くと、F1スコア（コンペの指標）が大幅に低下します。高精度なクラスタリングを実現するため、以下の処理を実装しました。

2段階のクラスタマージ

- **Stage 1 (同一ペア内)**：H行列が近いクラスタ（回転角・スケール・並進の正規化差 < 0.02 ）を Union-Find でマージ
- **Stage 2 (異なるペア間)**：source/dest の bbox 間の IoMin (Intersection / min(area1, area2)) ≥ 0.3 のとき、同一インスタンスとしてマージ

高精度マスク生成

- マージしたクラスタの全対応点から H行列を再計算
- 凸包 + 膨張で source/dest マスクを生成
- H行列の変換誤差 (mean + 2σ 以内) を使ってマスクを精密に refine
- 逆変換を使って双方向に refine を適用

うまくいかなかったこと

- **他の特徴記述子 (SURF, ORB, AKAZE, SuperPoint)**：生物学的画像ドメインで十分なキーポイントを抽出できず、精度が低かった
- **ディープラーニングベースのアプローチ**：DINOv2/SegFormer バックボーンと self-correlation モジュールを組み合わせた CMFD モデルを試したが、精度が不十分だった

まとめ

Component	Details
Panel Detection	YOLOv8-m $\times$ 5 (WBF アンサンブル)、合成データで学習
Text Detection	YOLOv8-m、手動アノテーション + 合成データ
Features	SIFT (contrast_threshold=0.001)
Matching	G2NN ($\alpha=0.7$) + FLANN KDTree

Component	Details
Geometric Estimation	Affine RANSAC + H行列フィルタリング
Clustering	HDBSCAN + 2段階マージ (H類似度 → IoMin)
Mask Refinement	凸包 + H変換誤差ベースの refine