

5位解法 — DINOv3 セマンティックセグメンテーション

Rank	5
Team	Guanshuo Xu
Author	Guanshuo Xu
Topic ID	697699
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/recodai-luc-scientific-image-forgery-detection/discussion/697699>
Retrieved with Kaggle CLI on 2026-07-18.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Kaggle と Recod.ai/LUC に、この興味深いコンペを開催してくださったことを感謝します。私は Private リーダーボードで5位になりました。

最終スコア：

- Public LB: 0.422
- Private LB: 0.376
- [inference code](#)
- training code は末尾に添付

概要

私の解法はシンプルさと頑健さを重視しました。このタスクを主に**セマンティックセグメンテーション問題**として扱いました。

学習用のマスク生成では、画像に複数のコピー・ムーブのインスタンスが含まれる場合、すべての改ざん領域の**和集合**を学習ターゲットとしました。言い換えると、モデルはインスタンスセグメンテーションモデルではなく、二値の「改ざん領域セグメンター」として学習されました。

推論時も、複数のコピー・ムーブのインスタンスを分離しませんでした。これは意図的な簡略化です。

最終スコアに最も大きく寄与した要因は2つです。

- 汎化を改善するために外部データセットを使ったこと。
- 入手可能な最強の事前学習済み DINOv3 バックボーンを使ったこと。

検証

主に、ホストが提供した48枚の supplemental 画像でモデルを検証しました。これらの多パネル画像が、実際のテストセットに最も近いからです。

バックボーンとセグメンテーションヘッド

事前学習済みの DINOv2/DINOv3 バックボーンに、非常にシンプルなセグメンテーションヘッドを使用しました。

モデルは ViT バックボーンの最終パッチトークンを取り、それを2次元の特徴グリッドに reshape し、単一の 1×1 Conv2d ヘッドを適用して1枚のロジットマップを生成します。

学習時は、正解マスクをパッチグリッドの解像度に合わせてダウンサンプリングしました。

- DINOv2 では 14×14
- DINOv3 では 16×16

推論時は、低解像度マスクを予測した後、単純に双線形補間で元の画像サイズにリサイズしました。

拡張 (Augmentations)

最も有用だった拡張は、シンプルな画像レベルの拡張でした。

```
A.RandomRotate90(p=1.0)
A.HorizontalFlip(p=0.5)
A.GaussianBlur(p=0.15)
A.ToGray(...)
A.HueSaturationValue(...)
A.RandomBrightnessContrast(p=0.9)
A.ImageCompression(p=0.25)
```

かなりアグレッシブな色拡張を使いました。改ざんの信号は必ずしも色に固有ではないためです。モデルは、色の分布を暗記するのではなく、構造的・局所的な一貫性の手がかりを学ぶ必要がありました。

重要な学習の選択

- BF16 autocast
- 全パラメータのファインチューニング (Full fine-tuning)
- FlashAttention-2
- 入力画像サイズ：1024 × 1024
- Vanilla BCE loss

重要な推論の選択

- T4 GPU の 16GB メモリ制限に収めるための 8-bit 推論
- SDPA attention
- 入力画像サイズ：1024 × 1024
- 4方向の rotate90 テスト時拡張 (TTA)

後処理

後処理パイプラインはシンプルでした。

- 固定しきい値を使って高信頼の二値マスクを作成する。
- この高信頼マスクの面積を、アクティブなピクセルを合計して計算する。
- 高信頼領域の面積が `min_area` より小さければ、そのサンプルを `authentic` と分類して停止する。
- 設定したしきい値 `mask_thr` を使って最終的な二値マスクを作成する。
- 最終マスクにアクティブなピクセルがなければ、そのサンプルを `authentic` と分類して停止する。

初期の結果

DINOv2 モデルから始めました。supplemental 画像での検証スコアはわずか **0.092** でしたが、提供された学習セットの分割での検証スコアははるかに高いものでした。

学習データを調べたところ、データセットは小さくはないものの、含まれる画像タイプの多様性が限られていることが分かりました。その結果、ファインチューニングしたモデルは、視覚的にかなり異なる supplemental セットにうまく汎化しませんでした。

外部データセット

汎化を改善するため、学習データの多様性を増やせる外部データセットを探しました。最終的に次のデータセットを追加しました。

- [CASIA](#)
- [GRIP](#)
- [FAU](#)

supplemental 画像での検証結果は次のとおりでした。

Training data	Validation score
Competition training set only	0.092
Competition training set + CASIA	0.185
Competition training set + GRIP	0.095
Competition training set + FAU	0.129
Competition training set + CASIA + GRIP + FAU	0.240

これらの外部データセットは生物医学のものではありませんが、その多様性がモデルにより汎用的なコピー・ムーブ検出の手がかりを学ばせるのに役立ちました。

より良いバックボーン

コピー・ムーブ検出は難しいタスクなので、より強力な事前学習済みバックボーンが大きな差を生みました。

バックボーンを DINOv2 Giant から DINOv3 Huge+ へアップグレードすると、検証スコアがそれ以前の範囲から **約 0.35** に改善しました。この2つのモデルはサイズが比較的近いので、改善は主に DINOv3 のより強い事前学習から来ていると考えています。

その後、オリジナルの **DINOv3 7B** モデルを使い、検証スコアはさらに **0.51** まで改善しました。追加のハイパーパラメータ調整で、最良の検証スコアは **0.56 を超えました**。

全体として、最終的な解法はシンプルなままでした。強力な事前学習済み ViT バックボーン、最小限のセグメンテーションヘッド、多様な学習データ、軽量な後処理です。