

birdclef-2026

3rd Place Solution (3位解法)

Rank	3
Team	kapenon
Author	kapenon
Topic ID	704420
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704420>

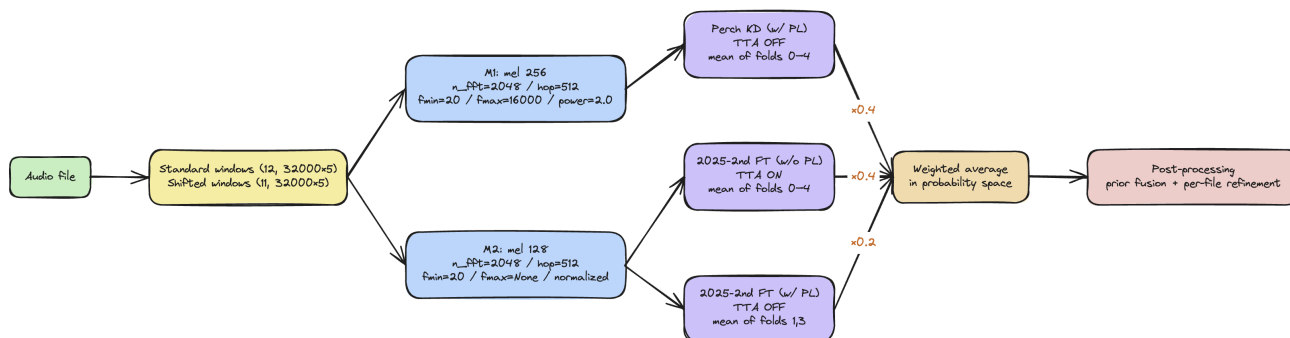
Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文 (Kaggle Discussion) : <https://www.kaggle.com/competitions/birdclef-2026/discussion/704420>

推論 (Inference)

推論は OpenVINO ランタイム上で実行しています (モデルは IR フォーマット)。



アンサンブル設計

アンサンブルによって大きなスコア向上が得られることが分かったので、以下のポイントを変化させることで、各メンバーをできるだけ異なるものにしました。

- **特徴量 (Features)** : Perch KD は mel(256, fmax=16000, power) を使用し、2025-2nd FT モデルは mel(128, fmax=None, normalized) を使用。
- **バックボーン (Backbone)** : Perch KD は `seresnext26t` を使用し、2025-2nd FT モデルは `efficientnetv2_s` を使用。
- **学習レシピ (Training recipe)** : Perch KD 対 2025-2nd FT、擬似ラベル (PL) の有無、そしてハイパーパラメータ。

Perch KD と 2025-2nd FT (w/o PL) は特徴量とアーキテクチャの両方が異なっており、このペアがスコアを最も押し上げました。2 つの 2025-2nd FT バージョンは mel とアーキテクチャが同じであるため、w/ PL の重みは 0.2 と低めに抑えました。

TTA

- $0.4 \times \text{標準} + 0.3 \times \text{隣接するシフトウィンドウの重み付き平均}$ 。

後処理: prior fusion (事前確率の融合)

- **site / hour / site×hour** ごとに、各種 (species) が `train_soundscape_labels.csv` にどのくらいの頻度で出現するかを数え、事前確率 (prior probabilities) を構築します。
- サンプル数 N に基づいて各バケットを全体平均に向けて引き寄せます ($w = N / (N+K)$ 、 $K_{\text{hour}}=8$ 、 $K_{\text{site}}=8$ 、 $K_{\text{sh}}=4$)。
- それらを $\text{logit}(\text{prediction}) + 0.2 \times \text{logit}(\text{prior})$ で組み合わせ、その後 sigmoid で元に戻します。

後処理: per-file refinement (ファイル単位の補正)

1. **file_confidence_scale**: 各クラスについて、上位 2 ウィンドウの平均を信頼度スコアとして用い、すべてのウィンドウに $\times(\text{conf}^{0.4})$ を掛けます。これにより、全体的に弱いファイルを下げます。
2. **rank_aware_scaling**: 各クラスのファイル単位の最大値を使って $\times(\text{max}^{0.4})$ を掛けます。少なくとも 1 つのウィンドウに強い証拠がない限り、そのクラスを下げます。
3. **adaptive_delta_smooth**: 時間軸方向の信頼度ベースの平滑化。各ウィンドウを、その両隣 2 ウィンドウの平均に向けて $\alpha = 0.20 \times (1 - \text{max_prob})$ でブレンドします。これにより、確信度の高いウィンドウはほぼ変化せず、確信度の低いウィンドウほど強く平滑化されます。
4. $[0, 1]$ にクリップします。

後処理は公開ノートブックに大きく依拠しています。オリジナルの作者にクレジットを付けたいのですが、原典を見つけられなかったため引用は省いています。

学習 (Training)

私はサンプリング戦略に特に注意を払いました。Macro ROC-AUC + 極端な不均衡、focal→soundscape のドメインギャップ、soundscape にしか存在しない種、そして site バイアス、これらはすべてサンプリングに帰着します。そのため、希少種のアップサンプリング、focal/soundscape のバッチ比率、site の重み付けを慎重にチューニングしました。

モデルは大きく 2 つのファミリーに分かれます。

1. **2025-2nd FT**: [BirdCLEF 2025 2位レンピ](#) のチェックポイントから出発し、SED モデルを単純にファインチューニングします。
2. **Perch KD**: Perch v2 を教師 (teacher) とした知識蒸留 (knowledge distillation) で学習します。
[@tuckerarrants](#) さんの [Distilled SED Baseline](#) をベースにしています。

最終的なアンサンブルはこれら 2 つのファミリーから構築され、以下の 3 つのモデルで構成されています (mel 列の M1/M2 は推論図のブランチに対応しています)。

Model	Backbone	mel	PL	Weight	TTA	Fold
2025-2nd FT (w/o PL)	<code>efficientnetv2_s</code>	128 (M2)	No	0.4	ON	0-4
2025-2nd FT (w/ PL)	<code>efficientnetv2_s</code>	128 (M2)	Yes	0.2	OFF	1,3
Perch KD (w/ PL)	<code>seresnext26t</code>	256 (M1)	Yes	0.4	OFF	0-4

2025-2nd FT (w/o PL)

データ

- focal (train_audio、追加の iNat または XC) — バッチ比率 0.95、ハードラベル (primary + secondary)
- ラベル付き soundscape ウィンドウ — バッチ比率 0.05、ハードラベル

モデル / パラメータ

- 234 クラス、32 kHz、5 秒ウィンドウ、mel(128)、5 folds
- `tf_efficientnetv2_s_in21k` + AttHead (SED)、BCE + Focal (label smoothing 0.005)
- AdamW (lr=5e-4) + CosineAnnealingWarmRestarts、epochs=20、batch=128
- データ拡張: wave mixup / SpecAugment / RandomFiltering / 希少種アップサンプリング
 - **SpecAugment**: mel に対して適用 — 周波数マスク 1 つ (幅 ≤ 10) に加えて時間マスク 2 つ (幅 ≤ 10) 。
 - **RandomFiltering** (2025 年 2 位解法より) : 波形を STFT し、周波数軸に沿って `n_bands=4` 個のランダムなゲイン (-20 to 0 dB) を線形補間して作った EQ カーブを適用し、その後 iSTFT で波形に戻します。これにより周波数応答にランダムな変化を加えます。

2025-2nd FT (w/ PL)

データ

- focal (train_audio) — バッチ比率 0.7、ハードラベル (primary + secondary)
- ラベル付き soundscape ウィンドウ — バッチ比率 0.1、ハードラベル
- ラベルなし soundscape ウィンドウ — バッチ比率 0.2、擬似ラベル (ソフト、sigmoid 確率)

モデル / パラメータ

- 234 クラス、32 kHz、5 秒ウィンドウ、mel(128)、5 folds
- `tf_efficientnetv2_s_in21k` + AttHead (SED)、BCE + Focal (label smoothing 0.05)
- AdamW (lr=1e-3) + CosineAnnealingWarmRestarts、epochs=20、batch=64
- データ拡張: wave mixup / SpecAugment / RandomFiltering / 希少種アップサンプリング

擬似ラベル (Pseudo labels)

- 1 ラウンドのみ生成 (反復ループなし) 。
- 生成元のモデルはこのモデルと同じ設定で学習しており、バッチ比率のみを focal 0.9 / ラベル付きウィンドウ 0.1 に変更 (擬似ラベルなし) しています。
- ラベルなし soundscape ウィンドウは、site バイアスを減らすために `1/sqrt(site_count)` でサンプリングします。

Perch KD (w/ PL)

データ

- focal (train_audio) — バッチ比率 0.7、ハードラベル (primary + secondary)
- ラベル付き soundscape ウィンドウ — バッチ比率 0.1、ハードラベル
- ラベルなし soundscape ウィンドウ — バッチ比率 0.2、擬似ラベル (ソフト)

モデル / パラメータ

- 234 クラス、32 kHz、5 秒ウィンドウ、mel(256)、5 folds

- `seresnext26t_32x4d` + `DistillHead` + `SEDHead`、分類損失 (classification loss) + 蒸留損失 (distillation loss)
- AdamW (lr=5e-4) + 2-epoch warmup + CosineAnnealing、epochs=25、batch=64
- データ拡張: wave mixup / gain / noise / time shift / focal mixup / SpecAugment / 希少種アップサンプリング

擬似ラベル (Pseudo labels)

- 1 ラウンドのみ生成 (反復ループなし)。
- 生成元は 3 つのモデルのアンサンブルです。
 - 2025-2nd FT (w/o PL)、`tf_efficientnetv2_s_in21k`
 - Perch KD (w/ PL)、`seresnext26t_32x4d`
 - Perch KD (w/o PL)、`eca_nfnet_l0`
- ラベルなし soundscape ウィンドウは、site バイアスを減らすために `1/sqrt(site_count)` でサンプリングします。

推論カーネル (Inference Kernel)

<https://www.kaggle.com/code/kapenon/birdclef2026-3rd-place-submission>

おわりに (Closing)

私自身のアイデアは、公開情報に基づいた手法には勝てなかったため、最終的な解法はディスカッションや過去コンペの上位解法のアイデアの寄せ集めになりました。この 3 位という結果は、惜しみなく知識を共有してくださった皆さんのおかげです。

ホストと Kaggle チームにも感謝します。