

birdclef-2026

4位解法: BirdCLEF+ 2026

Rank	4
Team	BirdCLEF+ 2026 Team
Author	Starry
Topic ID	704309
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704309>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文（Kaggle Discussion）：<https://www.kaggle.com/competitions/birdclef-2026/discussion/704309>

BirdCLEF 2026 — 4位解法

チームメンバー全員に感謝します！シェイクダウンが起きなかったのを見られてうれしいです。Public 上位 10 チームの多くが大きく順位を落とすなか、幸いにも私たちは Private LB が最も高い提出を選択できていました。

概要

私たちの解法は、Perch v2 の生体音響（bioacoustic）基盤モデル、独自に学習した 2 つの SED（Sound Event Detection、音響イベント検出）モデル、そして Perch から蒸留した 2 つの SED モデルを組み合わせた 5 モデルのアンサンブルです。BirdCLEF 2025 の 2 位解法による事前学習済み XC バックボーン、Perch の知識蒸留（KD）、および分類学的な後処理を用いたマルチモデルのブレンディングを活用しました。

モデル一覧表

	perch	v2s	v2s_2025_2nd	v2s_perch_distill	se26_perch_distill
Type	Foundation	SED	SED (OpenVINO)	SED + Distill	SED + Distill
Backbone	Perch v2	EfficientNetV2-S-IN21K	EfficientNetV2-S-IN21K	EfficientNetV2-S-IN21K	SeriesResNext26d-32x4d
Pretrain	Perch v2 (Google)	2025 2nd place XC pretrain	2025 2nd place XC pretrain	2025 2nd place XC pretrain	2021/22/23/24 data pretrained
Mel bins	—	128	128	256	256
Hop size	—	256	512	512	512
fmin / fmax	—	40 / 14000	20 / None	20 / 16000	20 / 16000
Mel power	—	2.5	2.0	2.0	2.0
Duration	5s	10s	5s	5s	5s
Batch size	—	256	64	64	64
Epochs	—	40	50	30	30
LR	—	5e-5	1e-4	5e-4	5e-4
Optimizer	—	AdamW	AdamW	AdamW	AdamW

	perch	v2s	v2s_2025_2nd	v2s_perch_distill	se26_perch_distill
Scheduler	—	CosineAnnealing	CosineWarmRestarts	Warmup+Cosine	Warmup+Cosine
Loss	—	Weighted BCE	FocalBCE	BCE	BCE
Balanced sampler	—	✓	✓	✓	✓
Mixup	—	Audio-level mix (p=0.5)	Half-mix (p=0.5)	Audio-level mix (p=0.5)	Audio-level mix (p=0.5)
SpecAug	—	✗	FreqMask + TimeMask	FreqMask + TimeMask	FreqMask + TimeMask
Random Filtering	—	✗	✓ (STFT-based)	✗	✗
Soundscapes (5x)	—	✓	✓	✓ (labeled SC)	✓ (labeled SC)
Pseudo labels	—	✗	✗	0.938 SED and 0.934 PerchDistill, 0.5 threshold	0.938 SED and 0.934 PerchDistill 0.5 threshold
Standalone LB	~0.928	~0.938	~0.930	~0.942	~0.942
Ensemble weight	0.40	0.182 (0.70 in SED)	0.078 (0.30 in SED)	0.085 (0.25 in PDENS)	0.255 (0.75 in PDENS)

学習の詳細

perch

Google Perch v2 の生体音響基盤モデルを、ファインチューニングなしでそのまま使用しました。単独の予測器としての役割と、アンサンブル内でのプロトタイプランカー（prototype ranker）としての役割の両方を担います。

v2s

私たちのベースライン SED モデルです：

- **Backbone:** EfficientNetV2-S-IN21K。BirdCLEF 2025 の 2 位解法の事前学習済み重みを用い、2026 のコンペティションデータ上で 234 クラスのヘッドでファインチューニングしました
- **Data:** コンペティションの train + soundscapes（5 倍にアップサンプリング）+ 外部データ（iNat/XC、種ごとに threshold=100）
- **Augmentation:** 音声レベルのミキシング（50%）、周波数フィルタ SpecAug は無効化

まず Starry の BirdClef 2025 コードから着手しました。最初に、2021/22/23/24 のデータを用いて SED モデル（tf_efficientnetv2_b3 バックボーン）を BCE 損失で事前学習しました。これは約 0.897 のスコアでした。使用し

たパラメータは以下の通りです: mel_bin: 192 f_min/f_max: 40/140000 n_fft: 2048 win_length/hop_size: 1024/512 train/infer durations: 10/5s

public LB 改善の道のり（単一モデル、実行時間: 約 20 分）

Methods	Scored
Baseline	0.897
remove spectrum aug / mel mixup / upsample labeled soundscapes	0.910
use last year efv2s pretrained models	0.928
add time prior generated by claude code	0.935
hop_len -> 256, mel_bin -> 128, mel_power -> 2.5	0.938

v2s_2025_2nd

2025 年 2 位の SED アーキテクチャを、2026 向けに最小限の変更で再現しました:

- **Backbone:** EfficientNetV2-S-IN21K。構造・事前学習済み重みのいずれも 2025 年 2 位のもの
- **Loss:** Focal BCE ($\alpha=0.25$, $\gamma=2.0$)
- **Augmentation:** STFT ベースのランダム周波数フィルタリング、周波数/時間マスキング、半分の割合での音声ミキシング
- Kaggle 上での CPU 効率的な推論のため、**OpenVINO** IR 形式に変換

v2s_perch_distill & se26_perch_distill（Perch の知識蒸留）

このパイプラインは [tuckerarrants](#) の公開コード を改変したものです。そこにいくつか小さな変更を加えています。

これらのモデルは、鳥の種を分類すると同時に [Perch v2](#) の埋め込みと整合するように学習されます:

Architecture:

- SED バックボーン (EFv2-S または SeriesResNext26d) + 追加の蒸留投影ヘッド (Linear $\rightarrow$ 1536 次元の Perch 埋め込み空間)
- 周波数方向の集約のための Generalized Mean pooling (学習可能な指数)
- 時間方向のアテンション + 分類ヘッド

Training:

public LB 改善の道のり（単一モデル、実行時間: 約 20 分）

Methods	Scored
baseline (efv2b3 backbone)	0.914
use last year efv2s pretrained models	0.934
0.934 PerchDistill model and 0.935 SED model as teacher to generate unlabeled soundscapes pseudo labels	0.942

Methods	Scored
modified to seresnext26d_32×4d backbone	0.942

アンサンブルと後処理

アンサンブルの重み

Group	Models	Inner weight	Outer weight
perch	perch	—	0.40
SED blend	v2s	0.70	0.26 (total)
	v2s_2025_2nd	0.30	
PDENS blend	v2s_perch_distill	0.25	0.34 (total)
	se26_perch_distill	0.75	

ブレンド戦略: Rank-gating composite（ランクゲーティング合成）。perch を種のランキングプロトタイプとして機能させ、SED の信頼度スコアをゲーティングすることで、より弱い SED モデルが希少種で偽陽性を持ち込むのを防ぎます。

後処理パイプライン

- Genus smoothing（属レベルの平滑化、 $\alpha=0.12$ ）**：同一の分類学上の属（genus）に属する種は、互いに確率を平滑化します。共起する近縁種に有効です
- Time-of-day prior（時間帯事前分布、 $\alpha=1.0$ ）**：種ごとの時間別活動分布をすべての予測に適用します
- Sonotype mirroring**: 合成された音のバリエーションは、そのグループの最大予測値を共有します
- Fat-tail temporal smoothing（裾の重い時間平滑化）**：カーネル半径=3、重みは $\text{distance}^{-1.5}$ に比例

推論パイプライン（Kaggle CPU-4 制約）

すべての推論は、動的な CPU バジレットスケジューラを用いて Kaggle の 4 vCPU 制限内で実行されます：

Budget: 4 vCPU total, 2 vCPU per lane

Timeline:

```
[0s]  perch (2 CPU) + v2s_perch_distill (2 CPU) → start together
[Xm]  perch done → v2s starts (2 CPU)
[Ym]  v2s_perch_distill done → v2s_2025_2nd starts (2 CPU)
[Zm]  v2s done → se26_perch_distill starts (overlaps v2s_2025_2nd tail)
[Wm]  All done → BLEND
```

v2s_2025_2nd は CPU 効率的な推論のため OpenVINO で提供され、perch は ONNX Runtime で提供されます。

うまくいかなかったこと

- **自前の XC 事前学習**: 独自のバックボーンを 814K の XC 録音（約 7,489 種）でゼロから事前学習しようと試みましたが、結果は一貫して、[2025 年 2 位解法](#)の事前学習済み重みを直接使う場合よりも悪くなりました。
- **標準的な擬似ラベリング (PL)** : アンサンブルした SED モデルの出力を soundscape セグメントのソフトラベルとして使っても、性能は向上しませんでした。基盤モデルによる Perch ベースの擬似ラベルのみが、意味のある改善につながりました。
- **AnuraSet の外部データ**: AnuraSet のカエルの録音を含めると、ドメインの不一致により LB がわずかに低下しました。
- **外部データの種ごとの threshold >100**: ノイズが増える割に改善はわずかでした。

見落としている点があるかもしれません。何でも気軽に質問してください！

補足Q&A

質問者 (Ethan Kershner) : 素晴らしい成果、そしてチームの皆さんおめでとうございます！ 気になっているのですが、皆さんはクロスバリデーションの手法を見つけることができましたか？ こう尋ねるのは、私は private と public のリーダーボードで大きく順位を落としてしまったので、どうすればこれを防げたのだろうかと考えているからです。いろいろな CV の手法を試しましたが、私にはどれもうまく機能しませんでした。ローカル CV が public LB での改善と相関することが一度もありませんでした。

著者 (Starry) : あなたが気にされていることは、私が 2023 年に BirdClef シリーズのコンペに参加し始めたときに気にしていたことそのものです。つまり、信頼できるクロスバリデーション戦略が見つからない、ということです。答えは少しがっかりさせるものかもしれません。私は今でも信頼できる CV 戦略を見つけられていません。私はただローカルでモデルを学習し、提出して、参考としてのスコアを得ます。それから学習戦略を調整し、また提出します。言い換えれば、public LB を CV として使っているのです。public LB への過学習を避けるために私が唯一やっていることは、ハイパーパラメータを過度にチューニングするのではなく、直感的なアイデアを見つけようということです。

質問者 (chenwenqiang_001) : おめでとうございます。v2s についてもう少し詳細を教えてくださいませんか？ どうやってグループ化するのですか？ focal と soundscapes はどのように使うのですか？ mixup はバッチ内でミックスするのですか？ weighted bce の重みはどのように設定するのですか？

著者 (Starry) : すみません、グループについてもう少し説明していただけますか？ focal とラベル付き soundscapes については、ラベル付き soundscapes を 4 倍にアップサンプリングし、focal のサンプルと連結しています。mixup については、答えはイエスで、バッチ mixup です。bce の重みは負例と正例で 1:19 です。

質問者 (chenwenqiang_001) : 丁寧にお答えいただきありがとうございます。私が言いたかったのは、どのように fold に分割するか、ということです。groupkfold か stratifiedkfold のどちらを使いますか？ v2s は 1 つの fold だけを使うのですか？ 負例について、これは nocall のサンプルのことですか？ 外部データを負例として使っているのですか？

著者 (Starry) : 私たちはすべてのデータを学習に使い、train セットの小さな部分（10%）を検証セットとして使っています。つまり検証セットは意味を持ちません。そして負例については、このタスクはマルチラベル分類タスクなので、負例とはターゲットクラス以外の出力の予測を指します。