

birdclef-2026

6位解法

Rank	6
Team	Sinan Calisir
Author	Sinan Calisir
Topic ID	704949
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704949>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文 (Kaggle Discussion) : <https://www.kaggle.com/competitions/birdclef-2026/discussion/704949>

皆さん、こんにちは。

主催者およびホストの方々に心から感謝します。そして、すべての入賞者の皆さん、おめでとうございます。この2か月間、このコンペティションを本当に楽しむことができました。

TL;DR: 多様なバックボーンによってそれぞれ独立に生成したソフトな疑似ラベル (pseudo-label) 、スペクトログラムを共有するOpenVINOアンサンブル、そしてpublicなPerchモデルとのランクブレンド。

はじめに

私は過去のBirdCLEFやその他いくつかのオーディオ系コンペティションに参加してきましたが、勝つためのテーマは常に同じでした。すなわち、多様性 (diversity) 、事前学習 (pretraining) 、より多くのデータを用いた疑似ラベリング (pseudo-labelling) 、そして巧妙な後処理のトリックです。私はこのレシピに従い、ソリューションのあらゆる段階を多様化することを試みました。

私のソリューションは (他の複数チームと同様に) 昨年の1位および2位の解法をベースにしています。私は2位のコードを出発点として使いました。それを [こちら](#) で公開してくれた [@vialactea](#) 氏と [@vladimirsydor](#) 氏に心から感謝します。

バリデーション

soundscapeのみでのバリデーションです。サイト (site) で層化したファイル単位の分割を行い、各foldで**すべてのtrain_audio**を学習に使用しました。それ以外については、LB上でも妥当に見える変更のみを採用しました。やや緩いやり方ですが、過去の年でも同様のシグナルが見られたので、これで進めることにしました。

モデリング

すべてのバックボーンに共通するセットアップで、5秒のウィンドウを用います。

- **Mel:** sample_rate=32000, n_mels=128, n_fft=2048, hop_length=512, f_min=20, normalized=True, fixed_amplitude_to_db=True
- **Augmentation:** mixup p=0.5 (波形レベル) , SpecAugment (周波数/時間マスク, p=0.3) , RandomFiltering(min_db=-20)
- **損失 / サンプリング:** BCE focal loss、sqrtクラス重みを用いたclass-balanced sampler
- **最適化:** 1e-6までのcosine decay、label smoothing 0.05、バッチサイズ64 (SwinV2: 32) 、val ROC-AUC上位3チェックポイントに対するSWA
- **バックボーンごと:** ECA-NFNetとEfficientNetV2にはRAdam lr=1e-3 + fp32、SwinV2にはAdamW lr=5e-4, wd=0.05 + bf16-mixed
- **エポック数:** 30~50、後半の疑似ラベルラウンドではより少なく、最終モデルはわずか10エポックのみ学習

SwinV2は正方形の入力を必要とするため、そのブランチではmelを256×256にリサイズしています。

疑似ラベリング

ループの流れは以下の通りです。

- ラベル付きsoundscape + train_audioで学習する
- ラベルなしsoundscapeにラベルを付け直す (relabel)
- 再学習する
- これ以上改善しなくなるまで繰り返す

ECA-NFNetとSwinV2では3ラウンド、EfficientNetV2では2ラウンド（昨年のtf_efficientnetv2_s_in21k_pretrain_from_bigXCV2Ext_swa.ckptから開始）を実施しました。各トラックは独立に実行し、最終学習では最終ラベルをアンサンブルしました。

疑似ラベルなしでは、モデルのスコアは0.900～0.915でしたが、最終ラベルを用いると、5-foldのECA-NFNetとSwinV2は単独で0.945～0.950に達しました。

- ラベルは**ソフト**です。すなわち、いずれかの種で $p \geq 0.55$ となればそのセグメントを残し、0.05未満の確率はゼロにして、教師 (teacher) の生の確率をそのまま学習しました。0.55という閾値は、held-outのS22セグメントで健全性チェックを行い (precision ≥ 0.8 となる最も低い閾値)、ソフトターゲットはそれ自体が不確実性を含んでいるため、ハードラベルの最適値よりわずかに低く設定しました。さまざまな閾値も試しましたが、0.55が一貫して最もうまく機能しました。
- さらなる多様性のため、EfficientNet教師の確率については、閾値処理の前に時間方向のスムージング（近傍セグメントとの平均化）とべき乗変換（1.5乗）を施しました。

アンサンブル

すべてのモデルが同じmel入力を共有しているため、各アンサンブルを**単一のOpenVINOグラフ**としてエクスポートしました。すなわち、生の波形を (batch, 160000) で入力し、log-melを**一度だけ**計算し、各サブモデルがそこから分岐し（例えばSwinV2の256×256リサイズ）、グラフは内部で重み付き平均された確率 (batch, 234) を出力します。このアプローチにより、アンサンブルモデルで7～8分節約できました。

私のモデルからの最終アンサンブルは以下の通りです。

- ECA-NFNet + EfficientNetV2 - それぞれ5 fold
- ECA-NFNet + SwinV2 - それぞれ2 fold（時間制限のため）

それぞれ約40～45分で実行され、public 0.950～0.951 / private 0.954のスコアでした。

public Perch/ProtoSSMを蒸留したSEDブランチ + 最終ブレンド

publicノートブックでPerchがいかに強力かを見て、しかも自分のアンサンブルには1つもなかったもので、これを追加するのは自然な次のステップでした。自分自身のPerchパイプラインを構築しようと2～3週間費やしましたが、競争力のあるものにはできなかったため、publicノートブックを直接統合しました。ここでの私の貢献はあまり多

くなく、主に推論時間を節約するため、実行のたびに再学習するのではなく、学習済みモデルが読み込まれるようにした点です。それを自分のアンサンブルと等重みでランクブレンドしました。

```
out[prob_cols] = 0.5 * a[prob_cols].rank(pct=True).values + 0.5 * b[prob_cols].rank(pct=True).values
```

TTAも一貫して結果を改善しましたが、推論時間の面でアンサンブルのサイズと競合するため、私はその予算をより多くのモデルに使うことを選びました。選択した提出（submission）は両方ともゴールドに達し、より良い方（ECA-NFNet + SwinV2をPerchとブレンドしたもの）は最終的に**private 0.95762**となりました。

うまくいかなかったこと

- 10秒/20秒の入力。
- 自分のアンサンブルにおける、時間方向スムージングを超える後処理（top-k、ファイル単位のスケールリング）。一貫した改善を示したのは時間方向スムージングだけでした。これはおそらく、私のパイプラインで閾値を用いて疑似ラベルを扱う方法に起因していると思います。
- その他のバックボーン（resnest50d, convnext, seresnext26d, regnety_040, rexnet_150）は大きな改善を示さなかったため、計算資源を節約するためにマルチラウンドのセットアップには持ち込みませんでした。
- ソフトラベルの代わりにハードラベル。
- 他のモデルに適用したのと同じ疑似ラベリングのレシピをPerchに適用すること。

コーディングツールに関する作業メモ

私はコンペティションを通してClaude Codeを使用しました。主に元のコードベースを適応させるためです。いくつか気づいた点を挙げます。

- **アイデアは私から、実装はClaudeから。** 新しい実験に創造性を期待したときはいつも、それは期待に届きませんでした。私が次のステップを決め、コードの処理をClaudeに任せました。
- **メモリは諸刃の剣だった。** Claudeは実験に関する議論の「重要な」部分を自身のメモリに保存しましたが、時にはそれが打ち切った実験まで含んでいました。数日後、新しい実行を、私たちがすでに捨てたアイデアと比較することがありました。増え続ける実験リストとともにこれを管理するのは負担になりました。
- **コンテキスト面での優位性。** エージェントが結果を見られるようにW&Bを統合しましたが、緩いバリデーションセットしかなかったため、public LBから得た私の知識、W&Bのログ、そして過去の解法は、モデル自身のコンテキストに対する大きな優位性でした。

読んでいただきありがとうございました！

参考文献

- <https://www.kaggle.com/competitions/birdclef-2025/writeups/nikita-babych-1st-place-solution-multi-iterative-n>
- <https://www.kaggle.com/competitions/birdclef-2025/writeups/volodymyr-vialactea-2nd-place-journey-down-the-rab>
- https://github.com/VSydorskyi/BirdCLEF_2025_2nd_place
- <https://www.kaggle.com/code/tuckerarrants/bc2026-distilled-sed>