

birdclef-2026

Private 9位 | Public 2位 解法 - ランダム性との戦い

Rank	9
Team	Yannan Chen
Author	Yannan Chen
Topic ID	704887
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704887>

Retrieved with Kaggle CLI on 2026-07-03.

原文 (Kaggle Discussion) : <https://www.kaggle.com/competitions/birdclef-2026/discussion/704887>

概要

これは私にとって初めての音響 (acoustic) コンペティションであり、このコミュニティから膨大なことを学びました。メルスペクトログラム、STFT、フレーム単位 vs クリップ単位の教師信号など、そのほとんどは皆さんのノートブックやディスカッションを読むことで学んだものです。主催者、Cornell Lab、Kaggle、そして共有してくださったすべての方々に心から感謝します。

もしこのコンペティションが私にとって何か一つのことだったとすれば、それは**ランダム性との戦い**でした。評価指標はノイズが多く、ローカル検証はシード間で約±0.02、private LBは約±0.005も変動します。そのため、ほとんどの「改善」はシグナルと運の混じり合ったものであり、本当の仕事はそれらを見分けること、すなわち重要な場所で検証し、複数シードで再実行し、生き残ったものだけを残すことでした。以下は、私がpublicリーダーボードで徐々に順位を上げるのに役立った主要な要素すべてです。一部はprivateでも機能することが判明し、一部はほぼ中立的でした。

1. バックボーン

私は昨年 (2025年) のXeno-Cantoで事前学習されたEfficientNetV2-Sバックボーンを使用しました。これはVladimir Sydorskyy 氏のおかげであり、彼の2025年の事前学習済みバックボーンを土台に構築しました。このドメインに適した事前学習は、アーキテクチャ上のどんな工夫よりも重要でした。

私はまた、アンサンブルを多様化させるためにいくつかの代替バックボーン (hgnetv2_b4、regnety032、seresnext26t) を自前で事前学習しましたが、どれも機能しませんでした。eca_nfnetが最も惜しく、多様性のために残しましたが、private LBでは同じように弱いものでした。

私が想像していた多様性は本物ではありませんでした。EfficientNetこそが王者でした。

私はまた、メル設定の微調整 (マルチメル、fminのスweep、より細かいhop、すべて無意味) も諦めました。メルのフロントエンドは事前学習と結び付いているため、単一の固定設定を維持しました: `sr=32000, n_mels=128, n_fft=2048, win=2048, hop=512, fmin=20, fmax=16000`

2. 学習

CV戦略

- **4フォールド 分割**: focalは `primary_label` によるStratifiedKFold、ラベル付きサウンドスケープは `filename`によるGroupKFold (再現性のため固定分割)。
- **サウンドスケープのみで検証**し、フォールド全体のmacro-AUCの平均を参照指標として使用。ただしそのLBとの相関は理想的ではない。

- AdamW、lr 5e-4、weight_decay 1e-4、batch 64。
- **flat-cosineスケジュール**、合計30エポック = 2 warmup + 20 flat + 8 cosine。
- **EMA**（decay 0.999、エポック3から追跡、検証と保存重みの両方に使用）。EMAは学習を大幅に安定させ、指標の曲線を明らかに滑らかにしました。
- **BCE loss** はクリップレベルのロジットと、**フレームレベル**（フレーム最大値）のロジットの両方に適用。
- **min_sample = 100**（各希少focalクラスを100セグメントまでアップサンプリング）。これはpublic LBスコアに実質的で一貫した向上をもたらします。

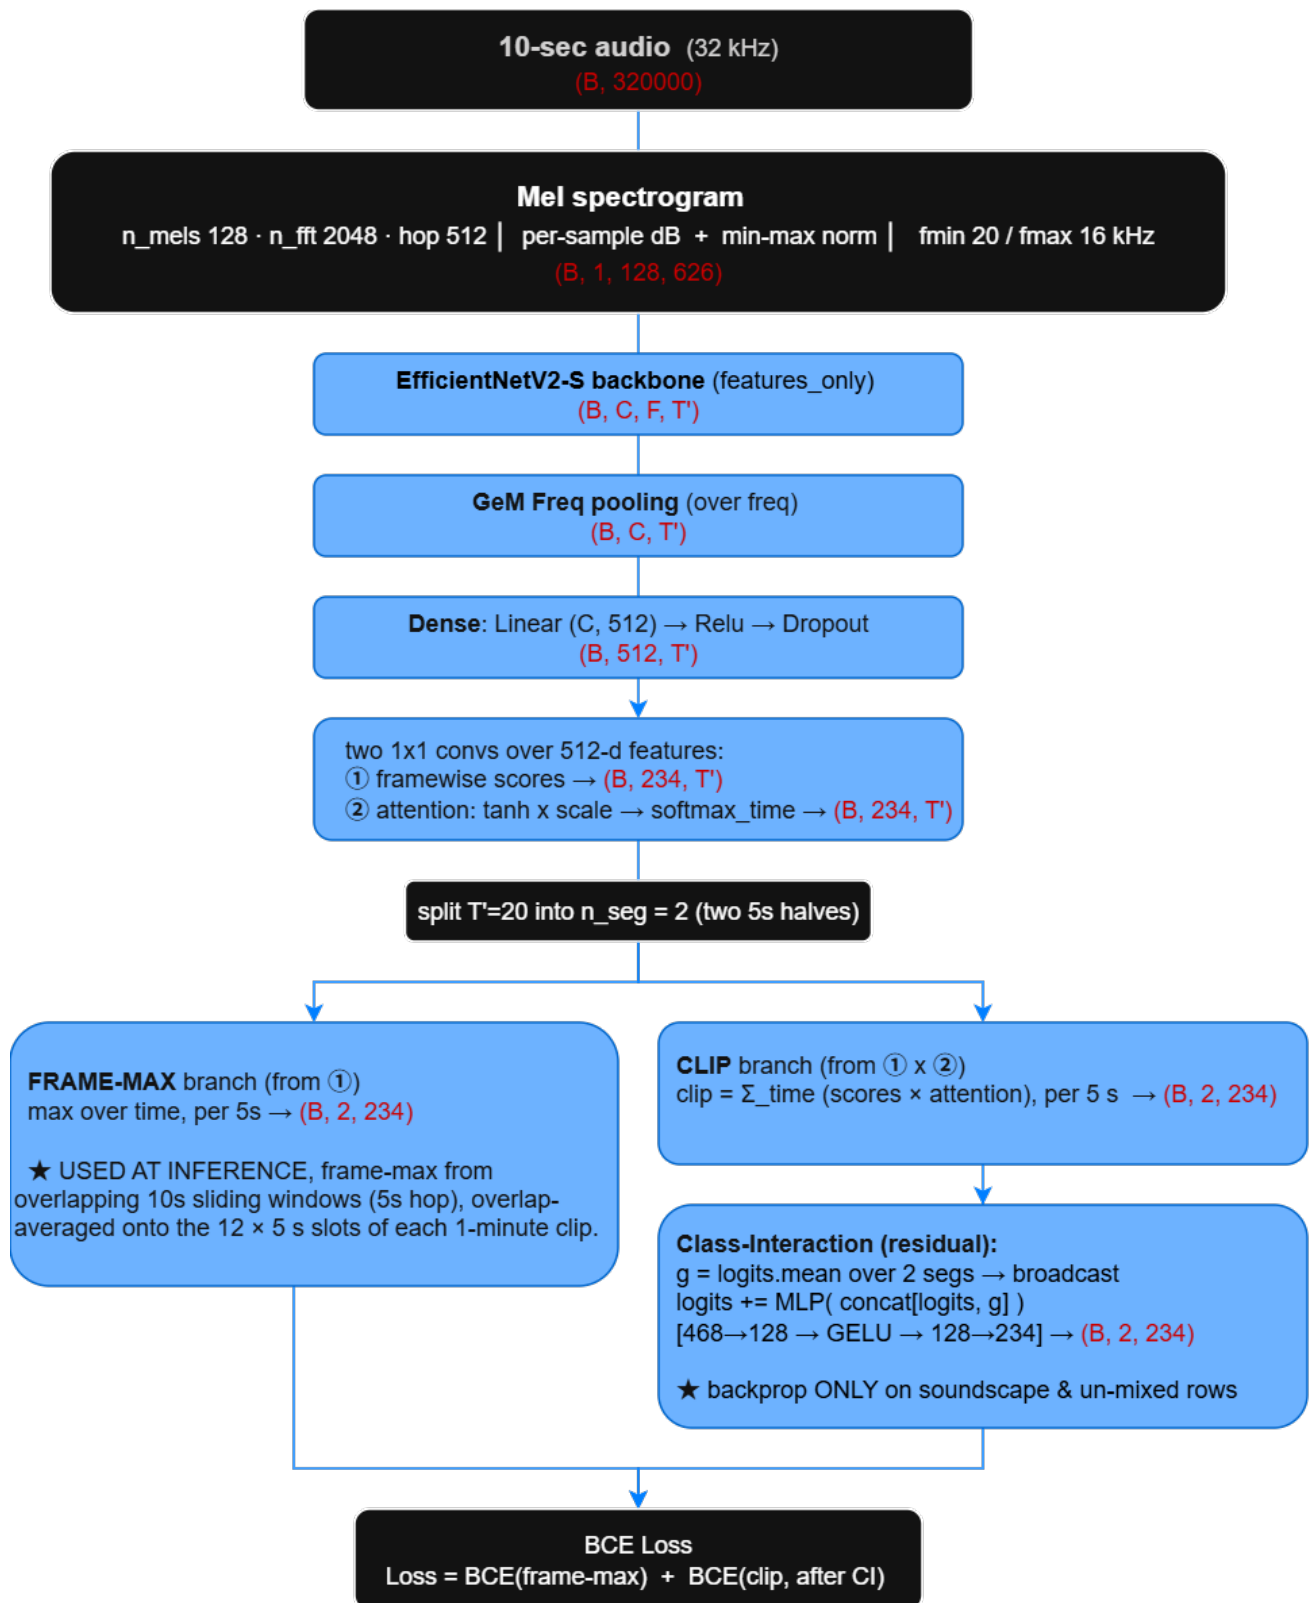
MixUp は、**focal → サウンドスケープのドメインギャップ**を橋渡しするもう一つの重要なつまみでした。ほぼすべての学習データがfocal（クリーンで、ほとんどが単一種のXeno-Cantoクリップ）であり、サウンドスケープはごくわずかしかなり利用できないという事実のため、各バッチのfocalクリップをペアで混合し、サウンドスケープのような複数種のサンプルを合成します。これにより、主にfocalで学習したモデルがサウンドスケープの予測に転移します。2つの設計上の選択がこれを機能させます（MixProb=0.5、MixAlpha=0.4、n_max=2）：

- **メル変換の前に、生波形上で混合**（各クリップは最初にabsmax正規化）。
- **focalと希少なサウンドスケープで非対称な役割**。focalクリップのみがパートナーを混ぜてもらいます。**ラベル付きサウンドスケープのセグメントはクリーンに保たれ**（左側では決して混合されず、perm[i]=i）、希少な実サウンドスケープの教師信号は純粋なアンカーとして残ります。ただしそれらは場合によっては、focalクリップに混ぜ込まれるパートナーとして機能することもあります。Beta(0.4) はU字型なので、ほとんどの混合は一つの大音量 + 一つの微かなクリップとなり、背景の鳴き声に対する前景の鳥というサウンドスケープを模倣します。

```
lam = Beta(0.4, 0.4).sample((B,)) # U-shaped: usually one loud + one faint
# eligible = focal clips only; partner may be focal OR a (rare) labeled-soundscape segment
perm = partner_index(eligible, exclude=unlabeled_pool) # labeled-SC kept clean on the left
(perm[i]=i)
wav = lam[:,None]*wav + (1-lam)[:,None]*wav[perm] # raw-waveform mix, before the mel
label = lam[:,None]*label + (1-lam)[:,None]*label[perm] # multi-hot label mix
# only p=0.5 of samples are actually mixed
```

3. アーキテクチャ

私のすべてのモデルは標準的なSED（Sound Event Detection）スタック（EfficientNetV2-S → GeMFreqプーリング → attentionヘッド → クリップ + フレームロジット）に従っており、**10秒ウィンドウ**、**2サブセグメント**です。その上に、私は****クラス間相互作用モジュール（class-interaction module）****を追加しました。これはクリップ単位のロジットに対する小さな残差的なクラス×クラスの精緻化（Linear→GELU→Linear、ゼロ初期化）です。



クラス間相互作用（class-interaction）モジュールは、パンタナールの実際の種の共起（この湿地帯で実際に一緒に出現する種）のみを学習するように設計されています。これは混合されていないラベル付きサウンドスケープサンプルからのみ勾配を受け取ります。focalデータとmixupされたサンプルはこれをスキップします。ゼロ初期化から始まり、このクリーンな事前分布を徐々に拾い上げていきます。

決定的に重要なのは、**クラス間相互作用と10秒/2ウィンドウは、ほとんど一緒に効果を発揮する**ということです。public LBでは、5秒/1でのクラス間相互作用（exp_B）は**0.939**で横ばいのままですが、10秒/2（exp_D）と組み合わせると**0.952**に跳ね上がります。

```
# the CI MLP now takes 2*n_cls inputs: [own-segment logits, global mean]
self.ci = nn.Sequential(nn.Linear(2*n_cls, 128), nn.GELU(), nn.Linear(128, n_cls))

def apply_ci_pool(logits, mask):
    # logits: (B, n_seg, n_cls); mask =
    is_soundscape & is_unmixed
    if mask.any():
        # ONLY these rows get refined (and only they
        backprop into ci)
        g = logits.mean(dim=1, keepdim=True).expand(-1, n_seg, -1) # broadcast to each seg
        logits = logits.clone()
        logits[mask] = logits[mask] + self.ci(torch.cat([logits[mask], g[mask]], dim=-1)) # each
        seg sees [self, global]
    return logits
```

私はより長い長さ（15秒、20秒）も試しましたが、10秒がスイートスポットでした。それ以上長くしても何も得られませんでした。

4. 外部データ

私はpublicなソース（Xeno-Canto / iNat）から234の対象種に対して追加サンプルを取得し、**1種あたり200件**に上限を設けて学習に追加し（検証は変更せず）、同じパイプラインを再学習しました。これにより、疑似ラベルの蒸留を一切使わずに、public LBがさらに**0.958**まで押し上げられました。

5. 推論時の後処理

私は2つの後処理手法のみを使用しました：

- **分類群を考慮したスムージング（Taxon-aware smoothing）**：テクスチャ分類群（Insecta/Amphibia、連続的な鳴き声）は平均スムージングを受け、イベント分類群（Aves/Mammalia/Reptilia、一過性の鳴き声）は局所最大+小さな適応的シフトを受けます。これにより、**ピークの信頼度を平坦化することなく近傍がクリーンアップ**されます：

```
out[:, texture] = (1-a_tex)*p[:, texture] + a_tex*neighbor_mean(p[:, texture]) # a_tex ~ 0.35
out[:, event] = (1-a_evt)*p[:, event] + a_evt*neighbor_localmax(p[:, event]) # a_evt ~ 0.15
```

- **File-post**（クレジット：[BirdCLEF 2025 2位](#)）：各セグメントの種ごとの確率は、ファイル全体でのその種のトップ確率によって強化され、1分間クリップのどこかに確実に存在する種の信頼度を高めます：

```
probs = probs.reshape(n_files, 12, n_cls) # 12 five-second slots per 1-min file
file_top = probs.max(axis=1, keepdims=True) # per-file, per-species top prob
probs = probs * file_top # reinforce species confident somewhere in the file
```

苦労して学んだ警告：**サイト/時間の事前分布ブレンド（site/hour prior blend）**は**早期（LBが約0.95未満のとき）には役立ちましたが、その後は悪影響を及ぼし始めました。それは私の実験を密かに汚染していました（すべての比較が、正味でマイナスに転じた後処理ステップの上で実行されていた）**。私はこれに非常に遅れて気づき、それ以降は完全に削除しました。

★ 段階的なアブレーション

以下の表は主要な実験をまとめたものです。これはセクション1〜4のコンポーネントに対する段階的なアブレーションであり、すべてセクション5の同じ後処理を共有しています。ローカル検証セットが小さく、指標がノイズが多いため、各設定を複数のランダムシードで実行し、public LBが最良のものを報告します。

exp	dur/n_seg	recipe	public LB	private LB
exp_A	5s/1	baseline	0.939	0.944
exp_B	5s/1	baseline + class-interaction	0.939	0.947
exp_C	10s/2	baseline + 10s	0.946	0.948
exp_D	10s/2	baseline + 10s + class-interaction	0.952	0.950
exp_E	10s/2	baseline + 10s + class-interaction + external data (cap 200)	0.958	0.955

6. Noisy Student

次のステップは、前のステップで学習した最良の生モデルを使用することから始めて、ラベルなしのサウンドスケープを活用することです。Noisy-Studentによる疑似ラベリングの各ラウンドは次のように進みました：現在の最良のアンサンブルを取り、ソフトラベルを抽出し（ノイズを抑制するために**1.3〜1.4乗**でシャープ化）、それらを次のラウンドにMixUpのターゲットとして投入し、学習し、そして提出し、最良のものを残して、再生成する。約2ラウンド後、単一の（マルチフォールド）モデルが**public LB約0.96**に達しました。

これは確実にpublic LBを約0.01加算しました。private LBでは効果はやや不明瞭です：疑似ラベルはラウンド全体でprivateをほぼ**0.95付近で安定**させました（私の最良の生モデルであるexp_Dの0.950から、0.951〜0.953まで上昇）が、すでに強力な外部データのラウンドでのみ低下しました。このprivate指標がいかにもノイズが多いか（上記のシードスイープは約±0.005変動する）を考えると、約0.95で安定を保つことは、単なる幻想ではなく、穏やかな**プラス**と読み取れます。

exp_Dからのnoisy studentの反復：

exp	public LB	private LB	note
exp_D	0.952	0.950	raw
exp_D+	0.962	0.953	trained wtih pseudo labels (round 3)
exp_D++	0.963	0.951	trained wtih pseudo labels (round 5)

exp_Eからのnoisy studentの反復（より多くの外部データで学習）：

exp	public LB	private LB	note
exp_E	0.958	0.955	raw
exp_E+	0.962	0.954	trained wtih pseudo labels (round 1)
exp_E++	0.962	0.950	trained wtih pseudo labels (round 2)

7. マルチモデル / マルチバックボーンの再重み付け

私の実際の2つの提出は、異なるバックボーン（effnet & ecanet）の4〜6グループのモデルからなる精巧な疑似ラベルアンサンブルです。これはprivate LBを押し上げるのに役立ちましたが、それほど大きくはありませんでした：

sub	public LB	private LB
v1	0.967	0.956
v2	0.966	0.956

余談：コンペティション終了後、私は2つの生のEfficientNetモデル（exp_C + exp_D）だけの極めて単純なアンサンブルを試しました。代替バックボーンも疑似ラベルもなしで、それがprivateで私の実際の提出のどちらよりも高いスコアを出しました：

ensemble	public LB	private LB
exp_D + exp_E (raw)	0.962	0.958

2つの生のモデルが、私が構築したあらゆる複雑なアンサンブルを、両方の提出を含めて上回りました。おそらくこれが現実というものなのでしょう。あなたが誇りに思う巧妙な操作の山が、いくつかの単純な判断に打ち負かされるのです。

締めくくり

ランダム性との戦いにおいて、勝算を傾ける最も確実な方法は、また最も優雅さに欠ける方法でもあります：**力任せ (brute force)**、すなわちより多くの実験、より多くのシード、より多くの比較です。私は今回いくつかの良いアイデアを見逃しました（特にPerchの蒸留、privateで強力だったことが判明しました）が、後悔はありません。私はすべてを注ぎ込み、それは最高に楽しい時間でした。

学習 & 推論コード：<https://github.com/yannan90/birdclef-2026-private-9th-public-2nd-solution>

補足Q&A

質問者 (Antoine Masq) : まず、ソロ金メダルおめでとうございます！クラス間相互作用モジュールのアイデアがとても気に入りました。それについて何かアブレーション実験を行いましたか？これをサイト、時間、日付の事前分布を学習するように拡張できるのか興味があります。

著者 (Yannan Chen) : こんにちは @antoinemasq さん、

返信が遅れて申し訳ありません。CIモジュールは確かに私が見つけた興味深いコンポーネントであり、それに対するアブレーションを実行しました。しかし、一部の結果は私のwrite-upで言及した不適切な事前分布（Site x Hour）の後処理問題の影響を受けていたため、現在それらを再実行しています。

また、ランダム性があるようなので、複数のシードでテストしています。今のところ結果は良好に見えますが、いくつかの実行はまだ保留中です。すべてが完了したら、10秒の長さ設定と一緒に機能するCIモジュール定義の修正とともに、write-upを更新します。

続報をお知らせします。

質問者 (Kurise) : 金メダルおめでとうございます！ 昨年のバックボーンを使うことでどれくらいの改善が得られたか教えていただけますか？

著者 (Yannan Chen) : 質問ありがとうございます。事前学習済みバックボーンは非常に役立ちました、public LBで少なくとも+0.01の向上があったと言えます。初期の段階では、スクラッチから学習すると0.92前後で苦戦していましたが、それを使った後は0.93~0.94になりました。

著者 (Yannan Chen) : こんにちは @antoine.masq さん、より多くの実験結果でノートを更新しました。残念ながら、指標は異なるシード間で極めて不安定でノイズが多いものでした。これはおそらく、ローカルのラベル付きサウンドスケープのサイズが小さく、検証とCIモジュールの学習の両方に十分なシグナルを提供できなかったことが主な原因だと思います。CIモジュールが確実に機能するとは自信を持って言えません。私が言えるのは、私の実験では10秒の長さが5秒よりもうまく機能したということです。そして、私の最良のモデルはすべてCIモジュールで学習されたということです。

サイト、時間、日付の事前分布を学習するというあなたのアイデアについては、私は非常にためらっています。主な理由は、ローカルのラベル付きサウンドスケープが非常に少なく、学習するのに十分な真の知識を形成できないからです。

質問者 (chenwenqiang_001) : おめでとうございます。私はあなたの説明にほぼ完全に従い、あなたのパイプラインをほぼ完全に再現しましたが、publicリーダーボードのスコアが非常に低いです。メルスペクトログラムのパラメータは：sr=32000, n_mels=128, n_fft=2048, win=2048, hop=512, fmin=20, fmax=16000 で、メルスペクトログラムのサイズは (128, 313) です。4フォールド分割については：focalセットはprimary_labelに基づくStratifiedKFoldを使用し、ラベル付きサウンドスケープセットはfilenameに基づくGroupKFoldを使用します。それから、各フォールドについて、focalとラベル付きサウンドスケープのデータを結合します。私は学習にfold2のみを使用し、サンプルが100未満のクラスを100までアップサンプリングし、あなたの学習戦略に正確に従います。最終的に、単一フォールド (fold2) でpublicリーダーボードで0.87しか達成できません。もしよろしければ、どこに間違いがあるか確認するのを手伝っていただけますか？ ありがとうございます。

著者 (Yannan Chen) : やあ、私は一度に単一フォールドを提出したことはありません。私は常に4フォールドのアンサンブルと一緒に提出します。それでも、LBスコアは依然として非常に不安定です。ノイズの多さはこのコンペティションの本質だと思います。また、私が言及した事前学習済み重みを使用しているか確認してください。

質問者 (chenwenqiang_001) : 返信ありがとうございます。もしよろしければ、いくつか質問に答えていただけますか？ 私はあなたが言及した重みを完全に使用しています。私が再現したパイプラインは「exp_A 5s/1 baseline 0.939 0.944」です。このパイプラインで、あなたは上記で言及した追加データを加えたのでしょうか。focalサンプルの前処理をしましたか、それらの一部は破損しています。それが私があなたのLBスコアに到達できなかった理由かもしれませんか？

著者 (Yannan Chen) : こんにちは、私は追加データを加えていません。しかし、破損したものについてはxencantoから再ダウンロードして修正しました。ただし、それらはごくわずかです。パフォーマンスに大きな影響を与えるとは思いません。もう一つ考えられる詳細は、事前学習済みバックボーンを使用する際に、「use_features_only」をオンにすることを忘れないでください、ということです。