

birdclef-2026

10位解法、いつも通りのシンプルなモデル

Rank	10
Team	coolz
Author	coolz
Topic ID	704271
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704271>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文 (Kaggle Discussion) : <https://www.kaggle.com/competitions/birdclef-2026/discussion/704271>


スキーム概要:

*** このパイプラインは PERCH v2 以外のモデルではうまく機能しません。HGNET をはじめ、いくつかの代替バックボーンを試しました。PERCH v2 と同様に、これらのモデルは事前学習済みの重みを必要とします。BirdSet の XC データを使って実験しましたが、到達できたのはおよそ 0.94 止まりでした。 ***

1. 私のベストな private 単一モデル

<https://www.kaggle.com/code/cooolz/perchv2-sed>

2. モデルアーキテクチャ



▼
Output: (att_logits, max_logits) – 2 heads, (B, 4, 234) each

3. 学習可能な perchv2

この PyTorch モデルは、GPT の助けを借りて TF 版から変換したものです。また、[hengck23](#) が作成した公開版も利用可能です。

4. 学習パラメータ

warmup 付きの Cos スケジュールで、0 から $2.5e-4$ まで上げ、その後 $1e-6$ まで下げ、おおよそ 10 エポック。Bce loss。

5. サンプリング戦略

80-500、あるラベルのファイルが 500 件を超える場合は、低いサンプル重みを与える。あるラベルのファイルが 80 件未満の場合は、高いサンプル重みを与える。strong soundscape データには x2.5 の重み。

6. データ拡張

- 0.8 の確率: random gain ± 4 dB
- 0.5 の確率: random time and frequency masking (ランダムな時間・周波数マスキング)
- 1.0 の確率: mixup

7. 推論と後処理

最終的な推論では、OpenVINO 経由で ONNX にエクスポートしたモデルを使用します。後処理パイプライン:

```
60s audio → Mel Spectrogram → Single Model → Prior Fusion
→ Smooth Day/Night → Sigmoid
→ Amphibia Month Prior → File Confidence Scale
→ Per-Taxon Temporal Smoothing → Final Probs
```

7.1. 推論

- 5-fold の ONNX モデル
- 入力: 60s audio → 6000 フレームの mel spec → model → $12 \times 5s$ clip logits
- 出力: logits (12, 234)

7.2. 後処理

7.2.1. Prior Fusion（事前分布の融合）

- Site、hour、site×hour の事前分布を soundscape の strong labels からフィッティング

7.2.2. Smooth Day/Night Correction（昼夜の平滑化補正）

多くの種は固有の昼夜の活動リズムに従っており、これは夏に冷たい飲み物の売上が高くなるのに似ています。それらの時間ごとの事前分布は、soundscape ラベルの確率分布から算出しました。裏付けとなる証拠は下記に示します。

7.2.3. Amphibia Month Prior（両生類の月別事前分布）

両生類の活動は乾季と雨季の間で変動し、季節ごとの飲料消費傾向に似ています。月別の事前分布は soundscape の確率統計からフィッティングしており、関連する証拠を下記に添付します。

これは、よく知られた ML の逸話を思い起こさせます。ある DL の専門家が飲料店のデータをフィッティングして、「冷たい飲み物は夏によく売れ、温かい飲み物は冬によく売れる」と結論づけた、というものです。

7.2.4. File-Level Confidence Scale（ファイル単位の信頼度スケーリング）

7.2.5. Per-Taxon Temporal Smoothing（分類群ごとの時間方向の平滑化）


7.3 アンサンブル


このアンサンブルは PerchV2 バックボーンのみを使用しているため、多様性に欠けます。Transformer を Mamba やその他の系列モデルに置き換えてみましたが、この変更でも同程度の性能指標を維持できます。実際のところ、単一モデルで十分に良い結果が得られます。

後処理の証拠

今回、主催者は site、month、hour のメタ情報を提供しており、これは活用できます。私は気づくのが遅く、モデル内で使う時間がありませんでした。

いくつかの証拠を得ました:





疑似ラベル

疑似ラベルがこの手法にとって有益かどうかは依然として不明です。疑似ラベルなしで学習したベースモデルは、1か月前の時点で public LB で 0.951 を記録していました。いずれにせよ、私は学習用コーパスに 10~12 件の疑似ラベル付きサンプルを追加して学習を行いました。

コード共有

[birclef26](#) このコードは OMO によって要約されています。

補足Q&A

質問者 (Salman Ahmed) : [@coolz](#) この件について、GitHub リポジトリ / コードを共有していただくことは可能でしょうか？

著者 (coolz) : コードは DeepSeek で要約されています。AI が関与しているため、プロジェクトは整理されておらず、全体のコードフローを追うのは難しいです。お役に立てば幸いです。

link, <https://github.com/610265158/birdclef26>