

birdclef-2026

14位 ソロ金メダル解法

Rank	14
Team	Dieter
Author	Dieter
Topic ID	704864
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704864>

Retrieved with Kaggle CLI on 2026-07-03.

原文（Kaggle Discussion）：<https://www.kaggle.com/competitions/birdclef-2026/discussion/704864>

BirdCLEF+ 2026 14位解法

最終 private LB: **0.95531**、順位 **14**。

概要（短縮版）

最終サブミッションは3ブランチのアンサンブルでした。

1. **SED main**: 20秒 EfficientNetV2-B3 SED student。234クラスの全タクソノミーを対象とし、ブレンドしたソフト擬似ラベルとsonotype特化の擬似ラベルシャープニングで学習しました。
2. **SED small**: 同じベースレシピですが、BirdNET-v3スタイルのglobal/frequency/time neckとより広いhopを採用しました。これは主に多様性のためのブランチです。
3. **ProtoSSM / Perch ブランチ**: Perch v2 のロジットと1536次元埋め込み、MLP probe、site/hour prior、軽量な系列モデル、そして残差系列補正で構成しました。

最終ブレンドでは、ProtoSSM の予測をクラスごとに1つの main SED へヒストグラムマッチングし、そのうえでグループ別の重みを使用しました。

group	SED main	SED small	ProtoSSM
Aves	0.72	0.18	0.10
non-Aves	0.40	0.10	0.50

データと検証

コンペティションの train audio に加えて、ラベル付きの train soundscape を使用しました。実際に使ったfold分割は soundscape-aware split で、fold ごとに共有 soundscape と排他的 soundscape を混在させました（テストセットでも同様です）。

検証は、壊れた変更を検出したりグループレベルの診断を行ったりするには役立ちましたが、最終モデルの選択には使いませんでした。train soundscape のラベルは小さすぎて絶対的な CV を信頼できませんでした。最終的な選択は以下の組み合わせで行いました。

- 全タクソノミーの検証によるサニティチェック、
- Aves / non-Aves / Insecta / sonotype ごとのメトリック分割、
- public LB の動き、
- 実行時間の実現可能性、
- そしてブランチ間の相関/多様性。

sonotype 列がタクサ（分類群）を分けて扱う主な理由でした。これらには単独の focal recording が存在せず、音響的に分離するのが難しいため、最終モデルを Aves のみのリーダーボード最適化器にしたい欲しかったのです。

SED students

両方の SED ブランチとも `tf_efficientnetv2_b3.in21k_ft_in1k`、32 kHz オーディオ、20秒クリップ、224 mel bin、`n_fft=4096`、`fmax=16000`、BCEスタイルの window loss と clip loss、EMA、SpecAugment を使用し、CPU 推論のために OpenVINO でエクスポートしました。

`tf_efficientnetv2_b3`

これがメインの SED ブランチでした。

重要な設定:

- 4つの5秒出力ウィンドウを持つ20秒コンテキスト。
- 234クラスの全タクソノミー。
- XCL で事前学習。
- 内部の `blend4` teacher から得たソフト擬似ラベル。
- 擬似/train-audio mixup の前に、sonotype の擬似ラベル確率を $1 / 0.65$ でべき乗（power-raise）。
- `soundscape/train-audio` の強制 mixup、lambda を `[0.3, 0.7]` にクランプ。
- `mixup_prob=0.5`、`soundscape_oversample=2`

役立ったのは汎用的な擬似ラベリングではありませんでした。タクソン特化の変換を伴う擬似ラベリングです。べき乗を sonotype のみに適用する方が、全クラスをグローバルにシャープニングするよりも安定していました。

blend 擬似ラベル teacher

`blend` は SED student の擬似ラベルに使った内部 teacher です。これは単一のモデルではなく、最終サブミッションのアンサンブルとも別物です。私はこれをグループ単位の teacher として構築しました。というのも、鳥、カエル/爬虫類、sonotype、そして残りの non-Aves クラスでは、最良のシグナル源がそれぞれ異なっていたからです。

Component	Model specifics	Target used in teacher	Weight in blend	Why it was included
BirdNET V3 Aves specialist	BirdNET V3 11K backbone, 20 s context, Aves-only head, WABAD/ PteroSet soundscape rows	Aves	55% Aves, histogram anchor	最も強力でも最もよくキャリブレーションされた鳥の teacher。一般的な発声する鳥に対するカバレッジが良い。
Perch ProtoSSM Aves specialist	Perch v2 1536-d embeddings, MLP probes, ProtoSSM sequence model over 12 windows	Aves	35% Aves	単なるもう1つの mel CNN ではない、系列/コンテキストのシグナルと埋め込みの多様性を追加。

Component	Model specifics	Target used in teacher	Weight in blend	Why it was included
EfficientNetV2-B3 Aves SED	EfficientNetV2-B3, 10 s mel SED, XCL/pretrain warm start, WABAD rows	Aves	5% Aves	BirdNET/Perch に対するランクの多様性のための小型 CNN サイドカー。
Full-taxonomy raw mean	Equal raw-probability mean of three 10 s SEDs: EfficientNet-B5, ConvNeXt-Base, EfficientNetV2-B3	All 234 classes	5% Aves, 50% Amphibia/Reptilia, 25% sonotypes, 100% remaining classes	広範なフォールバック teacher。より弱い full-target メンバーを置き換え、non-specialist/non-Aves のカバレッジの大部分を担った。
Amphibia/Reptilia EfficientNetV2-B3	EfficientNetV2-B3, 10 s mel SED, Amphibia/Reptilia-only head, BirdCLEF 2026 train-audio head transfer, non-target distractors	Amphibia/Reptilia	50% Amphibia/Reptilia, histogram anchor	特化した herp（両生・爬虫類）モデル。full-taxonomy SED よりも鳥に偏っていない。
Insect parent-gate EfficientNetV2-S	EfficientNetV2-S, 10 s mel SED, Insecta head with sonotype parent-gate auxiliary loss	Sonotypes	25% sonotypes	低容量の昆虫スペシャリスト。sonotype 擬似ラベルの安定化に寄与。
Insect parent-gate EfficientNet-B7	EfficientNet-B7, same parent-gate sonotype recipe, high drop path	Sonotypes	25% sonotypes	高容量の sonotype スペシャリスト。ノイズの多いラベルにもかかわらず有用。
Insect parent-gate ConvNeXt-Tiny	ConvNeXt-Tiny, same parent-gate sonotype recipe	Sonotypes	25% sonotypes, sonotype anchor	sonotype のためのアーキテクチャ多様性。昆虫 teacher が純粋な EfficientNet アンサンブルになるのを回避。

グループの組み立ては以下の通りです。

Group	Blend rule
Aves	55% BirdNET V3 Aves + 35% Perch ProtoSSM Aves + 5% full-taxonomy raw mean + 5% EfficientNetV2-B3 Aves。anchor 以外のメンバーは BirdNET V3 にヒストグラムマッチング。
Amphibia/Reptilia	50% Amphibia/Reptilia EfficientNetV2-B3 + 50% full-taxonomy raw mean。raw mean をスペシャリストにヒストグラムマッチング。
Sonotypes	25% full-taxonomy raw mean + 25% EfficientNetV2-S parent-gate + 25% EfficientNet-B7 parent-gate + 25% ConvNeXt-Tiny parent-gate。ヒストグラムマッチングなし。
Remaining classes	100% full-taxonomy raw mean。

tf_efficientnetv2_b3 with hop 920 and other neck

このブランチは同じレシピから始めましたが、head を変更しました。

- BirdNET-v3スタイルの global/frequency/time attention neck。
- MC-dropout スタイルの global head。
- より広いタイムグリッド挙動を維持するための hop_length=920 と、より小さい time masking。
- 旧 SED head から global/frequency/time head への head-row 転移。

単独では最も強いブランチではありませんでしたが、ヒストグラムマッチング後に有用な残差シグナルを持っていました。これを non-Proto 質量の20%に保ちました。メインモデルを多様化するには十分で、かつ弱いキャリブレーションが支配してしまわない程度です。

ProtoSSM / Perch ブランチ

Perch ブランチは public な Perch v2 アセットを使いましたが、生の高重み public ノートブック予測としては使いませんでした。

パイプライン:

1. Perch v2 を実行し、5秒ウィンドウごとにクラススコアと1536次元埋め込みを取得。
2. train soundscape ラベルから site/hour prior テーブルを構築。
3. 十分な正例を持つクラスについて、PCA 圧縮した Perch 埋め込み上で MLP probe を学習。
4. 12ウィンドウの系列上で軽量の ProtoSSM を学習。
5. first-pass の系列予測の上に ResidualSSM 補正を学習。
6. temperature scaling、file-confidence scaling、rank-aware scaling、adaptive delta smoothing、per-class threshold を適用。

最終カーネルでは、学習済みの train 側バンドルを scoring ノートブック内で再学習するのではなく、artifact から読み込みました。これにより十分な CPU 予算を節約でき、最終スタックに2つの SED ブランチを残せました。

ProtoSSM ブランチは Aves よりも non-Aves にとってはるかに重要だったため、最終的な重みは非対称にしました。Aves では 0.10、non-Aves では 0.50 です。

最終ブレンド

最終ブレンドで重要だったのは3つの詳細です。

1. 平均化の前のヒストグラムマッチング

ProtoSSM は周辺確率分布が異なっていました。直接平均すると、ブレンドの重みがキャリブレーションのスケールに依存してしまいます。そこで代わりに各クラス分布を main モデルにマッチングし、ブランチのランク順を保ちつつ、すべてのブランチをクラスごとに同じスケールへ揃えました。

2. タクソン考慮の重み

Aves は main モデルですでに十分うまく扱えていました。non-Aves には Perch 由来の系列/コンテキストシグナルが必要でした。これが最終的な重みが以下になった理由です。

```
Aves:      0.9 SED + 0.10 * ProtoSSM
non-Aves: 0.5 SED + 0.50 * ProtoSSM
```

ベストなサブミッションは、aves と昆虫についてはさらに ProtoSSM の重みを小さくしたものになっていたでしょう。

推論

SED ブランチは OpenVINO を使いました。SED は10秒 stride で20秒ウィンドウを実行し、その後モデルのウィンドウを Kaggle の5秒行へ変換し直しました。Perch ブランチは ONNX の Perch エクスポートを使い、学習済みの ProtoSSM artifact を読み込みました。

主な実行時制約は単一のモデルではなく、90分の CPU 上限のもとで十分な多様性を保つことでした。これが、最後にさらに full SED ブランチを追加するのを避け、代わりに小型かつ高速なブランチとキャッシュした ProtoSSM artifact を使った理由です。

うまくいったこと

- 20秒 SED コンテキストは、各5秒行を独立に扱うよりも一貫して良かった。
- 自前の SED student を学習する価値があった。public の Perch/ProtoSSM fork だけに頼ると public のプラトーと関連しすぎた。
- sonotype のみの擬似ラベルシャープニングは有用だった。グローバルなシャープニングは過学習しやすかった。
- ヒストグラムマッチングは、互換性のないキャリブレーションを持つブランチをブレンドする良い方法だった。
- Perch は、埋め込み/系列のシグナルとして使い、Aves では重みを下げれば罠ではなかった。
- 最終的なタクソン分割は重要だった。Aves と non-Aves では異なるブランチ重みが求められた。

うまくいかなかった、またはリスクが高すぎたこと

- ラベル付き soundscape の絶対 CV を信頼すること。
- 実質的な多様性なしに public の 0.950 スタイルのブランチを追加すること。
- public LB が好むからといって Perch/ProtoSSM に Aves の重みを与えずること。
- ローカルメトリックは美しいが LB での頑健な動きがない、後付けの希少タクソンサイドカー。
- CPU 予算に余裕を持って収まらない追加の full SED ブランチ。

他の上位解法との関係

私の最終解法は大まかな形は同じでしたが、ラベル作業は少なく、デプロイ可能な多様性も少なめでした。強力な private SED ブランチ2つに Perch 系列ブランチ1つです。それで14位には十分でしたが、トップとの差は、後処理の定数が1つ欠けているというよりも、モデルの多様性とラベルの品質にあるように見えます。

謝辞

Cornell/Kaggle のホストの皆さん、そしてこのコンペティションを可能にしてくれた録音者（recordist）の皆さんに感謝します。

public なエコシステムが大いに役立ちました。Google Perch v2、Perch ONNX エクスポート、Perch メタデータデータセット、public の SED/ProtoSSM ノートブック、そして BirdCLEF 2024 と 2025 の数多くの writeup です。特に 2024/2025 の上位解法は、2026 のリーダーボードが示すより前に、勝ちパターンを明確にしてくれました。長コンテキストの SED、丁寧な擬似ラベル、時間的/ファイル単位の後処理、そして推論エンジニアリングです。

来年また会いましょう。