

birdclef-2026

# 16位解法

|          |                      |
|----------|----------------------|
| Rank     | 16                   |
| Team     | goonew               |
| Author   | goonew               |
| Topic ID | 704689               |
| Version  | Japanese Translation |

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704689>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文（Kaggle Discussion）：<https://www.kaggle.com/competitions/birdclef-2026/discussion/704689>

この貴重な機会を提供してくださった主催者の皆様、ディスカッションフォーラムで知見を共有してくださった皆様、そして昨年の解法やノートブックを公開してくださった方々に感謝いたします。特に以下の共有物は、私の最終提出において非常に重要でした。

- [@hideyukizushi](#) さんの公開ノートブック [bird26-reproduce-perch-protossm-resssm-inf-train](#)、特に LB 0.926 バージョン。
- [@dylanliuofficial](#) さんの [BirdCLEF 2025 4位解法の解説](#) および [コードリポジトリ](#)、特に Soft AUC loss。
- [@vladimirsydor](#) さんと [@vialactea](#) さんの [BirdCLEF 2025 2位解法](#)、特に [事前学習済みバックボーン](#)。

金メダル圏内に到達できたのには、かなりの運の要素があったと思っています。それでも、昨年の解説が大いに役立ったので、私自身の解法メモもここに残しておくことにしました。

## 解法概要

私の最終提出は **3ブランチのランクアンサンブル** であり、その後に階層的な分類群（taxonomy）スムージングを適用しました。このスムージングは、0.950 レベルの公開ノートブックで一般的に用いられていたものです。3つのブランチは以下のとおりです。

1. **Perch ブランチ**: [@hideyukizushi](#) さんの公開ノートブック [bird26-reproduce-perch-protossm-resssm-inf-train](#) を改変したもの。
2. **SED ブランチ 1**: EfficientNetV2-S バックボーンの SED モデル。2021-2025 年の公開 BirdCLEF データで事前学習。
3. **SED ブランチ 2**: [eca\\_nfnet\\_l0](#) バックボーンの SED モデル。Soft AUC loss で学習。

ブランチ 2 と 3 は、それぞれ複数のランダムシードで学習したモデルのアンサンブルになっています。

## LB の推移

| # | 構成                                                                                | Public LB    | Private LB   |
|---|-----------------------------------------------------------------------------------|--------------|--------------|
| 1 | <b>Perch ブランチ</b> — <a href="#">@hideyukizushi</a> さんの公開ノートブックの直接再現               | <b>0.926</b> | <b>0.921</b> |
| 2 | Perch ブランチ v2: ProtoSSM の目的関数 + 後処理を変更                                            | 0.932        | 0.928        |
| 3 | #2 + <code>train_audio</code> と <code>labeled soundscapes</code> のみで学習したシンプルな SED | 0.934        | 0.930        |
| 4 | #3 + ソース別バランス Focal BCE と <code>train_audio</code> のソフトラベルを用いた SED                | 0.943        | 0.940        |
| 5 | #4 + ハードネガティブ                                                                     | 0.945        | 0.940        |

| # | 構成                                                                     | Public LB | Private LB |
|---|------------------------------------------------------------------------|-----------|------------|
| 6 | #5 + 自己蒸留による疑似ラベルと背景ベッド (background-bed) オーグメンテーション (SED ブランチ 1 として採用) | 0.951     | 0.946      |
| 7 | #6 + Soft AUC で学習した NFNet (SED ブランチ 2 として採用)                           | 0.95586   | 0.95482    |

## アンサンブルと提出戦略

ベースラインを改善して LB 0.932 の Perch + ProtoSSM パイプラインを得た後、しばらく Perch の蒸留とファインチューニングを試みました。しかし、単体 LB スコアが低いシンプルな SED モデルであっても、クラスごとのパーセンタイル／ランク空間で Perch + ProtoSSM パイプラインとアンサンブルすると最終スコアを改善できることが分かりました。

この観察に基づき、多様性を最大化するために、Perch をまったく使わない SED モデルを数多く構築しました。そして Public LB を改善するモデルを貪欲 (greedy) に追加していきました。Public LB への過学習をできる限り抑えるため、追加する各モデルは複数シードにわたるアンサンブルとしました。また、S22 のような特定のサイトを学習データから除外した追加バリエーションも学習しました。これらのバリエーションを提出してスコアの変化を観察し、平均的に良い性能を示すモデルを選択しました。

貪欲探索の際にどの候補を優先して提出するかを決めるため、検証用 labeled soundscapes 上でのモデル予測間の Spearman のランク相関を計算しました。あるモデルを追加して Public LB が大きく改善した場合、それに類似したモデルの優先度を上げました。改善に寄与しなかった場合は、類似したモデルの優先度を下げました。提出回数を節約するため、最終的には各モデルの単体スコアの測定はやめました。

上記の2つの SED ブランチは、この探索プロセスを通じて選ばれたものです。

## Perch ブランチ

このブランチは [@hideyukizushi](#) さんの公開ノートブックを直接ベースにしています。そのノートブックのコア部分を大きな変更なしに再利用しました。参照したバージョンは LB **0.926** でした。

- **Perch v2:** google/bird-vocalization-classifier。ONNX を用いて CPU 上で実行。234 クラスに対して、5秒ウィンドウごとに凍結された埋め込み (frozen embeddings) と生のロジット (raw logits) を出力します。
- **ProtoSSM v2:** ウィンドウ埋め込みの系列に対する小規模な状態空間モデル (state-space model)。  
d\_model = 320、d\_state = 32、SSM レイヤー 4層、クラスあたり 2 プロトタイプ、8ヘッドのクロスアテンション。パラメータ数は **5.78M** です。
- **MLP プローブ:** PCA → 128 → MLP(256, 128)、L2 = 0.005、58 クラスに対して学習。
- **ResidualSSM:** 補正項を予測する2つ目の SSM。d\_model = 128、補正の重みは **0.35**。
- **ブランチ内アンサンブル:** 0.5 × ProtoSSM + 0.5 × MLP + 0.35 × ResidualSSM correction。時間シフトの TTA [0, +1, -1, +2, -2] を併用。

このセットアップに加え、ProtoSSM の学習時にいくつかの小さな変更を行いました。

### 1. マッピングされたクラスのみへの蒸留 (Mapped-only distillation)

234 クラスのうち、Perch が実際に表現できる 205 クラスに対してのみ Perch のロジットを蒸留しました。残

りのクラスについては、蒸留損失を 0 に設定しました。その理由は、Perch が出力できないクラスについて生徒モデルに Perch を模倣させようとする、ノイズを注入するだけになると考えたためです。

## 2. ペアワイズランキング損失項 (Pairwise-ranking loss term)

サンプリングした正例／負例ウィンドウのペアに対して、クラスごとのヒンジ損失 `relu(margin - (s_pos - s_neg))` を追加しました。重みは 0.05、マージンは 1.0 です。評価指標が macro AUC であるため、これはクラス内での予測順序を直接改善しようとする試みでした。

いくつかの小さな後処理ステップ（その多くは公開ノートブックでも使われていたもの）を追加した結果、このブランチは LB 0.926 から 0.932 に改善しました。

## SED ブランチ 1

このブランチはバックボーンとして `tf_efficientnetv2_s.in21k_ft_in1k` を使用しました。10秒セグメントを 5秒ホップでスコアリングし、クリップレベルとフレームレベルの両方の予測を出力するアテンションベースの時間プーリングヘッド (temporal pooling head) を用いました。メルスペクトログラムの設定:

- `n_mels = 224`
- `n_fft = 2048`
- `hop = 512`
- `fmin = 50`
- `fmax = 14000`

モデルは Focal BCE で学習しました。

このブランチは4つのステップで構築しました。

- **ステップ 1:** 2021-2025 年の BirdCLEF コンペティションデータで事前学習。
- **ステップ 2:** labeled soundscapes と `train_audio` のみを使って学習。
- **ステップ 3:** ステップ 2 のモデルを用いて `train_audio` からのランダムウィンドウにオンラインでソフトラベルを付与し、再度学習。
- **ステップ 4:** ステップ 3 のモデルを用いて unlabeled soundscapes に疑似ラベルを付与し、再度学習。

全体のレシピ (EfficientNetV2-S、アテンションプーリングの SED ヘッド、Focal BCE、EMA、MixUp) は、かなり標準的な BirdCLEF SED パイプラインです。`train_audio` にソフトラベルを付与するというアイデアは、昨年の [5位解法](#) に基づいています。

私の主な変更点は次の3点です。

### (a) ソース別バランス Focal BCE

`train_audio` の録音ははるかに長くなり得るうえ、クリップレベルのラベルしか持たないため、soundscape のウィンドウに割り当てられた5秒ラベルは `train_audio` の弱ラベルよりも信頼できると仮定しました。そこで、ソースごとに別々に Focal BCE の平均を計算し、2つの損失を足し合わせました。

```
loss_ta = focal(logits[ta_mask], targets[ta_mask]).mean() # mean over train_audio only
loss_sc = focal(logits[sc_mask], targets[sc_mask]).mean() # mean over soundscape only
total = loss_ta + loss_sc
```

これにより、バッチ内に各ソースのサンプルが何個含まれているかにかかわらず、2つのソースが損失に等しく寄与するようになります。

いくつかのサンプラーを試しましたが、最終的にはバッチ構成を `train_audio` 75%、`soundscape` 25% に固定しました。このサンプラーの下では、この損失は Focal BCE において `soundscape` サンプルに 3 倍の重みを適用することと等価です。

## (b) ハードネガティブの重み付け

各5秒ウィンドウには 234 クラスがあり、ほとんどのクラスラベルは負例 (negative) です。これらの負例の大部分は容易 (easy) なもの、つまりまったく異なる生息環境の種であり、明らかに存在しないものです。しかし、一部の負例は困難 (hard) なもの、つまりその録音の文脈上ではありそうだが、その特定のウィンドウには存在しない種です。

モデルはこうした「ありそうだが存在しない」種に対して偽陽性 (false positive) を出す傾向があったため、それらをより強く罰したいと考えました。いくつかのバリエーションを試した末、シンプルな重み付け方式を採用しました。

- **ファイル内ハードネガティブ:** 同じ録音の他の箇所では正例だが、現在のウィンドウには存在しない種 →  $w = 3.0$
- **ファイル外ハードネガティブ:** 同じ (site, hour) グループに出現するが、現在のファイルには存在しない種 →  $w = 2.0$
- **その他すべての負例** →  $w = 1.0$

これらの重みは要素ごとの focal loss に乗算されました。

## (c) 背景ベッド (Background-Bed) オーグメンテーション

`train_audio` のクリップはしばしば focal recording であり、高 SNR かつ指向性があり、通常は特定の個体を狙って録音されています。一方、`soundscape` の録音は PAM 録音であり、無指向性で、より遠くの音を捉えている可能性が高いです。このドメインギャップを縮めるため、unlabeled soundscapes から5秒の背景ベッドをマイニングし、2エポックのウォームアップの後、確率  $p = 0.1$  で各 `train_audio` クリップにミックスしました。

ミックスの前に、`train_audio` の波形に対して以下の変換を適用しました。

### 距離シミュレーション (Distance Simulation)

- 高周波減衰: `uniform(0, 6)` dB。
- カットオフを `uniform(3000, 6000)` Hz からサンプリングした1次バターワース・ローパスフィルタとブレンド。

目的は、高周波が距離とともにより強く減衰する大気吸収 (atmospheric absorption) を大まかにシミュレートすることです。

### リバーブ (Reverb)

- 3-8 個の初期反射 (early reflections) を追加。
- 各反射の遅延は `uniform(2, max_delay)` ms。ここで `max_delay` は 5-80 ms にクリップされます。
- 各反射の減衰は `uniform(0.1, 0.4) × (1 - i / n)` であり、後の反射ほど弱くなります。

- 遅延させたコピーは `result[delay:] += wave[:-delay] * decay` として加算されます。
- 最後に、波形を元のピークに正規化し直します。

目的は、樹木や地形からの自然な反射を近似することです。

## スペクトル EQ 転写 (Spectral EQ Transfer)

- 信号と背景ベッドの両方のスペクトル包絡を、8バンドを用いて推定します。
- `ratio = sqrt(sig_env / bed_env)` を計算し、`[0.3, 3.0]` にクリップします。
- このゲインを背景ベッドの FFT に適用し、ベッドの音色を信号のものに近づけて、スペクトル的に目立ちすぎないようにします。
- 結果を平滑化し、逆 FFT を適用します。

最後に、オーグメント済みの波形を、ランダムな目標 SNR でミックスしました。

```
snr_db = uniform(5, 20)
target_noise_rms = sig_rms / 10 ** (snr_db / 20)
mixed = wave + bed * (target_noise_rms / noise_rms)
if abs(mixed).max() > 1:
    mixed /= abs(mixed).max() # peak-normalize only when clipping would occur
```

5-20 dB という SNR 範囲は、見かけ上の距離が異なる鳥をシミュレートすることを意図しています。

この背景ベッドオーグメンテーションは、単独で使うとほぼ LB 中立でしたが、ブランチ内のモデルの半分に適用するとアンサンブルスコアが改善しました。私は音響の専門家ではないので、これらの変換すべてが物理的に正しいかどうかは完全には確信がありません。したがって、このオーグメンテーションが本当に有益だったのかは、私にはかなり不明瞭です。

このブランチを Perch ブランチとアンサンブルすると、スコアは LB 0.951 に達しました。

## SED ブランチ 2

このブランチはバックボーンとして `eca_nfnet_l0` を使用しました。推論時には、各60秒の soundscape を6つの10秒片に分割しました。モデルはフレームごとの予測を行い、各5秒ウィンドウは対応するフレームにわたる最大値を取ることでスコアリングされました。

ブランチ 1 と同じタイプのアテンションベースの時間プーリングヘッドを用い、クリップレベルとフレームレベルの両方の予測を出力しました。

メルスペクトログラムの設定:

- `n_mels = 256`
- `n_fft = 2048`
- `hop = 64`
- `fmin = 60`
- `fmax = 16000`

Focal BCE の代わりに、このブランチは BirdCLEF 2025 4位解説にある AUC の代理損失 `AUCLoss` / `SoftAUCLoss` を使用しました。labeled-soundscape の損失重みは 5 に設定しました。

疑似ラベル生成では、[BirdCLEF 2025 2位解法](#) で公開された大規模な Xeno-Canto 事前学習チェックポイントから初期化しました。その後、異なるバックボーン、メルパラメータ、損失関数で学習したモデルのアンサンブルを使用しました。

このブランチを SED ブランチ 1 と意図的に差別化するように設計したわけではありませんが、結果としてバックボーン、スコアリング手順、メルパラメータ、損失関数において異なるものになりました。これがおそらく多様性の向上に役立ちました。

このブランチを追加したことで、スコアは最終的に LB 0.955 に達しました。

また、ブランチ内の安定性を犠牲にする方法も試しました。すなわち、各ブランチ内でマルチシードのアンサンブルを維持する代わりに、より多くの異なるブランチを追加するというものです。それらの提出の中には、より高い Private LB スコアを達成したものもありました。しかし、その Public LB スコアは最大でも 0.952 だったため、最終提出として選択するのは困難でした。

## うまくいかなかったこと

---

専用の sonotype モデルの構築に多くの時間を費やしましたが、うまくいきませんでした。外部データから昆虫の音声ファイルを収集し、その後、Perch 埋め込みが sonotype ウィンドウの埋め込みと高い類似度を持つウィンドウのみを選択しました。それらのウィンドウを使って事前学習モデルを構築し、その後 sonotype クラスのみを対象とするモデルを学習しました。多くのパラメータ設定を試しましたが、LB は悪化し続けました。