

birdclef-2026

BirdCLEF+2026 18位解法: アンサンブルこそ全て (Ensemble is all we need)

Rank	18
Team	Win or lose?
Author	cjwing
Topic ID	704287
Version	Japanese Translation

Source: <https://www.kaggle.com/competitions/birdclef-2026/discussion/704287>

Retrieved with Kaggle CLI on 2026-07-03.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

原文（Kaggle Discussion）：<https://www.kaggle.com/competitions/birdclef-2026/discussion/704287>


Kaggle と BirdCLEF+2026 の主催者の皆様に感謝します。これほど興味深いコンペティション、しっかり運営されたプラットフォーム、そして自然界にもっと注意深く耳を傾けさせてくれるデータセットを提供してくださいました。

Submission	Description	Public LB	Private LB
BirdCLEF+2026-infer - 957-5tta-model3	TTA付き3モデルのランクアンサンブル	0.954	0.957
BirdCLEF+2026-infer - 4model-4321-192-923	4モデルのランクアンサンブル	0.954	0.955

概要

この解法は単一の魔法のようなトリックではありませんでした。その大部分は、複数の不完全なモデルを注意深くアンサンブルしたものです。BirdCLEF では、種、地点、時間帯、背景のテクスチャによって好ましい帰納バイアスが異なるため、1つのモデルを過信するのではなく、相補的な視点を組み合わせようと試みました。

Private の最高スコアは3モデル版から得られました。4モデル版も依然として強力でしたが、追加した NFNet ブランチはこの実行では Private LB を改善しませんでした。



Private ベストの submission は、明示的に3つのブランチを使用しました。256-mel SED モデル、128-mel SED モデル、そして Perch/ProtoSSM スタックです。4モデルの実験では NFNet 系のブランチを追加しましたが、それは Private のベスト実行ではありませんでした。

タスクの枠組み

各 soundscape は60秒の録音です。これを5秒の12個のウィンドウに分割し、各ウィンドウについて234個のターゲットクラスを予測します。すべてのモデルは `sample_submission.csv` の順序を正規のクラス順序として使用します。

教師あり学習用のデータは2種類あります。

- `train_audio`: primary label と secondary label を持つ focal 録音。
- `train_soundscape_labels.csv`: soundscapes からラベル付けされた5秒ウィンドウ。

検証のため、focal 録音は primary label で StratifiedKFold により分割します。Soundscape ウィンドウはファイル名で GroupKFold により分割するため、同一の60秒ファイル由来のウィンドウが fold をまたいでリークすることはありません。また、ラベル付き soundscapes において S22 が顕著にノイジーであるため、non-S22 の macro AUC も追跡しています。

SED モデル

主要な CNN 系列は、5秒のオーディオチャンクで学習した sound event detection（音響イベント検出）スタイルのモデルです。

オーディオは 32 kHz モノラルにリサンプリングされ、log-mel スペクトログラムに変換されます。中核となる mel の設定は以下の通りです。

Branch	Mel bins	Hop	Backbone
SED-1	256	512	EfficientNet-B0
SED-2	128	512	EfficientNetV2-S / EfficientNet-B0 スタイルのブランチ
SED-4	192	768	NFNet-L0

SED ヘッドは以下を使用します。

- 入力1チャンネルの timm 画像バックボーン、
- 周波数軸に沿った GeM プーリング、
- 512次元のボトルネック、
- 時間軸に沿った attention logits と class logits、
- attention 重み付けされた frame logits からの clip レベル logits。

学習時には、clip 予測と最も強い frame 予測の両方を教師信号とします。

```
loss = 0.5 * BCE(clip_logits, y) + 0.5 * BCE(max_frame_logits, y)
```

一部のバリエーションでは、focal BCE、label smoothing、クラス頻度で重み付けしたサンプリング、background/no-call ノイズ、SpecAugment、focal-focal MixUp、focal-soundscape MixUp を使用します。

Perch 蒸留

256-mel の EfficientNet-B0 ブランチは、Perch v2 を teacher としても使用します。凍結した Perch ONNX モデルが各5秒チャンクについて1536次元の embedding を生成します。この embedding は固定のランダム直交射影器を用いて512次元へ射影され、student バックボーンが MSE 蒸留ヘッドでそれを予測します。

これが有用なのは、小規模なコンペデータセットでは完全には提供できない幅広い生物音響知識を Perch が持っているためです。モデルは依然としてコンペのラベルを学習しますが、その表現はより強力な音響 embedding 空間へ引き寄せられます。

Perch + ProtoSSM ブランチ

3つ目のブランチは、mel CNN とは意図的に大きく異なるものにしています。

各5秒ウィンドウについて、Perch v2 は以下を生成します。

- 生のクラススコア、
- 1536次元の embedding。

次に、site、hour、site-hour のテーブルを用いた fold-safe なメタデータ prior を追加します。これらの prior は、強い地理的パターンや時間帯パターンを持つ種に対して有用に見えました。prior の融合は分類体系を意識 (taxonomy-aware) しており、イベント的なクラスと、昆虫や両生類のようなテクスチャ的なクラスとで異なる smoothing の挙動を取ります。

シーケンスモデルは ProtoSSM です。各60秒ファイルを12ウィンドウのシーケンスとして扱い、Perch のスコアと embedding に対する時間的な補正を学習します。主要な設定は以下の通りです。


Component	Value
input embedding	1536
sequence length	12
model width	256
SSM layers	3
state dim	16
metadata	site + hour
extra heads	prototype head + family head

このブランチはまた、PCA 圧縮した Perch embedding に raw/prior/base スコアを加えたものに対して、クラスごとの MLP プローブも学習します。最後に、ProtoSSM と MLP/prior のスコアをブレンドし、second pass として残差 SSM 補正を利用できるようにしています。

擬似ラベル (Pseudo Labels)

Training pipeline

Second distilled model creates pseudo labels; Perch single uses MixUp.



Pseudo labels are not ensembled; they are used only for Perch single-model MixUp training.

擬似ラベルの部分は、最終アンサンブルよりも限定的でした。

1. 2つ目の蒸留済み単一モデルを、ラベルなしの `train_soundscapes` に対して実行する。
2. Kaggle のランタイムに収めるため、作業を5つのシャードに分割する。
3. シャードを正規の `row_id` とクラス順序に統合し直す。
4. 得られた5秒ウィンドウのスコアを soft label として使用する。

これらの擬似ラベルは、Perch の単一モデル学習の実行にのみ使用しました。手法自体はシンプルなままです。pseudo MixUp は focal 録音と擬似ラベル付き soundscape ウィンドウを混合します。

```
mixed_audio = 0.5 * focal_audio + 0.5 * pseudo_soundscape_audio
mixed_label = 0.5 * focal_label + 0.5 * pseudo_label
```

混合の前に、擬似スコアは以下の式でシャープ化されます。

```
pseudo_label = score ** 1.6
```

擬似ラベルのプールは各 fold 内の検証ファイルを除外しており、これによりループがよりクリーンに保たれます。これらの擬似ラベルの作成に最終的なフルアンサンブルは使用しておらず、また全ブランチに対する汎用的な second-round のシグナルとしても使用していません。

推論 (Inference)

推論は、そこそこ CPU に優しいように設計されています。SED モデルは OpenVINO XML にエクスポートされ、128個の soundscape ファイルのロット単位で実行されます。共有のオーディオキャッシュと mel キャッシュにより、デコードやフロントエンド処理の重複を避けています。

各 SED fold について、以下を計算します。


```
prediction = 0.5 * sigmoid(clip_logits) + 0.5 * sigmoid(max_frame_logits)
```

fold ごとの予測を平均します。その後、3点の時間的 smoothing を適用します。

Class group	Kernel
event-like classes	[0.20, 0.60, 0.20]
texture-like classes	[0.35, 0.30, 0.35]

Perch/ProtoSSM ブランチは独自のネイティブな後処理を保持します。taxon ごとの温度スケーリング、file レベルの信頼度スケーリング、rank を意識したスケーリング、delta smoothing、そしてクラスごとの閾値シャープ化です。

ランクアンサンブル (Rank Ensemble)



最終的なブレンドは、私たちが最も信頼した部分です。

生の確率を直接平均するのではなく、まずすべてのモデルを `row_id` でアラインし、次に各モデルのクラスごとの予測をグローバルなパーセンタイルランクに変換します。

```
ranked_score[class] = percentile_rank(model_score[class])
```

そして、それらのランクを等しい重みで平均します。

これが役立ったように見えたのは、各ブランチのキャリブレーションが大きく異なるためです。

- SED CNN の確率はしばしばシャープで局所的です。
- Perch/ProtoSSM の logits はより prior を意識し、シーケンスを意識したものです。
- pseudo MixUp で学習した Perch 単一モデルはスコアのスケールを変えることがあります。
- 異なる mel 設定は異なる信頼度分布を生み出します。

ランク平均は順序を保持しつつ、キャリブレーションのミスマッチを低減します。ランクブレンドの後、最終的に file レベルの top=1 後処理を1回適用します。すなわち、各60秒ファイルとクラスについて、最も強いウィンドウがそのファイルの12ウィンドウ全体の予測をスケールします。これは file レベルの存在 (presence) を強化しつつ、ウィンドウレベルの局在化を保ちます。

アブレーションスタディ

アブレーションの根拠は控えめかつ実用的に留めました。以下の行のほとんどは、単一の完璧に制御されたオフラインプロトコルではなく、コンペ側の実験ログから得られたものであるため、方向性を示すエンジニアリング上の証拠として扱っています。

V2S ブランチについては、最も有用だった変更は1つの劇的なトリックではなく、小さな意思決定の連続でした。

V2S experiment	LB	Note
initial V2S baseline	0.918	初期の基準
clean-audio subset	0.918	private +0.001
moderate weighted sampling	0.924	WRS = 0.5; public LB を改善
alternative weighted sampling	0.919	WRS = -1; private +0.004
file-level top-1 postprocess	0.926	最強ウィンドウによる file スケーリング
full-audio training	0.929	より広範なオーディオ利用
class-type temporal smoothing	0.933	event/texture 固有のカーネル
corrected V2S stack	0.942	baseline のバグを修正; 先行する変更の累積効果

class-type temporal smoothing は、event-like クラスと texture-like クラスに対して異なる3点カーネルを使用します。後の除去チェックでは、public と private が逆方向に動きました。private は約 +0.002 改善し、一方で public LB は約 0.0005 低下しました。

corrected V2S stack については、後になって以前の baseline の経路にバグがあったことが判明しました。したがって 0.942 への大きな跳躍は、単独の重み付けトリックとしてではなく、baseline のバグ修正後における先行変更の累積結果として解釈すべきです。

Perch/蒸留 側については、擬似ラベリングはより分割 (split) に敏感でした。それはクリーンな public LB の向上ではありませんでしたが、私たちのログでは private の方が良く見えました。

Perch/distillation experiment	LB	Note
row-order alignment check	0.917 -> 0.914	アラインメントは敏感な失敗モードだった
512-dim Perch projection	0.917	private -0.004
Perch single without pseudo labels	0.926	より強い public LB
Perch single with pseudo-label MixUp	0.923	public は低下、私たちのログでは pseudo なしより private が良好

うまくいったこと

主な向上は、1つの巨大なモデルからではなく、多様性から得られたように見えます。

最も有用に見えた要素は以下の通りです。

- 複数の mel 解像度とバックボーン、
- clip と frame-max の教師信号、
- 256-mel ブランチに対する Perch 蒸留、
- 非 CNN のシーケンスブランチとしての Perch + ProtoSSM、
- site/hour prior、
- 2つ目の蒸留済み単一モデルから得た擬似ラベル（Perch 単一モデルの MixUp にのみ使用）、
- グローバルなクラスごとのランク融合、
- 最終的な top-window の file レベル後処理。

4モデルのアンサンブルは魅力的に見えましたが、Private LB はよりクリーンな3モデル TTA アンサンブルを支持しました。私たちの解釈は、追加のブランチが有用な public セットの多様性をもたらした一方で、private セットのノイズも幾らか加えた、というものです。とはいえ、これは事後的な読みに過ぎません。アンサンブルのサイズは、アンサンブルの質と同じではありません。

推論コード

推論コードはこちらで公開する予定です: [open-source inference code](#)。

最後に

正直に言うと、私たちの結果の大部分は、昨年のオープンソースコードと、多くの強力な競争者たちのディスカッション投稿・返信の上に築かれたものです。それらのリソースは私たちを大いに助けてくれました。避けられない運の役割と相まって、それらこそが私たちを金メダルへと到達させてくれたものです。

私たちはまだこの分野に比較的不慣れであるため、自分たちの取り組みの全ての詳細を提示できていないかもしれません。ご質問があれば、下記でお気軽にお尋ねください。

最終スコアは単一の魔法のトリックから来たものではありません。それは、妥当だが同一ではない一連のモデルに生産的に意見を食い違わせ、その食い違いをランク融合を通じてゲインへと変えることから来たものです。

今回の私たちの取り組みにおいて、アンサンブルは基本的に最強の武器であり、今回はそれで十分でした。

オープンソースコード [bc2026-distilled-sed](#) を公開してくれた [@tuckerarrants](#) に、そしてオープンソースコード [bird26-reproduce-perch-protossm-resssm-inf-train](#) を公開してくれた [@hideyukizushi](#) に感謝します。

また、BirdCLEF+ 2025 のオープンソース解法 [1st place solution: multi-iterative n](#) を公開してくれた [@nikitababich](#) に、そして BirdCLEF+ 2025 の2位解法の write-up [2nd place journey down the rab](#) を公開してくれた [@vladimirsydor](#) と [@vialactea](#) にも感謝します。

さまざまなコメント欄で私の質問に答えてくれた [@tuckerarrants](#) に特別な感謝を。彼の返信は私を大いに助けてくれました。