rogii-wellbore-geology-prediction

1位 Solution

Rank	1
Team	Ruby
Author	Ruby
Topic ID	733220
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733220
Retrieved with Kaggle CLI on 2026-08-06.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

このような興味深いコンペを開催してくださったKaggleと主催者の皆様に感謝します。リーダーボードのshake-upを幸運にも生き残り、初めての1位金メダルを獲得できました。

また、アイデアを公開してくださった皆様、とりわけコンペ序盤にニューラルネットワークを試すきっかけをくださった@tuckerarrants、そしてparticle filter baselineを最初に共有した方（残念ながら元の著者を突き止められませんでした）にも感謝します。

コードの大部分はGPT-5.5/5.6を使い、Codexで書きました。repositoryには実装の詳細が多数含まれるため、このwrite-upでは性能向上に最も寄与したと考えるアイデアだけを扱います。完全な実装については、コードをAI coding agentへ渡して詳細を説明させることをお勧めします。repositoryには無効化された実験的featureも多数ありますが、それらは無視して構いません。

Task Formulation and Loss

この問題を**2D alignment task**として定式化し、主目的関数に**cross-entropy loss**を使いました。

alignment gridは次の通りです。

- **Horizontal well:** 345 positions（32でdownsample）。1,024のvisible regionと10,000のtarget regionから構成。
- **Typewell:** 最終visible TVTの±100 ftを0.5-ft resolutionで覆う400 positions。

このwrite-upでは一貫して、すべてのTVT値をanchorとなる**最終visible TVTに対する相対値**として扱います。

training targetはground-truth alignmentを中心とする指数平滑化probability distributionで、typewell dimensionに沿って正規化します。

追加lossは次の通りです。

- predicted probability mapとgrid TVT valuesから計算したexpected TVT pathに対する**Huber loss**。
- **GR penalty loss:** `mean(probability × grid_GR_gap)`。小さいながら追加改善がありました。

Model

ConvNeXt backboneを持つ標準的な**2D U-Net**を使いました。

- `timm/convnext_small.in12k_ft_in1k_384`
- decoderには標準的なresidual blocks。

ConvNeXtの**LayerNorm**を**BatchNorm**へ置き換えると一貫して良くなりました。ただしNaN lossを避けるにはBF16 trainingが必要です。

downsamplingとupsamplingには、learnableな代替手法より単純な**average pooling + interpolation**の方が良好でした。

Features

Typewell

- GR
- GR is NaN
- TVT

Typewell GRはvisible regionを使ってcalibrateします。`(TVT, GR)`をTVT binsへaggregateし、typewell axisへinterpolateして戻した後、元のGR値とblendします。

Horizontal well

downsampleした各binについて次を使います。

- GR mean
- GR nan rate
- GR standard deviation
- GR slope
- Last − first GR
- Quadratic fitting coefficients
- Quadratic fitting residual RMSE
- Visible-region TVT mean

Typewell × Horizontal interactions

- `|typewell_GR - horizontal_GR|`
- `|typewell_TVT - visible_TVT|`

Coordinate based

- `z_diff`

Particle-filter features

- 2D particle probability heatmap
- `|typewell_TVT - PF_TVT|`

XY-neighbor features

- Predicted TVT difference
- Predicted TVT
- `|typewell_TVT - predicted_TVT|`

累積TVT情報をすでに含むparticle-filter channelsがある場合、TVT differenceだけよりaccumulated TVTを使う方が良好でした。

Particle Filter

私はparticle filterにあまり詳しくなかったため、このcomponentは主にAI coding agentsの支援で開発しました。standalone local CVはおよそ**7.4 RMSE**です。

public baselineと比べ、主な改善は次から来たと考えています。

- 低確率のlarge jumpを許容
- Calibrated typewell GR
- FFBSi smoothing
- 多様なcfg profilesのblending
- raw resolutionではなくbins（64 samples）単位でparticleをupdate

このほかにも多くの細かな実装上の工夫があり、公開コードで確認できます。

XY Neighbor Information

局所的なgeological surfaceが次を満たすと仮定します。

> **S = TVT + Z + C**

さらにSが局所的にlinearなら、

> **ΔTVT = aΔX + bΔY − ΔZ**

となります。`(a, b)`は`(x,y)` neighborsを使ったweighted least squaresで推定します。

実装にはanisotropic distance、singular-case handling、regularizationなど多くのengineering detailがあります。ただし単純な上式に対する改善はわずかだったので、ここでは詳述しません。

standalone local CVはおよそ**11.4 RMSE**です。

XY-neighbor informationを加えると**local CVは一貫して改善**した一方、**Public leaderboardは悪化**したため、いくつか分析しました。

1. XY-neighbor prediction単体は**12.9 LB**で、50 wells sampleに対するhigh probability region内にあります。
2. neighborhood statisticsがtraining distributionの95th percentileを超えた場合、XY based predictionsをGR + `z_diff` predictionsへ置き換えました。

neighborhood statisticsは次の通りです。

- Mean neighbor distance
- 10th percentile neighbor distance
- Prefix/visible neighbor weight ratio
- Distance(query, neighbor center) / average distance(neighbor, neighbor center)

- Average abs cosine corr((x_diff,y_diff),(x_nbr_diff,y_nbr_diff))

これらのstatisticsではleaderboard degradationを説明できませんでしたが、neighborhood qualityは十分表現していると考えます。

そこで不一致はlabel inconsistencyに由来すると判断し、約**0.3 RMSE**一貫して改善するlocal CVを信頼しました。同じneighborhood quality statisticsを後段のensembleでも使います。

Data Augmentation

最も重要な2つのaugmentationは**Z-shift**と**GR transform**です。

Z-shift

TVT + Zを一定に保ちながらTVT pathをrandom sampleします。

sampled pathはreal TVT differencesに対するblock bootstrapで生成します。

GRは次を使ってtypewellへmatchさせ、再生成します。

- TVT + TVT noise

TVT noiseはsmoothed white noiseから構成されます。

まれなfault jumpもsimulationし、**TVT + Z**へoffsetを入れます。

GR transform

typewell GRへ次を適用します。

> `GR' = a × GR + b`

これによりabsolute valuesよりshapeへ依存するようmodelを促します。

Other augmentations

- Reverse path（冒頭の一部をvisibleに保ったまま逆方向へ辿る）
- MD stretching
- 2D channel masking
- GR noise shift（各well内でresidual `GR - matched_typewell_GR` をshift）
- Tail cropping
- Typewell axisに沿ったsequential masking
- Typewell GR jitter（GR channelsへ一貫したtransform）
- PF rotate/shift（shortcut learningを減らすためPF channelsをcorrupt）

Ensemble

信頼できるXY-neighbor informationがないwell（約**10%**）には、XY-neighbor channelsを持たず、代わりに `z_diff` channelを含むmodelを使います。

以下で「default」はparticle-filterまたはXY-neighbor featureを持たず、GR、TVT、`z_diff` channelsを使うmodelです。augmentationやtraining configurationもmodelごとに少し異なります。

Model	Features	Weight (general / no XY)	CV (3 seeds × 5 folds avg)	Public LB	Private LB
Weighted ensemble	—	—	**4.627**	**5.980**	**5.639**
0719_V1	Default	0.07 / 0.40	5.09	5.648	6.130
0729_V3	+ Particle filter	0.00 / 0.20	5.53	6.202	6.768
0801_V1	Default	0.07 / 0.40	5.16	5.723	5.884
0724_V1	+ XY-neighbor channels	0.28 / 0.00	4.86	6.095	5.831
0801_V2	+ XY-neighbor channels	0.28 / 0.00	4.80	6.166	5.937
0803_V2	+ XY-neighbor channels + Particle-filter channels	0.28 / 0.00	5.00	6.185	5.778

Code

inference notebookはこちらです。

https://www.kaggle.com/code/w5833946/submit-reproduce

full training pipelineの再現方法も説明しています。各`3 seeds × 5 folds`のtrainingは、単一の4080Sでおよそ8時間かかります。