rogii-wellbore-geology-prediction

2位解法：AnchorCNN — 条件付き確率経路モデリング

Rank	2
Team	Bilzard
Author	Bilzard
Topic ID	733432
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733432
Retrieved with Kaggle CLI on 2026-08-10.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このコンペを開催してくださったhostの皆様に感謝します。（忠実な相棒であるClaude Code Agentにも感謝します :D）

Public LBの順位が伸び悩み続け、終盤は本当に厳しい戦いでした。この解法をできるだけ多くの人に知ってもらいたくて、上位で終えることを強く望んでいました。締切3時間前までmodelを学習し続け、それがPrivate LB 2位という結果につながったことを嬉しく思います。

TL;DR

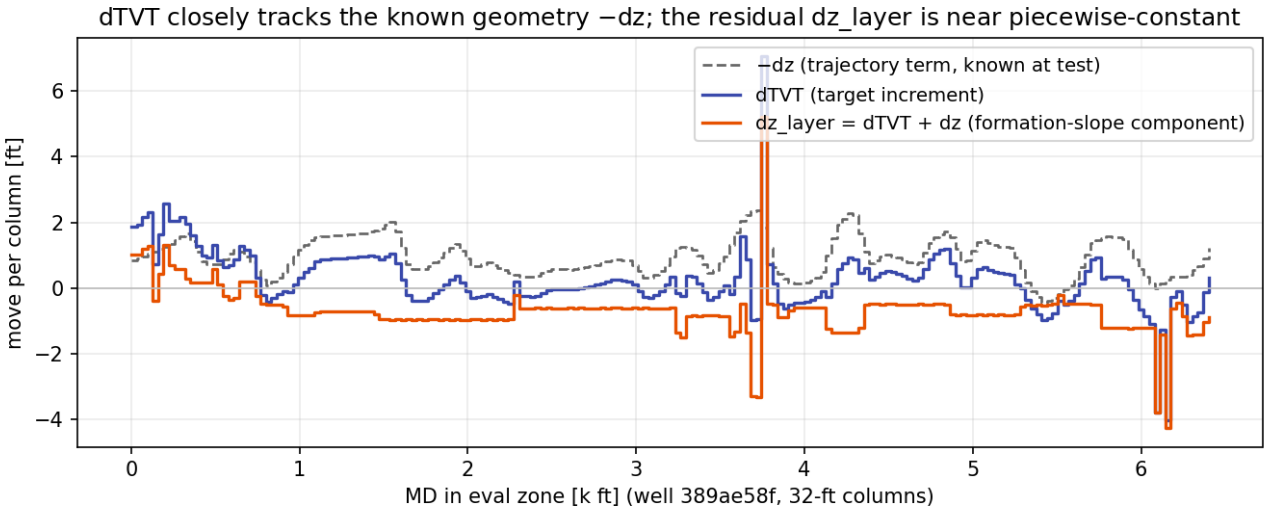
物理的に整合する合成データで、条件付き移動分布 `P(dTVT | TVT)` を予測するanchor-grid CNNを学習しました。経路の期待値はdynamic programmingで厳密にdecodeし、少数の支配的なwellに左右されにくいvalidationでmodelを選択しました。

データから得た重要な洞察

expertが解釈したformation surface（train dataの `ANCC`、`BUDA` などの列）は、特徴的な「直線が連なる」形をしています。formation surfaceの深度を `z_layer` と書き（その増分 `dz_layer` がformation slope成分）、次の恒等式が成り立ちます。

```
dTVT = dz_layer − dz    (1)
```

これは `z_layer := TVT + z − b_well` と定義すれば直接導けます。`z` はtrajectoryの実測TVDであり、test時も全rowで既知です。real sampleを見ると、`dz_layer/dMD` は階段状です。大半の区間では一定で、ときどきstepがあります。恒等式によって係数は-1に固定されるため、**stepがない場所ではdTVTの形が `−dz` と正確に一致します**（下図で2曲線が平行なのはこのためです。stepは約10%のcolumnにしか現れません）。



→ `dz/dMD`（dip z）をinput featureとして与えると、modelの仕事は「滑らかなstructural slope `dz_layer` を推定する」ことへ縮小され、expertが描きそうなformation surfaceへ強く誘導されます。

合成データ

私の合成データ生成は、次の**生成仮定**に基づきます（同じstratigraphic depthのrockは同じ性質を持つ、というlayer-cake近似です）。

```
GR_obs = f(TVT) + r(TVT)    (2)
```

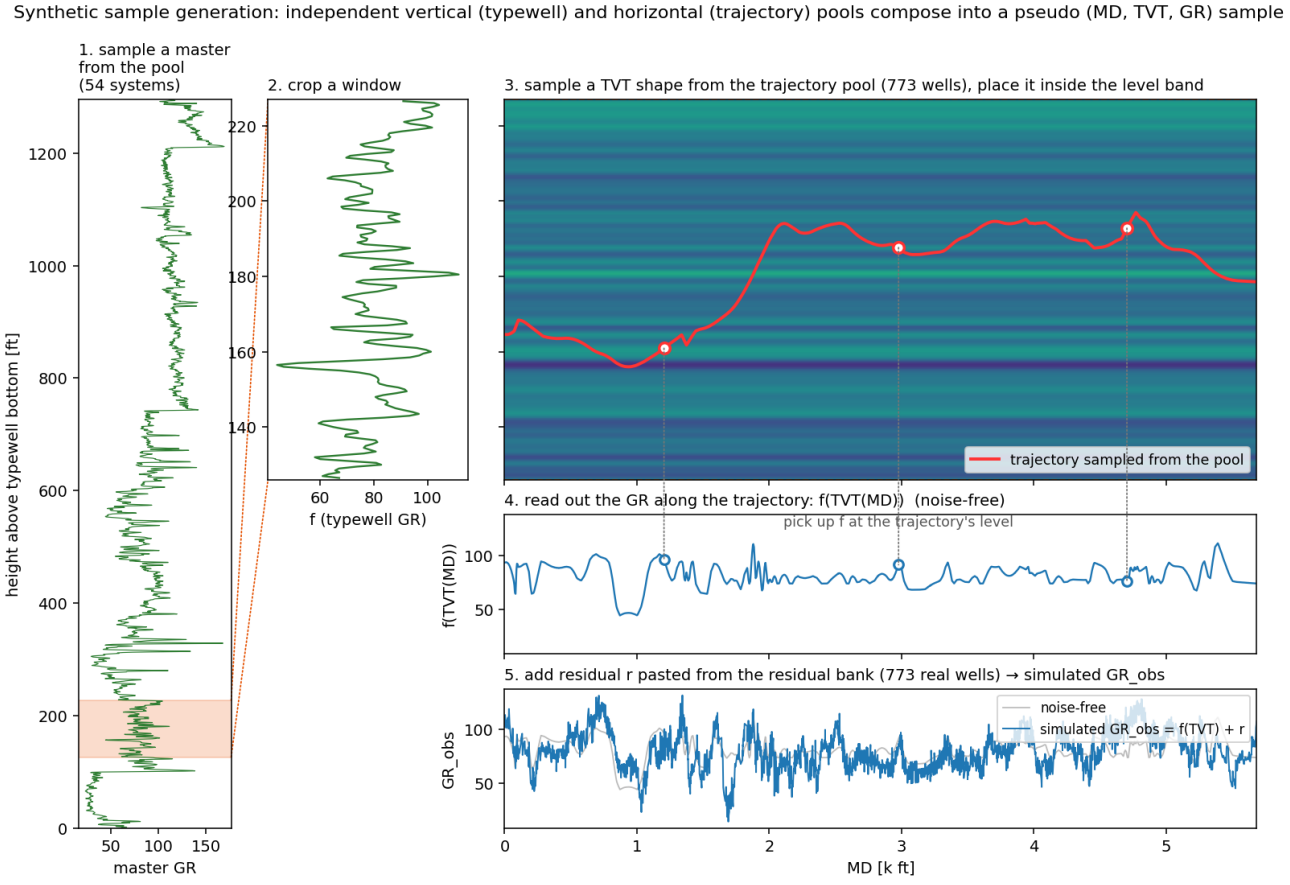
- `f`: typewellのTVT–GR profile
- `r`: residual noise

(2)はTVTの関数なので、注目すべき性質があります。**任意のTVT trajectoryが与えられれば、この仮定と整合するデータを無制限に生成できます。** 仮定が破れる部分（同じTVTでもwellごとにGRが異なる部分）はreal dataから偏差を測り、後述するresidual `r`として合成へ組み込みました。

データ合成pipeline

vertical material（typewellのlevel→GR profile）とhorizontal material（MDに沿ったTVT trajectory）は独立したpoolからsampleし、`f(TVT)`を読み出してpseudo `(MD, TVT, GR)` sampleを構成します。

1. master pool（54 systems）から1つmasterをsampleする
2. windowをcropし、typewell profile `f`とする
3. real-well pool（horizontal pool）からTVT trajectory shapeをsampleし、level band内の深度へ配置する
4. trajectoryに沿ってGRを読み出す：`f(TVT(MD))`（noise-free）
5. residual bank（773 real wells）からsampleしたresidual `r`を加え、simulated（noisy）`GR_obs`を作る



次の3 subsectionで、このpipeline順に各stageを説明します。

Typewell GRの合成（steps 1–2）

Discussion comment [3]で指摘されたとおり、trainのtypewellは少数のmaster well seriesへ統合できます。私自身の検証では**54 systems**へ統合され、各system内の全typewellが1本のmaster TVT–GR seriesへ完全に含まれることを確認しました。master seriesから任意のwindowをcropすれば、どのlevel rangeに対してもtypewell profile `f` を生成できます。

TVT trajectoryの生成（step 3）

trainでは決して現れないcurveを与えるとmodelが偽のfeatureを学ぶため、free-form curveではなく、**real train trajectoryから2段階で**生成します。

(a) Shape：real trajectoryのshapeをvertical shiftと2 trajectoryのmixupで変形します。

```
TVT_mix = λ·TVT1 + (1−λ)·TVT2    (3)
```

(b) systemへの配置（re-skinning）：shapeへtypewell systemを割り当て、配置する深度を決めます。source systemのdrilling band（そのsystemのwellが実際に掘られたlevel分布）内で元trajectoryが占めていたquantileを、target systemのdrilling bandで同じquantileへ写像します。shapeは保持され、深度はtarget systemにとって現実的になり、GRはtarget systemのmaster seriesから再生成されます（新しい「skin」）。

> 注（`z` の整合性）：trajectoryを変換する間、内部表現として保持するのは `z` ではなく**`z_layer`**です。最後に `z = z_layer − TVT` として `z` を導出します。これにより、どのような変換を適用しても恒等式(1)との整合性が構造的に保たれます。

Residualの追加（step 5）

real wellのresidual `r = GR_obs − f(TVT)` を調べると、**TVT上で集約したときに現れる滑らかなwell固有mean profile**と、残りへ分解できます。

```
r(TVT) = δ_w(TVT) + ϵ    (4)
```

- `δ_w`：systematic component。各深度で「このwellのGRがtypewellからどれだけずれるか」を表すwell固有signature（TVT上で集約した `r` のmean）
- `ϵ`：残りのnon-systematic noise。white noiseではなくautocorrelationを持つ

各synthetic wellへ、次のどちらかでnoiseを注入しました。

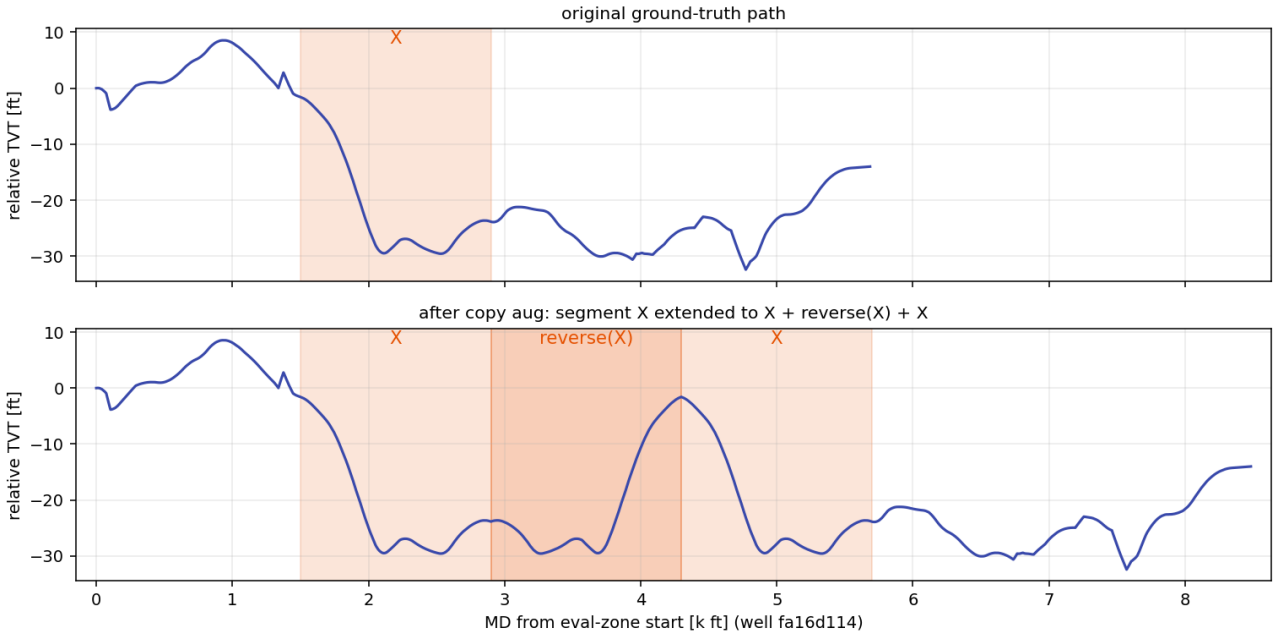
- **real residualの貼り付け**：real wellのresidual sequence `r` をそのまま貼る（`δ_w` と `ϵ` の両方をreal-dataの性質ごと引き継ぐ）
- **合成**：`δ_w` をTVTの滑らかなrandom functionとしてsampleし、`ϵ` はreal dataへfitしたAR noise modelで模倣する

これにより、現実的な「well固有GR profileの癖」を持つsynthetic dataができました。

Augmentation

training時にreal wellとsynthetic wellの両方へaugmentationを適用しました。主なものは次です。

- **Geometric**：MD flip、level flip（labelの符号も反転）、MD方向random crop、level shift（±32 ft）
- **Structural**：`z_layer`空間でのflipとscaling（structural slopeを伸縮）。内部表現に`z_layer`を使うため恒等式(1)との整合性を保つ
- **Length normalizationとstitching**：短いwellを、自身または他wellのfragmentのcopy&pasteでtarget lengthまで延長し、継ぎ目を短いspline（100 ft）で滑らかに接続する。eval zone内のsegmentを`X + reverse(X) + X`へ冗長に拡張するcopy augも使った（下図。継ぎ目で値は連続し、gradientだけ反転する）
- **Observation quality**：real missing dataと全く同じ形式でGR span（最大21 columns）をmaskするspecaug



Modeling

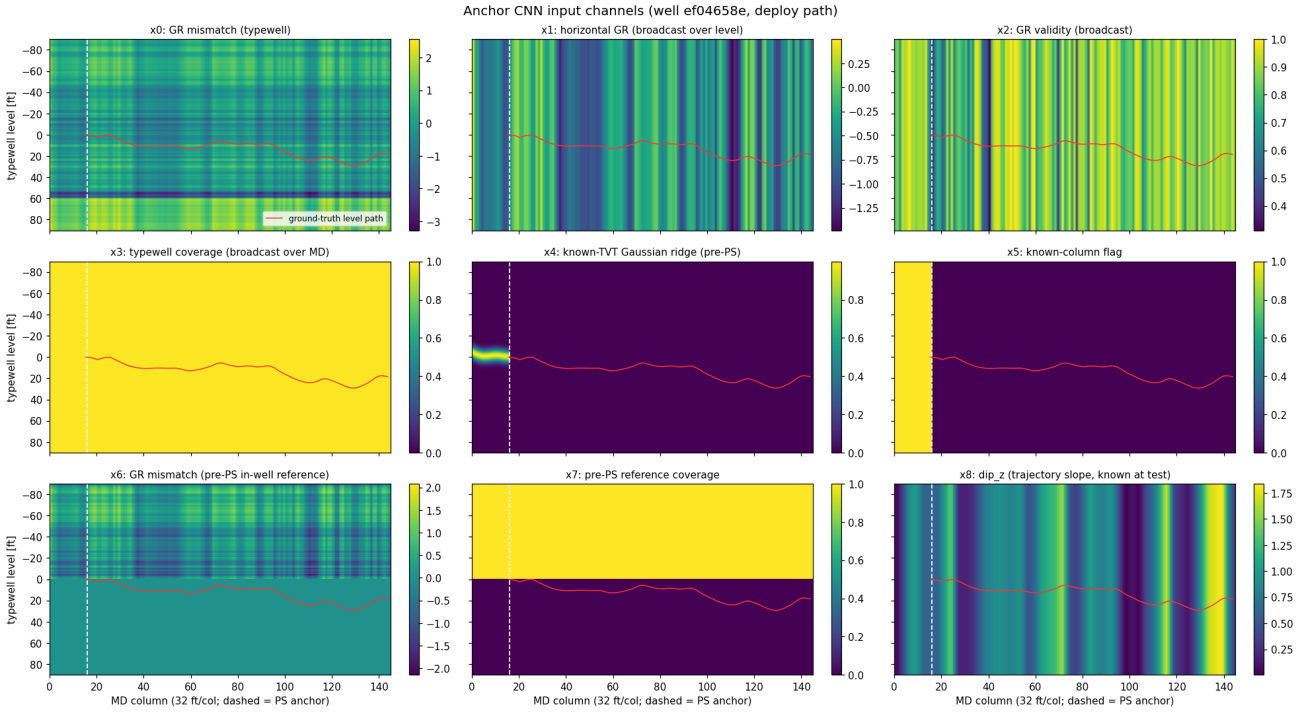
Discussion [1]で@hengck23が共有したCNNから始めました（残念ながらpaper [2]の著者はmodelの詳細な実装を公開していませんでした）。

このtaskのGR matchingには本質的な曖昧性があります。typewell GR profileには似たstripeが繰り返し現れるため、局所的には**複数のlevel仮説、つまり「wellはいまこの深度にいる」という仮説が、同程度にGRへ一致します。** つまりposteriorはmultimodalで、もっともらしいtrajectory candidateが複数あります（multi-path）。初期実験では、単一のteacher pathをregressionするmodelがこれらmodeの平均へcollapseし、どの仮説にも対応しないpathを作ることを確認しました。このtaskには不適合です。

[2]の本質は、multi-pathを条件付き確率model `P(dTVT|TVT)`として表すことだと解釈しました。つまり**すべてのlevel仮説について同時に**、「いまwellが深度TVTなら、次の区間でどれだけ上下へ動くか」の分布を持ちます。そこで、これを明示的に表現するprobability modelを設計しました。

Input features

inputは `(9, 512, 336)` のimage tensorです。縦軸はtypewell level（0.5 ft/bin、±128 ft）、横軸はMD（32 ft/column。最初の16 columnsは既知のpre-PS interval）です。



9 channelsは次のとおりです（x6–x8はコンペ終盤に追加したためgainを測定しています）。

ch	content	gain
x0	GR mismatch（typewell）：wellがそのlevelにいると仮定した各 `(level, MD)` で、lateral GRとtypewell GRの差	
x1	lateral GR（level方向へbroadcast）	
x2	GR validity（broadcast）	
x3	typewell coverage（MD方向へbroadcast）	
x4	known TVTのGaussian ridge（`TVT_input` prior。既知pre-PS intervalを最初の16 columnsへ描画）	
x5	known-column flag	
x6	GR mismatch（pre-PS）：同じwellのpre-PS intervalから作ったlevel→GR referenceとのmatching image（hostのtip [6]から着想）	x7と合わせてOOF −0.759 / Public −0.271 / Private −0.320
x7	x6のcoverage mask	x6とのpair
	dip z：trajectory `z` のcolumnごとのslope（test時に既知）	

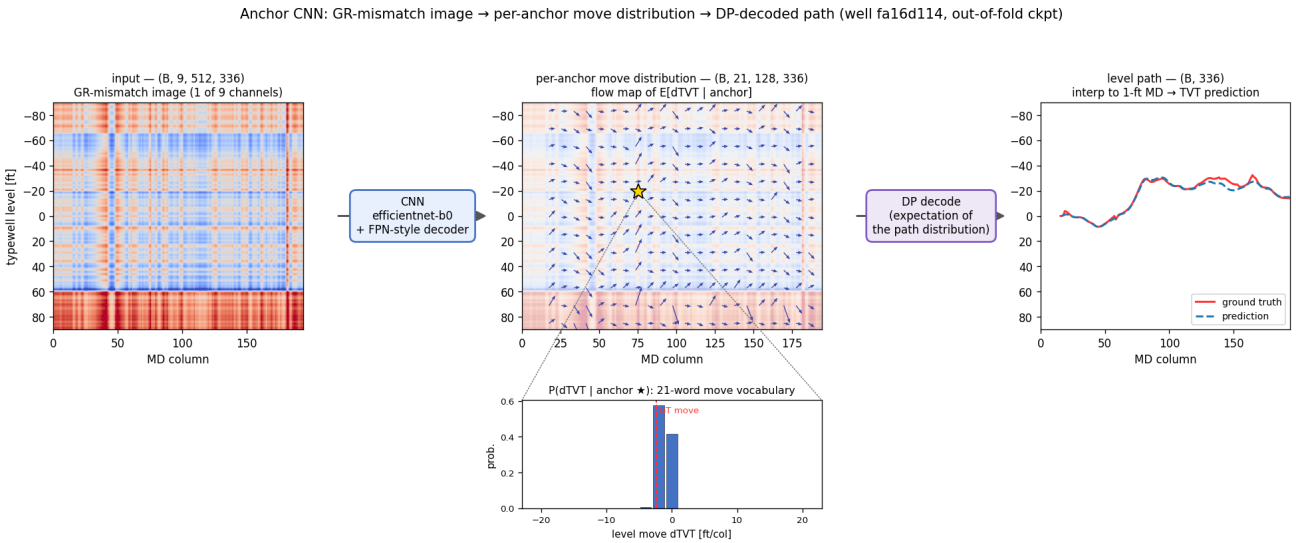
ch	content	gain
x8		Public −1.089 / Private −0.470 (*)

x6/x7のgainは、このchannelだけが異なるsubmission pair（sub061→062）の純粋な差です。x8（*）は、channel追加、structural augmentation改訂、decoderをDP-onlyへ切り替える、という3変更の混合効果です。

AnchorCNN

基本設計はanchor-based / anchor-free object detector family（YOLO [4]、CenterNet [5]など）から着想しました。CNNはlocal featureのencodeが得意で、特定座標 `(MD, TVT)` での移動方向 `dTVT` はlocal featureから予測しやすいからです。そこで、**「座標 `(MD, TVT)` にいる」というconditioning部分をCNN anchorへ対応付けました。** ここでanchorとはCNN feature map座標 `(i, j)` のembedding vectorです。座標 `(i, j)` は「MD column `j` でlevel `i` にいる」というlevel仮説に対応し、各anchorからその位置を条件とするmove distributionを読み出します。

具体的には、efficientnet-b0の全stage outputをFPN風decoderで融合し（各stageを1×1 convで共通widthへ投影し、単一解像度へinterpolateして加算）、`(B, 21, 128, 336)` **state grid**へ写像します。縦軸は2 ft/binのlevel、横軸は32 ft/columnです。各grid pointのanchorから、位置を条件とした離散move distribution `P(dTVT | anchor)` を予測します。`dTVT` のmove vocabularyは21 classes、{0, ±2, ±4, ⋯, ±20} ft/column（2 ft単位で {−10, ⋯, +10} bins）です。



Training

ground-truth pathに沿ったteacher forcingでsuperviseします。各columnでground-truth level上のanchorへ、quantizeしたground-truth moveに対するcross-entropy loss（および補助的なintra-bin position loss）を与えます。各epochでreal training wells（foldあたり約620）と、on-the-fly生成した2,048 synthetic wellsを混ぜました。warmup後はlearning rate `1e-3` 固定（decayなしのWSD schedule）、weight EMAを用い、120 epochs学習しました。5 folds × 3 seeds全体でsingle GPU約10時間でした。

Path generation

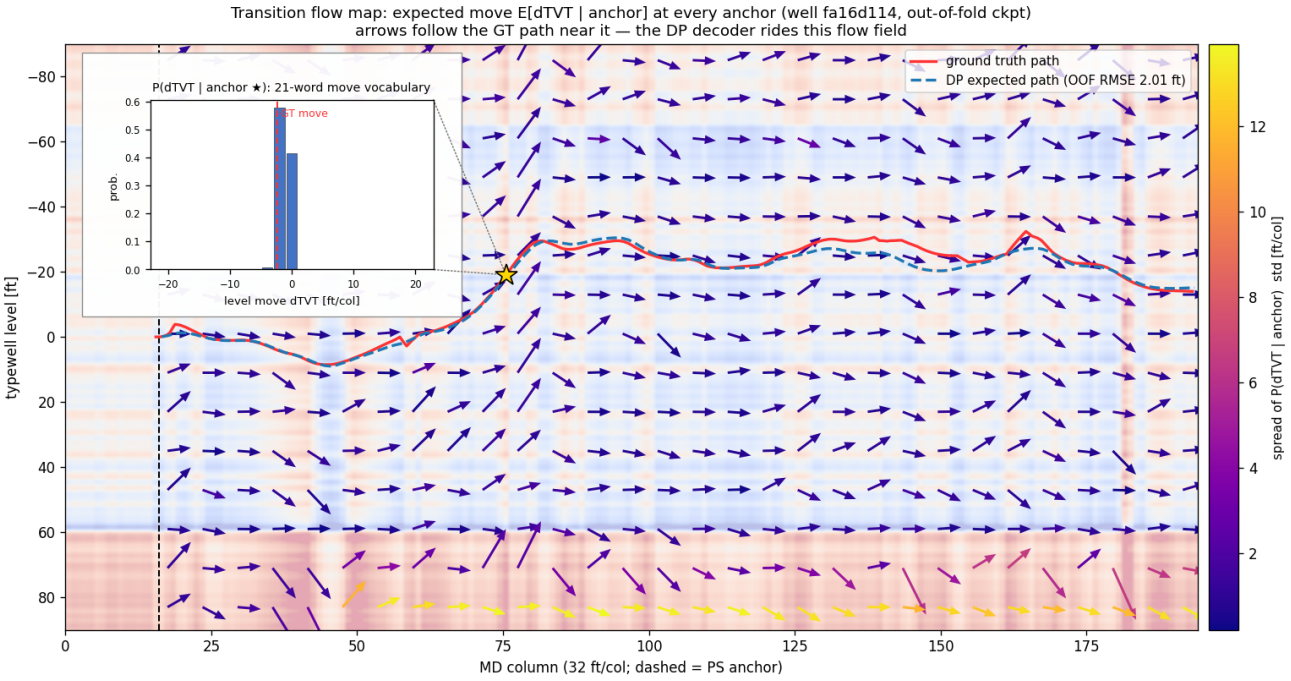
PS pointからstate grid上のprobability fieldを使ってpathを生成する方法は2つあります。

1. **Rollout**：`P(dTVT | anchor)`から確率的にsampleし、random path bundleを生成する
2. **Path expectation（DP）**：dynamic programmingでstate gridをmarginalizeし、path distributionの期待値を厳密に計算する。PS levelのpoint massからlevel marginal `p_k`をcolumnごとに伝播し、各columnのmeanを予測とする

```
p_{k+1}(s) = Σ_{s'} p_k(s') · P(dTVT = s − s' | anchor(s', k))    (5)
TVT_hat(k) = Σ_s p_k(s) · TVT(s)                                  (6)
```

samplingは行いません。(5)–(6)を厳密に計算します。

当初は`N=1024` rollout pathを生成してrerankerでfilterする予定でしたが、うまくいかなかったため、submissionではDPで計算した「average path」を使いました。なおViterbi（maximum-likelihood path）や他のmode-tracking decoderも、一貫して期待値より悪い結果でした。



Ensembling and TTA

final submissionは、5 folds × 3 seeds = 15 checkpointsのDP path × MD-phase TTA（8 views）× 2 grid resolutions（32 ft/columnと16 ft/column）を平均します。ensemble全体で200 hidden test wellsをKaggle T4上約40分でscoringしました。

MD-phase TTA：CNN inputのMD解像度は32 ft（1 column）なので、32 ft未満でcolumn境界をどこへ切るかというphase ambiguityが残ります。GR correlation length（約18 ft）に対してcolumnごとのbox averagingは粗く、columnの切り方でinput value自体が変わります（aliasing）。これを補うため、column-grid originを{0, 8, 16, 24, 32, 40, 48, 56} ftずらした8つのsub-resolution phaseでinferenceし、予測を平均しました。

Robust validationとmodel selection

competition metricのpooled RMSEはsquared error sumに比例するため、「catastrophic well」に支配されやすい指標です。すでに良いwellをさらに改善するより、大きく外している少数wellを直す方がmetricは大きく動きます。

問題は、少数wellでの改善がsystematicなのか、単なるluckなのかです。例えば支配的な5 wellにおける改善方向がrandomなら、real improvementではなくchanceとみなすべきです。

同時にdataは少なく、train 773 wells、Private testは148 wellsしかありません。そのため統計的に慎重なmodel selectionが不可欠でした。

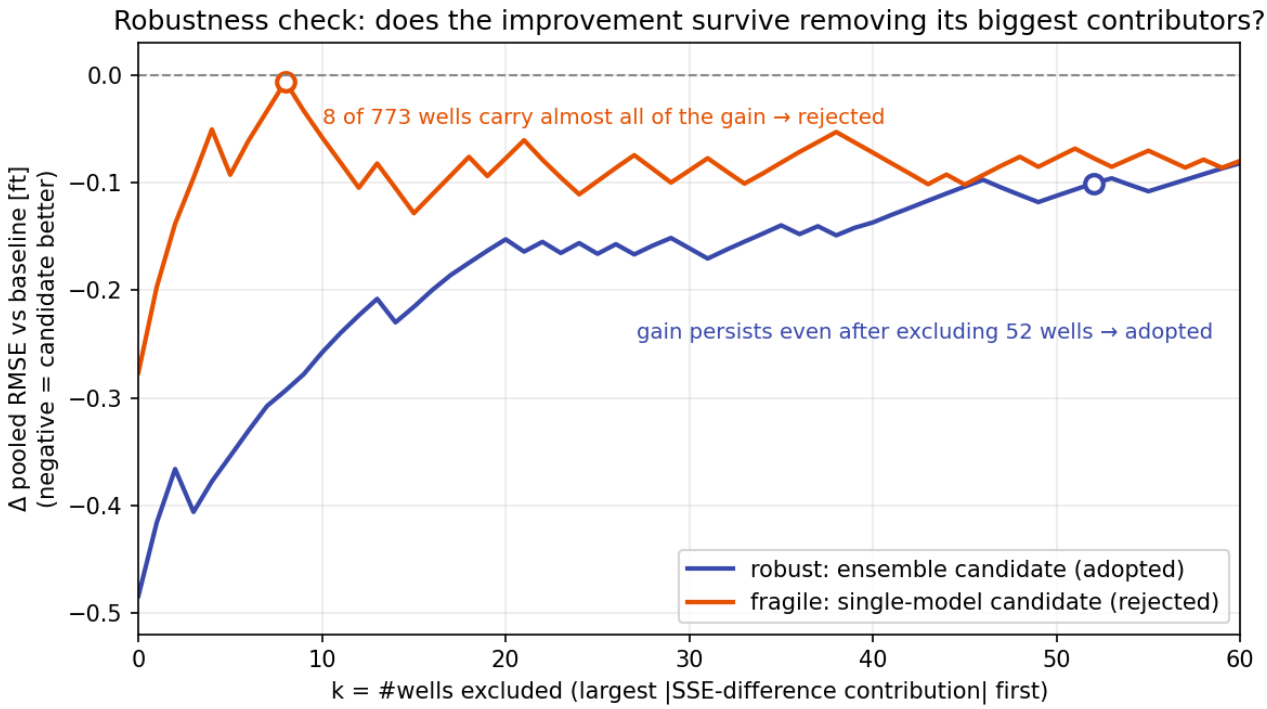
Robust acceptance test（leave-largest-contribution-out）

2 model `base`と`treat`を比較するとき、wellごとのsquared-error sum（SSE）の差を計算します。

```
g_w = SSE_treat(w) − SSE_base(w)
```

そして`|g_w|`の降順、つまり差へ最も大きく寄与するwellから除きます。改善が最初に消える除外数を`k*`と定義します。`k*`が十分大きくない、すなわち改善が少数wellのluckへ依存している場合はcandidateを棄却しました。

下図は実例（baselineに対する2 candidateのremoval curve）です。**orange curve**は`k=0`でOOFを-0.28改善しているように見えますが、773 well中わずか8 wellを除くとgainがほぼ消えます。改善が少数wellのluckに依存するため棄却しました。**blue curve**は緩やかに減衰し、Public LBと同じ52 wellを除いてもgainが残るため採用しました。



Results

sub	configuration	OOF pooled	Public	Private
068	AnchorCNN（32 ft/col grid）×15 ckpt	5.624	**5.780**	6.126
071	068 + MD-phase TTA8	5.417	5.820	6.078
075	16 ft/col grid × TTA8 alone（diagnostic）	5.348	5.970	5.882
076（final, selected）	dz_layer-head models × TTA8 + 16 ft/col × TTA8	**5.140**	6.146	**5.802**
077（final, hedge）	068-family × TTA8 + 16 ft/col × TTA8	5.242	5.910	5.905

- Final standing：**2位（Private 5.802、sub076）**

Inference Code

うまくいかなかったこと

設計の分岐点となった棄却例だけを挙げます。

path bundleからの選択（reranker、reinforcement learning）：rollout bundle（`N=1024`）の中には非常に良いpathが実際に含まれ、hindsightでbest pathを選ぶoracleはdeploy scoreを数ft上回りました。その差を回収するため、bundleから良いpathを選ぶrerankerとreinforcement learning（GRPO）を試しましたが、どちらもevaluation dataへ容易にoverfitし、DP expectationを一貫して超えられませんでした。最終的に「bundleから選ぶ」設計を捨て、DP marginalization（expectation decoding）へ集中しました。

explicit formation modeling：近傍wellからformation surface自体をmodelingするとfieldの粗いtopographyは捉えられますが、catastrophic wellを修正できませんでした。teacher label（expert interpretation）がformationを直接参照せず、GR matchingに基づくrelative judgmentだからだと推測しています。この結果から、explicit formation modelは使わず、GR matching上のprobability fieldへ全面的に集中しました。

Final thoughts

このmodelが模倣するのはgeosteering expertのinterpretation作業であり、その曖昧性はtaskに内在します。曖昧性を早く強制的に解消するのではなく、このapproachはcandidate move上のprobability distribution（`P(dTVT|TVT)`）として保持します。これが実務上最も価値のある性質だと考えます。GR matchingが曖昧な場所では、modelが代替path仮説を提示し、low-confidence intervalをhuman reviewへ回せます。さらに独立したexternal data（offset wellやseismicなど）が得られれば、仮説をreweightして曖昧なpathのうち最も妥当なものを絞れます。

References

- [1] discussion: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/699853

- [2] Sergey Alyaev et al., "Direct Multi-Modal Inversion of Geophysical Logs Using Deep Learning" — https://arxiv.org/pdf/2201.01871 （poster: https://nfes.org/assets/workshop2022/ambrus_sequential_multi_mode_inversion_poster.pdf）
- [3] typewellをmaster seriesへ統合できると指摘した@pcjimmmyのcomment: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/705210#3468651
- [4] Joseph Redmon et al., "You Only Look Once: Unified, Real-Time Object Detection" — https://arxiv.org/abs/1506.02640
- [5] Xingyi Zhou et al., "Objects as Points"（CenterNet） — https://arxiv.org/abs/1904.07850
- [6] PS前のlateral GRはtypewell GRより高解像度なのでGR correlationへ使う方が良いと指摘したhost @igorakuvaevのcomment: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/698825#3456361

補足Q&A

Tucker Arrants — 質問

MD-phase TTAの8 phaseはClaudeから提案されたのでしょうか。私のmodeling trialでもClaudeが全く同じformulationを提案し、自分のideaが尽きたときに出した数少ない本当に良い新規案の1つでした。私たちのClaudeが同じTTA ideaへ収束したのか、それともご自身の発案なのか気になりました。いま振り返れば当然に見えますが、私は自力では思い付かなかったでしょう。Kaggleではagentが「同じsolutionへ収束するだけ」と言われることも多いので、そのdata pointを集めています。

Bilzard — 回答

ClaudeがMD shiftを提案しましたが、shift幅をsub-column（32 ftのcolumn幅の内側）にして、その後に元へ戻すことを提案したのは私です。8 phaseはsweepの結果であり、どちらかが直感で選んだ数ではありません。

Claudeは大量のideaを提案しましたが、情報処理に圧倒されることもあり、ほとんどは有望に見えませんでした。（公平に言えば、自分では思い付かない素晴らしい仕事をすることもありましたが、議論全体の品質はかなりrandomに感じました。）

現在の「autonomous」agentはまだ十分にautonomousではなく、人が隣にいなければ初歩的な問題で止まります。human engineerが自らtorchを運び続けなければ、時間を燃やすだけになると思います。