rogii-wellbore-geology-prediction

2位解法：AnchorCNN — 条件付き確率による経路modeling

Rank	2
Team	Bilzard
Author	Bilzard
Topic ID	733432
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733432
Retrieved with Kaggle CLI on 2026-08-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このコンペを開催してくださったhostの皆さんに感謝します（忠実な相棒Claude Code Agentにも感謝します :D）。

Public LB順位が停滞し続け、終盤は本当に苦しい戦いでした。できるだけ多くの人にこの解法を知ってほしくて、上位で終えることを目標にしました。締切3時間前までmodelを学習し続け、その結果Private LB 2位になれたことを嬉しく思います。

TL;DR

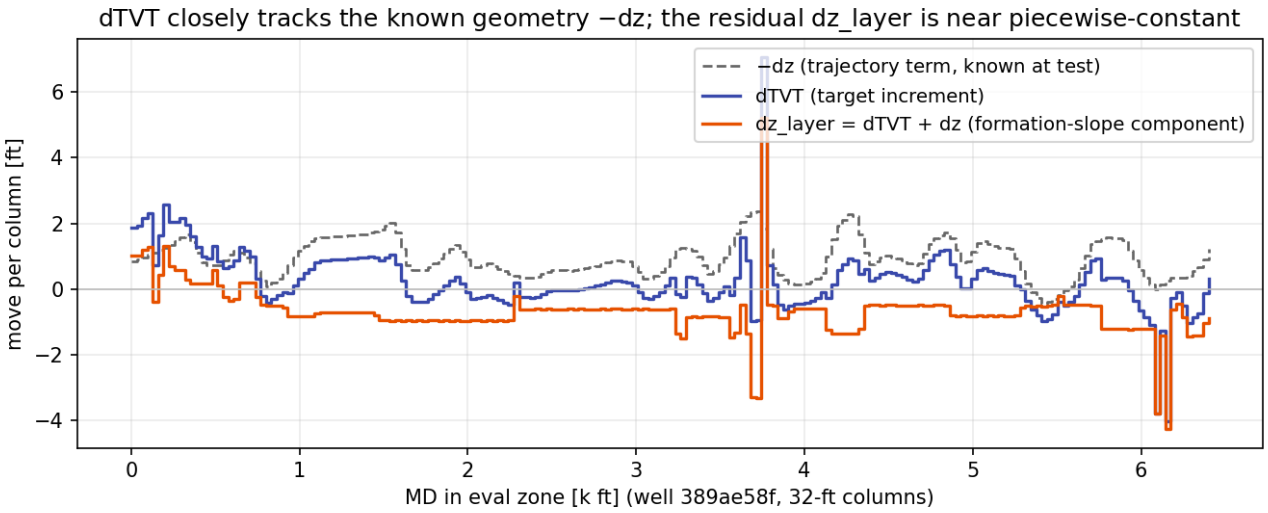
物理的に整合する合成データで、条件付き移動分布 `P(dTVT | TVT)` を予測するanchor-grid CNNを学習しました。dynamic programmingで期待経路を厳密にdecodeし、少数の支配的wellに頑健なvalidationでmodelを選びました。

データから得た重要な洞察

専門家が解釈したformation surface（train dataの `ANCC`、`BUDA` など）は、「直線が連なる」特徴的な形状を持ちます。formation surfaceの深さを `z_layer`、その増分をformation-slope成分 `dz_layer` とすると、次が成り立ちます。

```
dTVT = dz_layer − dz    (1)
```

これは `z_layer := TVT + z − b_well` と定義すれば直接導けます。`z` は軌跡のmeasured TVDで、test時も全rowで既知です。real sampleを見ると、`dz_layer/dMD` は階段状で、大半の区間では一定、たまにstepが入ります。この恒等式は `dz` の係数を−1に固定するため、**stepがない場所ではdTVTの形が `-dz` と完全に一致します**。図で2曲線が平行なのはこのためで、stepが現れるのは列の約10%だけです。



そこで `dz/dMD`（dip z）を入力すると、modelの仕事は「smoothなstructural slope `dz_layer` を推定すること」へ縮み、専門家が描きそうなformation surfaceへ強く誘導されます。

合成データ

合成データ生成は、次の**生成仮定**に基づきます。同じstratigraphic depthのrockは同じpropertyを持つというlayer-cake近似です。

```
GR_obs = f(TVT) + r(TVT)    (2)
```

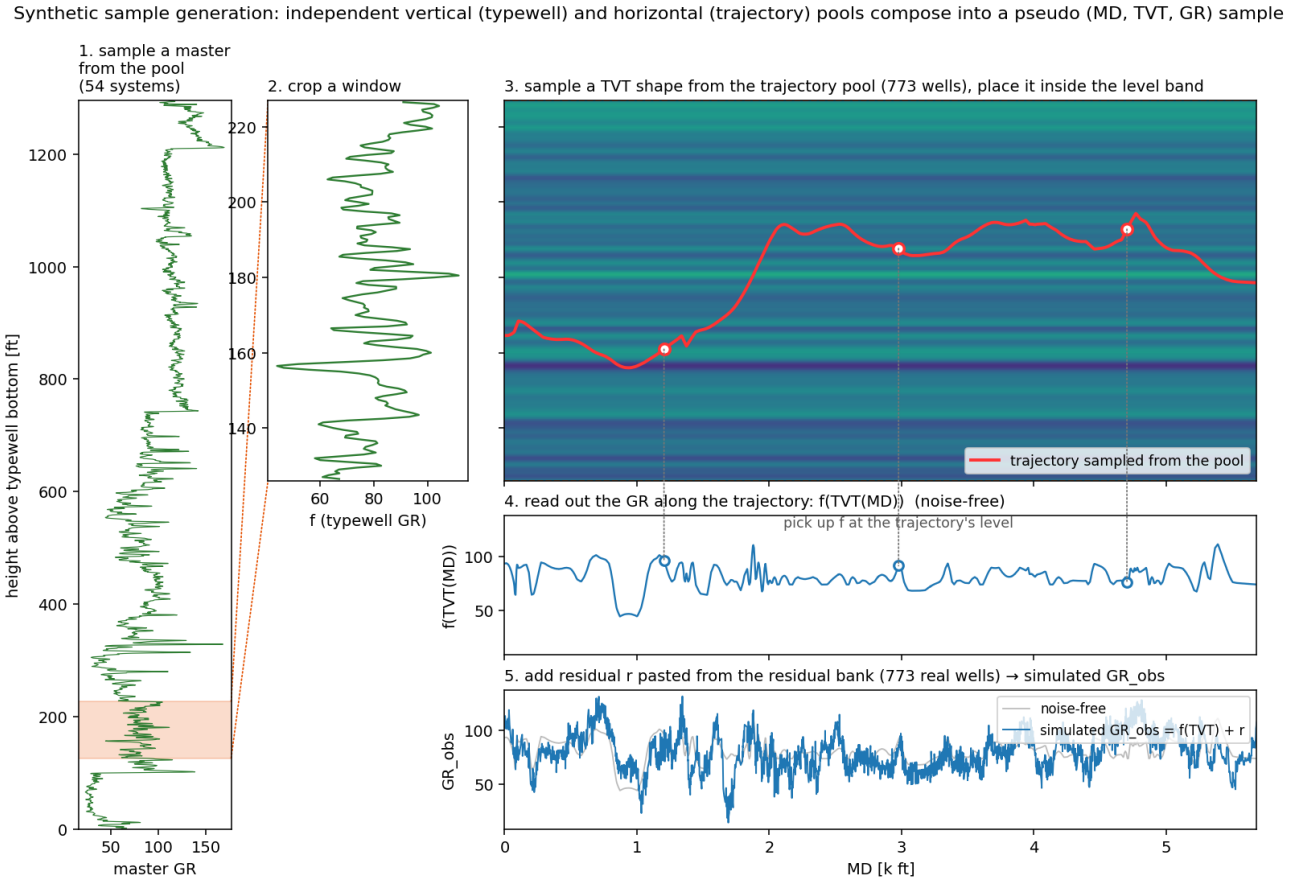
- `f`：typewellのTVT–GR profile
- `r`：residual noise

(2)はTVTの関数なので、**任意のTVT trajectoryを与えれば、この仮定と整合するデータを無制限に生成できる**という重要な性質があります。同じTVTでもwellごとにGRがずれる部分はreal dataで測定し、後述のresidual `r`を通じて合成へ持ち込みました。

Data synthesis pipeline

縦方向のmaterial（typewellのlevel→GR profile）と、横方向のmaterial（MDに沿うTVT trajectory）は独立poolからsampleし、`f(TVT)`を読み出してpseudo `(MD, TVT, GR)` sampleを作ります。

1. master pool（54 system）からmasterを1つsample
2. windowをcropしてtypewell profile `f`とする
3. real-well poolからTVT trajectory shapeをsampleし、level band内のdepthへ配置
4. trajectoryに沿って`f(TVT(MD))`を読み出す（noise-free）
5. residual bank（773 real well）からsampleした`r`を加え、simulated `GR_obs`を作る



Typewell GRの合成（step 1–2）

Discussion comment [3]で指摘された通り、train typewellは少数のmaster well seriesへ統合できます。私の検証では**54 system**となり、各system内の全typewellが1本のmaster TVT–GR seriesへ完全に含まれることを確認しました。このmaster seriesから任意windowをcropすれば、どのlevel rangeのtypewell profile `f`も生成できます。

TVT trajectoryの生成（step 3）

trainに現れ得ないcurveを与えるとmodelがspurious featureを学ぶため、free-form curveでなく、**real train trajectoryから2段階で生成**しました。

(a) Shape：real trajectoryをvertical shiftし、2軌跡をmixupします。

```
TVT_mix = λ·TVT1 + (1−λ)·TVT2    (3)
```

(b) systemへの配置（re-skinning）：shapeをtypewell systemへ割り当て、配置depthを決めます。source systemのdrilling band内で元trajectoryが占めたquantileを、target systemのdrilling bandの同じquantileへ写します。shapeは保たれ、depthは現実的になり、GRはtarget master seriesから再生成され、新しいskinになります。

> trajectory変換中の内部表現には`z`でなく**`z_layer`を保持**し、最後に`z = z_layer − TVT`で`z`を導出します。どの変換でも恒等式(1)が構造的に保たれます。

Residualの追加（step 5）

real wellの`r = GR_obs − f(TVT)`は、TVTで集約すると現れる**smoothなwell固有mean profile**と、残差へ分解できます。

```
r(TVT) = δ_w(TVT) + ε    (4)
```

- `δ_w`：systematic component。各depthで、そのwellのGRがtypewellからどれだけずれるかというwell固有signature
- `ε`：残るnon-systematic noise。whiteではなくautocorrelationを持つ

各synthetic wellへ、次のどちらかでnoiseを注入しました。

- **real residualをpaste**：real wellのresidual sequence `r`をそのまま貼り、`δ_w`と`ε`の実データ性質を両方移す
- **合成**：`δ_w`をTVTのsmooth random functionとして生成し、`ε`はreal dataへfitしたAR noise modelで模倣

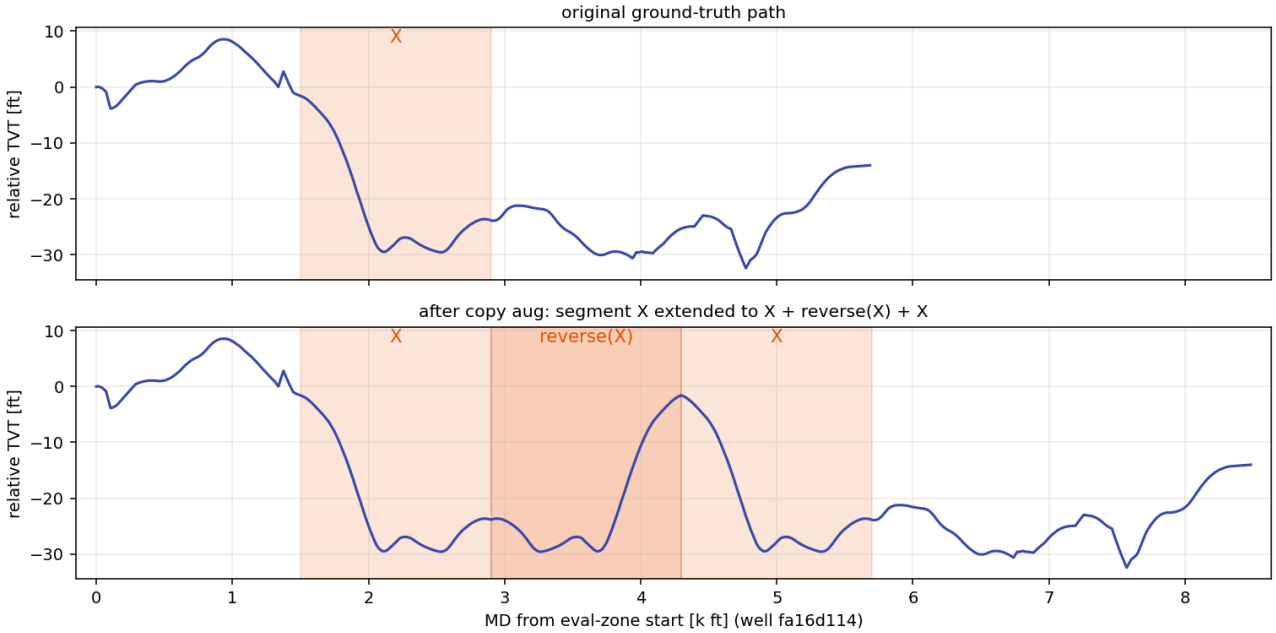
こうして現実的なwell固有GR profileの癖を持つsynthetic dataを作りました。

Augmentation

realとsyntheticの両方へtrain時augmentationを適用しました。主なものは次です。

- **Geometric**：MD flip、level flip（label符号も反転）、MD方向random crop、level shift（±32 ft）
- **Structural**：`z_layer`空間でのflipとscale。恒等式(1)は保持

- **Length normalization/stitching**：short wellを自己断片または別well断片のcopy&pasteでtarget lengthまで延長し、100 ftの短いsplineでseamを滑らかに接続。eval zone内のsegment `X`を`X + reverse(X) + X`へ延長するcopy augも使用
- **Observation quality**：real missing dataと同じ形式で最大21 columnのGR spanをmaskするSpecAug



Modeling

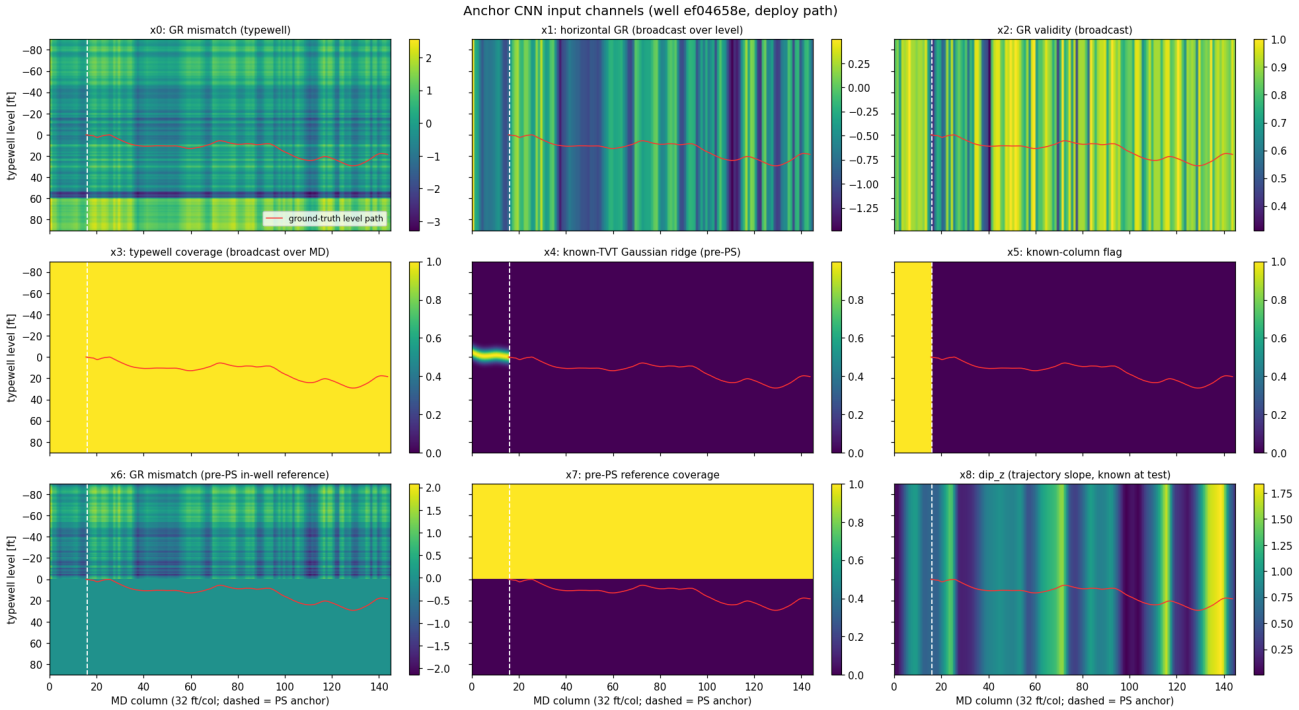
Discussion [1]で@hengck23が共有したCNNから始めました（論文[2]の著者はmodelの詳細実装を公開していませんでした）。

このtaskのGR matchingは本質的に曖昧です。typewell GRには似たstripeが繰り返し現れ、局所的には**複数のlevel hypothesisが同程度によく一致**します。posteriorはmultimodalで、もっともらしいtrajectory候補が複数あります。単一teacher pathをregressするmodelはmodeの平均へcollapseし、どの仮説にも対応しないpathを出すことを初期実験で確認しました。

論文[2]の本質は、multi-pathを`P(dTVT | TVT)`という条件付き確率modelで表すことだと解釈しました。**すべてのlevel hypothesisについて同時に**、「今TVTにいるなら次区間で何ft上下するか」を保持します。

Input features

入力は`(9, 512, 336)`画像tensorです。縦軸はtypewell level（0.5 ft/bin、±128 ft）、横軸はMD（32 ft/column、最初の16列は既知pre-PS区間）です。



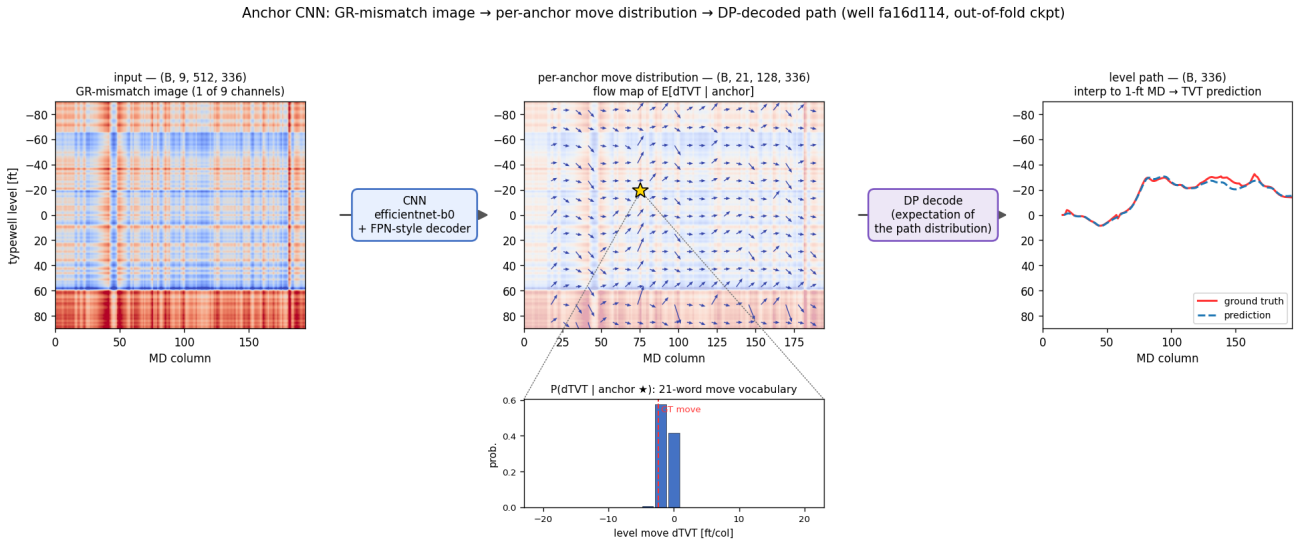
ch	内容	gain
x0	typewell GR mismatch。各 `(level, MD)` で、そのlevelにいると仮定したhorizontal GRとtypewell GRの差	—
x1	horizontal GR（level方向へbroadcast）	—
x2	GR validity（broadcast）	—
x3	typewell coverage（MD方向へbroadcast）	—
x4	known TVTのGaussian ridge。pre-PSの `TVT_input` priorを最初の16列へ描画	—
x5	known-column flag	—
x6	pre-PS GR mismatch。同じwellのpre-PSから作ったlevel→GR referenceとのmatching image	x7と合わせOOF −0.759 / Public −0.271 / Private −0.320
x7	x6のcoverage mask	x6と対
x8	dip z：test時既知のtrajectory z のper-column slope	Public −1.089 / Private −0.470（*）

x6/x7のgainは、変更点がこのchannelだけのsubmission pair（sub061→062）です。x8（*）はchannel追加、structural augmentation修正、decoderのDP-only化という3変更の混合効果です。

AnchorCNN

anchor-based/anchor-free object detector（YOLO [4]、CenterNet [5]など）から着想しました。CNNはlocal featureをencodeするのが得意で、特定座標 `(MD, TVT)` での移動方向 `dTVT` はlocal featureから予測しやすいからです。条件部分「座標 `(MD, TVT)` にいる」をCNN anchorへ対応させました。feature mapの座標 `(i,j)` のembedding vectorをanchorと呼び、level hypothesis `i`、MD column `j` に対応させ、その位置を条件とするmove distributionを読み出します。

efficientnet-b0の各stage出力をFPN style decoderで融合し、`(B, 21, 128, 336)` state gridへmapします。縦は2 ft/binのlevel、横は32 ft/columnです。各grid pointのanchorから離散move distribution `P(dTVT | anchor)` を予測します。move vocabularyは21 class、`{0, ±2, ±4, …, ±20}` ft/columnです。



Training

ground-truth pathに沿うteacher forcingでsuperviseします。各columnでtruth level上のanchorだけへ、量子化truth moveのcross-entropyと、intra-bin position補助lossを与えます。各epochはreal train well（foldあたり約620）と、on-the-fly生成する2,048 synthetic wellを混ぜます。warmup後constant LR `1e-3` のWSD schedule（decayなし）、weight EMAを用い120 epoch学習しました。5 folds × 3 seedsは単一GPUで約10時間でした。

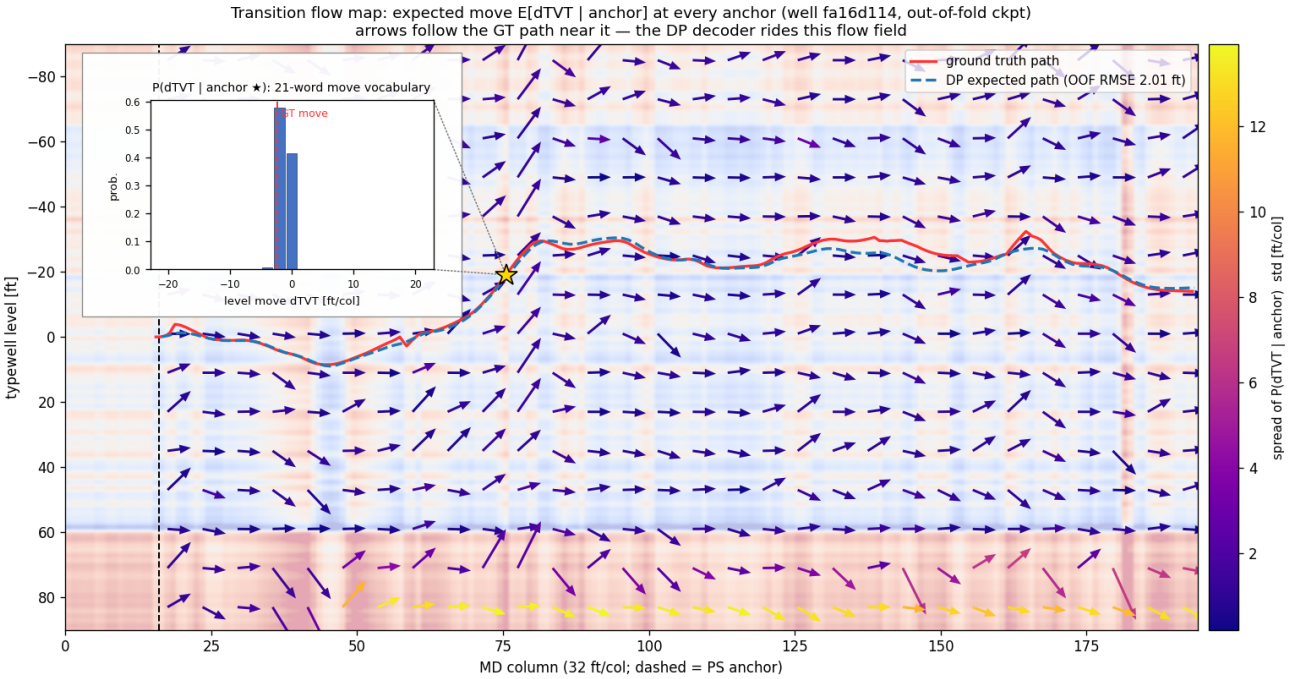
Path generation

PS pointから確率fieldでpathを作る方法は2つです。

1. **Rollout**：`P(dTVT | anchor)` からstochastic sampleし、random path bundleを生成
2. **Path expectation（DP）**：dynamic programmingでstate gridをmarginalizeし、path distributionの期待値を厳密に計算

```
p_{k+1}(s) = Σ_{s'} p_k(s') · P(dTVT = s − s' | anchor(s', k))    (5)
TVT_hat(k) = Σ_s p_k(s) · TVT(s)                                  (6)
```

samplingは行わず、(5)–(6)を厳密に計算します。当初は `N=1024` rolloutをrerankerでfilterする予定でしたが失敗し、提出ではDPのaverage pathを使用しました。Viterbi（maximum-likelihood path）などのmode-tracking decoderも一貫して期待値より悪い結果でした。



EnsemblingとTTA

最終提出は、5 folds × 3 seeds = 15 checkpointのDP path、MD-phase TTA 8 view、2 grid resolution（32 ft/columnと16 ft/column）を平均します。Kaggle T4で200 hidden test wellを約40分で処理しました。

MD resolutionが32 ftなので、列の切り方に32 ft未満のphase ambiguityがあります。GR correlation length約18 ftに対してper-column box averageが粗く、grid originで入力値自体が変わります。そこでoriginを `{0,8,16,24,32,40,48,56}` ftへずらす8 sub-resolution phaseで推論し平均しました。

Robust validationとmodel selection

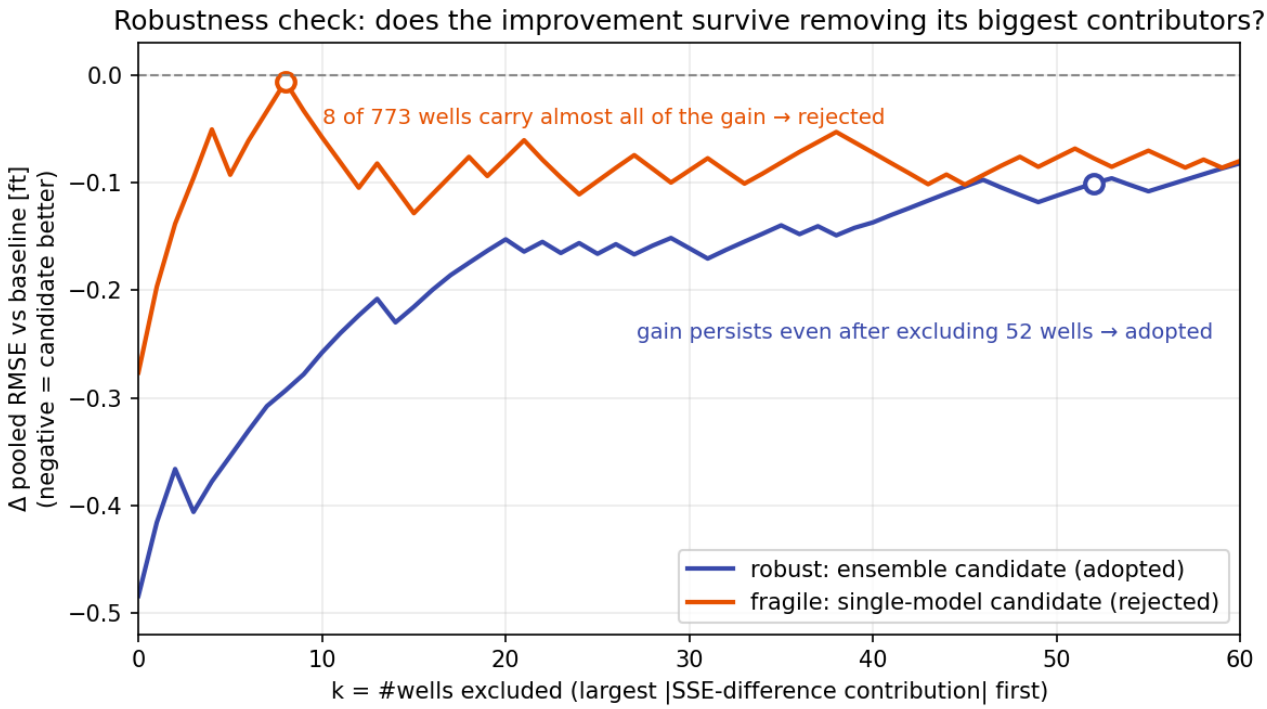
pooled RMSEはSSEに比例するため、catastrophic wellに支配されやすい指標です。すでに良いwellを少し直すより、悪い数wellを直した方が指標は大きく動きます。773 train well、Privateは148 wellしかないので、数wellの改善がsystematicかluckかを区別する必要があります。

Robust acceptance test（leave-largest-contribution-out）

baseとtreatを比較するとき、wellごとの差を次で計算します。

```
g_w = SSE_treat(w) − SSE_base(w)
```

`|g_w|` の大きいwellから除去し、改善が初めて消える除去数を `k*` とします。`k*` が十分大きく、少数wellのluckへ依存しない候補だけを採用しました。



orange案は k=0 でOOF −0.28に見えますが、773 well中わずか8 wellを除くとgainがほぼ消えるため棄却しました。blue案は緩やかに減衰し、Public LB規模の52 wellを除いてもgainが残るため採用しました。

Results

sub	configuration	OOF pooled	Public	Private
068	AnchorCNN（32 ft/col）×15 ckpt	5.624	**5.780**	6.126
071	068 + MD-phase TTA8	5.417	5.820	6.078
075	16 ft/col × TTA8単独（diagnostic）	5.348	5.970	5.882
076（final, selected）	dz_layer-head models × TTA8 + 16 ft/col × TTA8	**5.140**	6.146	**5.802**
077（final, hedge）	068-family × TTA8 + 16 ft/col × TTA8	5.242	5.910	5.905

最終順位は**2位（Private 5.802、sub076）**でした。

うまくいかなかったこと

path bundleからの選択（reranker、reinforcement learning）：`N=1024` rollout bundleには、hindsightでoracle選択すればdeployed scoreより数ft良いpathが含まれました。しかしrerankerとGRPOはevaluation dataへ容易にoverfitし、DP expectationへ一貫して勝てませんでした。bundle選択を諦め、DP marginalizationへ集中しました。

explicit formation modeling：近傍wellからformation surface自体をmodelingするとfieldの粗いtopographyは捉えられますが、catastrophic wellを直せませんでした。teacher labelはformationを直接参照せず、GR

matchingに基づく相対判断なのだと推測します。explicit formation modelを捨て、GR matching probability fieldへ集中しました。

最後に

このmodelはgeosteering expertの解釈作業と、その内在的な曖昧性を模倣します。曖昧性を早く潰さず、候補移動 `P(dTVT | TVT)` 上の確率分布として保持する点が実務上もっとも有用だと考えます。GR matchingが曖昧ならalternative pathを提示し、low-confidence区間を人の確認へ回せます。offset wellやseismicなど独立external dataがあれば、仮説weightを更新して候補を絞れます。

References

- [1] Discussion 699853
- [2] Sergey Alyaev et al., Direct Multi-Modal Inversion of Geophysical Logs Using Deep Learning（poster）
- [3] @pcjimmmyによるmaster seriesの指摘
- [4] Joseph Redmon et al., You Only Look Once
- [5] Xingyi Zhou et al., Objects as Points (CenterNet)
- [6] @igorakuvaevによるpre-PS lateral GRの解像度に関する指摘

補足Q&A

Tucker Arrants（質問）

共有と2位入賞、おめでとうございます。少し変わった質問ですが、8 phaseのMD-Phase TTAはClaudeの提案でしたか？ 私のmodelingでもClaudeがまったく同じ定式化を提案し、自分の案が尽きたときに出た数少ない本当に良い新規アイデアの一つでした。

私たちのClaudeが似たTTAへ収束したのか、それともあなた自身の発想だったのかが気になりました。後から見れば明らかですが、私は自力では思い付かなかったでしょう。「agentは同じ解法へ収束するだけ」と言う人が多いので、そのdata pointを集めています。

Bilzard（回答）

ClaudeがMD shiftを提案しましたが、shift幅を32 ft column内のsub-columnにし、あとで元へ戻すことを提案したのは私です。8 phaseはsweepの結果で、どちらも直感でその数を選んだわけではありません。

Claudeは大量のアイデアを提案しましたが、情報処理に圧倒されることもあり、大半は有望に見えませんでした。自分では絶対に思い付かない仕事を非常にうまく行う場合もありましたが、議論全体の品質はかなりrandomに感じました。

現在の「autonomous」agentは十分autonomousではなく、人が隣にいないと初歩的な問題で詰まります。今もhuman engineer自身がtorchを運ばなければ、時間を燃やすだけになると思います。