rogii-wellbore-geology-prediction

3位解法

Rank	3
Team	tereka & Takoi
Author	tereka
Topic ID	733319
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733319
Retrieved with Kaggle CLI on 2026-08-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、この素晴らしいコンペと興味深いchallengeを開催してくださったKaggleとhostの皆さんに感謝します。アイデア、実験、議論、粘り強い取り組みで支えてくれたteammate @takoihiraokazuにも深く感謝します。

このコンペの面白さは、HMMやParticle Filterのような確率的physics modelから、GR-correlation、neural sequence model、dynamic ensembleまで、非常に多様なapproachを探索できたことです。性質の違う手法がどう補完し合うかを調べることは、技術的に難しく、本当に魅力的でした。

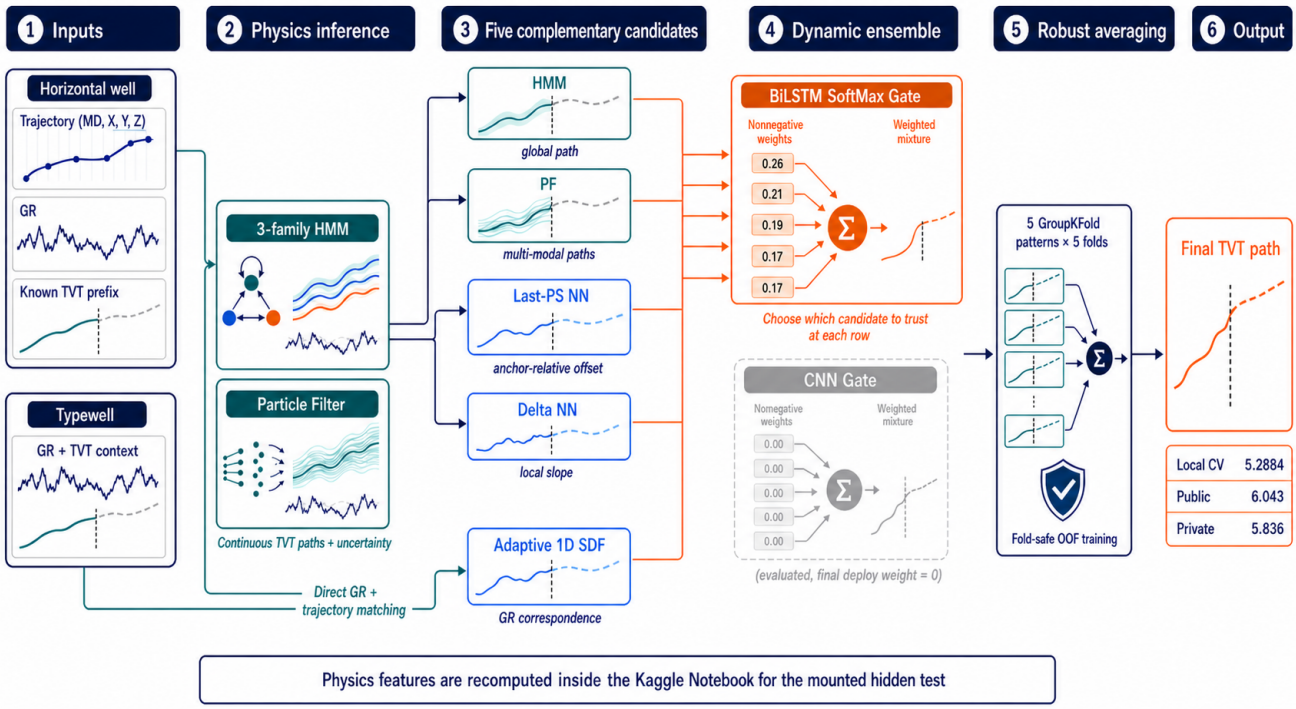
Solution

TL;DR

中心アイデアは、**物理的にもっともらしいTVT trajectoryを複数生成し、異なる種類の誤りをするneural modelを加え、各位置でSoftMax Gatingによって候補を混ぜる**ことです。

- **Physics models**：HMMとParticle Filter（PF）で、GRとwell geometryからTVT trajectoryを生成
- **Neural Network from Last PS**：Prediction Start（PS）直前の最終既知TVTに対する未来のabsolute offsetとuncertaintyを予測
- **Delta Neural Network**：row間のTVT変化を予測し、積分してtrajectoryを復元
- **Adaptive 1D SDF**：horizontal-well GR/trajectoryをtypewell GR/TVT候補へ直接matching。HMM/PF予測は使わない
- **Ensemble**：HMM、PF、2つのNN、Adaptive 1D SDFの5候補をsequential SoftMax Gateでdynamicに混合
- **Validation**：5種類のsplit patternそれぞれでwell単位5-fold GroupKFoldを行い、model familyごとに25 checkpoint

model選択に使ったfold-safe Local CVは**RMSE 5.2884**。提出Notebookは**Public 6.043 / Private 5.836**でした。



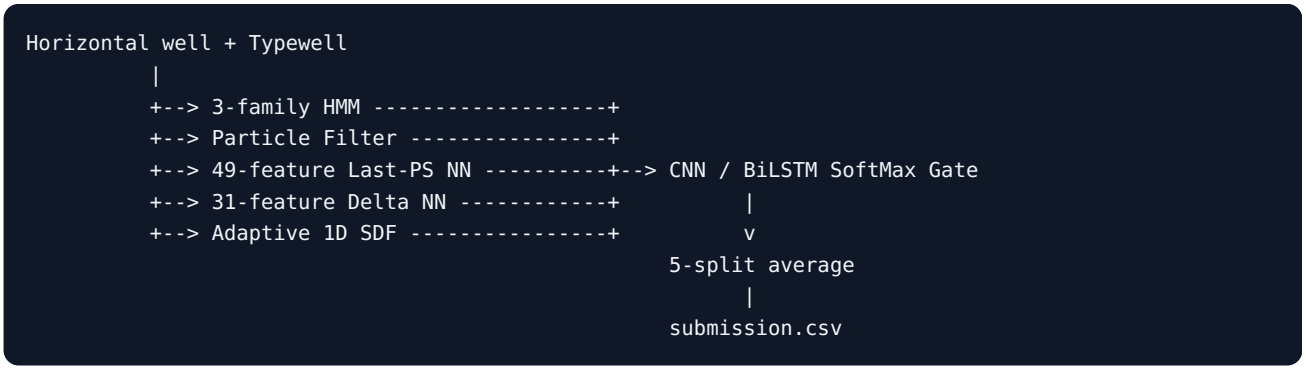
Solution overview

PS前は各horizontal wellの`TVT_input`が見え、PS後はTVTが隠されます。well trajectory（`MD, X, Y, Z`）、horizontal GR、typewell情報（`TVT, GR, Geology`）は使用できます。

pure time-series extrapolationではformation dipの小さな誤差が長いhorizontal sectionで累積します。pure GR matchingも、似たGR pattern、GR bias、欠損、thickness changeによって複数alignmentが成立するため曖昧です。そこで3段階にしました。

1. HMM/PFでtrajectory continuityを保ちながらGR matching
2. physics予測、trajectory、GR、typewell情報をNNへ入れ、physics modelのsystematic errorを補正
3. 5つのcomplementary candidateをSoftMax Gateでdynamicに混合

Method	Training loss	Local CV	Public LB	Private LB
3-family HMM	なし（probabilistic state estimation）	5.9703	6.207	6.229
Particle Filter	なし（Sequential Monte Carlo）	6.5827	7.011	6.725
Neural Network from Last PS	Gaussian NLL	5.4723	6.074	5.903
Delta Neural Network	Delta RMSE	5.7703	6.093	6.102
Adaptive 1D SDF	Candidate CE + 0.25 Smooth L1 + 0.10 Delta + 0.05 RNC	9.5415	8.502	8.837
CNN SoftMax Gate	Prediction MSE + best-candidate CE	5.4255	6.027	5.814
BiLSTM SoftMax Gate	Prediction MSE + best-candidate CE	5.3329	6.043	5.836
Final 5-split ensemble	BiLSTM Gateと同じ	5.2884	6.043	5.836



physics featureはmounted hidden test dataに対しKaggle Notebook内で再計算しました。competition dataset mountやhidden-test内容が変わっても、固定済みtest feature tableへ依存せず再現できます。

Validation strategy

GroupKFold by well

同じwell内のrowは強く相関するため、row-wise splitは深刻なleakageを起こします。`well_id`をgroupとする5-fold GroupKFoldを使い、同一wellの全rowを同じfoldへ置きました。

trainは773 well、3,783,989 rowです。validation well数は`155 / 155 / 155 / 154 / 154`。competition metricと同じrow-level RMSEでOOFを評価しました。

「Fold-safe」の意味

ここでfold-safeはwell単位splitだけではありません。validation labelやvalidation wellで学習したintermediate predictionが、feature生成、normalization、gate学習へ戻らないようpipeline全体をfold内で閉じます。

- **well-level split**：同一wellの全rowを1 foldへ固定
- **fold-local preprocessing**：mean/stdなどをtrain foldだけでfitしvalidationへ適用
- **OOF candidates**：NN、Adaptive 1D SDF、gateの学習入力には、そのvalidation wellを学習していないfold modelの予測だけを使用
- **base model/gate foldの同期**：同じwell assignmentを使い、gateがin-fold base predictionを見るのを防止
- **OOF-only blending**：CNN/BiLSTM weightとmodel選択をOOFだけで決定しPublic LBへfitしない
- **test-time fold averaging**：各fold modelをhidden testへ適用し、5 fold×5 splitを平均

gate-validation well`W`へ渡すNN candidateは`W`なしで学習したNNから作り、gate自身も`W`なしで学習して評価します。この二段OOFがないと、gateはin-fold base-model errorを利用して非現実的に良いLocal CVを出せます。

なぜ5 splits × 5 foldsか

- **5 folds**：全wellのleak-free OOFを作り、testで5 modelを平均
- **5 splits**：GroupKFoldのwell assignment自体を変え、特定fold compositionへの依存を下げる

`default, split101, split102, split202, split303`を使いました。seedごとにwell labelをdeterministically reorderしてGroupKFoldを適用し、assignment間のAdjusted Rand Indexは約`-0.0013`〜`0.0038`で、ほぼ独立でした。

各splitでNN49、NN31、Adaptive 1D SDF、CNN Gate、BiLSTM Gateを5 fold学習したため、各familyは25 checkpointです。3 splitから5 splitへ増やすと、同じGaussian-NLL configurationのPrivateは5.903→5.836（−0.067）、fold-safe Local CVは5.3069→5.2884（−0.0184）となりました。

Physics models

HMM

HMMはrowを独立予測せず、well全体を連続pathとして推定します。hidden stateは次を組み合わせます。

- TVT position

- formation rate `d(TVT + Z) / dMD`
- horizontal GRとreference GRのslowly changing bias
- typewell-orientedまたはsibling-lateral-oriented reference family

Reference GR

同じtypewellを共有するtrain wellをsiblingとしてgroup化し、そのlateral GRを0.25 ft TVT binへ集約しました。base HMMは2種類のreference mixtureを使い、2 orientationでtypewell/sibling weightを`0.2 / 0.8`とし、reference identityはhidden stateに残しました。

target wellのknown prefixから`(TVT_input, GR)` templateも作り、観測数に応じてHMM referenceへ混ぜました。known prefixとfuture sectionでGR calibrationが共通であることを利用します。

Initial stateとprefix-in-model

- 最後の256 known-prefix rowからinitial formation rateをrobust推定
- 最後の128 known-prefix rowをHMM sequenceの先頭へ追加
- prefix TVT stateを観測`TVT_input`付近へclamp

PS pointだけで初期化するより、直近dipとGR alignmentをHMM posteriorへ引き継げます。

GR emissionは自由度1のStudent-t分布で、Gaussianよりoutlierにrobustです。transitionはposition、rate、biasのsmoothな変化を促し、forward-backward smoothingで全sequenceを条件とするposterior meanを得ます。最後に、最後の256既知rowから推定したformation-rateの1st–99th percentile rangeへpathをprojectし、absolute rateを0.25、積分TVT correctionを10 ftへ制限しました。

Three-family HMM ensemble

HMM family	Weight	特徴
Exp417 base HMM	0.50	self-prefix、2 reference、bias state、exact forward-backward
Local-DTW HMM	0.20	small stretchを許すlocal GR-pattern matching
Fine-bin HMM	0.30	0.0625 ft binの高解像度sibling reference

Local-DTWは単体最強ではありませんがbase HMMとのerror correlationが低く、HMM mixture OOFを6.0492→5.9703、HMMPFを5.6648→5.6155へ改善しました。

Particle Filter

PFは多数のstochastic TVT trajectoryを追跡し、smoothなHMMへmultimodal hypothesisとuncertaintyを補います。particle stateはformation position`TVT+Z`、formation rate、GR bias、hard/soft observation family、typewell/sibling reference flagを持ちます。

主設定は500 particles、240 seeds、3 seed bases、rate momentum 0.9995、rate noise 0.001、position noise 0.005。各rowでhorizontal GRとreference likelihoodを評価し、Effective Sample Sizeがthreshold未満ならsystematic resamplingしました。reference/bias familyはresampling後も継承します。

observation modelは2種類です。

- `f015`：15% particleをhard familyとし、開始付近でlikelihoodを徐々に強化

- `soft`：全particleがGR biasを許す

seed-level pathはfull-sequence likelihoodでweightし、particle genealogyをbackward traceしてsmoothしました。NN featureとしてweighted mean、spread、skewness、IQR、q10/q25/q50/q75/q90と、それらの前後row差を保存しました。

PF candidateは`0.6×f015 + 0.4×soft`、HMMPF featureは`0.6×three-family HMM + 0.4×PF`です。

Neural networks

Neural Network from Last PS

各hidden rowをPS直前の`last_known_tvt`へanchorし、`target = TVT - last_known_tvt`を予測します。absolute TVTでなくanchor-relative offsetにすることでwell間level variationを除きます。

49 featureはraw/mask、PS-relative geometry、PF distribution、local dynamics、HMMPF/MultiGrid HMM/Adaptive 1D SDFなどのphysics/correlation candidateからなります。

architectureは96 channel input projection、16 full-resolution dilated-TCN residual blocks（kernel 7、dilation `1,2,4,...,128`を2周）、block 4/8/12/16後のMaxViT1D attention、block 8後のdownsampled typewell cross-attention、residual encoder + gated BiLSTM typewell encoder、1-layer gated LSTM output headです。

Gaussian headはmeanとvarianceを出し、lossはvalid hidden row上のGaussian NLLです。

```
L_GNLL = 0.5 × [log(σ²) + (y - μ)² / σ²]
σ² = softplus(raw_variance) + 0.001
```

推論では`μ`をcandidate、predictive stdをSoftMax Gateのconfidence featureとします。100 epoch、batch 16、Scheduler-Free AdamW、LR 0.002、weight decay `1e-4`、dropout 0.1、EMA 0.995。default split OOFは5.4723。3-splitでRMSE lossからGaussian NLLへ変えると5.4176→5.3645でした。

Delta Neural Network

`target_t = TVT_t - TVT_(t-1)`を予測し、PSの既知TVTから積分してpathを復元します。local slope changeは捉えますがsmall biasが長距離で蓄積するため、Last-PS NNと異なるerror patternになります。

31 featureはX/Y/Z/GR/TVT_inputの前後差、PF uncertaintyとその差、HMMPF/MultiGrid/Adaptive SDF offsetの前後差、`TVT_input_observed_delta_last`などです。同じdilated-TCN cross-encoder familyですが独立学習し、lossはvalid row上のdelta RMSEです。dropout 0.5、weight decay 0.01、head representationへprobability 0.5、`alpha=0.2`のmanifold mixup。OOF 5.7703。Gaussian-NLL Delta pilotは悪化したためRMSEを維持しました。

Training augmentation

Last-PS NNでは短い連続GR blockをmaskし、trajectory、physics candidate、周辺contextから復元させます。Delta NNではhead representationへmanifold mixupを使い、個別wellの細かいslopeへのoverfitを抑えます。augmentationはtrain foldだけへ適用しました。

Adaptive 1D SDF

horizontal-well rowがtypewellのどのTVT候補へ対応するかを直接推定するcorrelation modelで、HMM/PFとは独立です。

- horizontal GR/trajectoryを4-block TCNでencode
- typewell GR/TVT contextを3-block TCNでencode
- embedding 128のquery-key cosine-correlation volume
- typewell上256 TVT candidateを比較
- GR-value cost、trajectory progress、required formation rate、graph-edge featureを融合
- known prefixからwell-specific GR-bias correlation/scaleを推定
- temperature 1.75のSoftMax期待値を出力

```
L_SDF = L_candidate_CE + 0.25 L_SmoothL1(TVT/10) + 0.10 L_delta + 0.05 L_RNC
```

100 epoch、batch 8、hidden 64、dropout 0.5、EMA 0.999。単体は弱いものの、physics state estimationやdirect regressionとは違う解き方なのでdiversityを増やし、Gateが局所的に選べました。

Ensemble SoftMax Gating

gateへ次の5候補を入力します。

1. Three-family HMM
2. PF
3. 49-feature Last-PS NN
4. Adaptive 1D SDF
5. 31-feature Delta NN

候補値に加え、last known TVTからのoffset、candidate meanからのdeviation、one-step change、candidate std/range、PSからのMD/Z distance、3D step length、GRと差分・missing flag、hidden section内normalized position、Last-PS NN predictive stdを使います。

```
prediction_t = Σ softmax(logits_t)_k × candidate_(t,k)
```

CNN Gateはhidden 32、kernel 7、2 residual blocks。BiLSTM Gateはhidden 32の1-layer bidirectional LSTMです。8 epoch、次のlossで学習しました。

```
L_gate = MSE(y, Σ w_k × candidate_k) + CE(w, best_candidate)
```

fixed weightと違い、PS直後、long extrapolation、missing-GR、candidate disagreementを別扱いできます。非負・和1のconvex combinationは、773 wellしかない条件でunconstrained stackerのextreme extrapolationを抑えました。ただし全候補共通のdriftを候補範囲外へ直せません。

unconstrained BiLSTM refinerも試しました。Gaussian NLLはMSEより0.0140改善しましたがCV 5.4023で、SoftMax BiLSTM 5.2797より0.1226悪く、全5 foldで負けました。もっともらしい候補から選ぶ制約の方がgeneralizeしました。

five-split CNN/BiLSTMをそれぞれ平均し、OOFだけでfinal blendを選びました。保存weightはCNN 0、BiLSTM 1で、最終提出は実質**5 splits × 5 folds BiLSTM SoftMax Gate ensemble**です。

Private-LB insights

1. Reference-GR designがHMMで最重要

最大のPrivate gainはNN architectureより、HMMが参照するGRでした。typewellだけでなく同じtypewellを共有するsibling lateral GRを使い、fine TVT binへ集約し、target known-prefixをself-referenceとして混ぜ、reference familyを平均で潰さずstate/HMMとして分け、Local-DTWのような異なるerror structureを加えます。

別branchではspatial-distance-weighted sibling HMMでPrivate 5.817→5.691（−0.126）、rational distance weightingで5.817→5.720（−0.097）でした。

2. Known prefixの利用

initial-rate estimationを最後の30 rowから256 rowへ広げると、別branchのPrivateが5.854→5.812（−0.042）。known prefixをHMMへprependしstateをclampする方がlast-value anchorだけより安定しました。

3. 5つのGroupKFold patternを平均

同じGaussian-NLL設定を3 splitから5 splitへ増やすとPrivate 5.903→5.836（−0.067）。Publicへ選択するよりwell assignmentのOOF diversityがPrivateへtransferしました。

4. Final外branchで効いたphysics refinement

Rao-Blackwellized PF biasはPrivate 5.691→5.688（−0.003）、fold-specific HMM reference poolは5.726→5.718（−0.008）でした。小さいgainですが、reference/latent biasをwell levelでadaptする方向を支持します。

主な結論は、model complexityを足す前に**正しいreference GR、安定したinitial-rate、異なるHMM error mode、well-level CV diversity**を優先することです。NNとSoftMax Gateは強力でしたが、Private generalizationの基盤はphysics pipelineでした。