rogii-wellbore-geology-prediction

4位解法

Rank	4
Team	L & J & A & A
Author	James Day
Topic ID	733480
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733480
Retrieved with Kaggle CLI on 2026-08-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Overview

私たちの解法は、独立した3 approachのensembleです。

- **James**：周囲のtopographyとsurfaceに対するdrill motionからTVTを予測し、GRとtopography dataを2D画像へrenderします。CNNが8 control pointのoffsetを予測し、topographyベースの初期pathを補正します。
- **Lightsource**：各wellをmultichannel 2D canvasへrenderし、dense image segmentationに似た方法でU-NetがTVT pathをtraceします。補完的予測として1D Squeezeformerも使います。
- **Alijs**：Particle Filterでdrill motionとGR matchingからもっともらしいTVT pathを追跡し、topography、bidirectional decoding、learned correctionで改善します。単純なPFを傷つけるwrong-layer matchingを減らします。

ensemble weightはOOF predictionへridge regressionをfitして選びました。3解法中Private LBで良かったのは1つだけでしたが、ほかもlocal CVでは有用で、full ensembleはcash Goldに十分robustでした。

Pipeline	Ensemble weight	CV	Public	Private
James	0.644	5.143	5.463	5.730
Lightsource	0.327	5.570	5.897	7.045
Alijs	0.029	7.035	6.217	9.138
Full ensemble	N/A	4.998	5.452	5.870

Jamesのパート

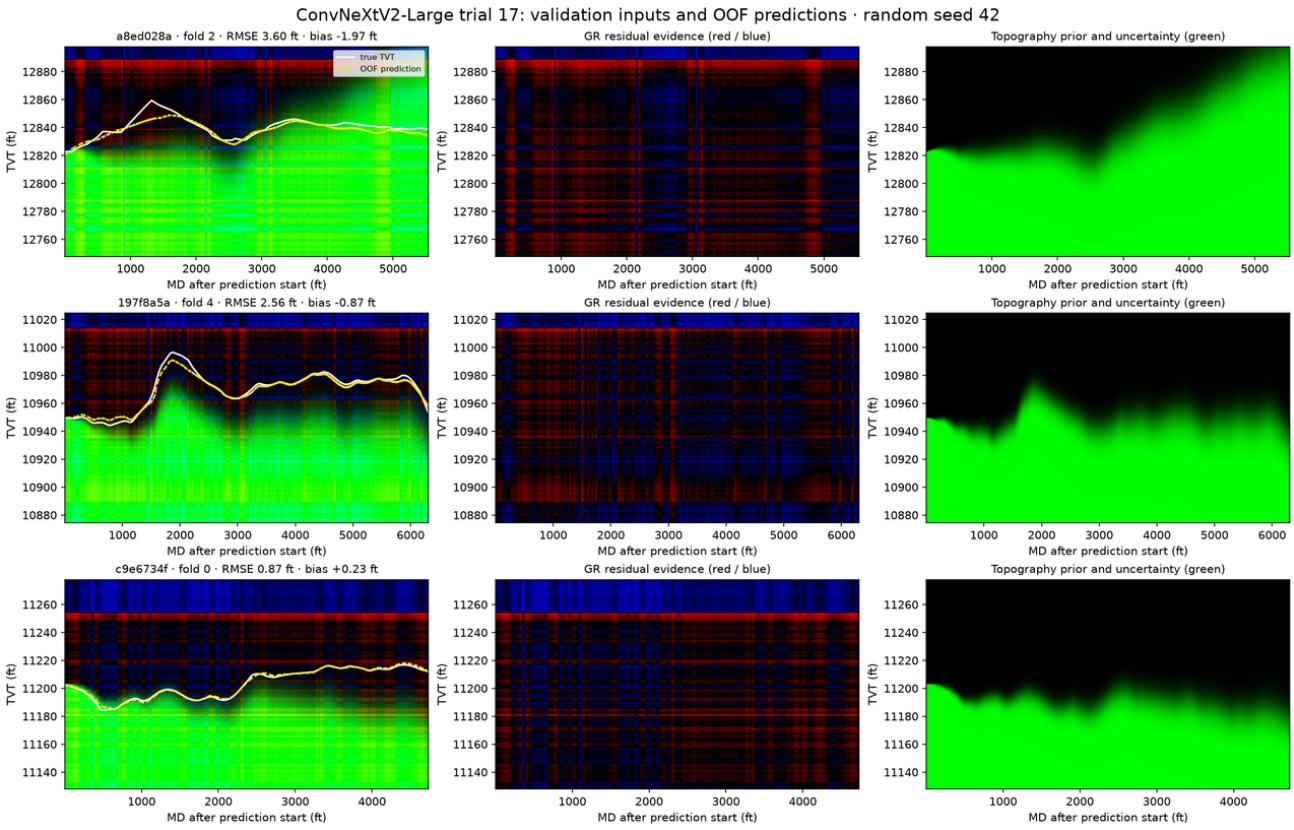
Overview

私の解法はPhysioNet ECG digitization competitionのwinnerから着想しました。以前segmentation modelに勝ったvision architectureを模倣し、このコンペでもうまくいきました。

予測は4段階です。

1. **drill pathに沿うrock formation slopeを予測**：`X, Y, Z, azimuth, pitch`をtabular regression ensembleへ入力。train/testが同じbasinにありglobal slopeがほぼlinearで、近傍井戸からdeviationを予測できる場合があるため機能します。downstream vision modelがwellごとの信頼性を判断できるようuncertaintyも出します。
2. **topographyからTVTを予測**：last-known TVTがあり、`change in TVT = change in rock elevation - change in Z`です。`Z`はすべて既知なので、未知なのはrock elevationの変化だけです。step 1のslopeとdrill距離でrough predictionを埋めます。
3. **topography予測とGRを2D imageへrender**：縦列は特定MD、横行は候補TVT。red/blue channelは、そのTVT仮説で観測GRが期待GRより高い/低いことを表すresidual。greenはtopography modelが「true TVTはcandidateより大きい」と考える確率です。

4. **topography offsetを予測**：画像をConvNeXt V2 Large + feature-pyramid regression headへ入れ、8 control pointの上下offsetを予測。間はlinear interpolate。第一generatorのsyntheticでpretrain、第二generatorでfine-tune、real wellでfine-tuneの3 stageです。



Topography prediction

rock formation slopeはdrill pathに沿う750 ft segmentごとに予測します。

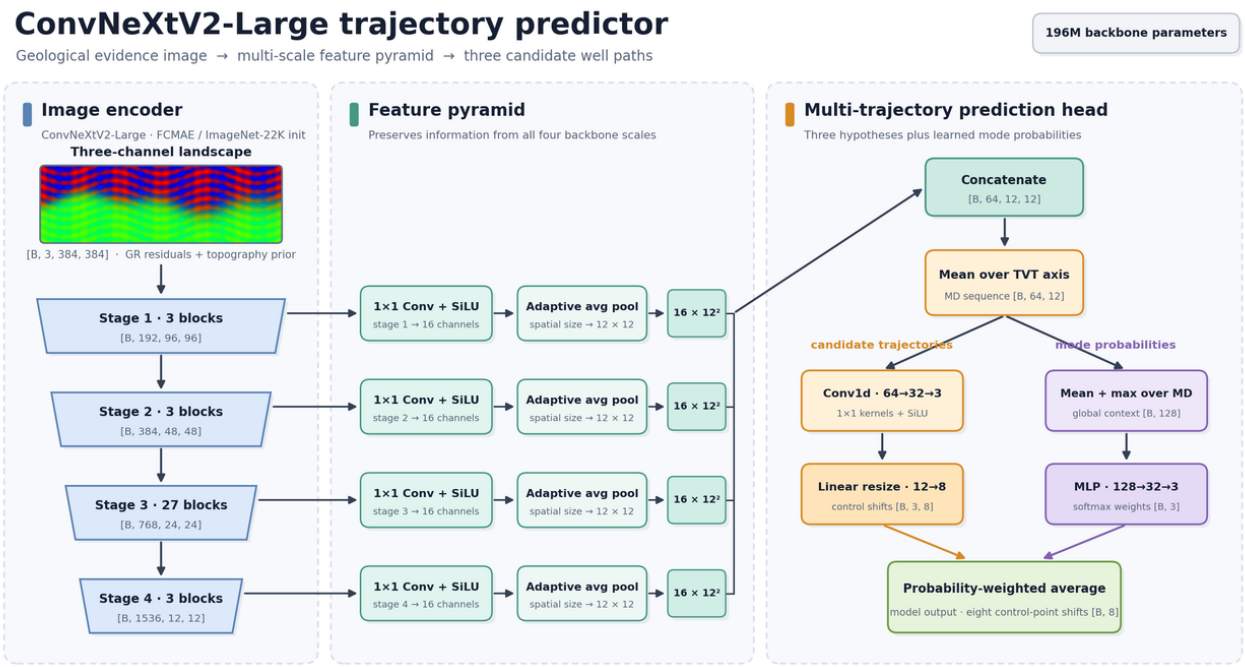
ensemble weightの約90%は、比較的単純なLightGBM quantile regressionから予測を受けるvision modelです。segment midpoint coordinateとdrill heading（azimuth/pitch）から`dA/dM`（ANCCのMD微分）のupper/lower confidence intervalを予測します。

残り約10%はTabPFN、RealMLP、LightGBMの強いensembleから`dA/dM, dA/dX, dA/dY`を受けます。このapproachはslope CV RMSE 0.0100→0.0088、visionなしPrivate 12.6→10.8と大幅に正確で、predicted sigmaとreal errorのPearson correlationも0.31→0.40でした。しかしtopography-onlyのCV gainがPublic gainの約20倍で、real-well dataへfine-tuneしたvision modelへ強いtopographyを与えるとtopography出力へ過度に依存しPublicが悪化したため、real wellで学習したvision modelとの組合せには使いませんでした。vision modelはconfidence interval calibrationの変更にも敏感で、弱いtopographyで学習したmodelへ強いensembleを差し替えるとCVが悪化します。

そこで大半のvision modelは古いtopographyを使い、GRへより集中させました。例外はsynthetic dataだけで学習しreal basinを一度も見ないfoundation modelで、特定topographyの挙動へoverfitできないため、新しいV2 topographyを使いました。

Vision model architecture

すべて同じarchitectureを使い、data augmentation、LR schedule、topography選択、data bagging、real fine-tuningなしのfoundation modelでdiversityを作りました。



Backbone selection

synthetic pretrain 5K、real fine-tune約700 wellでは約50M parameterのsmall modelが最適でしたが、pretrainを数万から数十万wellへscaleしても小modelはほぼ改善しませんでした。約540K wellで学習したConvNeXt Largeは、diversity目的でもsmall modelが不要になるほど強くなりました。

初期small-scaleではConvNeXtがViT/EfficientNet V2を上回ったため最初にscaleしました。後でMambaVisionのsmall modelが強くなりましたがscaleする時間がなく、ensembleへ入るほどではありませんでした。ConvNeXt Large fine-tuningの設定不良を締切48時間前まで直せず、scaleの力を過小評価していました。

そのほかのarchitecture選択

複数のGR-consistent pathがあるambiguous wellでは、metricは可能性の間を予測することを報いますが、single-trajectory headでは学びにくいです。Alyaev et al.のDirect Multi-Modal Inversion of Geophysical Logs Using Deep Learningを緩く模倣し、3 seriesのcontrol-point offsetと、それぞれがtruthに最も近い確率を出し、確率加重平均しました。論文のMTP lossだけではsingle-path RMSEにsuboptimalなので、MTP lossとweighted-average trajectory lossの両方をmulti-taskで最小化します。

PhysioNet winnerと同様、backbone最終層のpooled featureだけでなく複数spatial scaleが有効で、ここでは2 scaleでなく4 scaleすべてが有効でした。headは浅くinternal channelを少なくしbackboneへ仕事をさせ、mode probabilityではmean/max poolingを連結する方が単独poolingより良好でした。

Synthetic pretraining data

V0 generatorの500K synthetic well、その後V3のfiltered subset 37K wellでpretrainしました。real fine-tuneなしfoundation modelはCV 5.9 ft。初期実験ではsynthetic pretrainでreal training後CVが8.2→6.7、約1.5 ft改善し、現在の改良後は2 ft以上と推測します。

V0/V0.1 generator

1. real well bankからlast-known TVTとprediction lengthをsample
2. last-known TVT中心のsynthetic typewell GR-vs-TVT windowを生成
3. empirical TVT path bankから独立horizontal-well TVT-delta pathを生成しlast-known TVTを加える
4. typewellをTVTでinterpolateしてexpected horizontal GRを得る
5. expected GR依存成分とlow/medium/high-frequency noiseを含むGR residualを生成
6. `observed GR = expected GR + residual`
7. BUDA slopeを1つsampleしlinear BUDA pathを構築
8. `Z = BUDA - TVT` を逆算
9. known prefix rowとprediction rowsを書く

V0 topographyは単純で、true constant BUDA slopeへpiecewise-constant Gaussian slope errorを加え、integrated TVT RMSEへscaleをcalibrateします。

V3 generator

1. synthetic typewell GR-vs-TVT windowを生成・regularize
2. realistic well lengthとMD gridを作る
3. starting level/global slope、correlated slope wander、explicit fault jumpを持つBUDA pathを生成
4. BUDAに条件付けてZを生成。smooth BUDA increment + correlated residual variationから `dZ/dMD` をmodel
5. `TVT = BUDA - Z + relation_constant`
6. TVTがtypewell range外ならBUDA/Zをjointly resample
7. typewellをTVT pathでinterpolateしてexpected GR
8. expected-GR spineに条件付けてresidual生成
9. `observed GR = expected GR + residual`
10. known prefixとprediction rowsを書く

V3 residualはexpected level/local contrastでmeanとlocal varianceを変え、fat-tailed correlated noise、coherent excursion、missingnessを加えます。topography OOFもglobal Gaussianでなく、true BUDA geometry、roughness、slope change、real OOF behaviorに条件付けたsegmentごとのempirical slope error/uncertaintyです。

要約すると、V0は `TVT → expected GR → residual/GR → BUDA → Z`、V3は `BUDA → conditioned Z → TVT → expected GR → residual/GR` です。

V3は10K syntheticでEfficientNet V2 Smallを学習しreal fine-tuneしたmodelとsynthetic-only modelを50K追加wellへ適用し、real-well modelのerrorがsynthetic modelの2倍を超えるsampleを捨ててfilterしました。

V3は全metricでV0よりrealisticですが、必ずしも「better」ではありません。V0は収束が速く、最大3M training sampleまでtraining lossとreal CVのcorrelationが良好でした。3M超ではConvNeXt V2 Largeがhybrid lossを下げるためMTP classificationを完全に無視するdegenerate behaviorを起こし、real generalizationが悪化しました。loss weight/hyperparameterでは副作用なく直せませんでした。MambaはgeneratorをほぼMixした方が良く、CNNはV0→V3のstaged方式が良好でした。

Vision model training details

共通architecture

- `convnextv2_large.fcmae_ft_in22k_in1k_384`
- backbone 4 stageすべてのfeature-pyramid head
- pyramid levelごと16 projected channel、32 hidden channel
- MTP mode probability付き3 candidate trajectory
- 384×384 input、±75 ft TVT window
- topography centering/ImageNet normalizationなし
- BF16、AdamW（LR以外PyTorch default）、head dropoutなし
- pretrainingは12 control point、real fine-tuneは8

Stage 1 pretraining

500K V0.1、ImageNet/FCMAE pretrained weightから6 epoch、batch 16、2-process distributed。OneCycleLR cosine、peak LR `2.053e-4`、15% warmup、momentum cycling。Huber threshold 9.48。MTP best-trajectory regression、classification weight 0.164、weighted-average loss weight 1.0。first foldのみ学習しbest/final checkpoint保存。

主augmentationはmixup 75%（alpha 0.624）、vertical/horizontal flip 50%/25%、GR-residual inversion/flip各25%、simulated vertical shift 25%、shift時typewell flip 25%、topography-error permutation 25%、horizontal/typewell GR noise 50%（7.09% std）/25%（8.98% std）、vertical masking 50%（2 mask、各最大11.4%）。heavy augは最初の80%だけ。cutmix/channel dropout/affine GR/horizontal maskなし。

Stage 2 pretraining

Stage 1 bestから37K filtered V3で6 epoch、batch 16。architecture、LR schedule、loss、augmentation、resolution、TVT radiusは同じです。

Real-well fine-tuning ensemble

Trial	Role	Epoch/batch	OneCycle	Loss	CV RMSE	Blend weight
0	frozen Stage 2、V2 topography	N/A	N/A	N/A	5.9270	11.15%
1	baseline FT	64/8	cosine `1.027e-4`, 15% warmup	Huber 9.48	5.2940	16.81%

Trial	Role	Epoch/batch	OneCycle	Loss	CV RMSE	Blend weight
8	affine-heavy	80/16	linear `3.699e-5`, 30%	MSE	5.2842	3.20%
17	best individual	112/8	cosine `3.284e-5`, 15%	Huber 0.549	5.2013	48.50%
25	shorter low-LR	48/16	linear `1.987e-5`, 10%	Huber 3.013	5.2826	20.33%

4つのreal FTは5-fold CV、Stage 2 bestから初期化しlegacy non-centered topography OOFを使用。trial 0だけfrozen foundation modelでnew V2 topographyを使用します。

trial 1はStage 1 recipe、trial 8はflip/noiseをstrong affine transformとhorizontal/vertical maskへ交換、trial 17は112 epoch全体でaugmentation、trial 25はstrong horizontal-well affine、mild typewell affine、horizontal flip、GR inversion、simulated shift、小vertical maskです。MTP classification weightはtrial 1/8/17/25で0.164/0.0625/0.485/0.0898、weighted-averageは1.0/1.0/1.0/0.5。

optimal TTAとquarter-point re-anchor後、blendはtrial 17の5.2013から5.1428へ0.0585改善しました。

Test-time augmentation

- **Vertical flip（CV −0.13）**：単純image flipでなく、地下のrock layerを上下反転し、drillがsurfaceに対して逆方向へ進む物理をrenderします。green channelのtopographyも意味を保ちます。flipped予測を反転してstandardと平均します。
- **Quarter re-anchoring（CV −0.18）**：full range予測後、最後75%へcropし、25%地点の予測をlast-known TVTとみなして再render・再予測し、元予測と等weight平均します。50%地点の2回目re-anchorはCVで効いてもPrivateで悪化、3回目はCV/Public双方で悪化したためquarterだけです。

GR residual inversionは一部modelで有効ですがConvNeXt V2 Largeでは無効、horizontal flipは一貫して有害でした。

Lightsourceのパート

1. Approach

known TVT prefix、horizontal GR、trajectory（MD/Z）、vertical typewell（TVT/GR）からunknown suffixのTVTを予測します。物理priorは`observed_GR ≈ interp(typewell_GR, true_TVT) + noise`。known prefixとtrajectoryからgeometric priorを作り、residual correctionを学習します。

- **2D U-Net**：residual-TVT×MD空間のsegmentation
- **1D Squeezeformer**：MDに沿う同じresidualのsequence regression

`synthetic pretrain → post-pretrain → real-well finetune → NNLS blend`で学習し、chunk re-anchoringでautoregressive decodeします。

2. 2D modeling

scratch encoderのU-Net、16 input channel、1 output。final backboneはResNet-34、ConvNeXt-Tiny、Swin-Tinyと`geo_plane` recipeのResNet-34。

full canvas 384×512（residual axis×MD）、train crop 256×256。inferenceはtiled 256×256またはsingle-pass fullcanvasをOOFで選択。channelはGR–typewell mismatch、horizontal GR、residual axis、known/future mask、geometric prior、trajectory（`z,dz,d2z,md`）。

`cum_residual` modeでtrue residual boundaryより下にある確率をcumulative boundary maskとして出します。

```
prob = sigmoid(logits)
row = sum_over_H(prob) - 0.5
residual = interp(row → residual axis)
tvt = geometric_prior + residual
```

lossはBCE + Dice/Jaccard + decoded boundary row loss + optional smoothです。

3. 1D modeling

Squeezeformerへbase 1D signalと、±100 ftの201 TVT offsetに対するGR residual profile（strip CNN）を入力します。targetは`y = TVT_true - geometric_prior`。known prefixをmaskしunknown suffixへ重みを置きます。Huber/Gaussian-NLL style dense regression、optional smoothness/monotonicity/sparse control-point loss。`h_match=64`、re-anchor 500 ftのsame loopです。

4. Augmentation

empirical GR noise bank、GR dropout/gain/offset/white noise、magnitude warp、typewell swap、prior shift/slope noise/break、GR/TVT/Z/MDのcoherent time stretch/warp、full-canvasとrandom crop、hflip/vflip、mixup、channel dropout、random known fraction（約25–65%）、random cropを使いました。

5–6. Pretrainとpost-pretrain

real MD/Z + typewellを使い、synthetic TVT/GRを作るhonest pretrainです。known prefix lengthをsampleし、prefix+Zからgeometric prior、時にcorruptし、drift+spline+bump residualを加え`dTVT/dMD`をclamp、`GR = interp(typewell, TVT)+noise_bank`。

post-pretrainでは`geo_plane`へ切り替えます。

```
geo_z(MD) = (TVT_prefix + Z)_PS + plane_slope·ΔMD + piecewise_knots(MD)
TVT = geo_z − Z
```

gentle MD slope + 4–6 piecewise-linear knotsを使い、known prefixでzero、unknownへrampします。synthetic stack単体でもOOF約8.9でした。

7. Re-anchoring

long suffixのdriftを避けるため、current known TVTからcanvas/windowを作り、次の約500–950 ftを予測し、結果をknown prefixへappendしてpriorを再構築する処理を終端まで繰り返します。original prefixはhard constraintです。

8. Blend

ResNet/geo-plane ResNet/ConvNeXt/Swin/Squeezeformer-1DのOOFをNNLSで組み合わせます。member内seed checkpointは等weight、member weightはOOF NNLS、inferenceは各memberのbest canvas mode/re-anchor stride。単独でOOF約5.57です。

Alijsのパート

最初はsimple PF baselineから始め、LightGBM residual correctorでCV、特にPublicを改善しました。しかしrow-level LGBはwell全体を見られません。team参加時にはほかのmemberが強いNNを持っていたので、diversityのためLGB pipelineへ集中しました。single-model CV/PublicはPrivateと大きく違い、PrivateにはLGBが苦手なwellが多かったと考えています。

final partはPF + correctorです。64-seed PFがhorizontal GRとtypewellを照合してTVTをforward/backward追跡します。LightGBM L2+L1 residual blendが約115 self-diagnostic featureからbackbone errorを予測します。featureはPF seed spread、stride/derivative、typewell-rung aliasing companion付きViterbi second opinion、forward/backward disagreement、non-ML global stretch-squeeze DPとのdisagreementなどです。最後にprojection/smoothingします。

ArunodhayanのパートーSDF variant

1–2. Approach/model

unknown suffixのTVTをresidual-TVT×MD空間のsigned distance fieldとして予測します。各pixelはtrue boundaryまでのsigned vertical distance、boundaryはzero level setですが、decodeはroot findingでなくrow上のsoft expectationです。

```
sdf(row,col) = row_residual - true_residual(col)
p = exp(-|sdf| / tau)     # tau≈0.08
p /= sum_over_H(p)
row = sum(row_index * p)
residual = interp(row → residual axis)
tvt = geometric_prior + residual
```

zero crossingはfieldがflatな場所で不安定で、+1.70悪化しました。`smp.Unet` ResNet-34、16 channel、full 384×512、random cropなし、single-pass fullcanvas、re-anchor 500 ft。lossはSDF regression + sign + decoded row loss、Jaccard、Gaussian-NLL row、MD-weighted tail emphasisです。

3. Training

Lightsourceの`geo_plane` post-pretrain weightから開始し、同じchannelなのでencoder/decoderを直接transfer。real wellで50 epoch fine-tuneしrolled-out validation RMSEでpatience 8、実際はepoch 20–28でstopしました。

4–6. Augmentation、成功、失敗

主設定はhflip 0.35、vflip 0.03、mixup 0.06（alpha 0.80）、time stretch 0.44、time warp 0.31、magnitude warp 0.32、GR noise bank 0.31、gain/noise/offset、GR dropout 0.15–0.16、slope break 0.19、typewell swap 0.18、prior shift/slope noise、global TVT offset、channel dropout 0.32、known frac 0.17–0.68です。

変更	Δ
soft decode vs zero-crossing	−1.70
equal-weight ensemble	−0.43
full canvas, no crops	−0.39（9/10 folds, p=0.011）
hflip	−0.30（4/5 folds, p=0.028）
Optuna loss config	−0.16
`geo_plane` pretrain	−0.15（3/5 folds）

失敗はempirical prefix-fraction +0.357、vflip 0.5 +0.325、mixup 0.5 +0.154、hard-well mining +0.15〜+0.53、fitted ensemble weight +0.079/+0.122、typewell range clip +0.29、long unknown training +0.08、loss/dropout/LR sweepほぼ0でした。約22件の5-fold実験で勝ったのは2つだけで、どちらもmodel出力の意味を変える変更でした。

fold 0だけで勝って5-fold meanで負ける罠が4件ありました。run-to-run 5-fold mean stdはearly recipe 0.103、final 0.192。16 seedのbestはorder-statistic prediction（best-of-8 predicted 6.6387、observed 6.6389）通りでselection biasが見えました。

15 memberはin-sample 6.385、nested 6.578、equal 6.456。12 memberは6.188、6.323、6.244で、fitted weightが負けました。

8. Result

locked recipe 8 seedとcanvas/pretrain/flip/mixup probabilityのsmall variant、計12 memberをequal weightし、OOF RMSE **6.244**でした。