rogii-wellbore-geology-prediction

5位解法

Rank	5
Team	daimaru
Author	daimaru
Topic ID	733522
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733522
Retrieved with Kaggle CLI on 2026-08-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、ROGIIとKaggleに感謝します。本当に楽しいコンペでした。

Discussionで多くの知見を惜しみなく共有してくださった@hengck23には、特に感謝します。私の入力画像の基本channel構成は、彼が共有した表現から始まりました。

TL;DR： TVT×MD画像へCNNを適用し、合成井戸で約25 epoch pretrainした後、real wellで約2 epoch fine-tuneしました。backboneの異なるmodelをensembleしています。CVを信頼できるものにするため、何よりも合成データの忠実度を高めることへ集中しました。

1. 合成データを中心に据えるまで

1.1 Particle Filter

7月4日に参加し、多くのapproachを試しました。初期の主軸は、`horizontal GR - typewell GR`の分布を特徴付け、Particle Filter（PF）のlikelihood functionを反復改善することでした。PF variationを加えるたびにscoreは改善しました。同時に合成データも作り始め、CNN精度も向上していました。しかし、合成井戸をon-the-fly生成しながら複数PF variantを計算するのは重すぎたため、最終的にはPFを完全に廃止しました。

1.2 合成データ

公開NotebookではCVとPublic scoreのgapが大きく見えました。Kaggle datasetへの依存を減らし、主に合成データで学習することで、shake-downを避け、CVを信頼できるものにしようと考えました。時間の大半を合成データの忠実度向上へ使いました。

2. 合成データの構築

2.1 Synthetic GR version 1

horizontal-well GR logは次の順に生成します。

1. typewell GRを生成
2. 地層を生成
3. 掘削経路を生成
4. horizontal-well GR（typewell GR + noise）を生成

typewell GRもhorizontal GRもreal waveformの断片をcopyせず、すべてを統計的に似るよう生成しました。horizontal-well GRは3成分です。

```
hwGR(md) = tw(tvt(md)) + δ(tvt(md), md) + ε(md)
```

- `tw(tvt(md))`：現在TVTにおけるtypewell GR値
- `δ(tvt(md), md)`（lateral heterogeneity）：TVT軸×MD方向のGaussian Process。MD方向はstatic componentと、長いcorrelationを持つOU processによるslowly-swapping componentからなる

- `ε(md)`（measurement noise）：white noise + short-wavelength OU + long-wavelength OU

measurement errorはserial correlationを持つため、measurement noiseはMDの関数です。lateral-heterogeneity項は、well間でresidual patternが異なることを表します。同じwellが同じTVTへ戻ると似たresidualが再び現れますが、MD方向に離れるほど類似性が薄れます。`δ`がこの挙動を表します。

2.2 Synthetic GR version 2（latent geology）

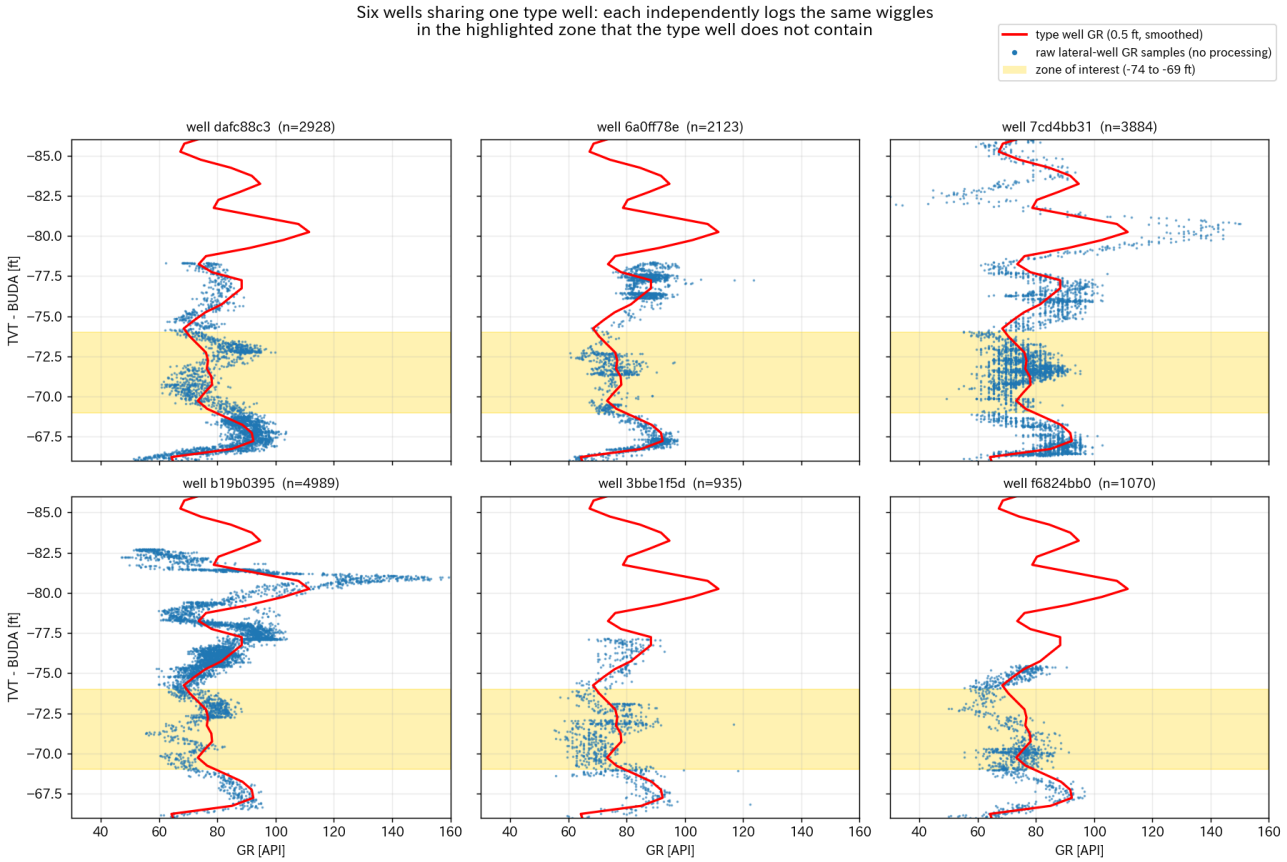
typewell GRとhorizontal-well GRを並べると、typewellはTVT軸方向へsmoothされ、ある厚さ以下の薄いbedによるGR変動が消えていることが分かります。そのため、horizontal GRを「typewell + noise」として作るだけではreal dataとの差を埋められません。

そこで、typewell GRとhorizontal GRの両方を**latent geology**から生成する方式へ変えました。

1. latent geological GRを生成
2. typewell GRを生成
3. 地層を生成
4. 掘削経路を生成
5. horizontal-well GRを生成

```
tw(tvt)  = H_tw[L](tvt)
hwGR(md) = H_hw[L](tvt(md), md) + δ(tvt(md), md) + ε(md)
L = L_lo + L_hi     # latent GRをlow/high frequency bandへ分解
```

latent geological GRは0.25 ft gridで生成します。typewell GRはlatent columnをsmoothし、その後0.5 ft、1 ftなどでsamplingして作ります。

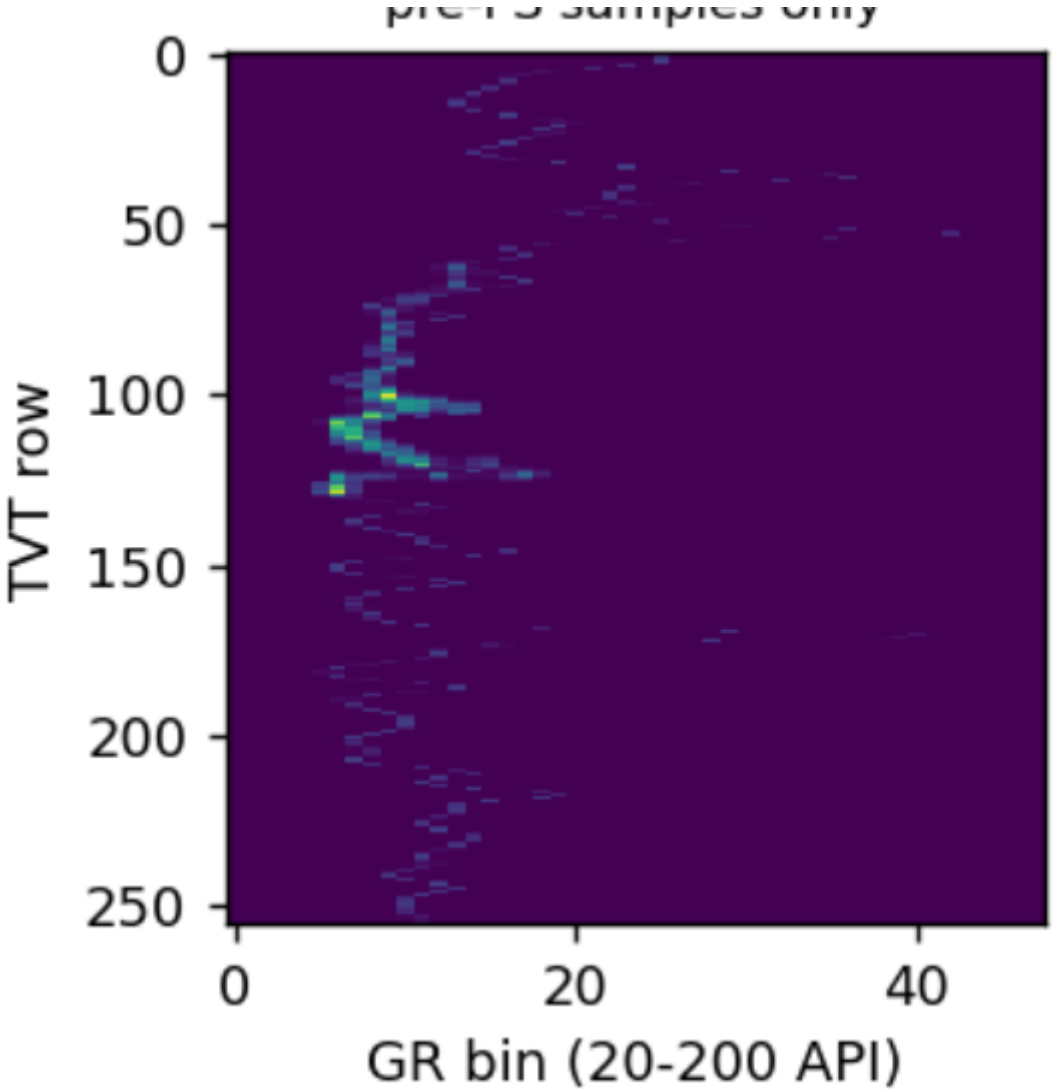


3. 入力

各horizontal wellを**256×768（+48）画像**へ変換します。行はTVT bin、列は各12 ftのMDです。

#	channel	内容
0	typewell GR	各TVT rowのtypewell GRを全列へ複製（vertical stripe）
1	hwGR	各MD列のhorizontal GR（12 ft平均）を全行へ複製（horizontal stripe）
2	GR coverage	各列で有効なGR sampleの比率。欠損箇所では低い
3	known path	pre-PSで確認済みのpathをGaussian lineとして描画。PS以降は空白
4	row coordinate	PS-point TVTをanchorとする各rowの相対TVT
5	cumulative `-ΔZ`	PS pointから各列までの累積Z変化。flat layer仮定でpathが位置する場所
6	dip	列ごとのtrajectory tangent slope（`dz/dmd`をclip）
7	azimuth sin	水平headingのsine
8	azimuth cos	水平headingのcosine
9	typewell − hwGR misfit	channel 0 − channel 1
10	context typewell GR	±800 ft近傍のreference typewell
11	context coverage	channel 10が有効なrowのmask
12	median hwGR	meanでなくmedianで集約した各列GR
13	typewell − median-hwGR misfit	channel 0 − channel 12

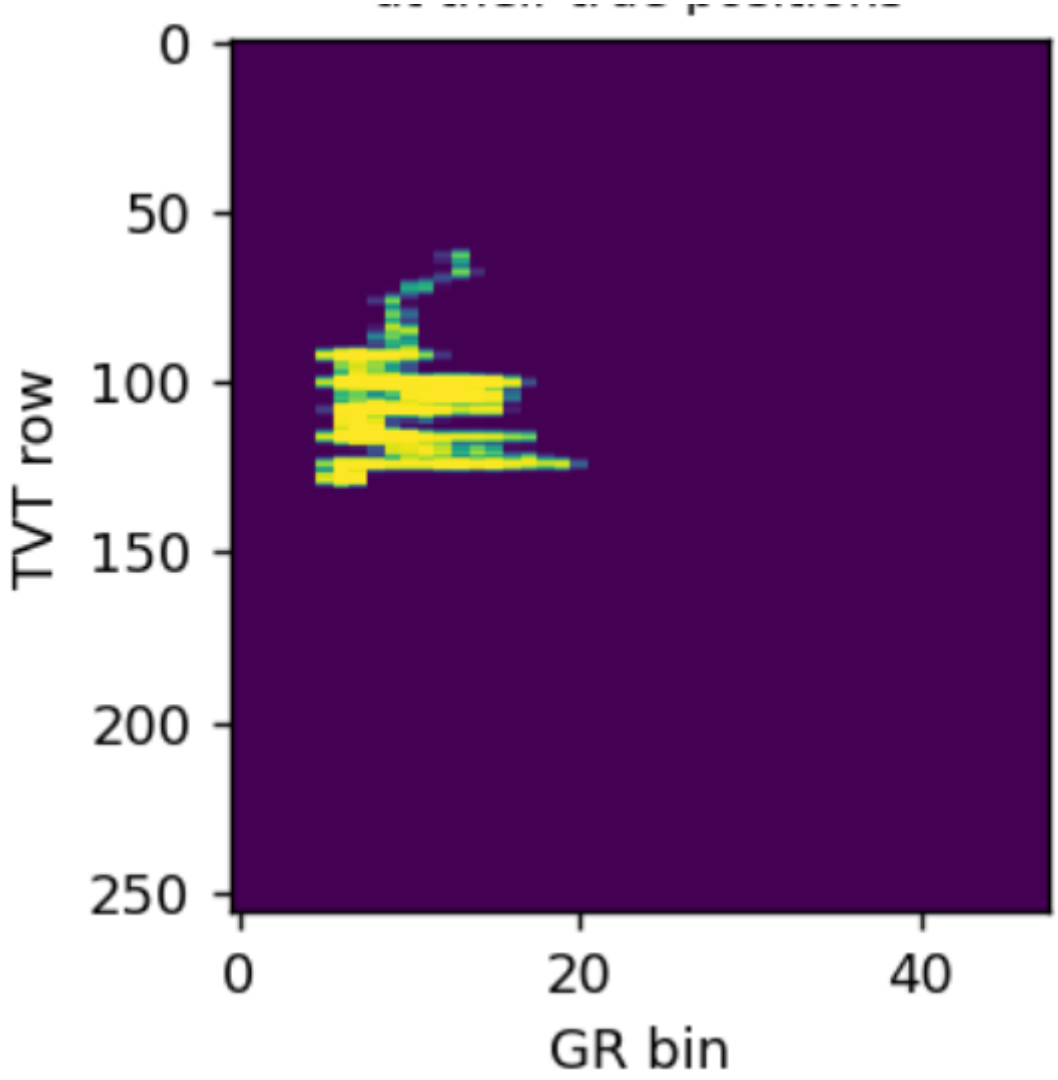
右側へ256×48画像を連結し、TVT×GR軸上にtypewell GRとpre-PS horizontal GRを描きます。



4. Model：TVT×MD canvas上のCNN

```
input 14ch × 256 rows × 768 cols (+48 appendix cols)
 ↓
① encoder: maxvit_tiny / effnetv2_rw_s / hrnet_w18
 ↓
② decoder: U-Net style
 ↓
③ heads
  head1: SDF = tanh × 3
  head2: row-classification logits
```

補助lossとして、true TVT pathをたどった場合にhorizontal-well GRが描く軌跡を、256×48画像上へpaintさせます。



正しいpathと誤ったpredicted pathを使ってhorizontal-well GRをTVT×GR chartへ描くと、失敗が目で見て明らかな場合があります。modelにまさにそれを学習させたかったのです。このauxiliary lossでscoreは約0.1 ft改善しました。

5. 学習

synthetic pretrainingは25 epochです。real dataでのfine-tuningは8 epoch実行しましたが、best epochはほぼ常にepoch 2でした。real data augmentationは2つだけです。

- PS位置のshift
- horizontal flip

real dataへのこの**浅い**接触こそ、CVの信頼性とdomain shiftに対するrobustnessの源だと考えています。

6. 推論

Typewell correction

同じtypewellを共有するwellについて、sibling horizontal wellからmedian residual profileを作り、typewellへ加えます。typewell GRは各TVTでの期待GRですが、観測品質の制約によりhorizontal GRと明らかに食い違う場所があります。ほかのwellのhorizontal GRで、その期待値を更新します。test dataの大半がtrain dataとtypewellを共有することも確認しました。

より大きなcanvasでの推論

1. すべてのwellを標準canvas、256 row（0.5 ft/row、anchor±64 ft）で予測
2. predicted pathの最大 `|relative TVT|` を取り、55 ftを超えるwellをflag
3. flagされたwellを384 row canvas（±96 ft）で再推論し、予測を完全に置換





7. Validation strategy

Public LBは約50〜60 wellしかなく、pure noiseのように振る舞いました。最後の6つの採点済み提出は次の通りです。

Sub	CV	Public	Private
v5	4.940	5.585（Public best）	5.993（Private worst）
v6（+ neighbor-well channel）	4.882	5.631	5.936
v8（+ flat-drilling-well correction）	4.87	5.593	5.940
v9	4.870	5.729（Public worst）	5.887
v10	4.891	5.618	5.907
v11（backboneをMaxViT-baseへ変更）	4.844	5.600	5.835

PublicとPrivateはほぼ**逆相関**し、CVとPrivateの順位相関は非常に良好でした。v5からOOFで0.1改善したv11をfinal 2の一つとして選ぶ予定でしたが、締切30分前にerrorでcrashしました。5分前に再提出できましたが、採点が終わったのは締切10分後でした。Private scoreなら3位相当でした。

原因は、model構築時に`timm`へ渡す`img_size`引数です。MaxViT-tinyでは不要ですが、MaxViT-baseでは必須でした。



8. うまくいかなかったこと

- 異なるseedでの学習
- より細かいMD resolution

9. Train/Testのdistribution shift

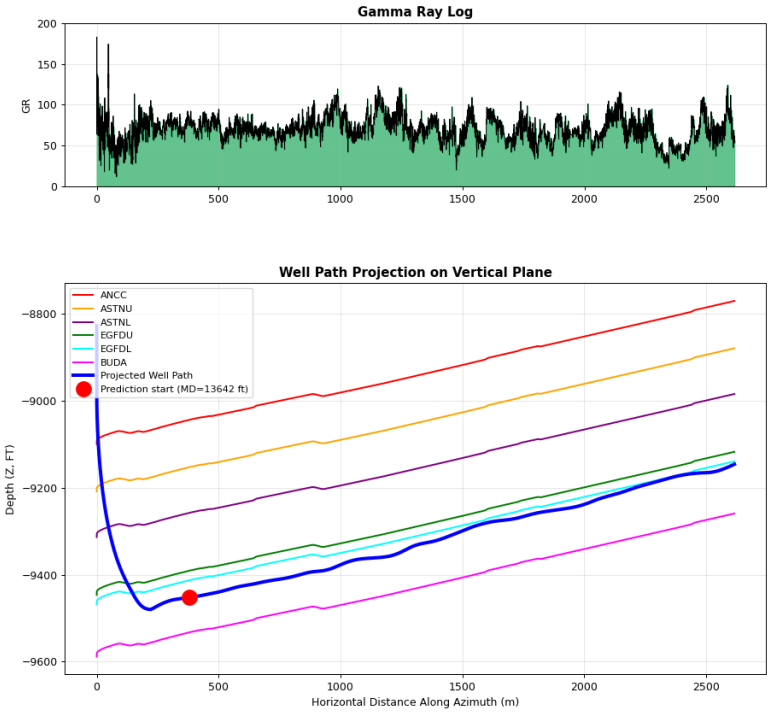
synthetic dataだけで学習し、fine-tuningしないmodelでもPrivate **6.342（約15位相当）**です。real dataでfine-tuneするとOOFとPublicは約1.5 ft改善しますが、Private改善は約0.5 ftだけでした。train dataとPublic testは非常に似ている一方、Private testには少し異なるdistributionがあるようです。testの大半はtrainとtypewellを共有するはずなので、drillerかGR toolが異なる可能性があります。最終的にこのコンペは、このような小さなdistribution shiftへのrobustnessを試したように見えます。

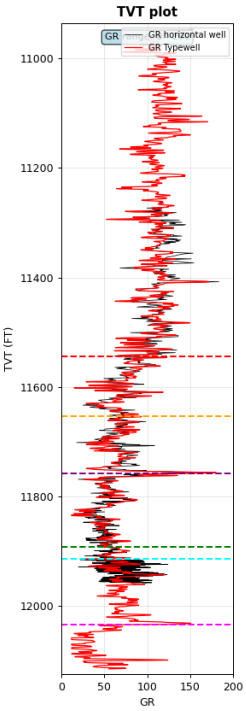
model	CV	Public	Private
synthetic pretrainingのみ（FTなし）	6.250	7.186	6.342
FTあり	OOF 4.844	5.600	5.835

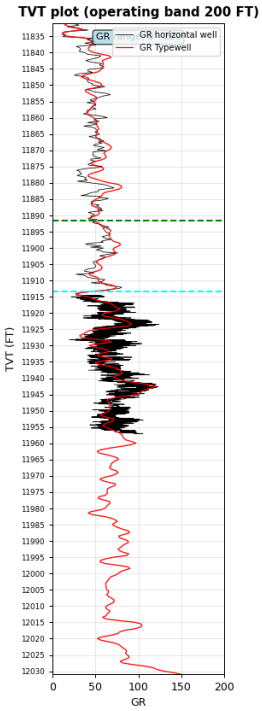
10. Bonus：blind test

以下の8画像はreal dataとsynthetic dataを混ぜたものです。CodexとGeminiには判別できませんでした。私にも分かりません。

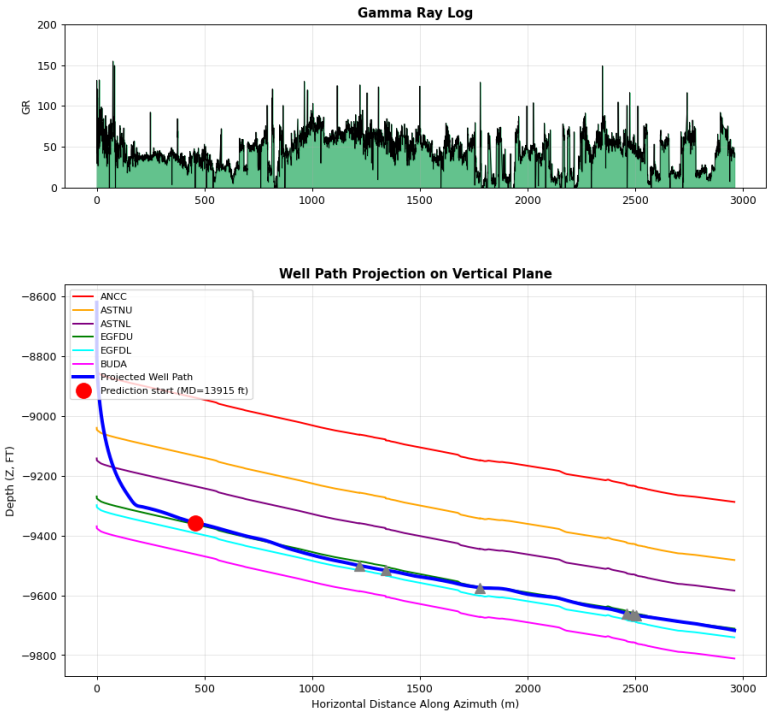
board | case_01 | tw step 0.50 ft

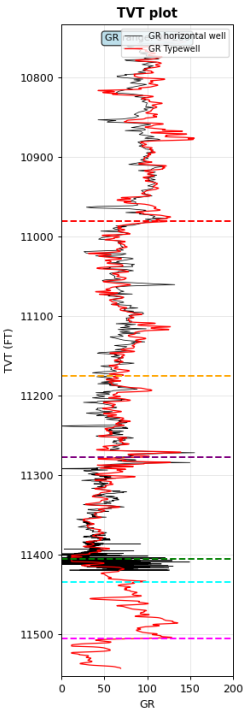


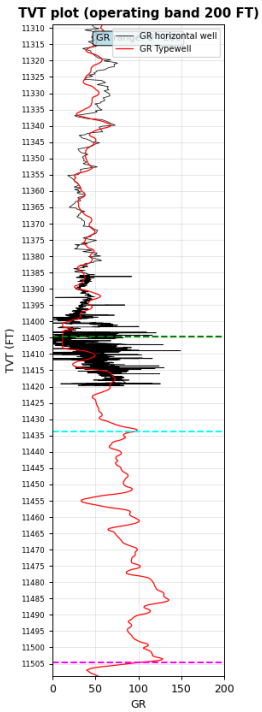




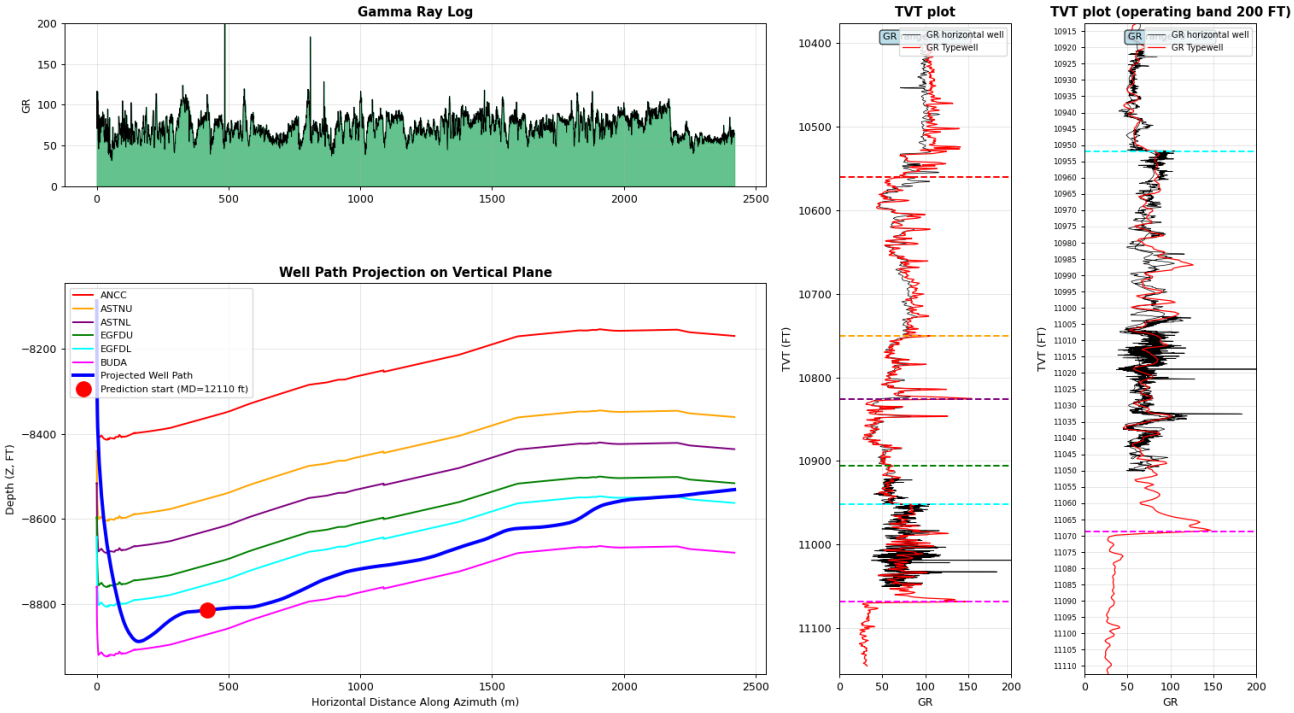
board | case_02 | tw step 0.25 ft



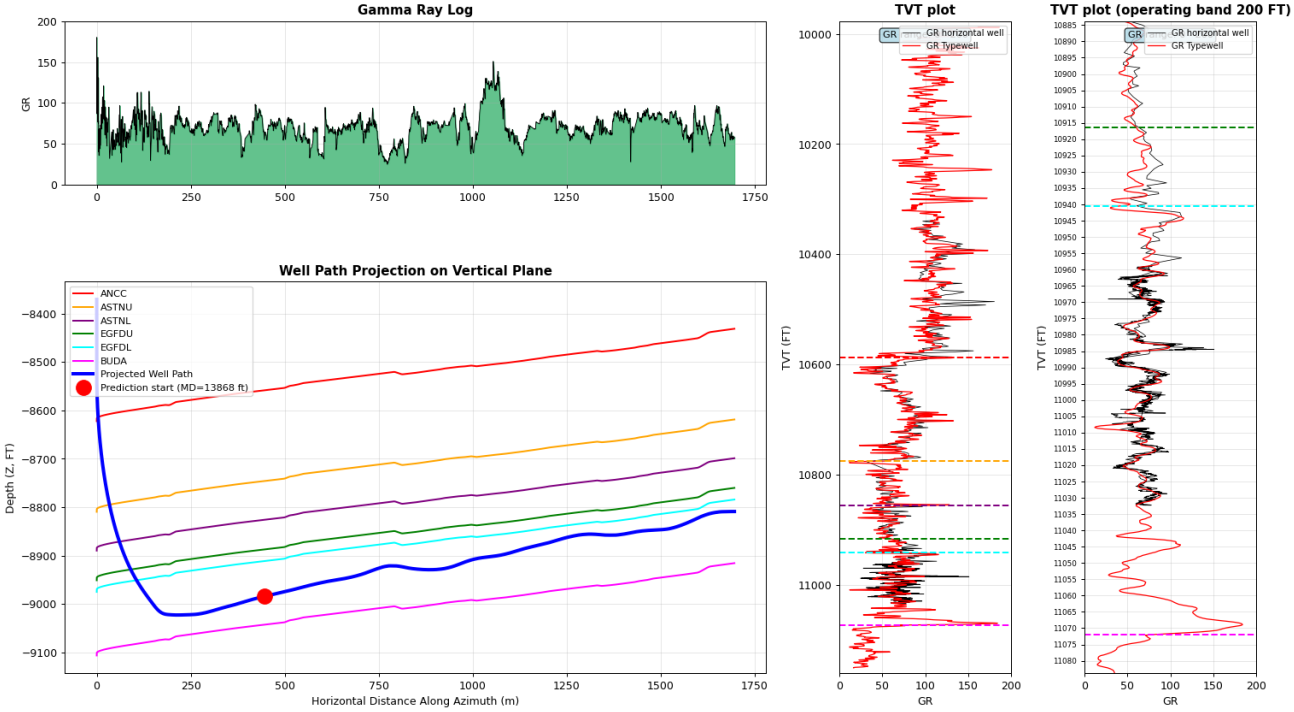




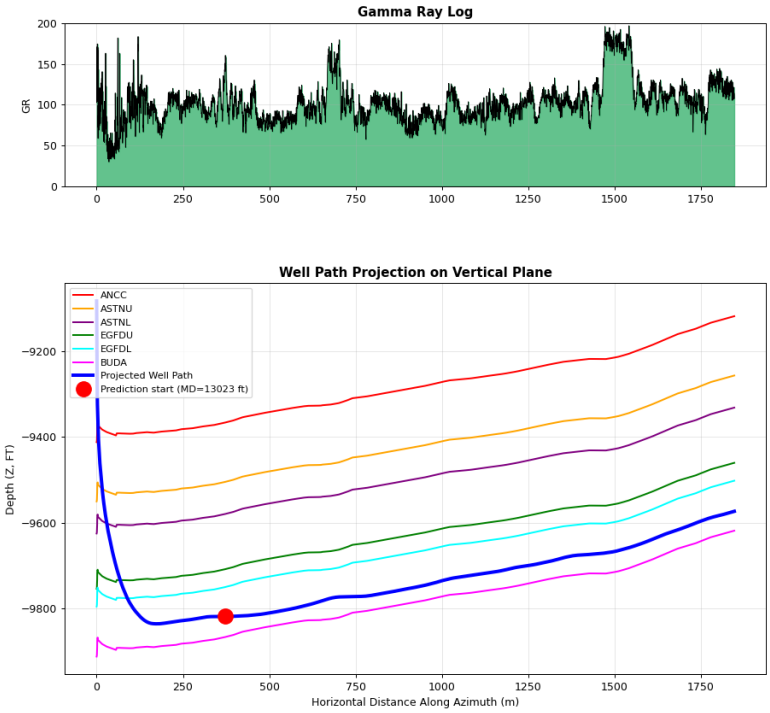
board | case_03 | tw step 0.50 ft

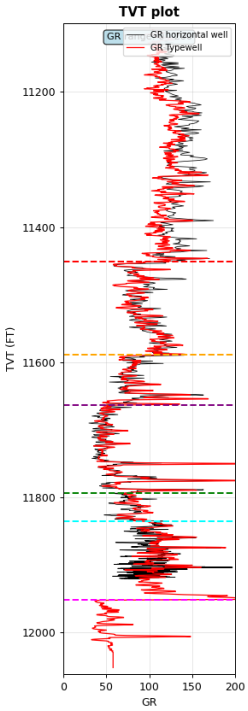


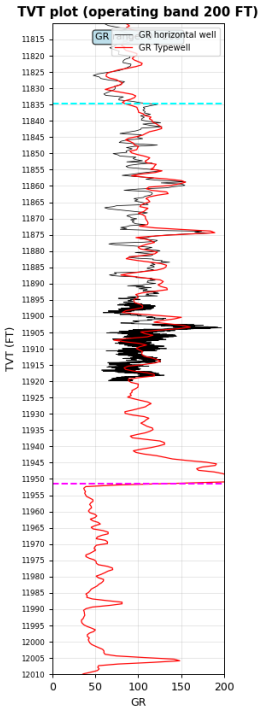
board | case_04 | tw step 0.25 ft



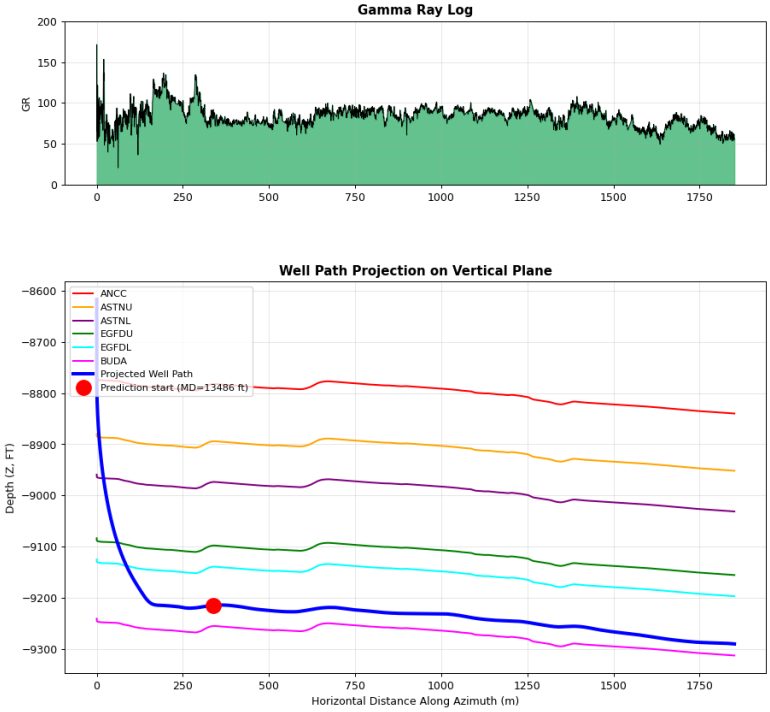
board | case_05 | tw step 0.50 ft

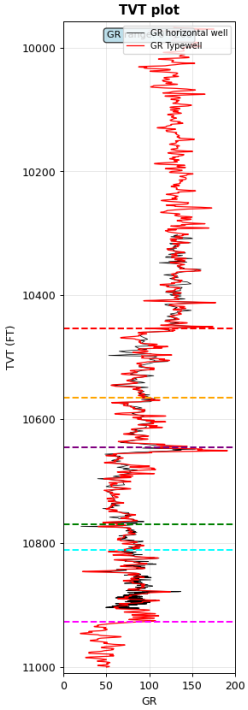


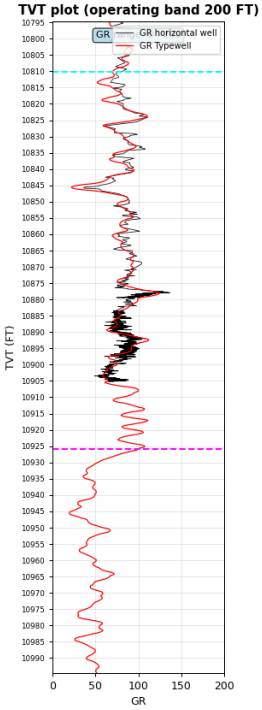




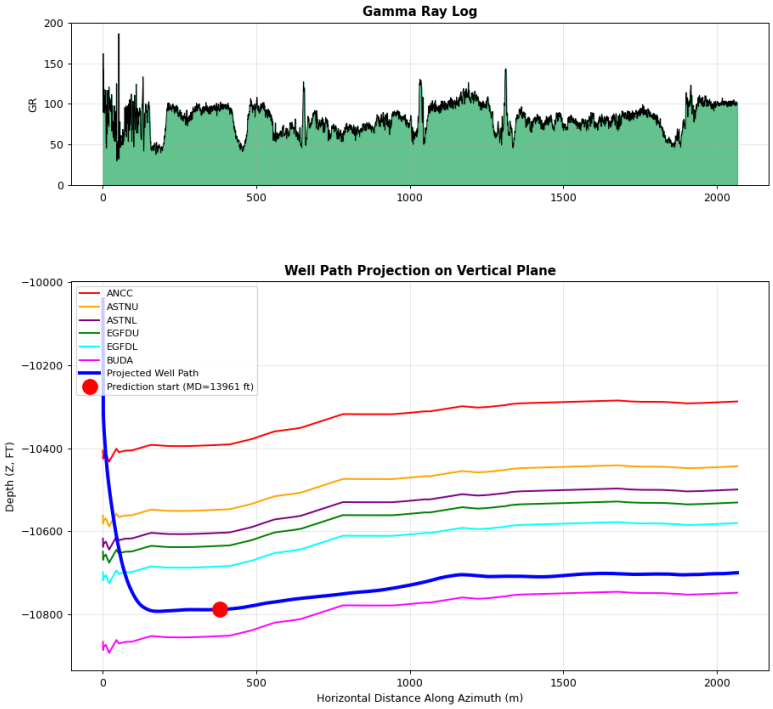
board | case_06 | tw step 0.25 ft

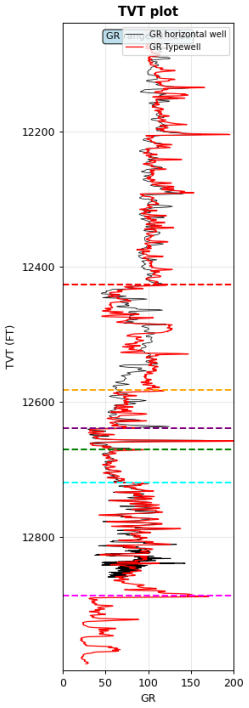


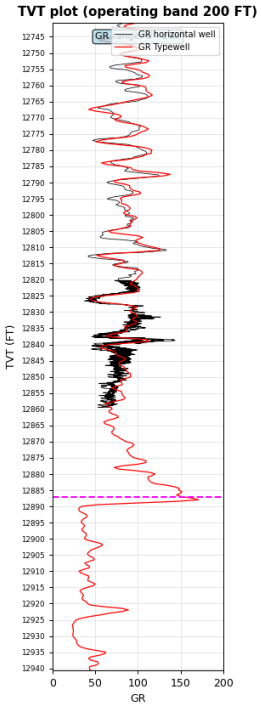




board | case_07 | tw step 0.50 ft







board | case_08 | tw step 0.50 ft

